



香港科技大學(廣州)
香港
科技大学 (广州)



香港科技大學
香港
理科大学
和技术

AIAA 2205：人工智能导论


戴恩艳

香港科技大学 (广州)


《最后的演讲回忆》

分类 vs 回归

- 分类：用于预测/分类**离散值**，例如男性或女性、真或假、垃圾邮件或非垃圾邮件等。
 - 回归：用于预测诸如价格、工资等**连续值**。




分类




目标检测

- 经典的兩阶段目标检测基于分类




目标检测

- 单阶段目标检测使用回归器获取边界框



大型语言模型

- 大型语言模型（LLM）是下一个标记预测，属于分类任务。



线性回归

给定训练数据: $D = (x_1, y_1), \dots, (x_N, y_N)$, 我们的目标是获得一个线性函数:

$$f(x) = w \cdot x + b,$$

均方误差最小化之处


均方误差损失:

$$\text{MSELoss}(w) = \frac{1}{N} \sum_{i=1}^N (f(x_i) - y_i)^2$$

例子

例子的例子

x	y
1	1
2	3
4	2



求解 $\mathbf{W}$ 和 $\mathbf{B}$

简化公式

$$\min_{\mathbf{w}_b} \left\| \mathbf{w}_a^T \mathbf{x}_a - \mathbf{y} \right\|^2$$

$$\begin{aligned} & \left\| \mathbf{w}_a^T \mathbf{x}_a - \mathbf{y} \right\|^2 \\ &= (\mathbf{w}_a^T \mathbf{x}_a - \mathbf{y})(\mathbf{w}_a^T \mathbf{x}_a - \mathbf{y})^T \\ &= \mathbf{w}_a^T \mathbf{x}_a \mathbf{x}_a^T \mathbf{w}_a + \mathbf{y} \mathbf{y}^T - \mathbf{y} \mathbf{w}_a^T \mathbf{x}_a - \mathbf{x}_a^T \mathbf{w}_a \mathbf{y} \\ &= \mathbf{w}_a^T \mathbf{x}_a \mathbf{x}_a^T \mathbf{w}_a + \mathbf{y} \mathbf{y}^T - 2 \mathbf{y} \mathbf{w}_a^T \mathbf{x}_a \end{aligned}$$

Let $\frac{\partial L}{\partial \mathbf{w}_a} = 0$, then we have


$$2 \mathbf{x}_a \mathbf{x}_a^T \mathbf{w}_a - 2 \mathbf{x}_a \mathbf{y} = 0$$

封闭形式解


$$\mathbf{w}_a = (\mathbf{x}_a \mathbf{x}_a^T)^{-1} \mathbf{x}_a \mathbf{y}$$

逻辑回归

逻辑回归用于**二分类**!



- 二进制: $Y \in \{0, 1\}$
- 多类别: $Y \in \{1, \dots, k\}$



例：恶性与良性眼肿瘤

逻辑回归

样本	估计概率	真实情况
x	$P(y x) = p$	$P(y x = 1) = 1$
x^2	$P(y x) = p$	$P(y x = 0) = 0$

采用线性回归器 $w \cdot x$ 来估计 p 吗？

NO!!! Because $p \in [0,1]$

解决方案：采用 $w \cdot x$ 对事件的对数几率进行回归：

$$w \cdot x = \log \left(\frac{p}{1-p} \right) \in (-\infty, +\infty)$$

逻辑回归

估计逻辑回归模型：


$$\mathbf{w} \cdot \mathbf{x} = \log\left(\frac{p}{1-p}\right)$$

$$\Rightarrow f(\mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w} \cdot \mathbf{x})} = p$$

Sigmoid Function $\downarrow$ $\sigma(z) = \frac{1}{1 + \exp(-z)}$


决策边界： $\mathbf{w} \cdot \mathbf{x} = 0$

优化：交叉熵损失下的梯度下降法



逻辑回归

二分类




Predict $y = 1$, if $f(\) \geq 0.5$

Predict $y = 0$, if $f(\) < 0.5$

感知

感知机可以被视为逻辑回归

· 方程: $Y = \text{sign } \sum(W_i X_i)$




交叉熵损失

$$H(f(x), y) = \begin{cases} -\log f(x) & \text{if } y = 1 \\ -\log(1 - f(x)) & \text{if } y = 0 \end{cases}$$



$$H(f(x), y) = -y \log f(x) - (1 - y) \log(1 - f(x))$$



损失 = 0

- if $y = 1, f(x) = 1$
- If $y = 0, f(x) = 0$

损失 = $+\infty$:

若 $Y = 1$, 则 $f(x) = 0$

- If $y = 0, f(x) = 1$

逻辑回归

Given **training data**: $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$,


我们的目标是获得一个线性分类器:

$$f(x) = \text{sigmoid}(\mathbf{w} \cdot \mathbf{x} + b),$$

在交叉熵损失最小化的地方

损失函数:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^K H(f(x_i), y_i)$$



例：恶性与良性眼肿瘤

如何理解交叉熵损失？

◆ 1. 自我信息：构建模块

在信息论中，一个概率为 p 的事件的自我信息（也叫“surprisal”）为
定义为：

$$I(p) = -\log(p)$$

直觉：

- 如果不太可能发生的事情（低 p ），自我信息就高——它更令人惊讶。
- 如果某件事很可能发生（高 p ），自我信息就很低——这并不令人惊讶。

例子：

- 如果有人告诉你某件事发生的几率是1%：
 $I(0.01) = -\log(0.01) = 4.6$ 位高信息！
- 如果你被告知一件有90%几率发生的事情：
 $I(0.9) = -\log(0.9) = 0.1$ 比特→低信息。

如何理解交叉熵损失？

2. 熵：预期自信息

定义：

随机变量 X 的熵 $H(X)$ 是其平均自信息：

$$H(X) = \mathbb{E}_{x \sim p(x)}[I(x)] = - \sum_x p(x) \log p(x)$$

- 口译：

- 度量 X 的“不确定性”或“无序性”。

- 当所有结果出现的可能性相等时达到最大值（例如，公平的硬币）。

示例：

- 对于一枚公平的硬币 ($p = 0.5$)：

$$H(X) = -0.5 \log_2(0.5) - 0.5 \log_2(0.5) = 1 \text{ bit.}$$

- 对于一枚有偏的硬币 ($p = 0.9$)：

$$H(X) = -0.9 \log_2(0.9) - 0.1 \log_2(0.1) \approx 0.47 \text{ bits.}$$

如何理解交叉熵损失？

3. 交叉熵：不同分布下的期望自信息

定义：

交叉熵 $H(p, q)$ 衡量的是从分布 p 中抽取的事件的平均自信息，但使用的是来自另一个分布 q 的概率进行计算：

$$H(p, q) = \mathbb{E}_{x \sim p(x)}[-\log q(x)] = - \sum_x p(x) \log q(x)$$

- 关键理念：

如果 q 完全匹配 p （即 $q(z) = p(z)$ ），那么 $H(p, q) = H(p)$ 。

否则， $H(p, q) > H(p)$ ，差值等于 KL 散度 $D_{KL}(p||q)$ 。

与熵和 KL 散度的关系：

$$H(p, q) = H(p) + D_{KL}(p||q)$$

- $H(p)$ ： p 的内在不确定性。
- $D_{KL}(p||q)$ ： 用 q 近似 p 所产生的惩罚。

如何理解交叉熵损失？

4. 直观示例：硬币抛掷预测

- 真实分布 (p)：一枚有偏硬币，正面朝上的概率为 0.6，反面朝上的概率为 0.4。

- 熵：

$$H(p) = -0.6 \log_2(0.6) - 0.4 \log_2(0.4) \approx 0.97 \text{ bits.}$$

- 模型预测 (q)：错误地假设正面朝上的概率为 0.8，反面朝上的概率为 0.2。

- 交叉熵：

$$H(p, q) = -0.6 \log_2(0.8) - 0.4 \log_2(0.2) \approx 0.6 \times 0.32 + 0.4 \times 2.32 \approx 1.06 \text{ bits.}$$

- KL 散度：

$$D_{KL}(p||q) = H(p, q) - H(p) \approx 1.06 - 0.97 = 0.09 \text{ bits.}$$

如何理解交叉熵损失？

5. 机器学习中的交叉熵

(1) 分类任务

- 真实分布 (p)：独热编码标签（例如，类别 0 为 $[1, 0, 0]$ ）。
- 预测分布 (q)：Softmax 输出（例如， $[0.7, 0.2, 0.1]$ ）。
- 交叉熵损失：

$$H(p, q) = - \sum_i p_i \log q_i = - \log q_{\text{true class}}$$

例如：若 $p = [1, 0]$ 且 $q = [0.9, 0.1]$ ，则 $H(p, q) = -\log(0.9) \approx 0.15$ 。

(2) 为何要最小化交叉熵？

- 最小化 $H(p, q)$ 会使 q 与 p 相匹配。
- 由于 $H(p)$ 是固定的，所以最小化 $H(p, q)$ 等同于最小化 $\text{DKL}(p \parallel q)$ 。

A

AI深度
研究员

AI深度研究员



删除

fn

首页

圣
向上

区
删除

结束

页面
下来

谷类

转变

nd

选项

梯度下降：优化可微模型

封闭形式解？


线性回归的闭式解：

$$\mathbf{w}_a = (\mathbf{x}_a \mathbf{x}_a^T)^{-1} \mathbf{x}_a \mathbf{y}$$

然而，封闭形式的解：

- 并非总是存在于不同的机器学习模型中
- 对于大规模数据来说可能会非常昂贵

梯度下降的直观理解



梯度下降

优化参数 $\mathbf{w}^*$:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{w})$$

梯度 $\nabla L(\mathbf{w})$ 是使损失增加最多的方向

梯度下降算法

1. 通过随机值初始化 $\mathbf{w}^{(0)}$

2. 对于 $t = 1, \dots, T$:


$$\mathbf{w}^{(t)} \leftarrow \mathbf{w}^{(t-1)} - \alpha \nabla_{\mathbf{w}} L(\mathbf{w})$$

α : 学习率, 梯度下降中的步长

$\nabla L(\mathbf{w})$: 损失相对于参数的偏导数


学习率的影响

α 太小




w

$\Delta\alpha$ 太小



w


α 好




w

损失 $L(w)$


价格预测示例






回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$ (对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)




损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




回归量 $f(\theta_0, \theta_1)$

(对于固定的 θ_0 , θ_1 这是 x 的函数)



损失 $L(\theta_0, \theta_1)$

(参数 θ_0 , θ_1 的函数)




偏差和方差

偏差和方差


☒ 偏差：模型的平均预测值与我们试图预测的正确值之间的差异。

☒ 方差：方差大的模型非常关注训练数据，但在测试数据上泛化能力差。


低偏差和
低方差




低偏差和高
方差



大偏差和低
方差



大的偏差和
大的方差



偏差 - 方差权衡

假设我们已经针对**训练数据**将误差（即损失）最小化了

- **训练**误差低并不意味着在测试数据上的预期表现良好：**过拟合**

- 我们希望对以下**预期损失**进行分析：

Training Data: $\{(x_1, y_1), \dots, (x_n, y_n)\}$

- 测试点: (x_*, y_*)

我们将预期损失分解为：

$$\mathbf{E}_{D, (y_*, x_*)} [(y_* - f(x_*|D))^2] = \text{Noise} + \text{Bias}^2 + \text{Variance}$$

- 定义（**未观测到的**）**真实**模型（h）：

$$y_* = h(x_*) + \epsilon_*$$

假设噪声均值为 0

[bias goes in $h(x_*)$] 偏见
随之而来 $h(x_*)$

- 用以下内容完成方框：

$$h(x_*) = h_*$$

$$\mathbf{E}_{D, (y_*, x_*)} [(y_* - f(x_*|D))^2] \quad \text{Expected Loss}$$

$$= \mathbf{E}_{D, (y_*, x_*)} \left[\underbrace{(y_* - h(x_*))}_a + \underbrace{h(x_*) - f(x_*|D)}_b \right]^2$$

$$(a + b)^2 = a^2 + b^2 + 2ab$$

$$= \mathbf{E}_{\epsilon_*} [(y_* - h(x_*))^2] + \mathbf{E}_D [(h(x_*) - f(x_*|D))^2] \\ + 2\mathbf{E}_{D, (y_*, x_*)} [y_* h_* - y_* f_* - h_* h_* + h_* f_*]$$

- 定义（未观测到的）真实模型（h）：

$$y_* = h(x_*) + \epsilon_*$$

- 用以下内容完成方框： $\mathbf{H}(xx) = \mathbf{H}^*$

$$\mathbf{E}_{D, (y_*, x_*)} [(y_* - f(x_*|D))^2] \text{ Expected Loss}$$

$$= \mathbf{E}_{D, (y_*, x_*)} [(y_* - h(x_*) + h(x_*) - f(x_*|D))^2]$$

$$= \mathbf{E}_{\epsilon_*} [(y_* - h(x_*))^2] + \mathbf{E}_D [(h(x_*) - f(x_*|D))^2]$$

$$+ 2\mathbf{E}_{D, (y_*, x_*)} [y_* h_* - y_* f_* - h_* h_* + h_* f_*]$$

Substitute defn. $y_* = h_* + \epsilon_*$

$$\mathbf{E} [(h_* + \epsilon_*)h_* - (h_* + \epsilon_*)f_* - h_* h_* + h_* f_*] =$$

$$\cancel{h_* h_*} + \mathbf{E}[\epsilon_*] h_* - h_* \mathbf{E}[f_*] - \mathbf{E}[\epsilon_*] f_* - \cancel{h_* h_*} + h_* \mathbf{E}[f_*]$$

- 定义（未观测到的）真实模型（h）：

$$y_* = h(x_*) + \epsilon_*$$

- 用以下内容完成方框： $H(x) = H$

$$\begin{aligned}
 & \mathbf{E}_{D, (y_*, x_*)} [(y_* - f(x_*|D))^2] && \text{Expected Loss} \\
 &= \mathbf{E}_{D, (y_*, x_*)} [(y_* - h(x_*) + h(x_*) - f(x_*|D))^2] \\
 &= \underbrace{\mathbf{E}_{\epsilon_*} [(y_* - h(x_*))^2]}_{\substack{\text{Noise Term} \\ \text{(out of our control)} \\ \text{☹}}} + \underbrace{\mathbf{E}_D [(h(x_*) - f(x_*|D))^2]}_{\substack{\text{Model Estimation Error} \\ \text{(we want to minimize this)} \\ \text{Expand}}}
 \end{aligned}$$

最小误差由噪声决定。

- 关于模型估计误差的进一步阐述：

$$\mathbf{E}_D [(h(x_*) - f(x_*|D))^2]$$

- 通过完成平方来

$$\mathbf{E}[f(x_*|D)] = \bar{f}_*$$

$$\mathbf{E}_D [(h(x_*) - f(x_*|D))^2]$$

$$= \mathbf{E} [(h(x_*) - \mathbf{E}[f(x_*|D)] + \mathbf{E}[f(x_*|D)] - f(x_*|D))^2]$$

$$= \mathbf{E} [(h(x_*) - \mathbf{E}[f(x_*|D)])^2] + \mathbf{E} [(f(x_*|D) - \mathbf{E}[f(x_*|D)])^2]$$

$$+ 2\mathbf{E} [h_* \bar{f}_* - h_* f_* - \bar{f}_* f_* + \bar{f}_*^2]$$

$$= h_* \bar{f}_* - h_* \mathbf{E}[f_*] - \bar{f}_* \mathbf{E}[f_*] + \bar{f}_*^2 =$$

$$h_* \bar{f}_* - h_* \bar{f}_* - \bar{f}_* \bar{f}_* + \bar{f}_*^2 = 0$$

- 关于模型估计误差的进一步阐述：

$$\mathbf{E}_D [(h(x_*) - f(x_*|D))^2]$$

- 通过完成平方来

$$f(x^*|D) = f$$

$$\begin{aligned} \mathbf{E}_D [(h(x_*) - f(x_*|D))^2] \\ = \underbrace{(h(x_*) - \mathbf{E}[f(x_*|D)])^2}_{(\text{Bias})^2} + \underbrace{\mathbf{E}[(f(x_*|D) - \mathbf{E}[f(x_*|D)])^2]}_{\text{Variance}} \end{aligned}$$

偏差与方差之间的权衡：

- 简单**模型**：高偏差，低方差
- 复杂**模型**：低偏差，高方差

— 欠拟合
— 过拟合

偏差 - 方差图





Image from <http://scott.fortmann-roe.com/docs/BiasVariance.html>

问题

你觉得哪个回归器是最好的？




大小
 $\theta_0 + \theta_1 x$

回归量1



大小
 $\theta_0 + \theta_1 x + \theta_2 x^2$

回归量2




大小 $\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$


回归量3

问题


你觉得哪种分类器是最好的？



分类器 1









分类器 2



分类器 3

过拟合和欠拟合



欠拟合

它无法捕捉到数据的潜在趋势。

它破坏了我们机器学习模型的准确性。

这种情况通常发生在我们可用的数据较少，难以构建准确模型的时候。

而且当我们试图为非线性数据建立线性模型时。

欠拟合——高偏差和低方差

减少欠拟合的技术：

1. 使用更多数据；
2. 增加模型的复杂度；
3. 增加特征数量，进行特征工程；
4. 从数据中去除噪声；
5. 增加训练的轮数或延长训练时长。

过拟合

- 训练数据有限

使用大量数据训练模型（当一个模型用如此多的数据进行训练时）

（数据，它从数据集中的噪声和不准确的数据开始学习。）


- 模型复杂度高。

过拟合——高方差和低偏差

减少过拟合的技术：


1. 增加训练数据；训练数据净化；
2. 降低模型复杂度；
3. 在训练阶段提前停止（留意训练过程中的损失值；一旦损失值开始上升，立即停止训练）；
4. 在深度神经网络中使用随机失活（Dropout）技术。

正则化的直觉



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

如果我们限制 θ_3 和 θ_4 的值很小



$$\approx \theta_0 + \theta_1 x + \theta_2 x^2$$

正则化

正则化项是损失函数的一个附加标准，用于确保我们不会过拟合。

它被称为正则化项，因为它试图使参数更正常/更规范。

这是模型中的一种偏差，它迫使学习过程更倾向于某些类型的权重而非其他类型的权重。

$$\operatorname{argmin}_{w,b} \sum_{i=1}^n \text{loss}(y_i y'_i) + \lambda \text{regularizer}(w, b)$$

常见正则化项

我们如何鼓励较小的权重？或者惩罚较大的权重？

LASSO 回归器：对权重绝对值之和进行惩罚（L1 范数）

$$\arg \min_{\mathbf{w}} L(\mathbf{w}) + \lambda \sum_i |w_i|$$

岭回归器：对权重平方和进行惩罚（L2 范数）


$$\arg \min_{\mathbf{w}} L(\mathbf{w}) + \lambda \sum_i |w_i|^2$$

λ ：需手动调整的超参数

LASSO 导致稀疏性

L1 正则化强制产生稀疏解：

损失轮廓首先触及 L1 正则化项的尖锐拐角。



评估指标与调优

混淆矩阵

		Predicted Class	
		Yes	No
Actual Class	Yes	TP	FN
	No	FP	TN

$$\text{Accuracy} = \frac{TP+TN}{n}$$

- TP: 真阳性
- FP: 误报
- FN: 假阴性
- TN: 真阴性

分类指标

		预测类	
		是	否
实际类	是	胡志明市	FN
	否	《外交政策》	TN

精度 = $\frac{TP}{\text{城市} + \text{FP房地产商的狗腿子}}$

$$\text{Accuracy} = \frac{TP + TN}{n}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

实际阳性中被预测为阳性的比例

预测为阳性的样本中实际为阳性的比例


分类指标

F1 分数结合了准确率和召回率

$$\text{F1 Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$


视觉视角

正类别的阈值可以进行调整



ROC 曲线

调整正类的阈值可得到以下的 ROC 曲线



$$\text{True Positive Rate} = \frac{TP}{TP + FN}$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN}$$

ROC-AUC 分数: ROC 曲线下面积

示例

问题与数据（乳腺癌）

诊断结果	手术病理结果		总计
	患者 (P)	非患者 (N)	
积极的	80	100	180
否定的	20	800	820
总计	100	900	1000

计算真正例率和假正例率。

摘要

如果诊断测试的**真阳性率**相对较低，就会有大量假阴性患者。
这会延误患者的就诊，影响疾病的进展和康复，甚至导致患者过早死亡。

如果诊断测试的**假阳性率**相对较高，就会出现很多假阳性患者。
这会浪费医疗资源，并导致患者无端恐慌和焦虑。

超参数调优与模型选择

给定数据：

训练数据

测试数据 Z_{test}

目标：选择具有最佳泛化能力的超参数/模型。


我们能否直接选择使测试集 Z_{test} 最小化的超参数？

不！！这会导致在测试集上过拟合。

这会泄露测试数据的信息

测试数据上的结果不能准确反映模型的泛化能力。

训练/验证/测试集划分



解决方案：在预留的验证数据上调整超参数/模型

K 折交叉验证

三重的一个例子



根据平均性能调整模型 避免在选定的验证集上过拟合

一个例子

假设我们有一个包含 6 个观测值的数据样本：

1 [0.1, 0.2, 0.3, 0.4, 0.5, 0.6]

第一步是选定一个 k 值，以确定
用于拆分数据的折叠次数。

这里，我们将使用 $k = 3$ 的值。这意味着我们将对数据进行 3 次洗牌。
获取数据，然后将数据分成 3 组。

由于我们有 6 个观测值，所以每个组的数量将相等。
2 个观测值的数量。

一个例子

例如：

第 1 折叠层: [0.5, 0.2]

2 折叠 2: [0.1, 0.3]

3 折叠 3: [0.4, 0.6]

训练并评估了三个模型，每次都将其中的一个折算作保留的测试集。

例如：

- 模型 1：在 Fold1 和 Fold2 上训练，在 Fold3 上测试
- 模型 2：在折 2 和折 3 上训练，在折 1 上测试
- 模型 3：在折 1 和折 3 上训练，在折 2 上测试

将这三个模型的平均值以及标准差作为最终结果。