



香港科技大學(廣州)
香港
香港科技大学
技术(广州)




香港
香港科技大学

AIAA 2205: 人工智能导论

戴恩艳

香港科技大学 (广州)


归一化能解决初始化不佳的问题吗？



玩具设置，二维输入和具有 ReLU 激活函数的两层神经网络


图像和序列数据

激活图



CNN 保留了空间信息

信号:



请提供需要翻译的文本。

你好吗？我很好。谢谢你，你呢？

但如何保留时间信息呢？

循环神经网络


循环神经网络（RNN）通过结合前一步的表示 h_{t-1} 和当前步骤的输入 x_t 来更新表示。

新州

$$h_t = f_W(h_{t-1}, x_t)$$

可学习函数

初始化隐藏状态




第一步的数据

循环神经网络

在每个时间步都使用**相同**的参数

$$h_t = f_W(h_{t-1}, x_t)$$





让我们来细看一些细节


如何构建 $h_t = F(W_{hh}h_{t-1} + W_{hx}x_t)$?

$$h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$$

$$y_t = W_{hy}h_t$$




深度堆叠循环神经网络



$$h_t^{(l)} = f(U^{(l)}h_{t-1}^{(l)} + W^{(l)}h_t^{(l-1)} + b^{(l)}),$$

双向循环神经网络




$$h_t^{(1)} = f(U^{(1)}h_{t-1}^{(1)} + W^{(1)}x_t + b^{(1)}),$$

$$h_t^{(2)} = f(U^{(2)}h_{t+1}^{(2)} + W^{(2)}x_t + b^{(2)}),$$


$$h_t = h_t^{(1)} \oplus h_t^{(2)},$$

字符级语言生成的一个例子



字符级的一个示例
字符级语言生成的一个
例子


一个热向
量



字符级的一个示例


字符级语言生成的一个例子

一个热向量




字符级的一个示例
字符级语言生成的一个例子

一个热向量




循环神经网络

一对多




示例：图像描述




循环神经网络

多对一





机器学习 (Machine Learning



循环神经网络

多对多

示例：机器翻译



循环神经网络



多对多


示例：词性标注

y


h

x





从 h_t 到 h_{t-1} 的反向传播乘以 W (实际上是 W_{hh}^T)



$$h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$$

$$= \tanh\left((W_{hh} \quad W_{hx}) \begin{pmatrix} h_{t-1} \\ x_t \end{pmatrix}\right)$$


等于 $\tanh\left(\begin{pmatrix} W_{hh} & W_{hx} \end{pmatrix} \begin{pmatrix} h_{t-1} \\ x_t \end{pmatrix}\right)$

$$\frac{\partial h_t}{\partial h_{t-1}} = \tanh'(W_{hh}h_{t-1} + W_{hx}x_t)W_{hh}$$

香草 RNN 梯度流

多个时间步长上的梯度：

本吉奥等人,《用梯度下降法学习长期依赖关系很困难》,《IEEE 神经网络汇刊》,1994 年 帕斯卡努等人,《论训练循环神经网络的困难》,ICML 2013 年



$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \frac{\partial L_t}{\partial W}$$


$$\frac{\partial h_t}{\partial h_{t-1}} = \tanh'(W_{hh} h_{t-1} + W_{xh} x_t) W_{hh}$$

$$\frac{\partial L_T}{\partial W} = \frac{\partial L_T}{\partial h_T} \frac{\partial h_t}{\partial h_{t-1}} \cdots \frac{\partial h_1}{\partial W} = \frac{\partial L_T}{\partial h_T} \left(\prod_{t=2}^T \frac{\partial h_t}{\partial h_{t-1}} \right) \frac{\partial h_1}{\partial W}$$

Vanilla RNN 梯度流

多个时间步长上的梯度:

本吉奥等人, “用梯度下降法学习长期依赖关系是
“困难”, 《IEEE 神经网络汇刊》, 1994 年
何斯长等人, 《论训练循环神经网络的难度》



$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \frac{\partial L_t}{\partial W}$$

最大值 > 1: 梯度爆炸

梯度裁剪

$$\frac{\partial L_T}{\partial W} = \frac{\partial L_T}{\partial h_T} \frac{\partial h_t}{\partial h_{t-1}} \cdots \frac{\partial h_1}{\partial W}$$

最大值 < 1:


梯度消失

长短期记忆 (LSTM)

RNN:

$$h_t = \tanh \left(W \begin{pmatrix} h_{t-1} \\ x_t \end{pmatrix} \right)$$

长短期记忆网络




i: 输入门, 决定是否向单元格写入数据


f: 遗忘门, 是否清空单元格

o: 输出门, 揭示多少单元内容

g: 网关, 给牢房写多少字?



长短期记忆网络



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$


$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o) \cdot \tanh(C_t)$$

决定输出单元状态的哪一部分



它决定要更新哪个组件。


Ct 提供变更内容

更新单元状态

长短期记忆 (LSTM)

单元状态仅包含线性运算，类似于残差连接。有人称“残差网络是旋转了 90 度的长短期记忆网络”

不间断的渐变流！



类似于 ResNet!

