检测与分割

主讲人：Hao Wang

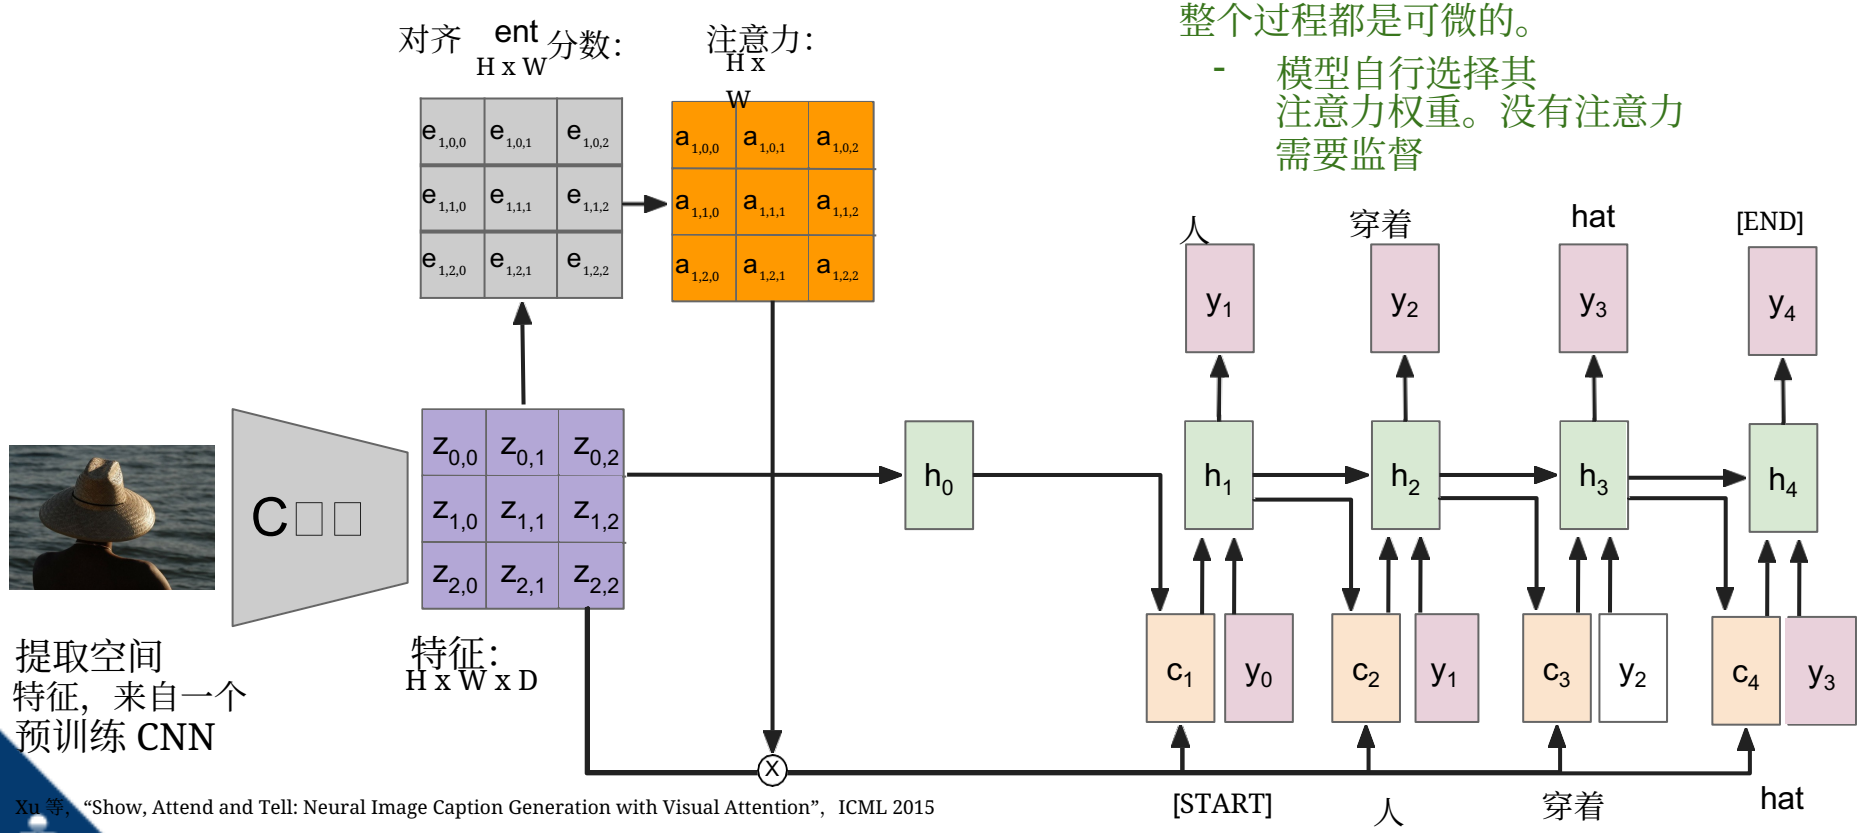
AI Thrust，信息枢纽



上周回顾



使用 RNN 和 注意力的图像描述



Xu 等，“Show, Attend and Tell: Neural Image Caption Generation with Visual Attention”，ICML 2015

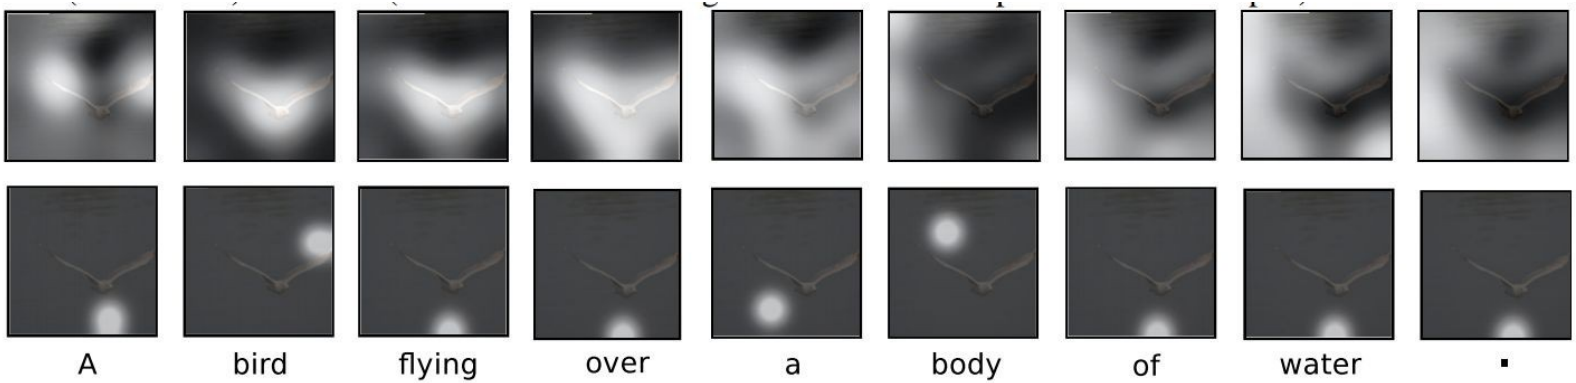
基于注意力的图像描述

软注意力



硬注意力

（需要强化学习）



Xu 等人，“Show, Attend, and Tell：基于视觉注意力的神经图像描述生成”，ICML 2015 图片版权归 Kelvin Xu、Jimmy Lei Ba、Jamie Kiros、Kyunghyun Cho、Aaron Courville、Ruslan Salakhutdinov、Richard S. Zemel 和 Yoshua Benchio 所有，2015。经许可转载。



基于注意力的图像描述



A woman is throwing a frisbee in a park.



A dog is standing on a hardwood floor.



A stop sign is on a road with a mountain in the background.



A little girl sitting on a bed with a teddy bear.



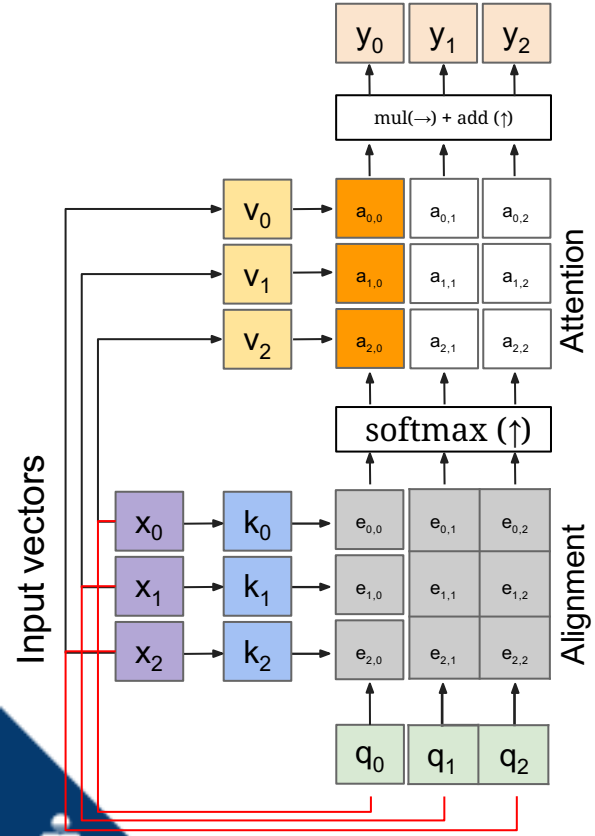
A group of people sitting on a boat in the water.



A giraffe standing in a forest with trees in the background.

Xu 等，“Show, Attend, and Tell: Neural Image Caption Generation with Visual Attention”，ICML 2015 图片版权归 Kelvin Xu、Jimmy Lei Ba、Jamie Kiros、Kyunghyun Cho、Aaron Courville、Ruslan Salakhutdinov、Richard S. Zemel 和 Yoshua Benchio 所有，2015。经许可转载。

通用注意力层



输出：
上下文向量：□（形状：D□）

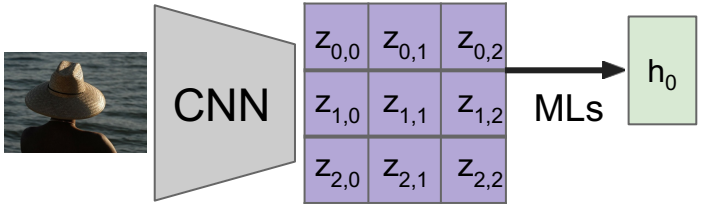
运算：
键向量：□ L □x q
值向量：□ L □x
查询向量：□ L □x
v 对齐：ei,□ q□kj 0 □D
注意力：y L softmax(□)
输出：y□L □¡ ai,□vi

输入：
输入向量：□（形状：N x D）
查询：□（形状：M x D□）

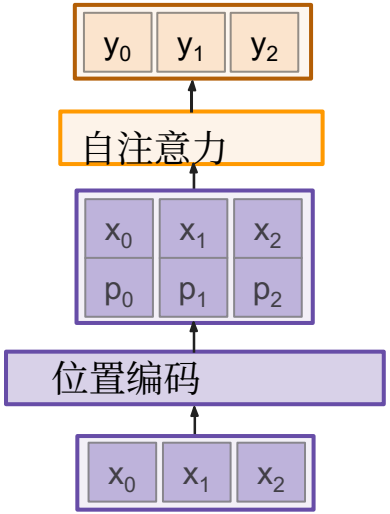
自注意力层

回想一下，查询向量是输入向量的函数

编码器：h P f (□)0 w其中 □是空间 CNN 特征 wf (.) 是一个 MLP



位置编码



将特殊位置编码 p□拼接到每个输入向量 x□

我们使用一个函数 *pos*: N □ R^d 来将向量的位置 ○处理为 d 维向量

因此， p□└ *pos*(○)

针对 *pos*(/) 的选项

1. 学习一个查找表：
   ○ 学习用于 *pos*(t) 的参数，其中 t □[2, T) ○ 查找表包含 T xd 个参数。

2. 设计一个满足这些期望条件的固定函数

□

$$\mathbf{p}(t) \text{ L } \begin{bmatrix} \sin(\omega_1 . t) \\ \cos(\omega_1 . t) \\ \sin(\omega_2 . t) \\ \cos(\omega_2 . t) \\ \vdots \\ \sin(\omega_{d/2} . t) \\ \cos(\omega_{d/2} . t) \end{bmatrix}_d$$

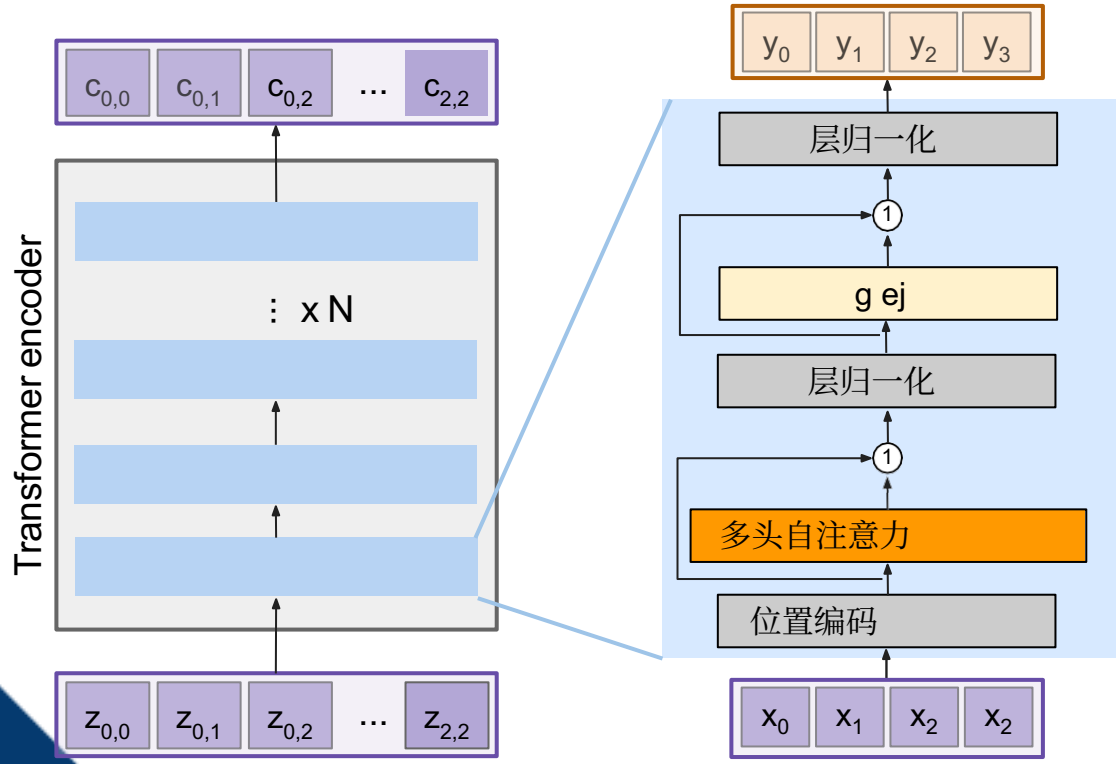
直觉：

0：	0	0	0	0	8：	1	0	0	0
1：	0	0	0	1	9：	1	0	0	1
2：	0	0	1	0	10：	1	0	1	0
3：	0	0	1	1	11：	1	0	1	1
4：	0	1	0	0	12：	1	1	0	0
5：	0	1	0	1	13：	1	1	0	1
6：	0	1	1	0	14：	1	1	1	0
7：	0	1	1	1	15：	1	1	1	1

其中 $\omega_k = \frac{1}{10000^{2k/d}}$

Vaswani 等，“注意力就是你所需要的一切”，NeurIPS 2017

Transformer 编码器块



Transformer 编码器块：

输入：一组向量 **x** **输出**：一组向量 □

自注意力是向量之间唯一的交互。

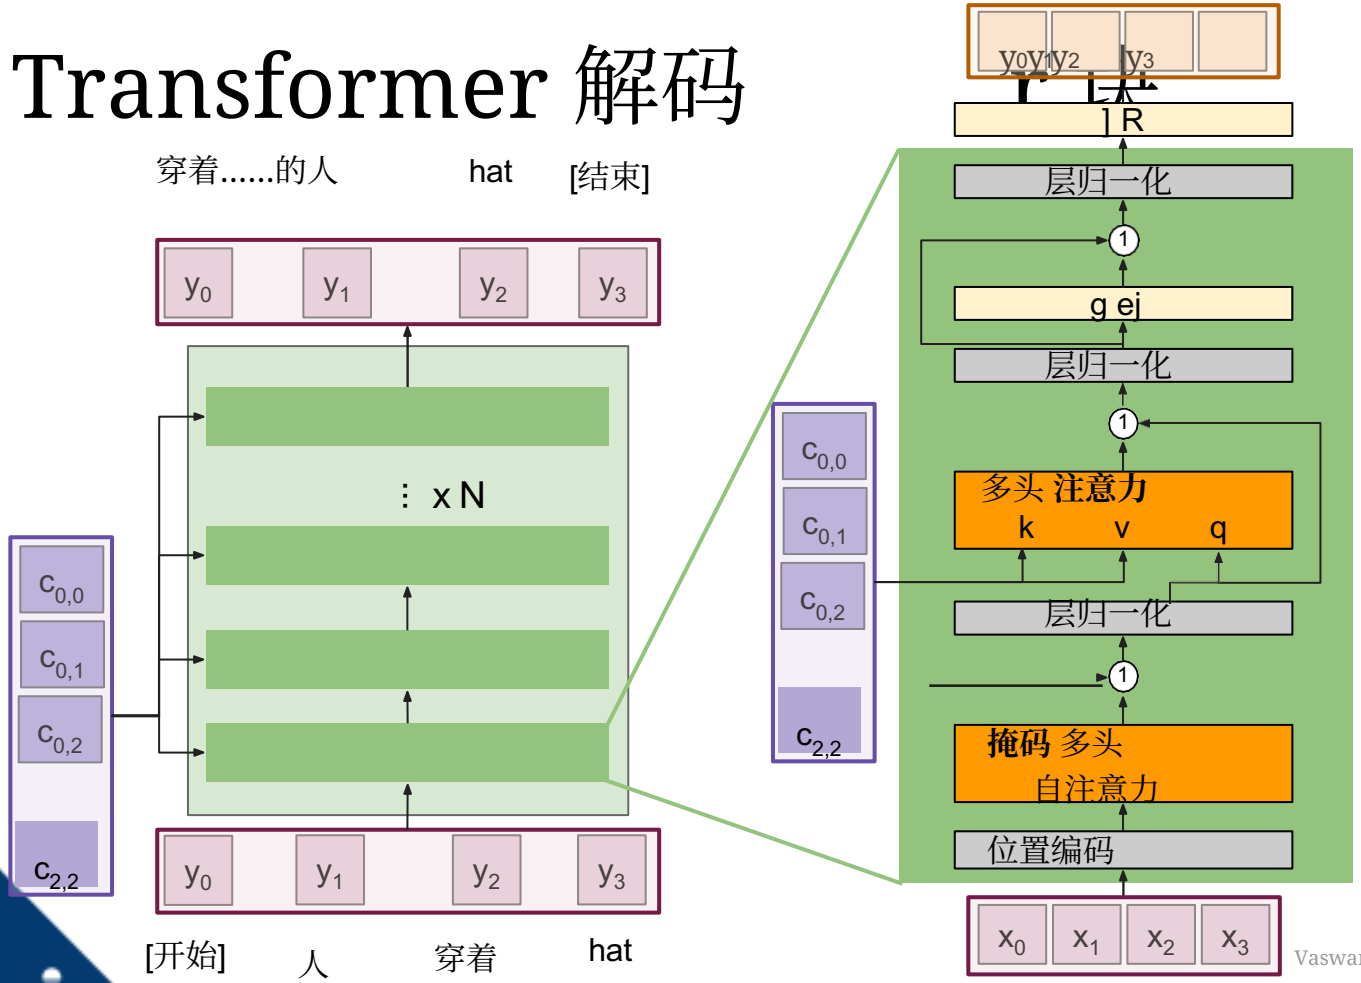
层归一化和 MLP 对每个向量独立进行运算。

高度可扩展、高度可并行化，但内存占用高

用法。

Vaswani 等人，“Attention is all you need”，NeurIPS 2017

Transformer 解码



Transformer 解码器块：

输入：向量集合 □和上下文向量集合 **c**。**输出**：向量集合 **y**。

掩码自注意力仅与过去的输入交互。

多头注意力块不是自注意力。它关注编码器输出。

高度可扩展、高度可并行化，但内存占用高。

Vaswani 等，“Attention is all you need”，NeurIPS 2017

今日

- **计算机视觉任务**
  - **语义分割**
  - 目标检测
  - 实例分割

- 可视化与理解
  - 模型层可视化
  - 显著性图
  - CAM & Grad-CAM

- 基础模型与提示分割



计算机视觉任务

分类



CAT

无空间范围

语义分割



草，CAT，树，
S□□

没有对象，只有像素

目标检测



狗，狗，CAT

实例分割



狗，狗，CAT

多个对象

本图像为CC0公共领域

回顾：图像分类：计算机视觉中的核心任务



本图像由□i□□提供，
依据以下许可：YY.C□ B0_

（假设给定一组可能的标签）{狗, 猫, 卡车 , 飞机 , ...}

t k□

语义分割

分类

CAT

无空间范围

语义分割



草地, CAT, 树, SKY

没有物体，只有像素

目标检测

DOG, DOG, CAT

实例分割

DOG, DOG, CAT

多目标

语义分割：问题





草地、CAT、树、天空、……

配对训练数据：对于每张训练图像， 每个像素都标注有一个语义类别。



S

在测试时，对新图像的每个像素进行分类。

语义分割思路：滑动窗口

完整图像



语义分割思路：滑动窗口

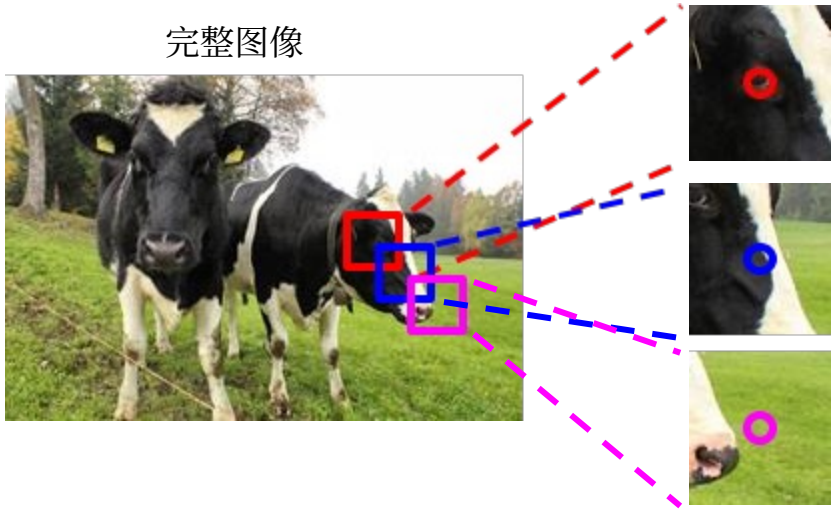
完整图像



没有上下文就无法分类

问：我们如何纳入上下文?

语义分割思路：滑动窗口

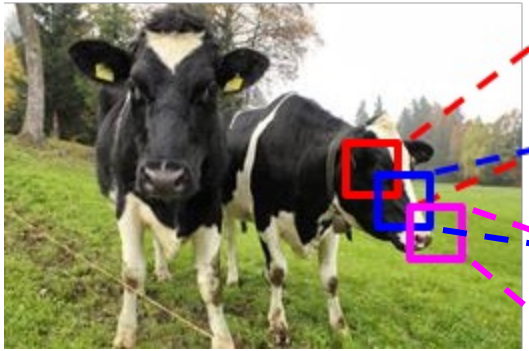


问：我们如何对此建模?

语义分割思路：滑动窗口

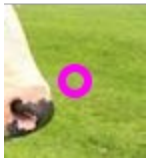
分类中心像素 使用 CNN 提取图像块

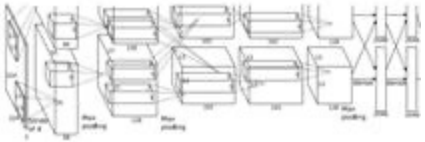
完整图像

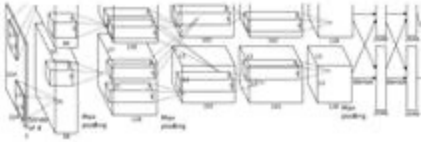


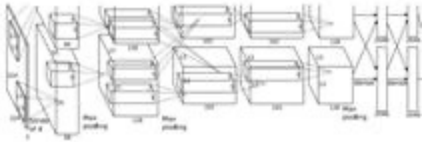












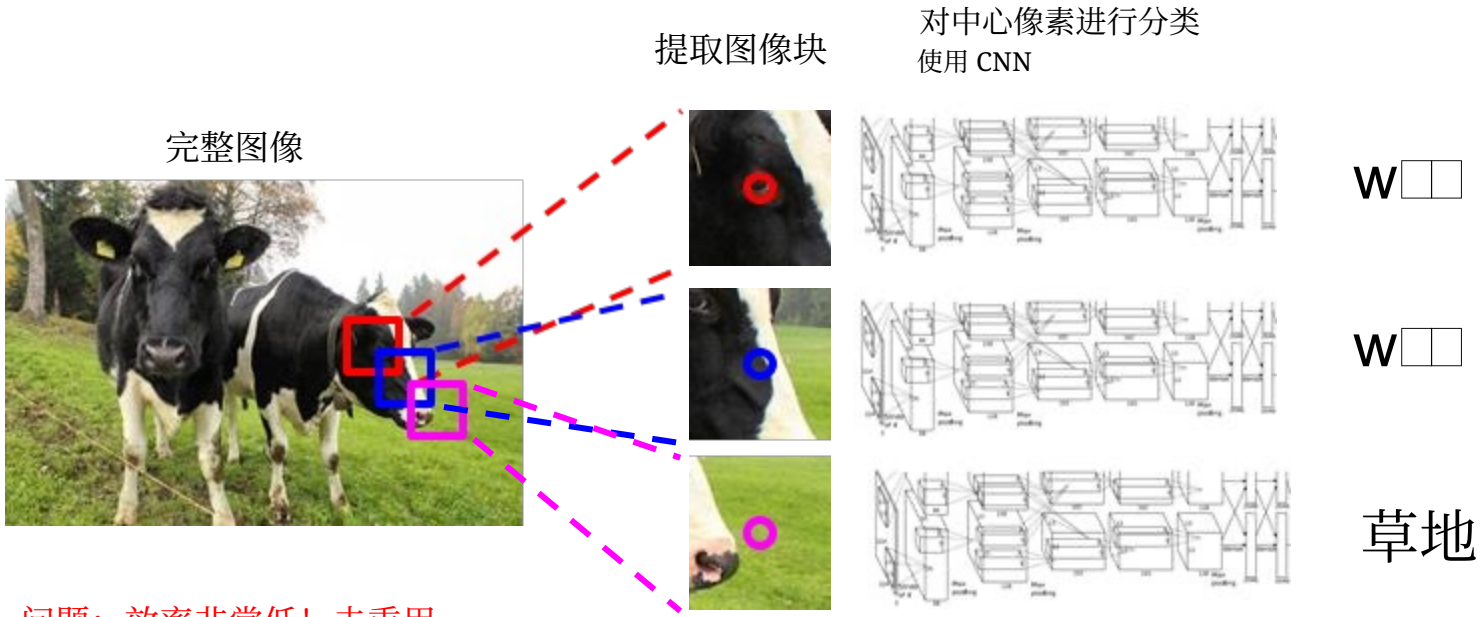
W□□

W□□

草

Farabet 等，“用于场景标注的层次特征学习”，TPAMI2013 Pinheiro 和 Collobert，“用于场景标注的循环卷积神经网络”，ICML 2014

语义分割思路：滑动窗口



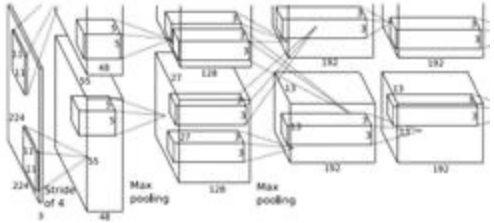
问题：效率非常低！未重用
重叠图像块之间的共享特征

Farabet 等，“用于场景标注的层次特征学习”，TPAMI2013 Pinheiro 和 Collobert，“用于场景标注的循环卷积神经网络”，ICML 2014

语义分割思路：卷积

完整图像





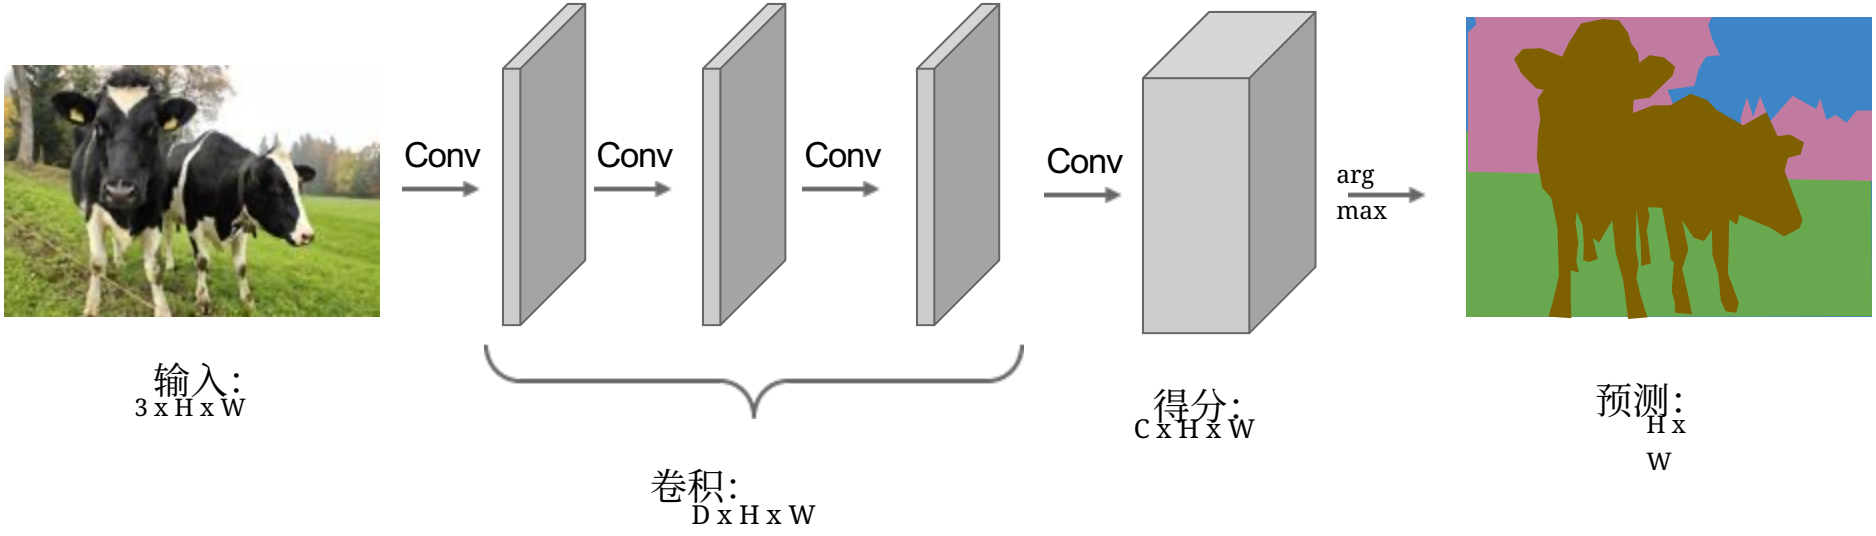


一个直观的想法：用卷积网络编码整张图像，并在其上进行语义分割。

问题：分类架构通常通过减小特征的空间尺寸来加深网络，但语义分割要求输出尺寸与输入尺寸相同。

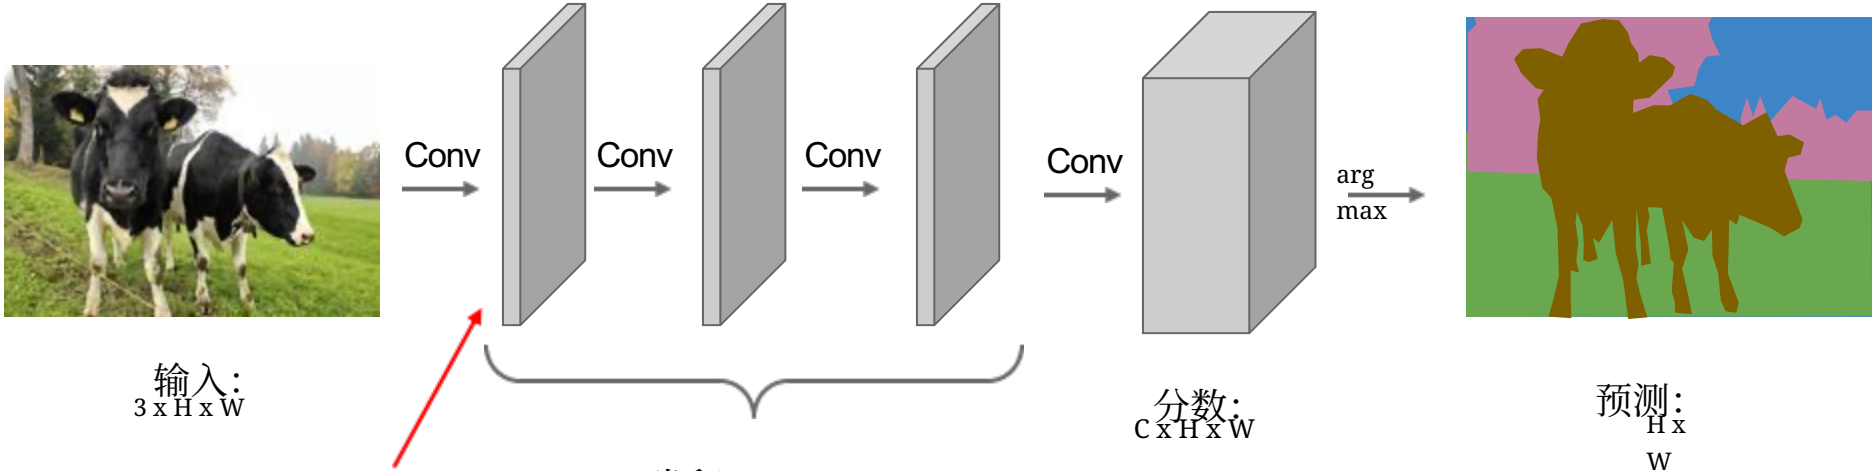
语义分割思路：全卷积

设计一个仅含卷积层、不含下采样算子的网络来预测 所有像素，一次性完成！



语义分割思路：全卷积

设计一个仅包含卷积层、不含下采样算子的
网络来进行预测 对所有像素一次性完成！



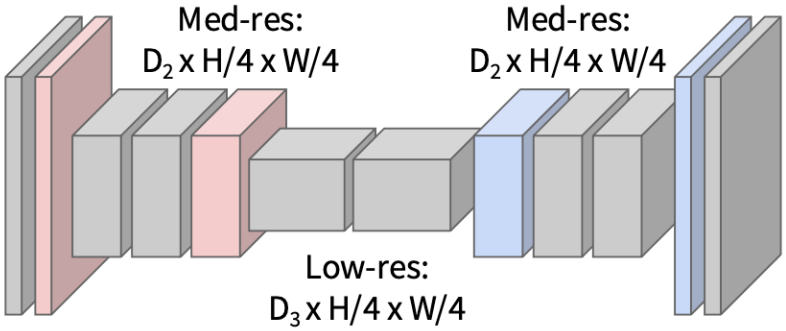
问题：卷积在原始图像分
辨率下将非常昂贵.....

语义分割思路：全卷积

将网络设计为一系列卷积层，其中包含 下采样 和 上采样 在网络内部！

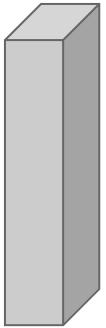


输入：
3 x H x W



高分辨率：
Dx H/2 x W/2

高分辨率：
Dx H/2 x □ 36



C x H x W



预测：
H x W

Long、Shelhamer 和 Darrell，“用于语义分割的全卷积网络”，CVPR 2015 Noh 等，“用于语义分割的学习反卷积网络”，ICCV 2015

语义分割思路：全卷积

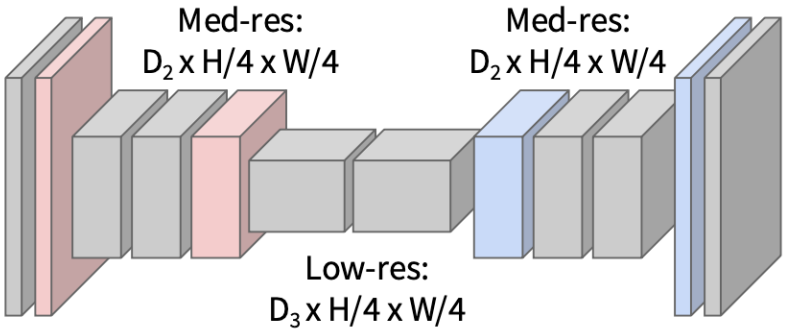
下采样：池化、跨步卷积

将网络设计成一系列卷积层，其中包含下采样和上采样，且这些都在网络内部完成！

上采样：???

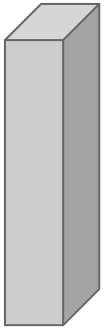


输入：
3 x H x W



高分辨率：
Dx H/2 x W/2

高分辨率：
Dx H/2 x □ 36



C x H x W

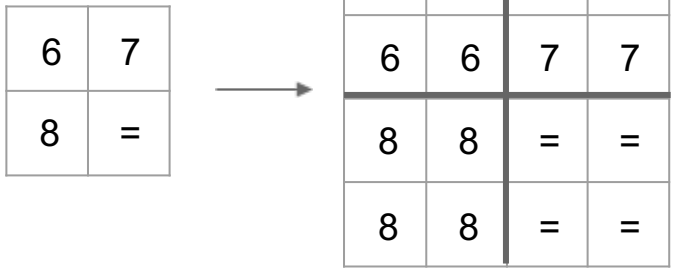


预测：
H x W

Long、Shelhamer 和 Darrell，《用于语义分割的全卷积网络》，CVPR 2015；Noh 等人，《学习用于语义分割的反卷积网络》，ICCV 2015

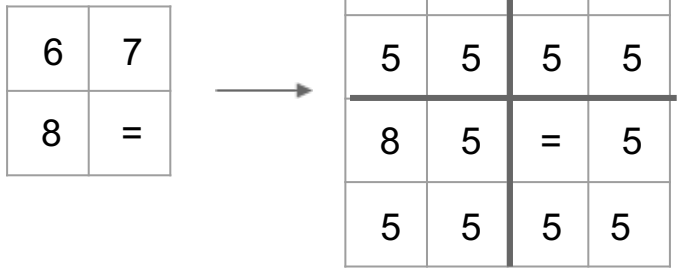
网络内上采样：“反池化”

最近邻



输入：2 x 2　　输出：4 x 4

“钉床”



输入：2 x 2　　输出：4 x 4

网络内上采样：“最大反池化”

最大池化 记住哪个元素是最大值！

6	7	I	8
8	?	7	6
6	7	7	6
L	8	=	M

输入：4 x 4

?	I
L	M

输出：2 x 2

网络的其余部分

最大反池化：使用
来自池化层的位置

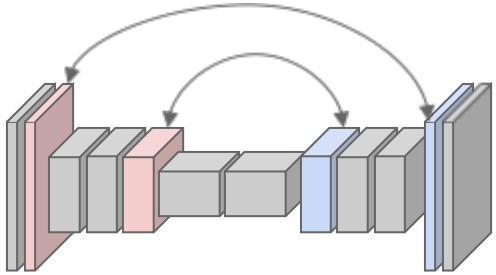
6	7
8	=

输入：2 x 2

5	5	7	5
5	6	5	5
5	5	5	5
8	5	5	=

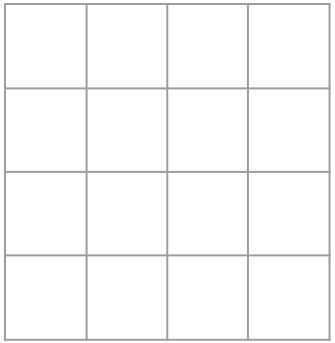
输出：4 x 4

对应的 降采样和上采
样层配对

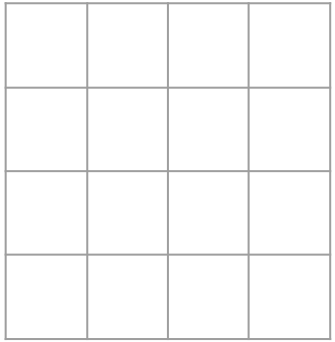


可学习的上采样

回顾：普通 3 x 3 卷积，步幅 1，填充 1



输入：4 x 4

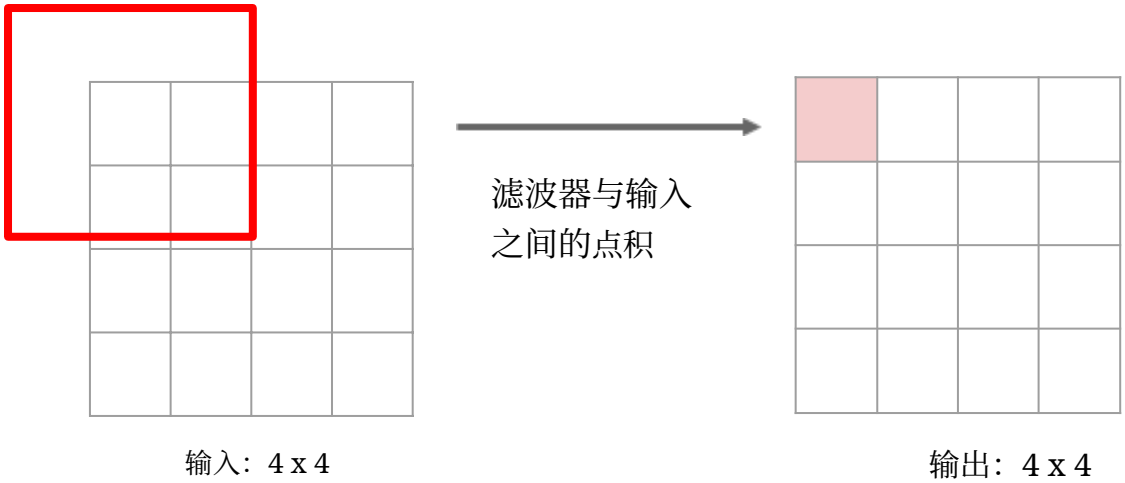


输出：4 x 4



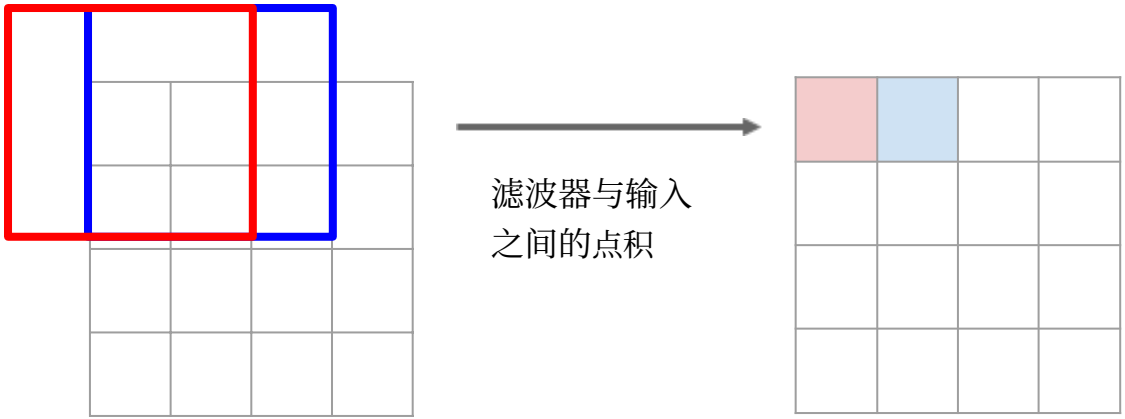
可学习上采样

回顾：普通 3 x 3 卷积，步长 1，填充 1



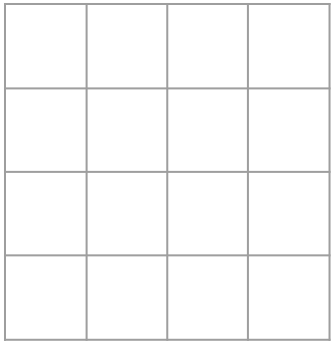
可学习上采样

回顾：普通 3 x 3 卷积，步幅 1，填充 1

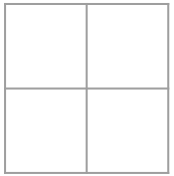


可学习上采样

回顾：普通 3 x 3 卷积，步幅 2，填充 1



输入：4 x 4



输出：2 x 2



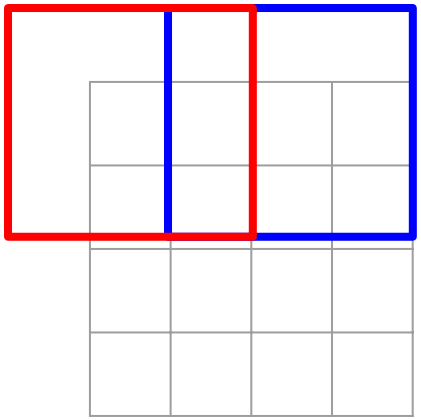
可学习上采样

回顾：常规 3 x 3 卷积，步幅 2，填充 1



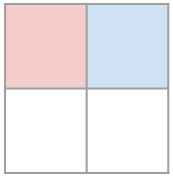
可学习上采样

回顾：普通 3 x 3 卷积，步幅 2，填充 1



输入：4 x 4

滤波器与输入之间的点积



输出：2 x 2

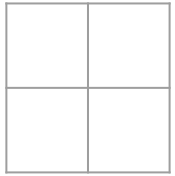
滤波器在输入中移动 2 个像素，对应输出中的每一个像素

步幅给出了 输入与输出中移动量之间的比率

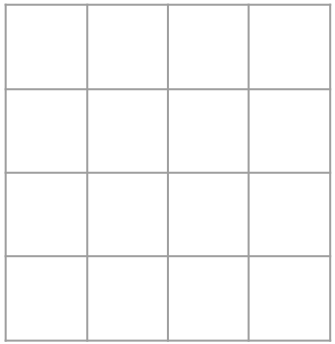
我们可以将带步幅卷积解释为“可学习下采样”。

可学习上采样：转置卷积

3 x 3 转置卷积，步长 2，填充 1



输入：2 x 2

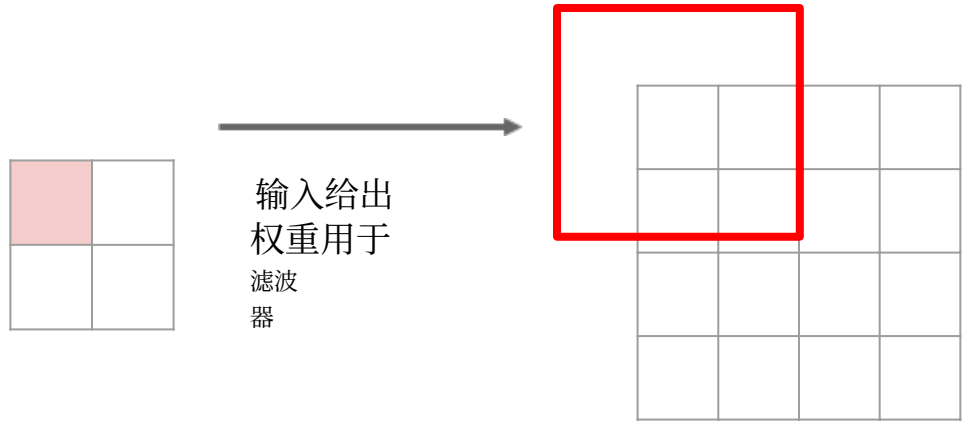


输出：4 x 4



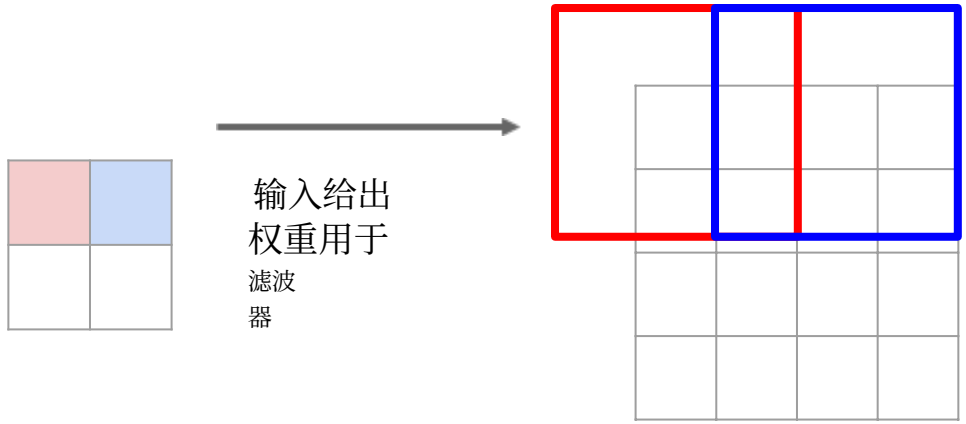
可学习上采样：转置卷积

3 x 3 转置卷积，步幅 2 填充 1



可学习上采样：转置卷积

3 x 3 转置卷积，步幅 2 填充 1



输入给出权重用于滤波器

输入：2 x 2

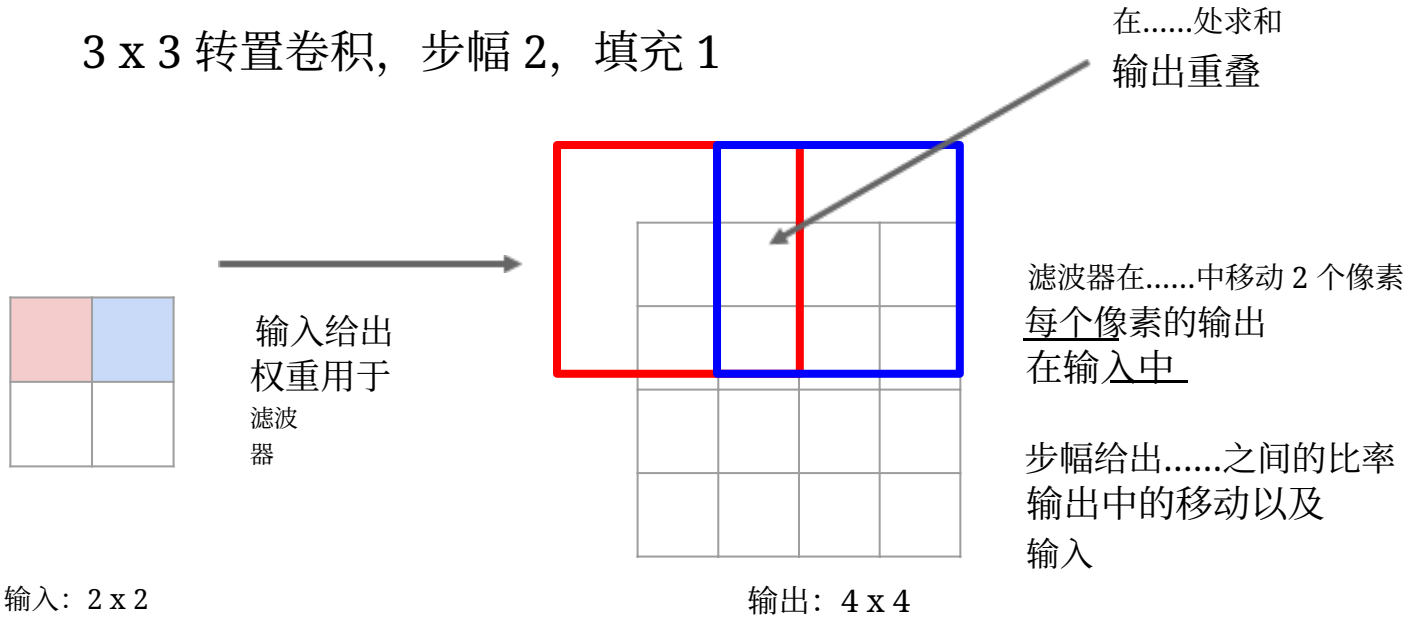
输出：4 x 4

滤波器在输出中移动2个像素，对应 输入中的每1个像素

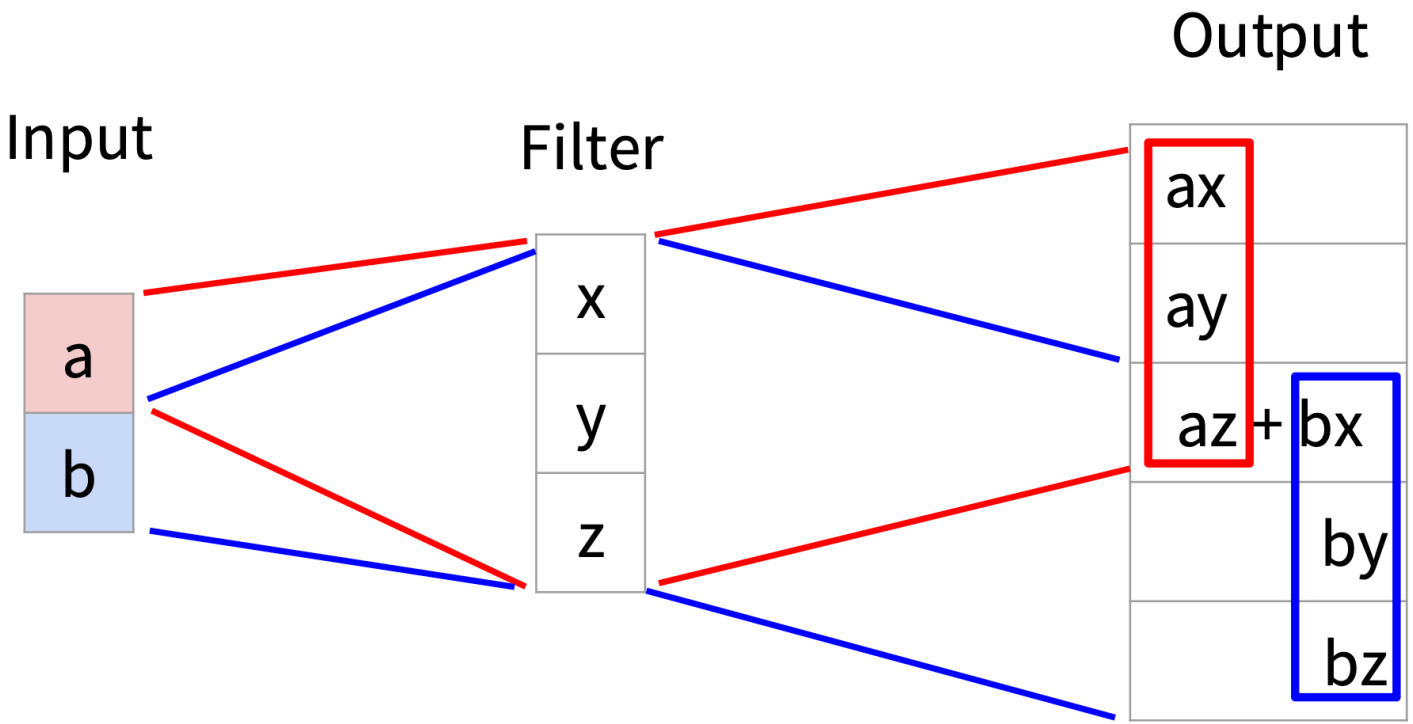
步幅给出比率，介于 输出与输入中的移动

可学习上采样：转置卷积

3 x 3 转置卷积，步幅 2，填充 1



可学习上采样：一维示例



Output contains copies of the filter weighted by the input, summing at where at overlaps in the output

语义分割思路：全卷积

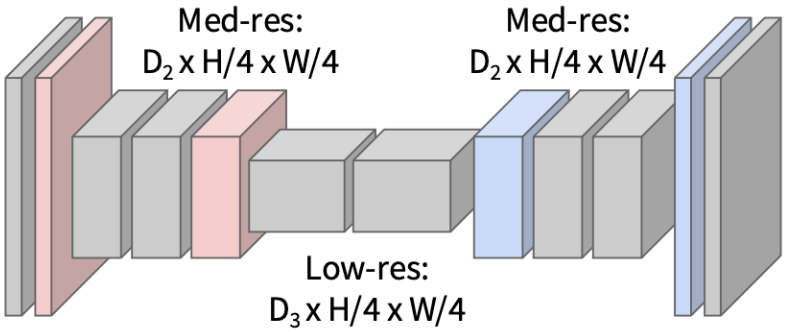
下采样：池化、步长卷积

将网络设计为一组卷积层，其中包含 下采样和上采样，并且这些操作都在网络内部完成！

上采样：反池化或步长转置卷积



输入：
3 x H x W



高分辨率：
Dx H/2 x W/2

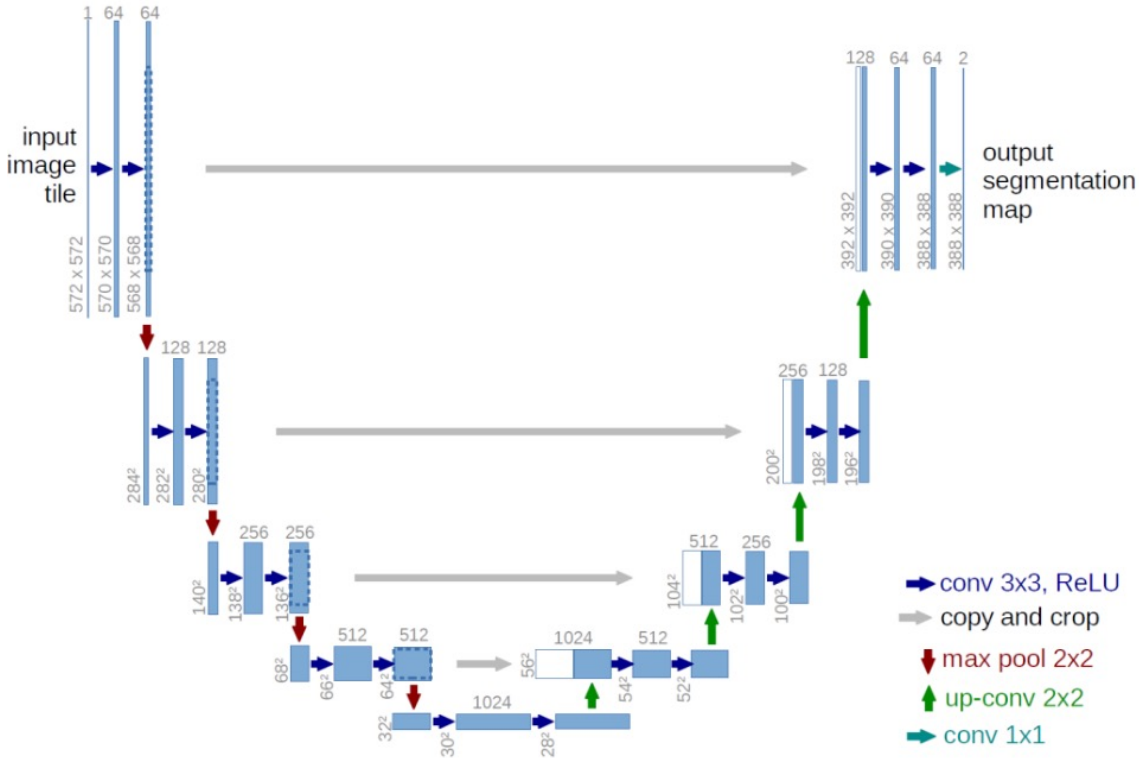
高分辨率：
Dx H/2 x W/2



预测结果：
H x W

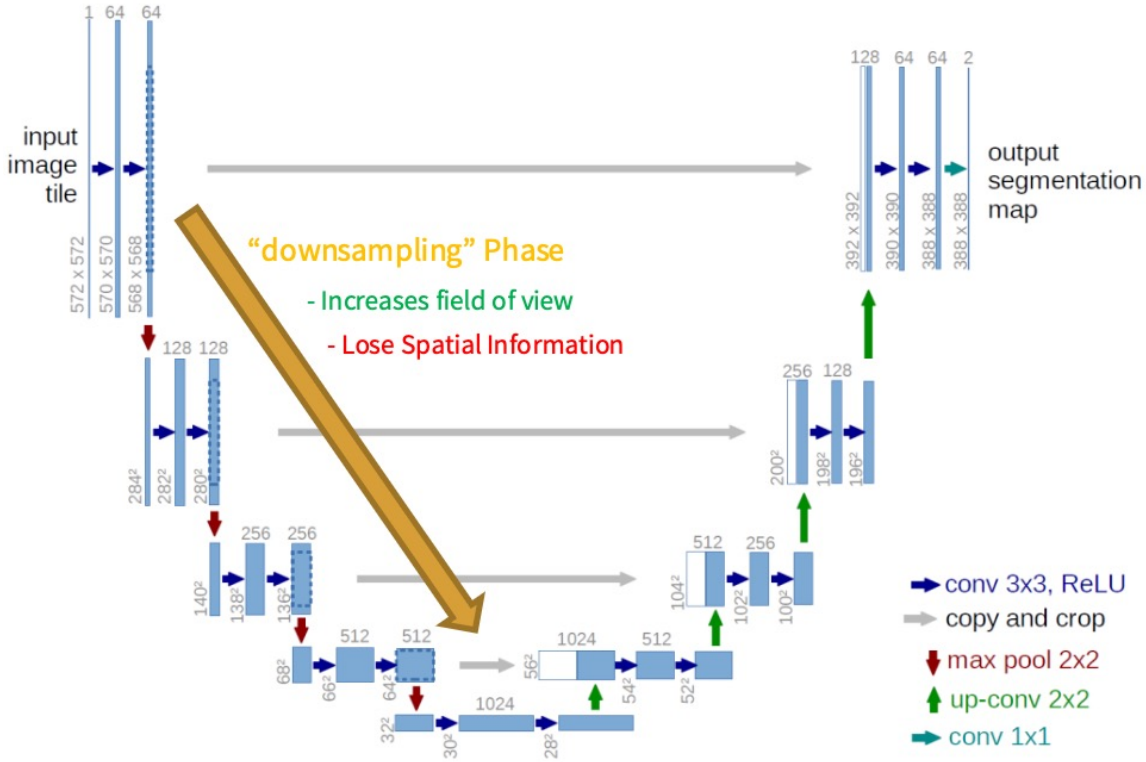
Long、Shelhamer 和 Darrell，“用于语义分割的全卷积网络”，CVPR 2015 Noh 等，“用于语义分割的学习反卷积网络”，ICCV 2015

U-Net



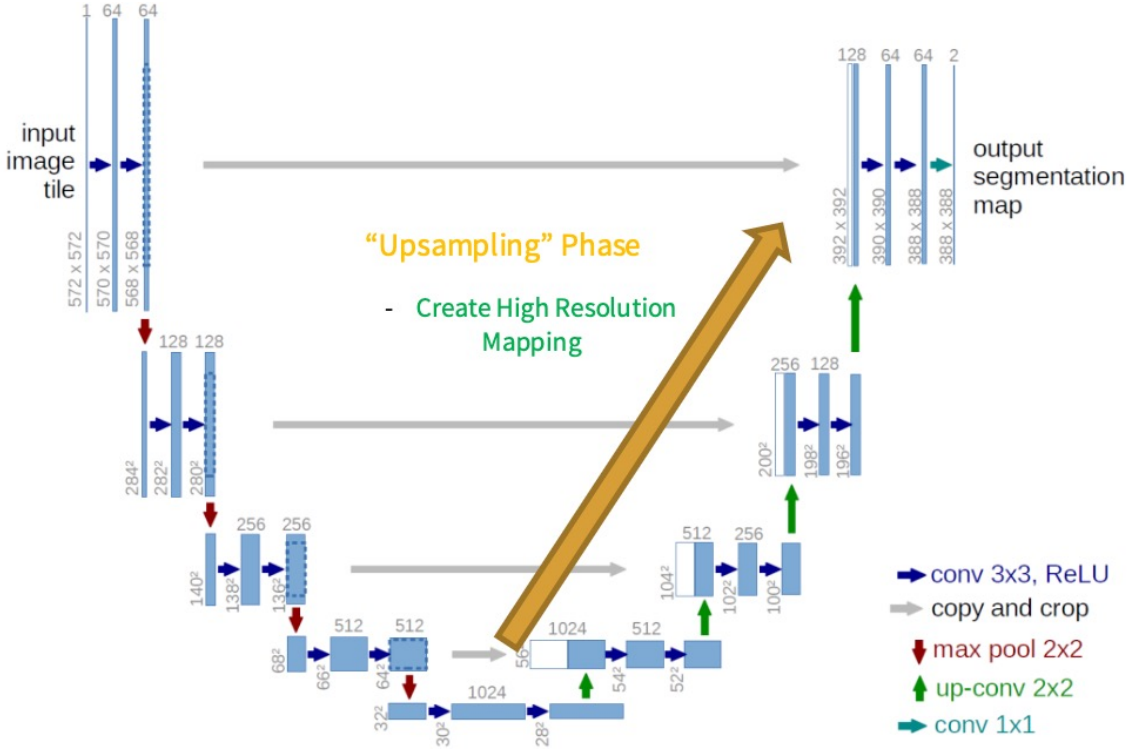
Ronneberger 等人 (2015) U-net 架构

U-Net



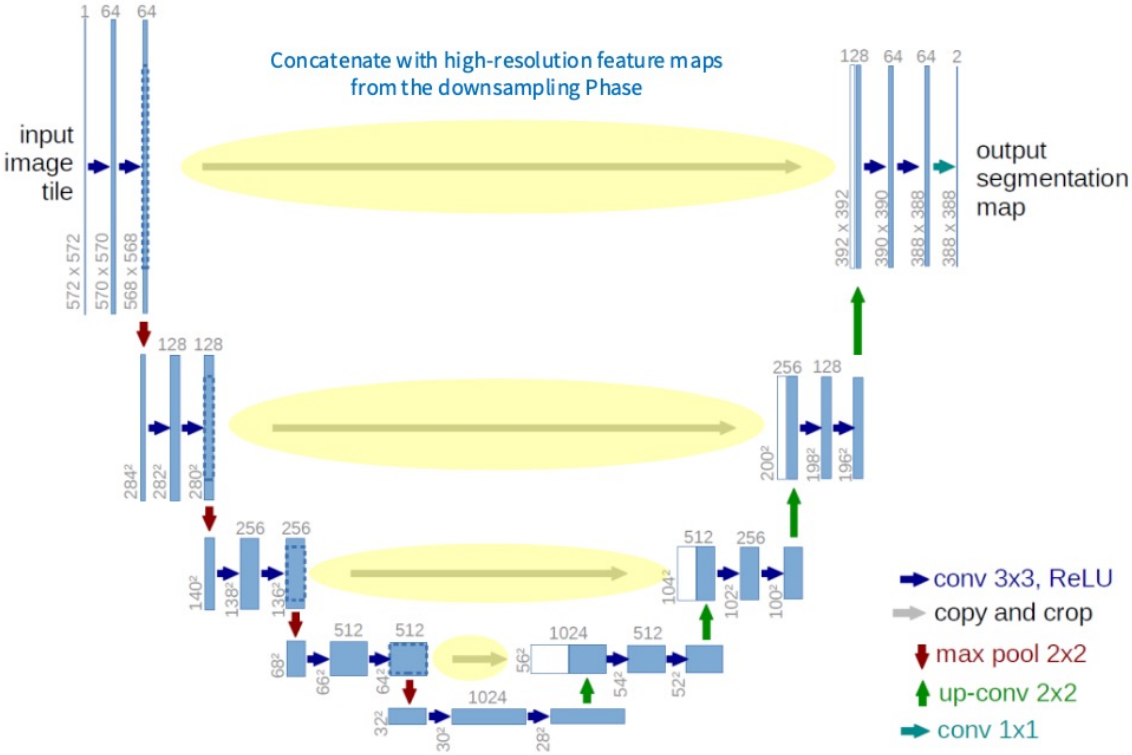
Ronneberger et al. (2015) U-net 架构

U-Net



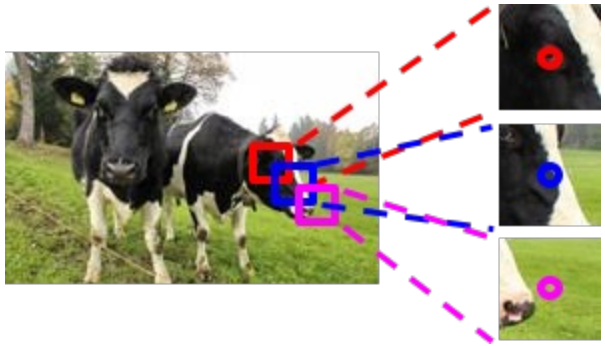
Ronneberger 等人 (2015) U-net 架构

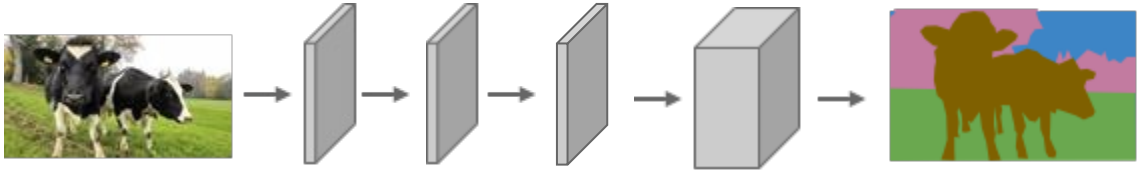
U-Net



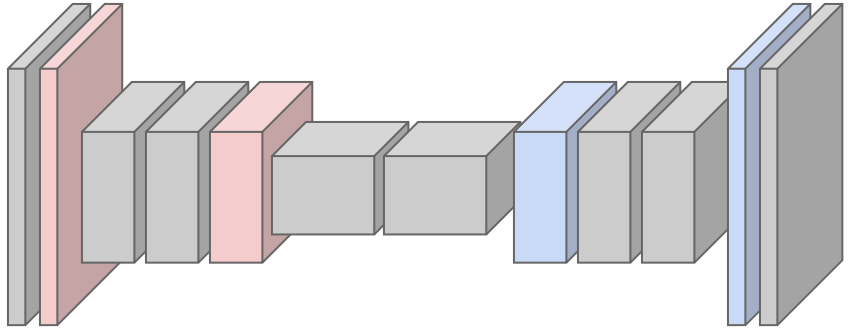
Ronneberger 等人 (2015) U-net 架构

语义分割：总结











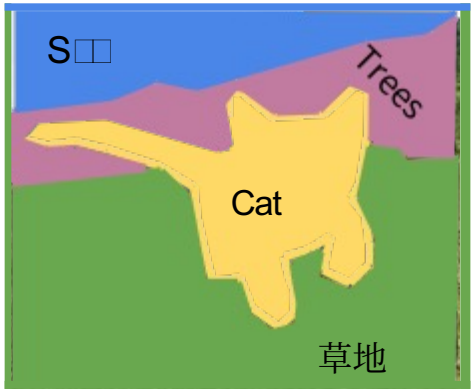
语义分割

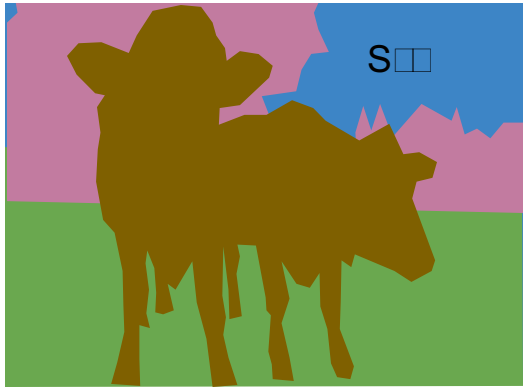
为图像中的每个像素标注类别标签

不区分实例，只关注像素









今天

- **计算机视觉任务**
  - 语义分割 - **目标检测** - 实例分割

- 可视化与理解
  - 模型层可视化 - 显著性图 - CAM 与 Grad-CAM

- 基础模型与提示分割



目标检测

分类

语义分割

目标检测

实例分割

CAT

无空间范围

草地，CAT，树，SKY

没有对象，只有像素

狗，狗，CAT

多对象



狗，狗，CAT

目标检测

分类

语义分割

目标检测

实例分割





CAT

草地, CAT, 树, SKY

狗, 狗,CAT

狗, 狗,CAT

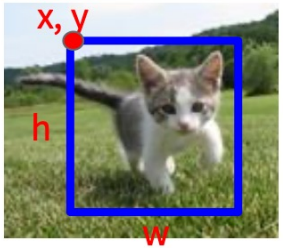
无空间范围

没有物体，只有像素

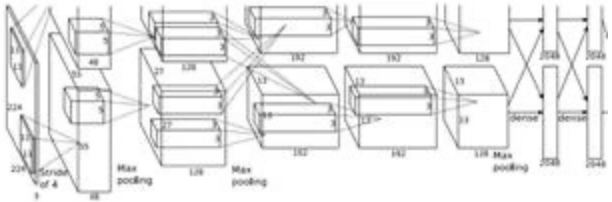
多目标

目标检测：单个对象

(分类 4 定位)



This image is CC0 public domain



全
连接：
4096 到 1000

类别
分数 猫：
4.G
狗：0.05
汽车：0.01
...

向量：
94G=

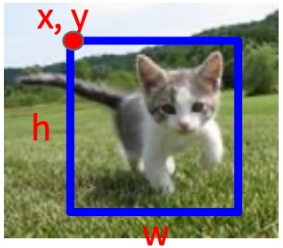
全
连接：
4096 到 4

Wbx
坐标
(x, y, w, h)

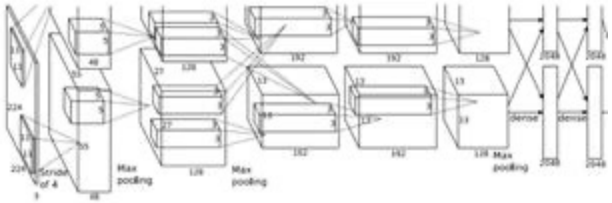
左上角

目标检测：单目标

（分类 4 定位）



This image is CC0 public domain



全
连通：
4096 到 1000

类别
分数 猫：
4.G
狗：0.05
汽车：0.01
...

Softmax
t oss

正确标签：
Cat

向量：
94G=

全
连接：
4096 到 4

Wbx
坐标
(x, y, w, h)

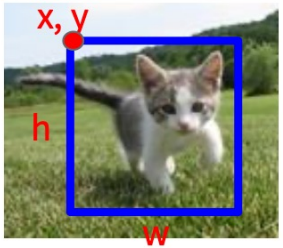
L2 损失

正确边界框：
(x', y', w', h')

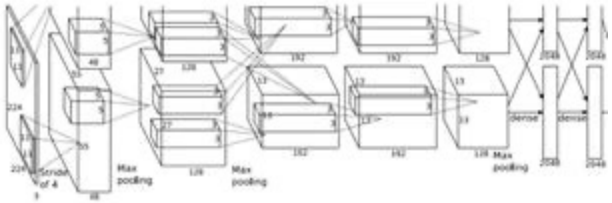
将定位视为一个
回归问题！

目标检测：单目标

（分类 4 定位）



This image is CC0 public domain



全
连接：
4096 到 1000

类别
猫的得分：
4.G
狗：0.05
汽车：0.01
...

Softmax
t oss

正确标签：
Cat

多任务损失

t oss

向量：
94G=

全
连接：
4096 到 4

Wbx
坐标
(x, y, w, h)

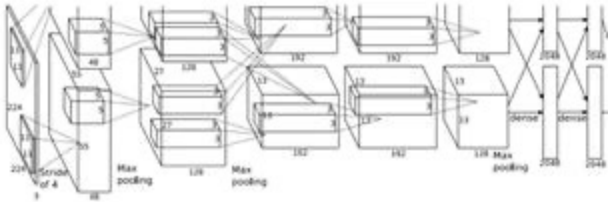
L2损失

正确边界框：
(x', y', w', h')

将定位视为一个
回归问题！

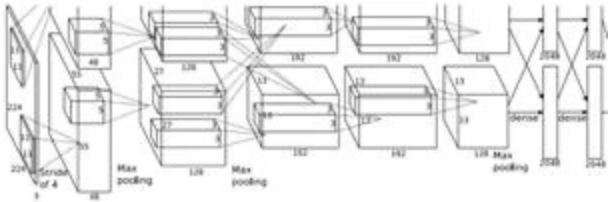
目标检测：多个对象





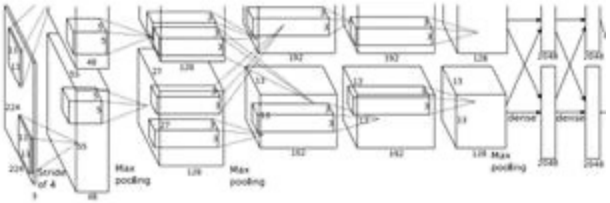
CAT：(x, y, w, h)





狗：(x, y, w, h) 狗：(x, y, w, h)
CAT：(x, y, w, h)



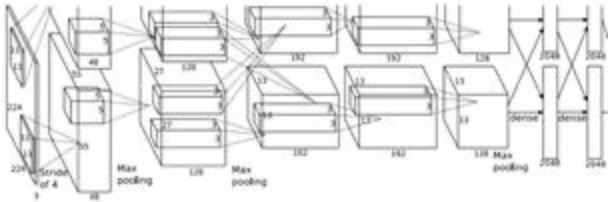


鸭子: (x, y, w, h) 鸭子: (x, y, w,h)....

目标检测：多个目标

每张图像需要不同的输出数量！

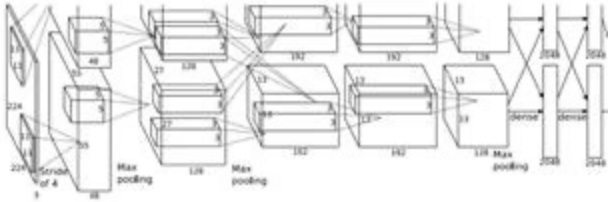




CAT: (x, y, w, h)

4个数字

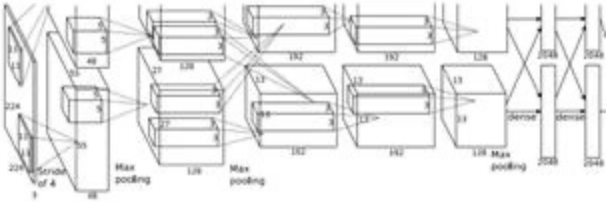




狗: (x, y, w, h) 狗: (x, y, w, h) CAT: (x, y, w, h)

12 个数字





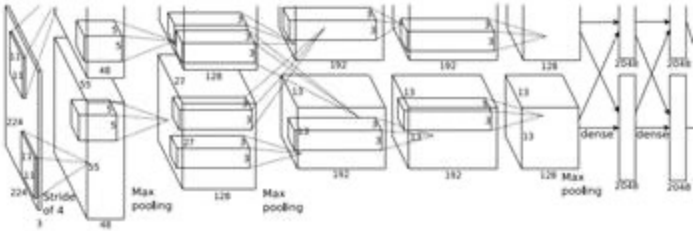
鸭子：(x, y, w, h) 鸭子：(x, y, w,h)....

许多数字！

目标检测：多个对象

将 CNN 应用于图像的许多不同裁剪区域，
CNN 将每个裁剪区域分类为对象或背景



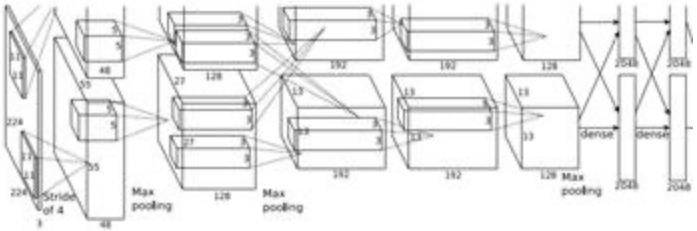


狗？ 否
猫？ 否 背景？ 是

目标检测：多个对象

将 CNN 应用于图像中许多不同的裁剪区域，
CNN 将每个裁剪区域分类为目标或背景



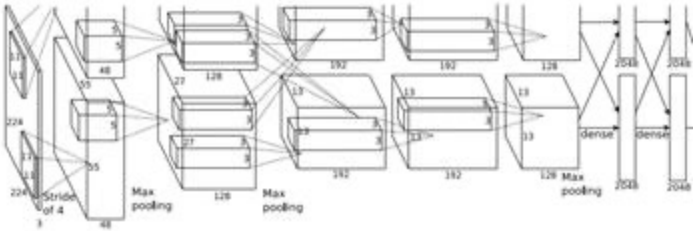


狗？是猫？
否 背景？否

目标检测：多个对象

将 CNN 应用于图像的许多不同裁剪区域，
CNN 将每个裁剪区域分类为目标或背景



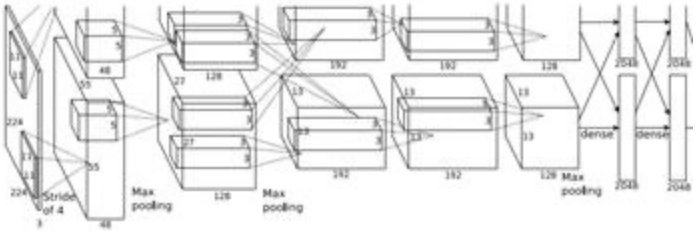


狗？是猫？
否 背景？否

目标检测：多目标

将 CNN 应用于图像的许多不同裁剪区域，
CNN 将每个裁剪区域分类为目标或背景



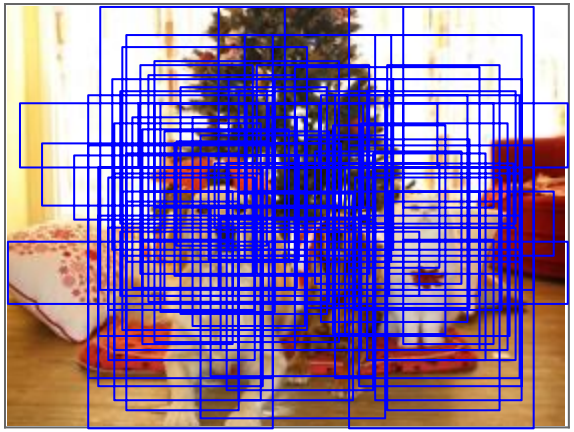


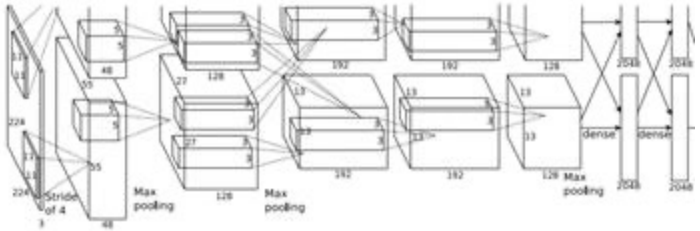
狗？否猫？
是 背景？否

问：这种方法有什么问题？

目标检测：多个对象

将 CNN 应用于图像的许多不同裁剪区域，
CNN 将每个裁剪区域分类为目标或背景



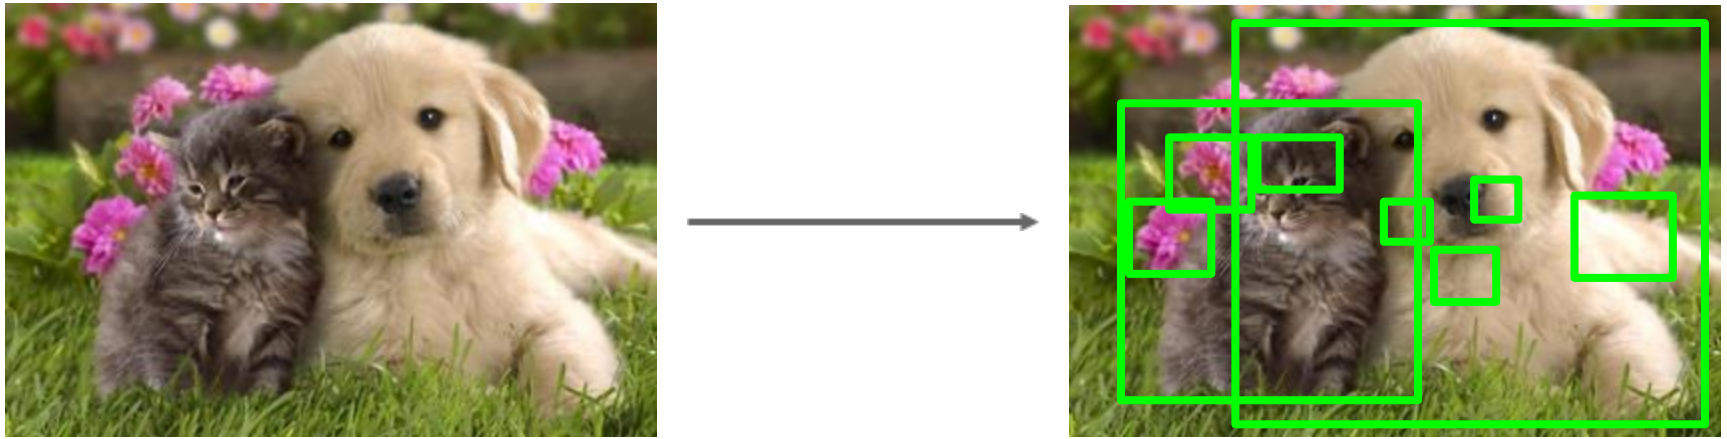


狗？否猫？
是 背景？否

问题：需要将 CNN 应用于巨大数量的
位置、尺度和纵横比，计算成本非常高！

区域提议：Selective Search

- 找出可能包含物体的“块状”图像区域
- 运行相对较快；例如，Selective Search 在CPU上几秒内即可给出2000个区域提议



Alexe 等，“测量图像窗口的目标性”，TPAMI 2012 Uijlings 等，“面向目标识别的 Selective Search”，IJCV 2013 Cheng 等，“BING：用于以300fps进行目标性估计的二值化范数梯度”，CVPR 2014 Zitnick 和 Dollar，“Edge Boxes：从边缘定位目标提议”，ECCV 2014

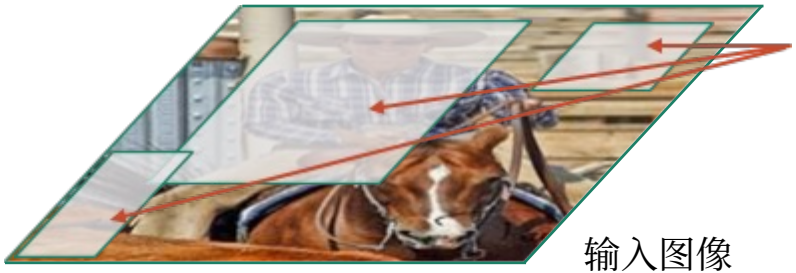
R-CNN



输入图像

↑ irshic□et al，“Rich feature hierarchiesfor accurateobject detection and semanticsegmentatior□ ℃VPR 2014。图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN

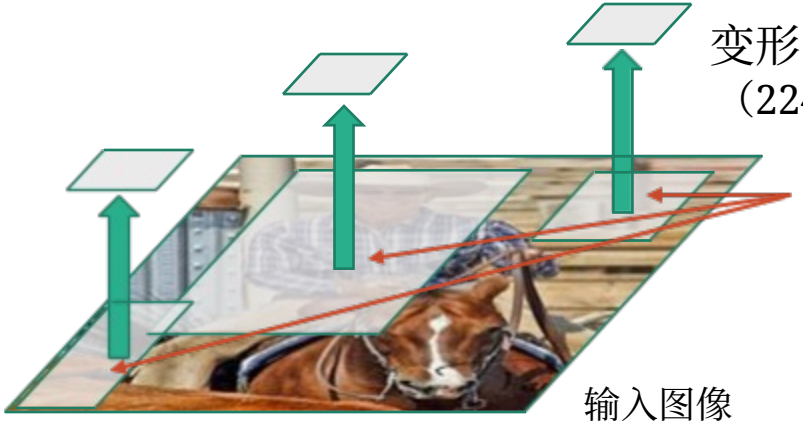


感兴趣区域 (RoI) 来自提议方法 (□2k)

输入图像

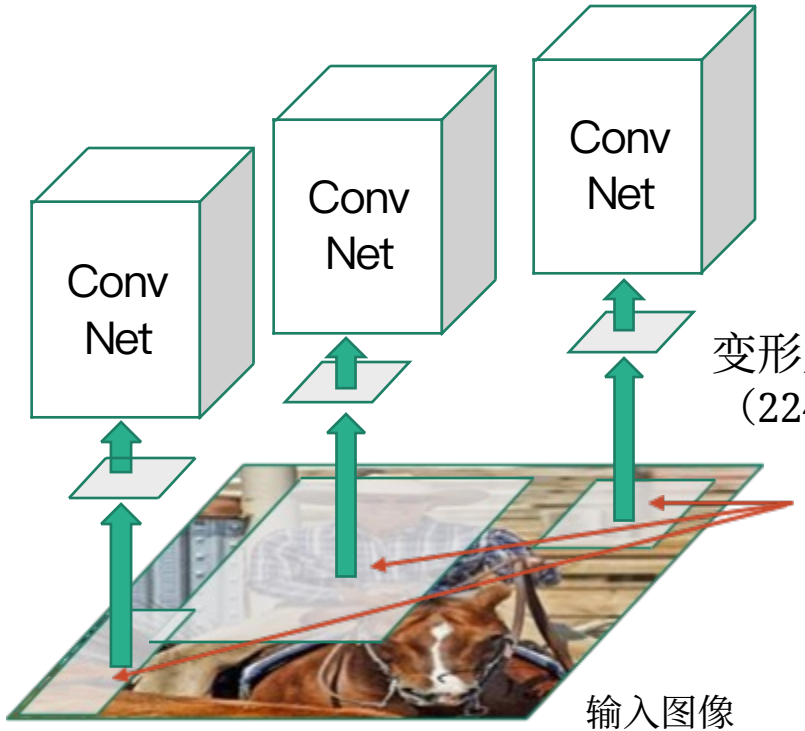
↑ irshic□et al，“用于精确目标检测和语义分割的丰富特征层次”，CVPR 2014。图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN



Girshick 等，“用于精确目标检测和语义分割的丰富特征层级”，CVPR 2014。图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN



将每个区域通过 ConvNet前向传播（经 ImageNet 预训练）

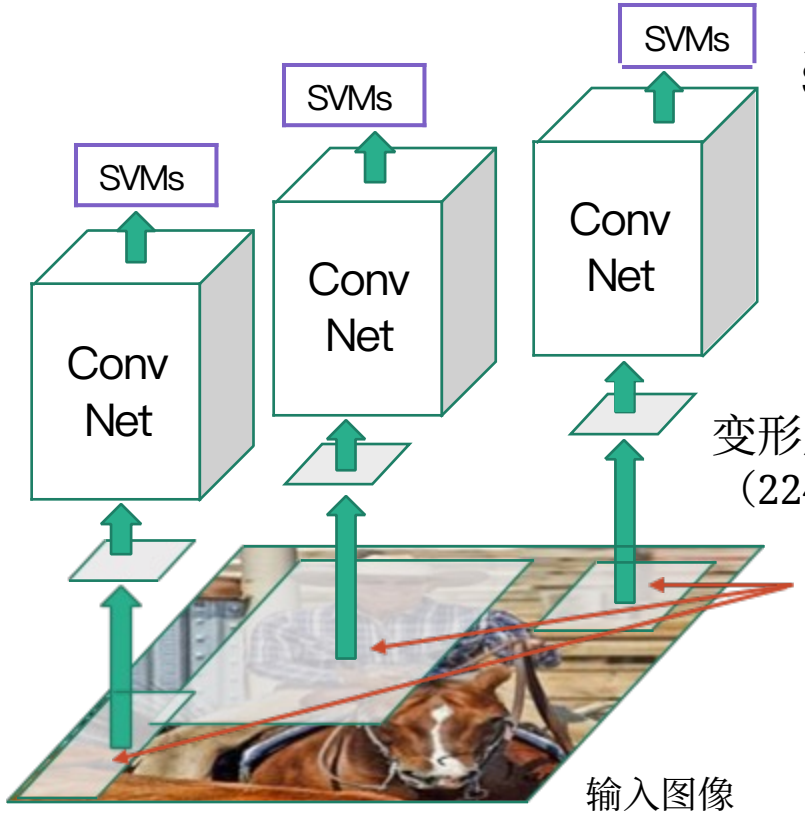
变形后的图像区域（224x224 像素）

感兴趣区域 (RoI) 来自候选提议方法（□2k）

输入图像

Girshick 等，“用于精确目标检测和语义分割的丰富特征层次结构”，CVPR 2014。
图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN



用以下内容对区域进行分类
SVMs

将每个区域前向传播
通过 ConvNet
（在 ImageNet 上预训练的）

变形后的图像区域
（224x224 像素）

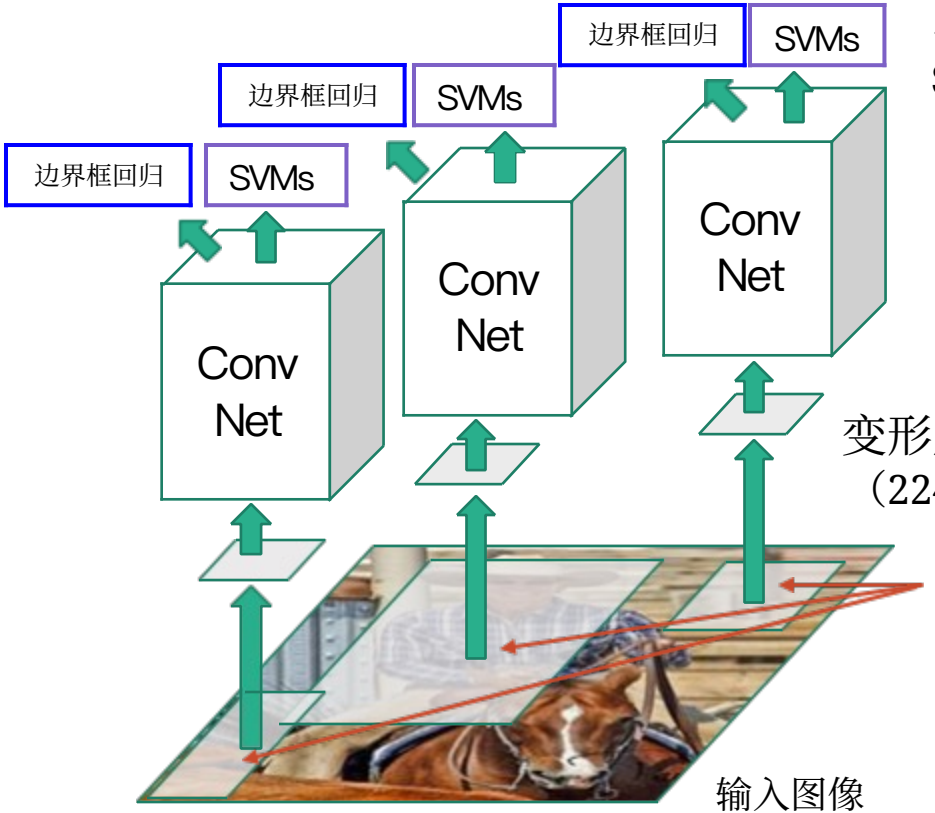
感兴趣区域
（RoI）来自提议
方法（□2k）

输入图像

↑ irshic□et al,"Rich feature hierarchiesfor accurateobject detection and semanticsegmentation□,CVPR 2014. 图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN

预测对 RoI 的“修正”：4 个数字：(dx, dy, dw, dh)



使用……对区域进行分类
SVMs

将每个区域前向传播
通过 ConvNet
（ImageNet 预训练的）

变形后的图像区域
（224x224 像素）

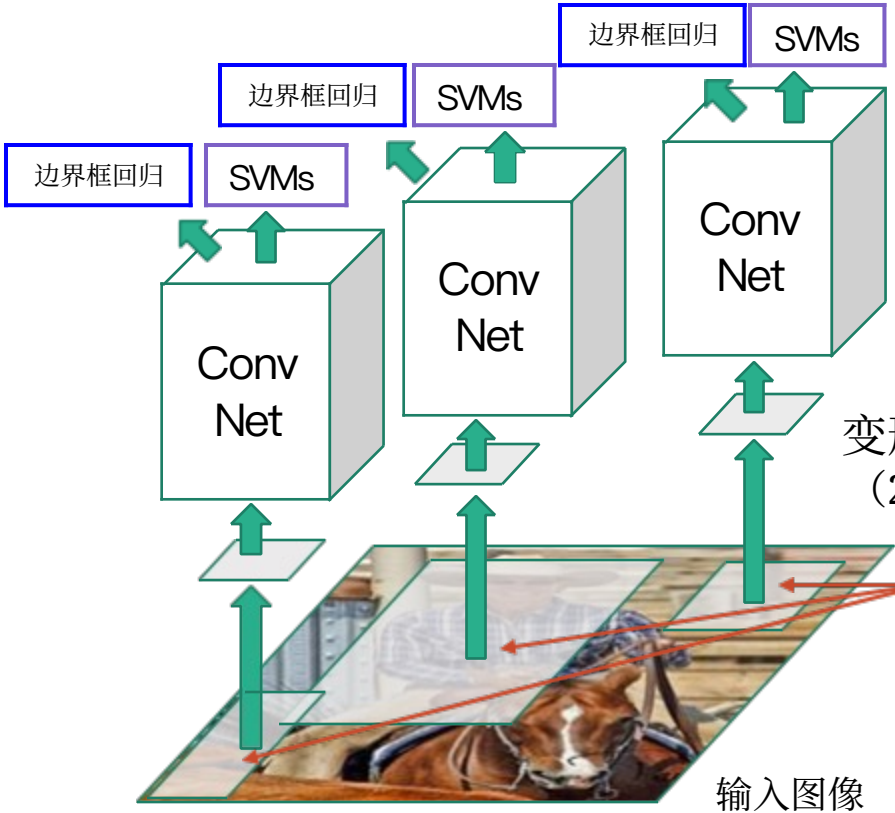
感兴趣区域
来自候选区域的 (RoI)
方法（□2k）

输入图像

Girshick 等，“用于准确目标检测和语义分割的丰富特征层次结构”，CVPR 2014。
图版权 Ross Girshick，2015；来源。经许可转载。

R-CNN

预测对 RoI 的“修正”：4 个数字：(dx, dy, dw, dh)



对区域进行分类，使用 SVMs

将每个区域前向传播通过卷积网络 (ImageNet 预训练)

变形后的图像区域（224x224 像素）

感兴趣区域（RoI）来自区域提议方法（≈2k）

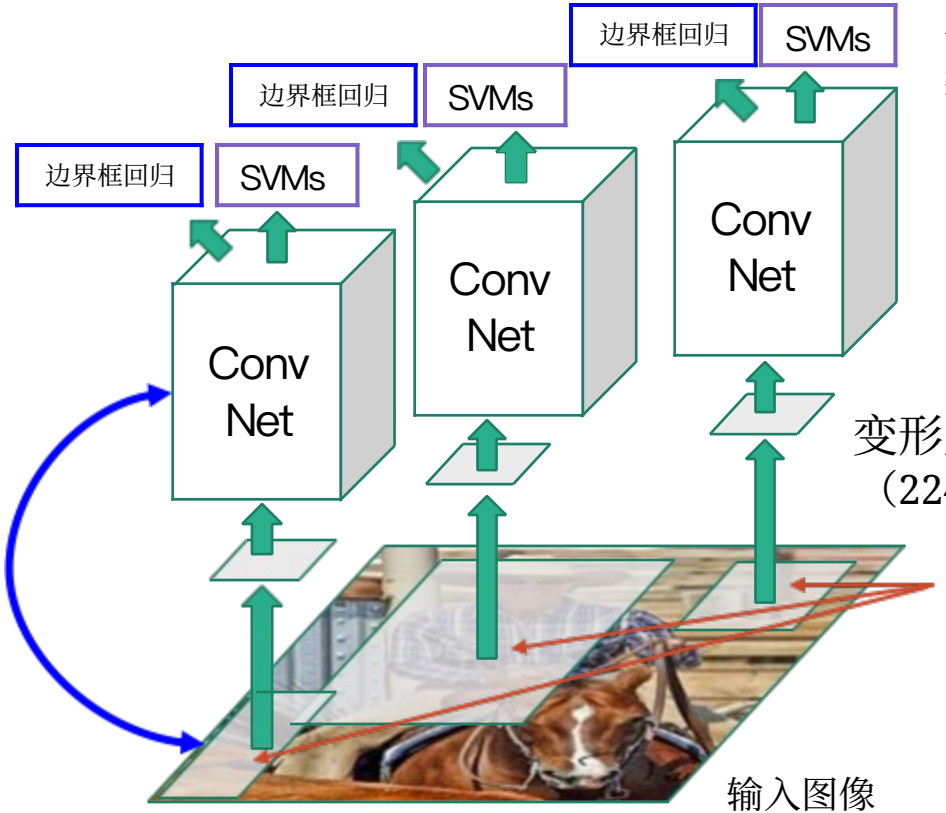
输入图像

问题：非常慢！需要对每张图像进行 ≈7 k 次独立前向 传递！

Girshick 等，“用于精确目标检测和语义分割的丰富特征层次”，CVPR 2014。图片版权 Ross Girshick，2015；来源。经许可转载。

“慢” b-Ca a

预测对 RoI 的“修正”：4 个数值：(dx, dy, dw, dh)



使用SVMs对区域进行分类

对每个区域进行前向传播通过卷积网络（经 ImageNet 预训练）

变形后的图像区域（224x224 像素）

感兴趣区域（RoI）来自区域提议方法（□2k）

输入图像

问题：非常慢！
需要执行 □7k 次

独立前向传播
每张图像都要进行多次传递！

思路：在裁剪前先让图像通过卷积网络！改为裁剪卷积特征！

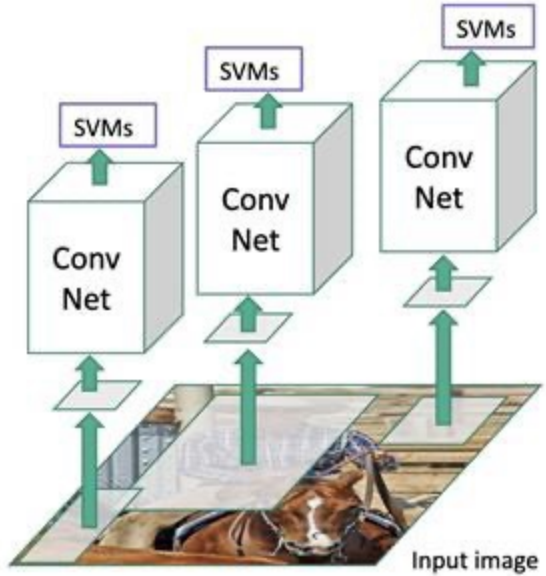
Girshick 等，“用于精确目标检测和语义分割的丰富特征层级”，CVPR 2014。图片版权 Ross Girshick，2015；来源。经许可转载。

Fast R-CNN



输入图像

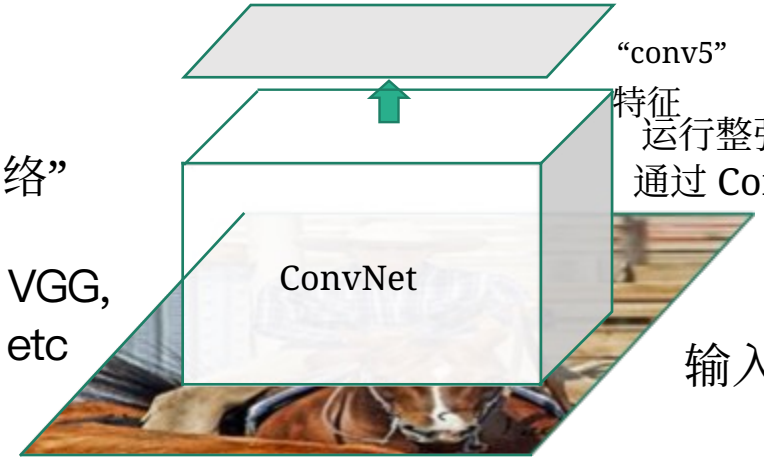
“慢速” R-CNN



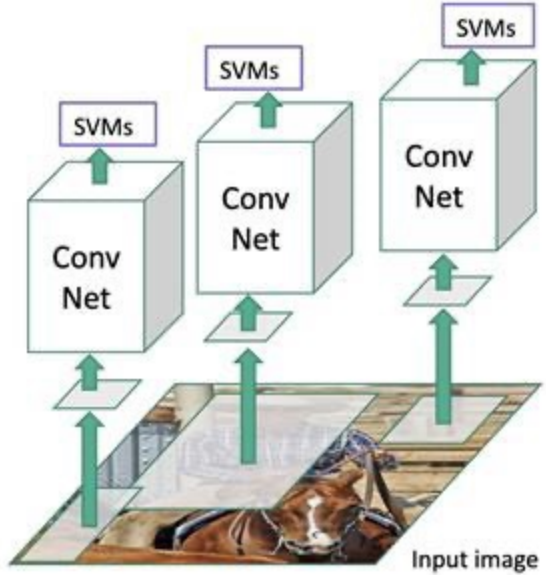
Girshick, “Fast R-CNN”. ICCV 2015。图版权 Ross Girshick，2015；来源。经许可转载

Fast R-CNN

“主干网络”
网络:
AlexNet , VGG,
ResNet , etc



“慢速” R-CNN

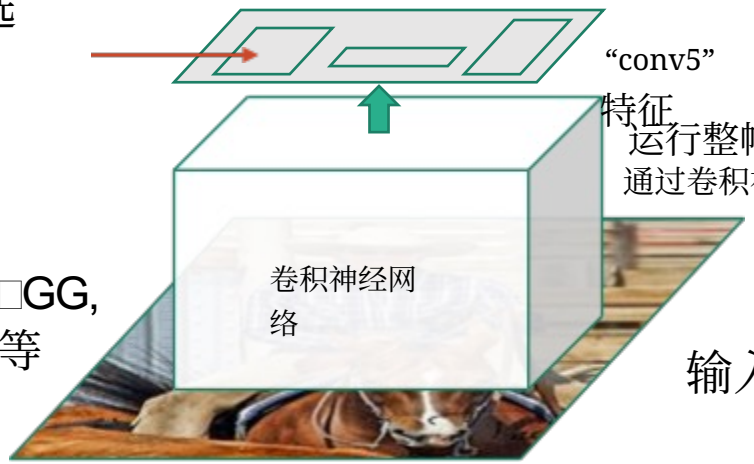


Girshick, “Fast R-CNN”, ICCV 2015。图版权 Ross Girshick，2015；来源。经许可转载.

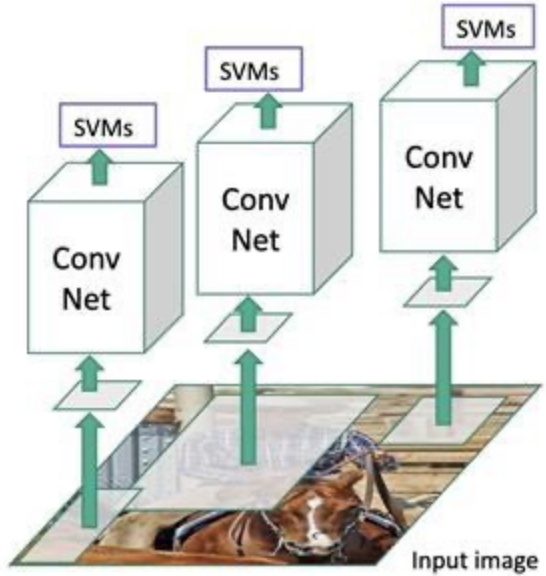
Fast R-CNN

感兴趣区域（RoIs）来自候选方法

“主干”网络：AlexNet，□GG，ResNet 等



“慢速” R-CNN

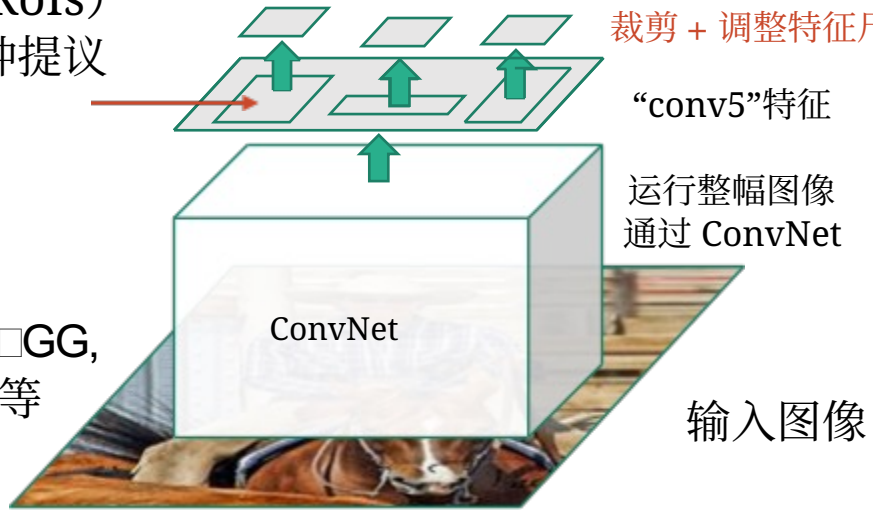


Girshick, “Fast R-CNN”, ICCV 2015。图片版权归 Ross Girshick 所有，2015； 来源。经许可转载.

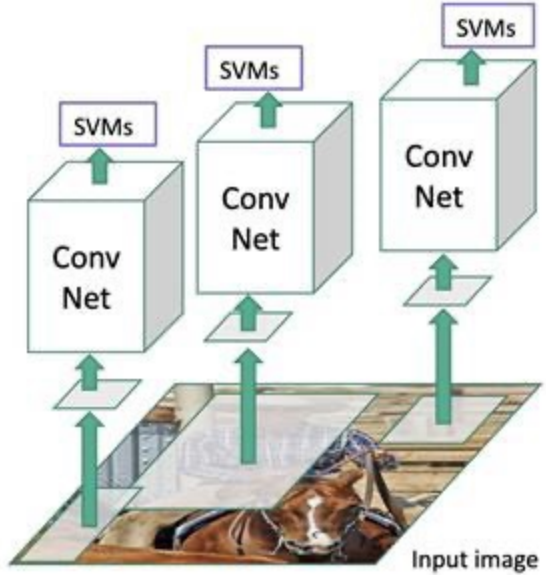
Fast R-CNN

的区域
兴趣（RoIs）
来自一种提议
方法

“主干”
网络:
AlexNet ，□GG,
ResNet 等



“慢速” R-CNN



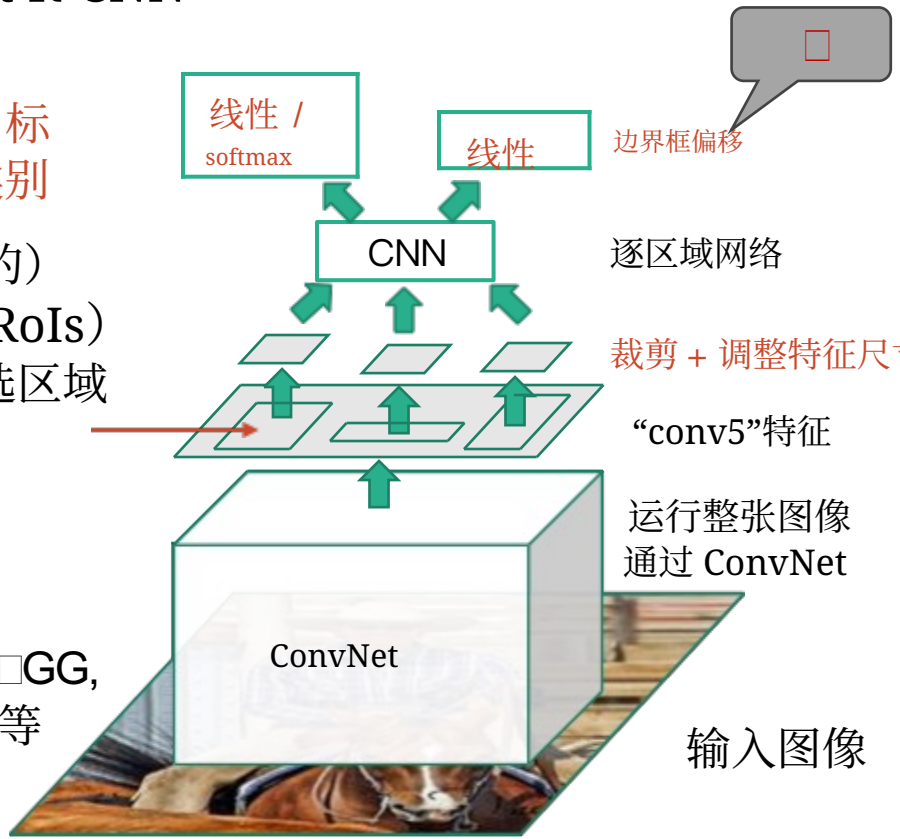
Girshick, “Fast R-CNN”, ICCV 2015。图片版权 Ross Girshick，2015；来源。经许可转载.

Fast R-CNN

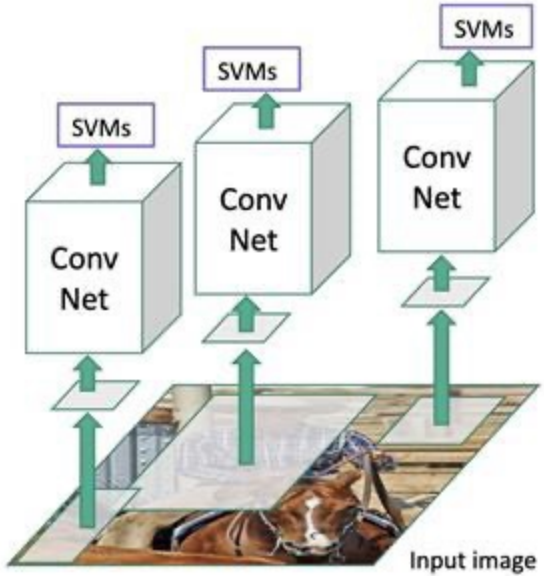
目标类别

区域（的）兴趣（RoIs）来自候选区域方法

“主干”网络：AlexNet，□GG，ResNet 等



“慢速” R-CNN



Girshick, “Fast R-CNN”，ICCV 2015。图版权归 Ross Girshick 所有，2015；来源。经许可转载.

Fast R-CNN

Fast 的局限性

R-CNN?

目标
类别

线性 / softmax

线性

边界框偏移

CNN

逐区域网络

区域
兴趣（RoIs）
来自候选区域
方法

裁剪 + 调整特征尺寸

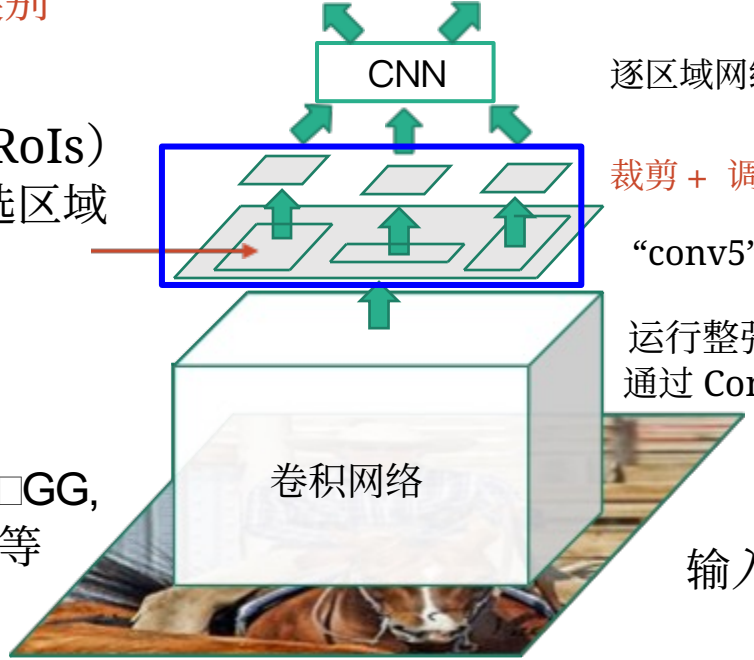
“conv5”特征

运行整张图像
通过 ConvNet

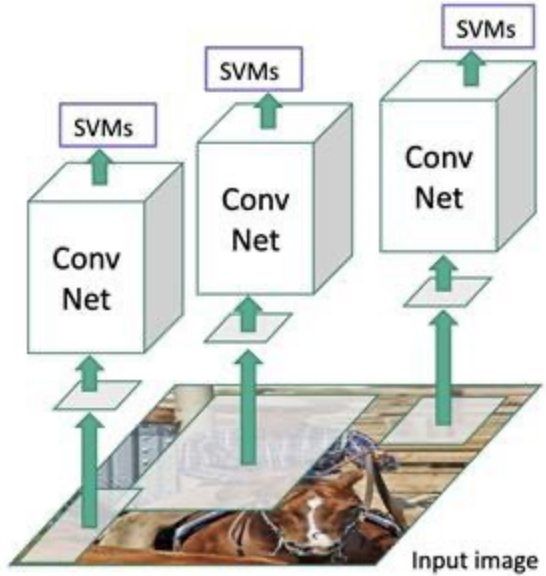
“骨干”
网络：
AlexNet ，□GG,
ResNet 等

卷积网络

输入图像



“慢速” R-CNN





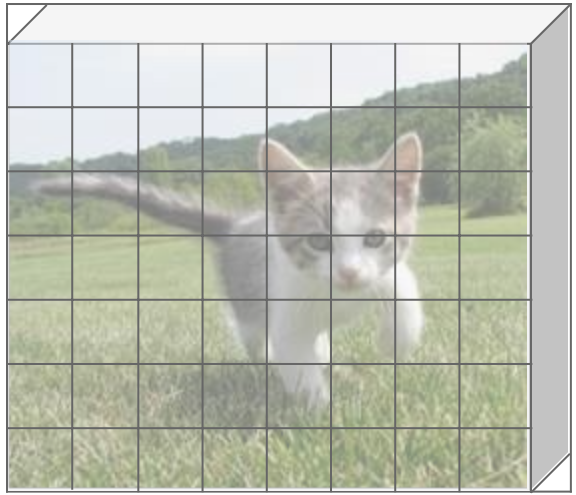
Girshick, “Fast R-CNN”, ICCV 2015。图片版权 Ross Girshick，2015；来源。经许可转载.

区域提议网络



输入图像（例如 3 x 640 x 480）

CNN



图像

特征

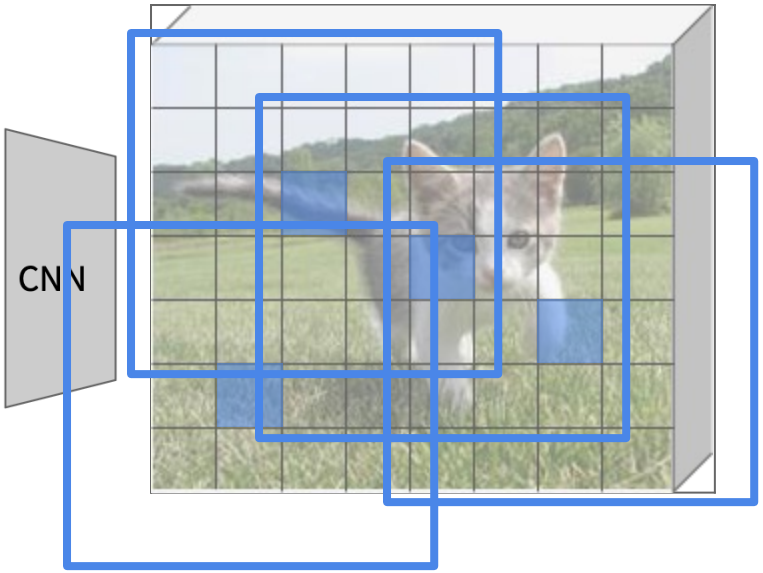
（例如 512 x 64 x 5: ）

区域提议网络

想象特征图中的每个点
处都有一个固定大小的锚框



输入图像
（例如 3 x 640 x 480）



特征

图像

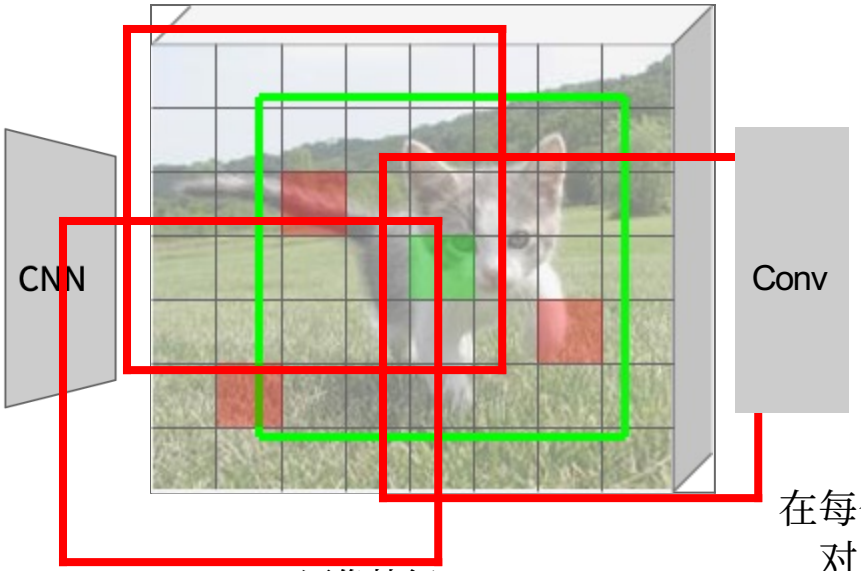
（例如 512 x 20 x 15）

区域提议网络

想象在特征图的每个点上都有一个固定大小的锚框



输入图像
（例如 3 x 640 x 480）



图像特征
（例如 512 x 20 x 15）

锚框是一个目标吗?
1 x 20 x 15

在每个点处，预测是否对应的锚框包含一个对象（二值分类）

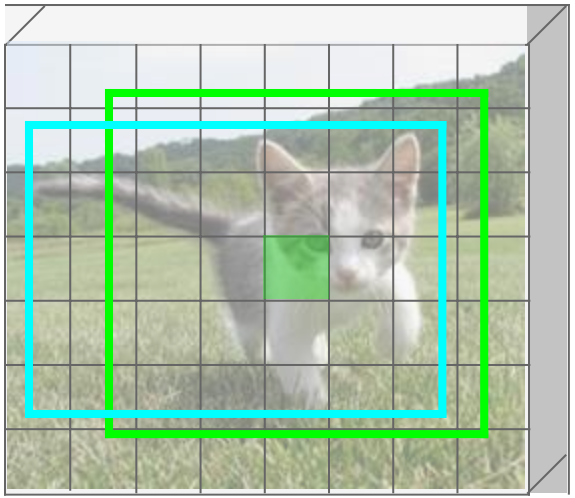
区域提议网络

想象在特征图的每个点
上都有一个固定大小的锚框



输入图像（例
如 3 x 640 x 480）

CNN



图像特征（例
如 512 x 20 x 15）

Conv

锚框是一个对象吗?
1 x 20 x 15

边界框修正
4 x 20 x 15
$(w_{x1}, w_{y1}, w_x, w_h)$

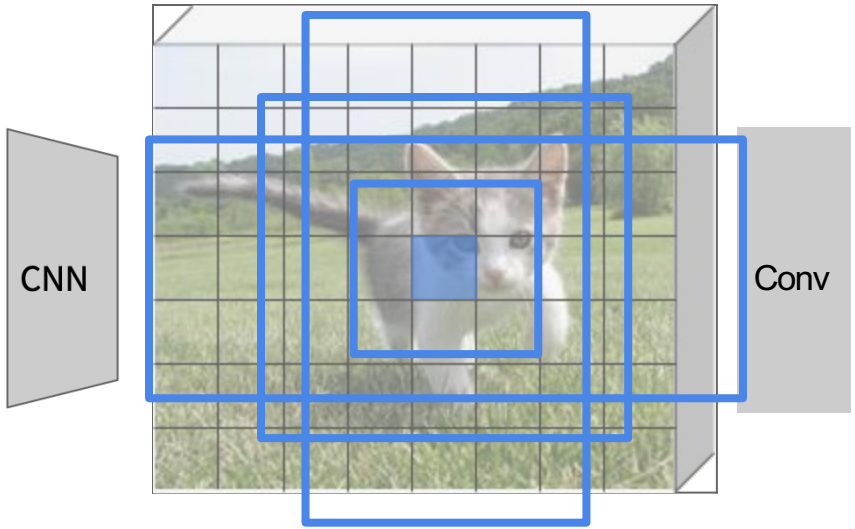
对于正样本框，还要预测从锚框到真实框的修正量（每个像素回归4个数值）

区域提议网络

在实践中，在每个点使用
K 个不同大小/尺度的锚框



输入图像（例
如 3 x 640 x 480）



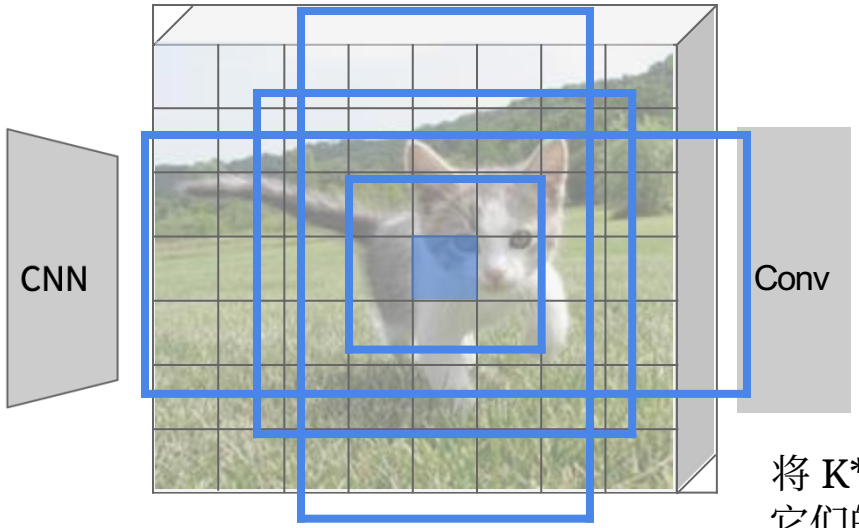
图像特征（例
如 512 x 20 x 15）

区域候选网络

在实践中，在每个点使用
K 个不同大小/尺度的锚框



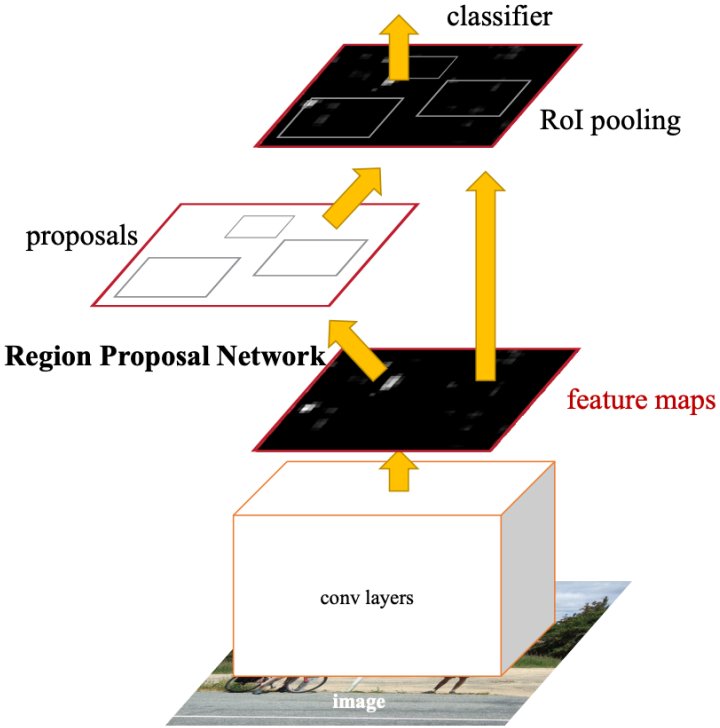
输入图像（例
如 3 x 640 x 480）



图像特征
（例如 512 x 20 x 15）

将 K*20*15 个框按
它们的“对象性”分数，取
前 □OGG 个作为我们的候选区域

Faster R-CNN

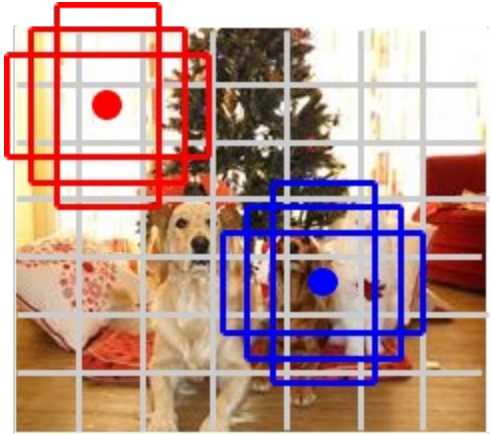


- **核心创新：“共享卷积特征”**
- **问题：**先前的方法（Fast R-CNN）依赖于外部的、缓慢的 候选区域生成方法（Selective Search），这些方法在 CPU 上运行。
- **解决方案：**集成一个 **区域提议网络（RPN）**，它与 **Fast R-CNN 检测器**共享相同的主干特征。
- **结果：** 生成候选框的成本几乎为 **零** （每张图像约 10ms）。

单阶段目标检测器：YOLO / SSD / RetinaNet



输入图像 3
x H x W



将图像划分为 7 x 7 的网格

一组以每个网格单元为中心的基准框，此处 B N3

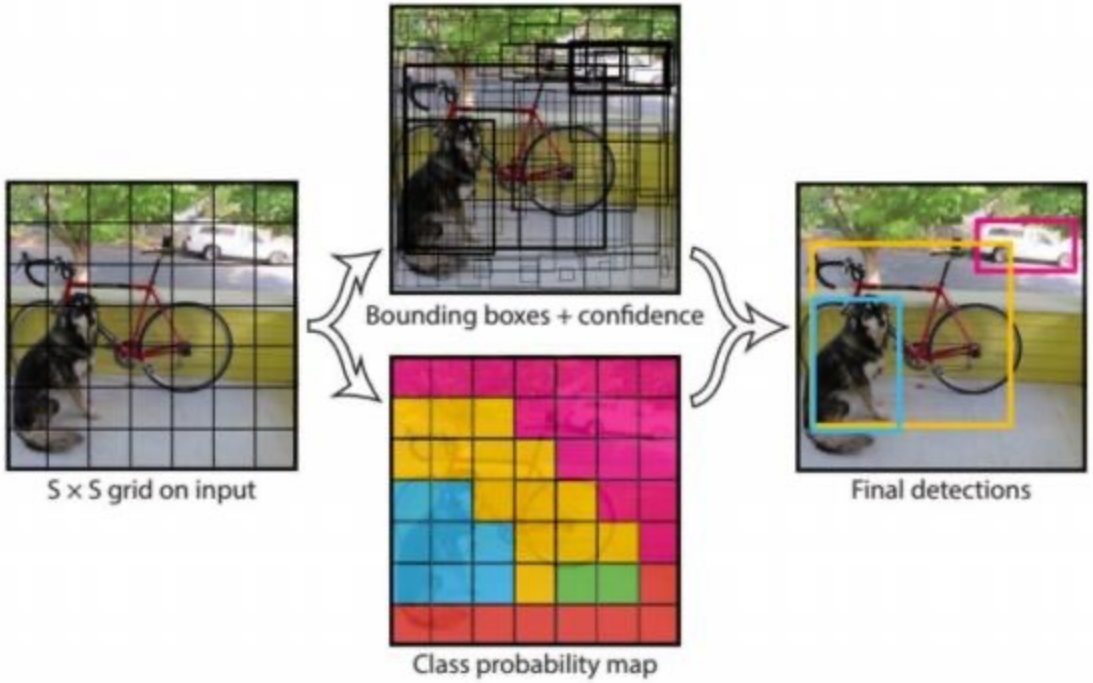
在每个网格单元内：

- C 从 B 个中的每一个回归基础框到一个最终框，该框具有 5 个数字：(dx, dy, dh, dw, confidence)
- C 为 C 个中的每一个预测分数类别（包括背景作为一个类别）
- C 看起来很像 RPN ，but 特定类别！

输出：7 x 7 x (5 * B 3 C)

Redmon 等，“你只看一次：统一的实时目标检测”，CVPR 2016 Liu 等，“SSD：单次多框检测器”，ECCV 2016 Lin 等，“用于密集目标检测的焦点损失”，ICCV2017

k e Ye (k □□ e □□Y□□□ e □no)实时目标检测



Redmon 等，“You only look once：统一的实时目标检测（2015）。”

YOLO



SxS 网格



Redmon 等，“You only look once: unified, real-time object detection (2015).”

YOLO



□x□
n rid

对每个框输出：

- P(object)：框包含对象的概率
- B 个边界框（x, y, h, w）
- P(class)：属于某一类别的概率

Redmon 等，“You only look once：统一的实时目标检测（2015）。”

YOLO



□x□
n rid

对于每个框的输出：

- P(object)：框包含物体的概率
- B 边界框 (x, y, h, w)
- P(class)：属于某一类别的概率

PL=

Redmon 等，“You only look once：统一的实时目标检测（2015）。”

YOLO



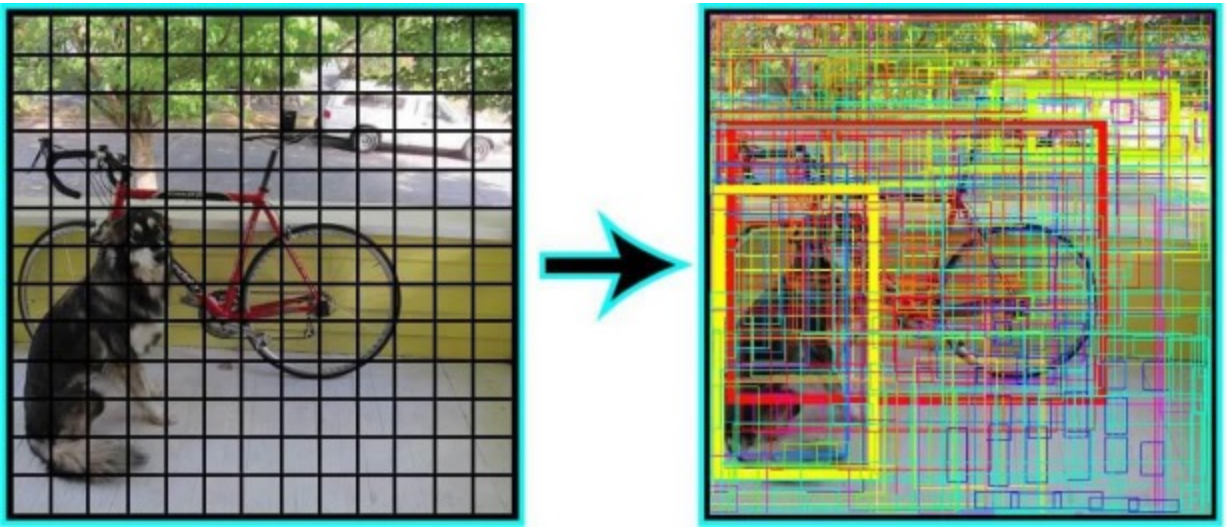
□x□
n rid

对于每个框的输出：

- P(object)：框包含物体的概率
- B 边界框 (x, y, h, w)
- P(class)：属于某一类别的概率

PL=

YOLO



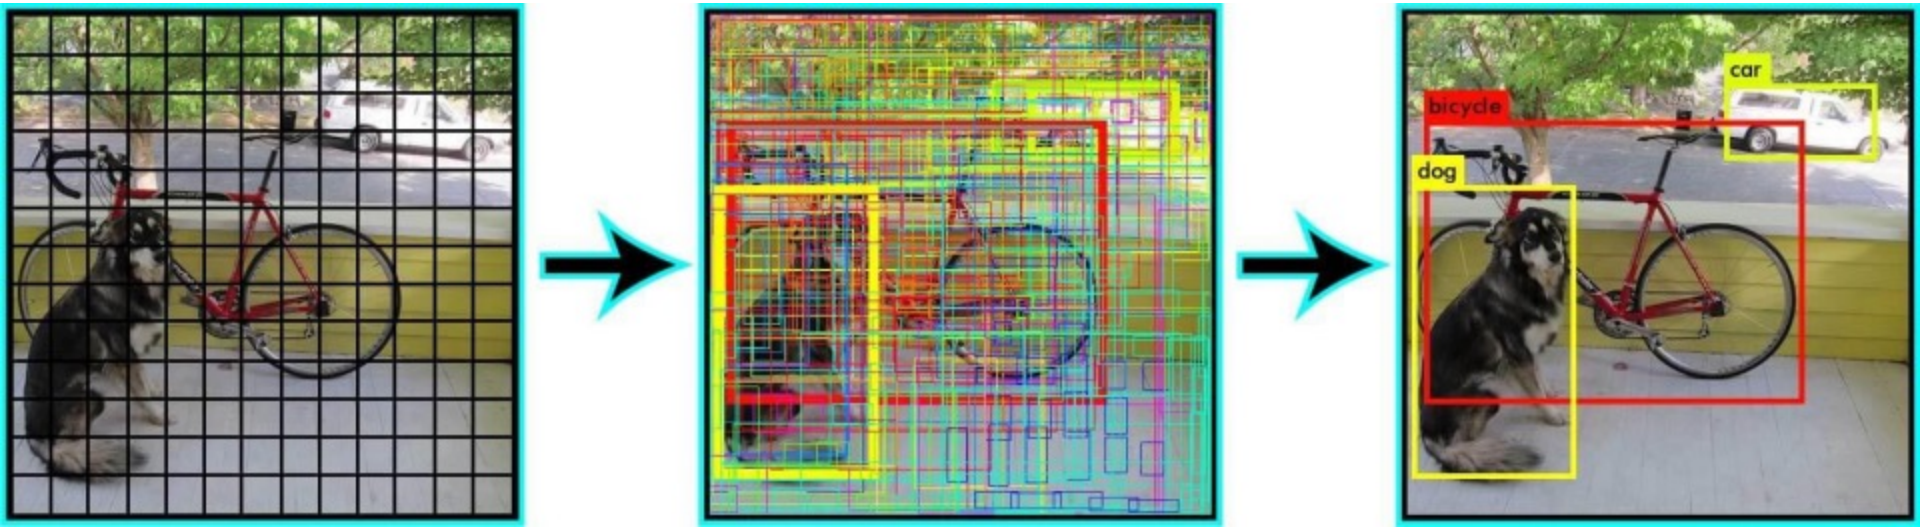
SxS 网格

许多具有不同目标概率的边界框



Redmon 等，“You only look once：统一的实时目标检测（2015）。”

YOLO



SxS 网格

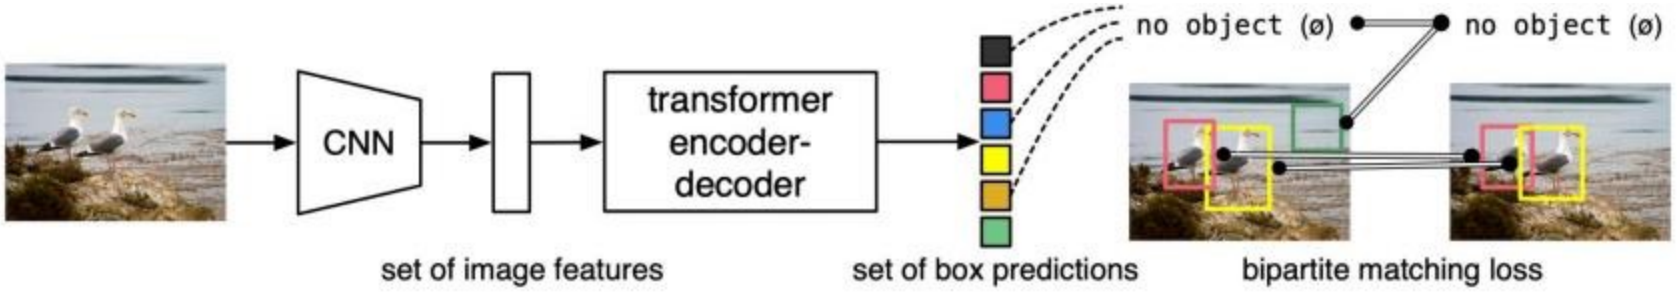
Redmon 等，“You only look once：统一的实时目标检测（2015）。”

基于 Transformer 的目标检测：DETR

简单的目标检测流程：直接从 Transformer 输出一组边界框

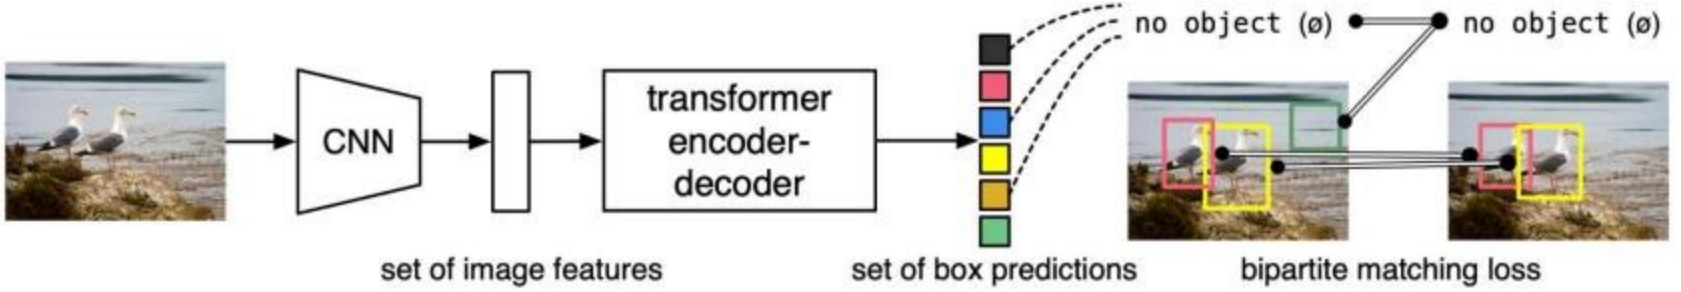
无锚框，无边界框变换回归

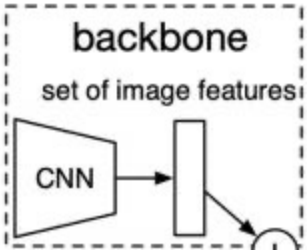
通过二分匹配将预测边界框与 GT 边界框匹配；训练以回归边界框坐标



Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

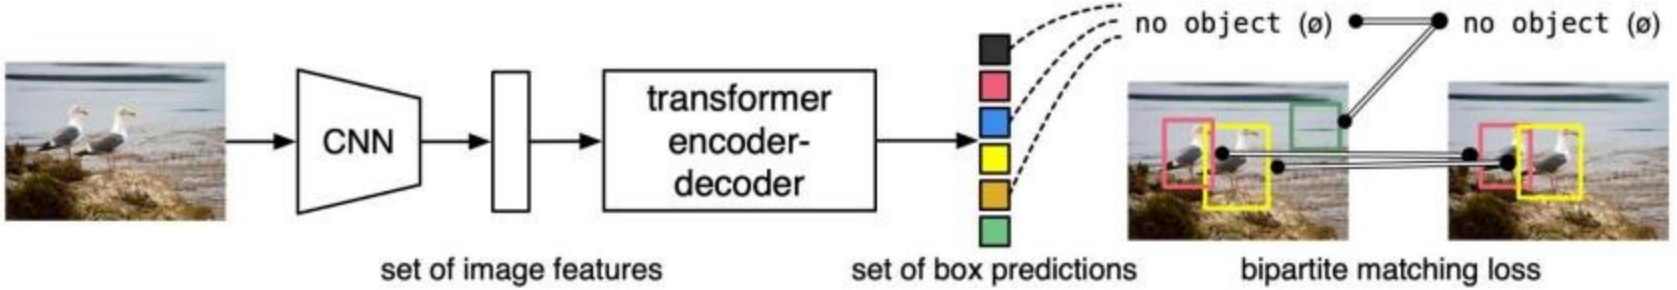
使用 Transformer 的目标检测：DETR

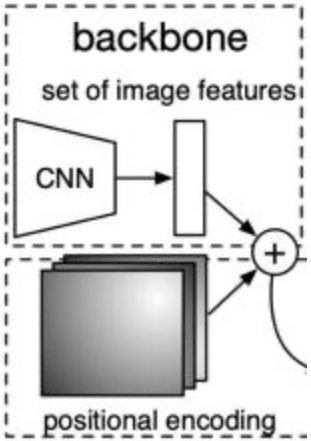




Carion 等人，“使用 Transformer 的端到端目标检测”，ECCV 2020

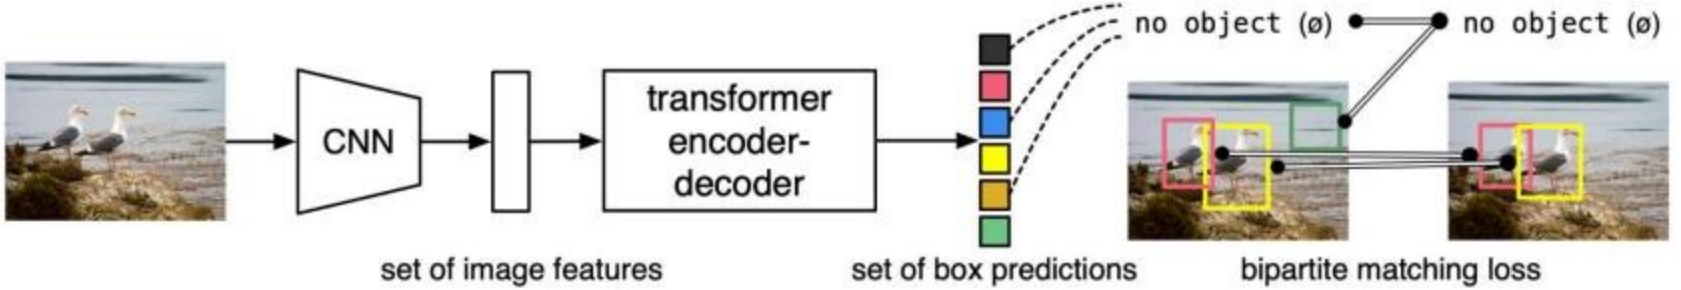
基于 Transformer 的目标检测：DETR

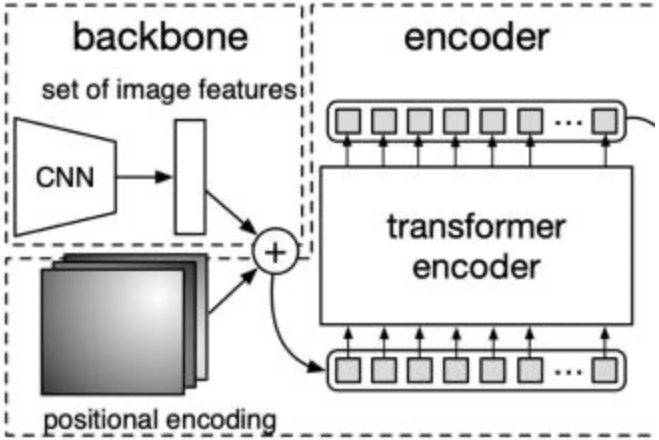




Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

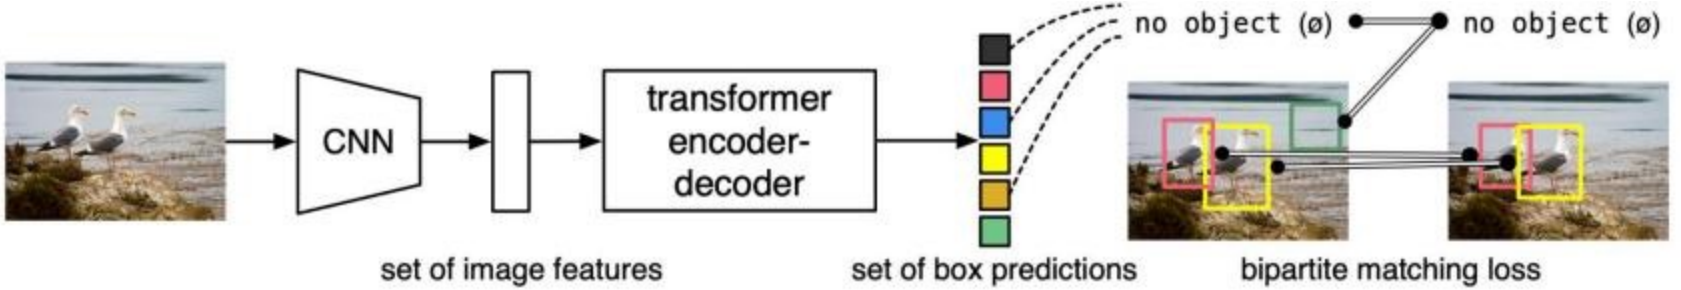
基于 Transformer 的目标检测：DETR

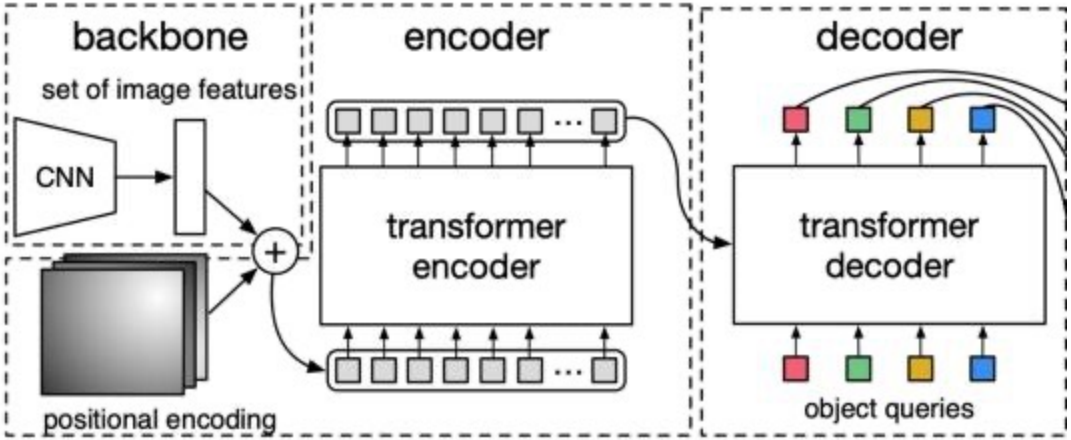




Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

使用 Transformer 的目标检测：DETR

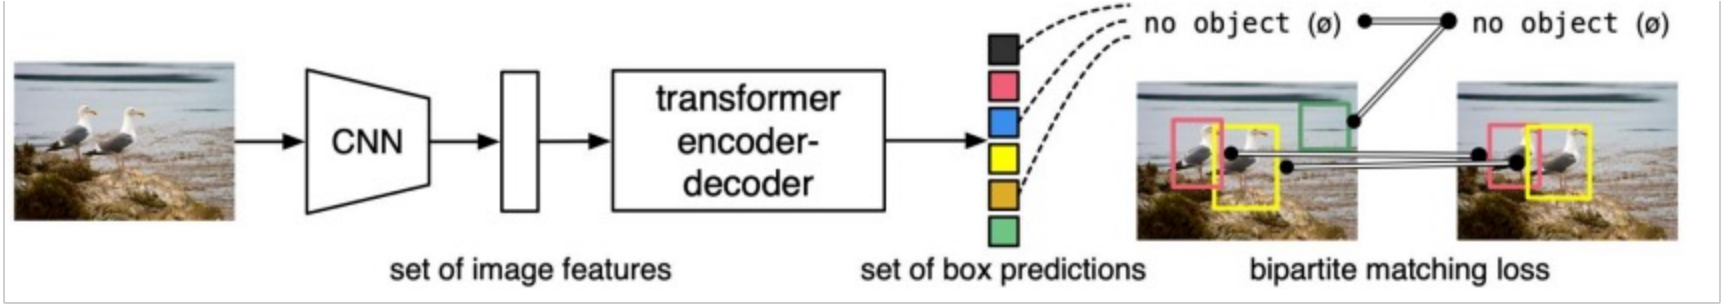


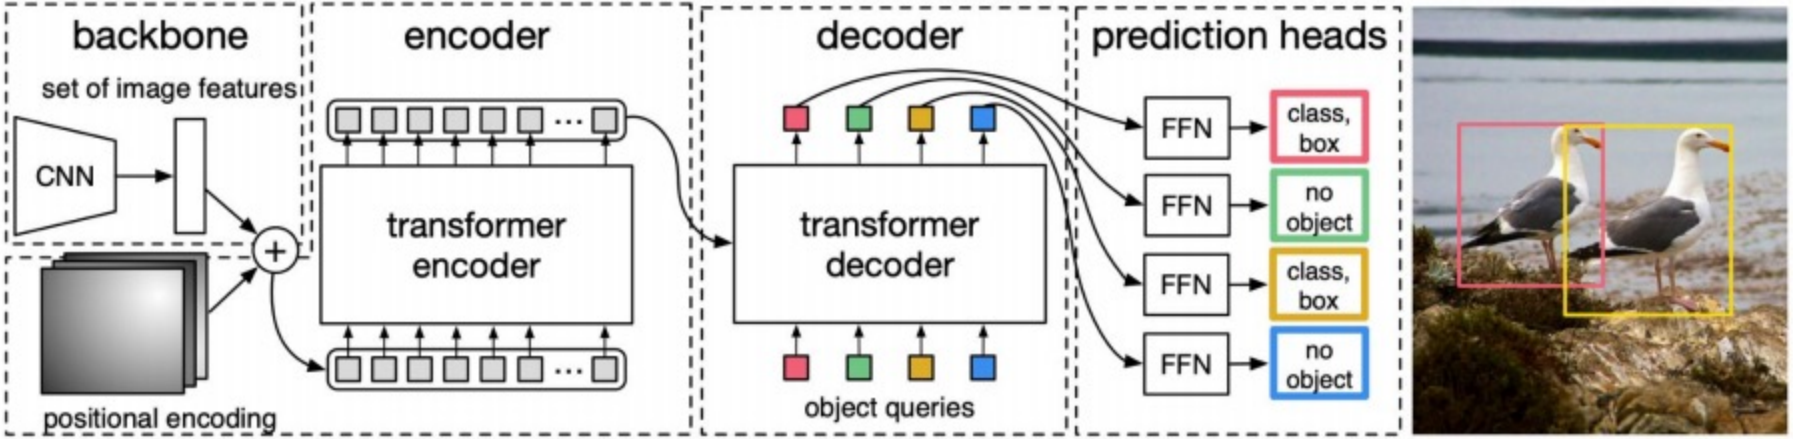


Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

基于 Transformer 的目标检测：DETR

集合预测 □
匈牙利匹配





Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

为什么选择
DETR?

先前方法：

Ø 复杂设计（锚框、IoU 阈值、NMS） Ø 大量工程化组件 Ø 重复预测 → 需要后处理 Ø 有限的全局推理（大多为局部感受野）

DETR：

- 将检测重新表述为集合预测：CNN 骨干网络 → Transformer → 对象查询
- 关键特性：Ø 无锚框 Ø 无 NMS Ø 端到端训练



Carion 等人，“End-to-End Object Detection with Transformers”，ECCV 2020

今日

- **计算机视觉任务**
  - 语义分割
  - 目标检测
  - **实例分割**

- 可视化与理解
  - 模型层可视化
  - 显著性图
  - CAM & Grad-CAM

- 基础模型与提示分割



实例分割

分类

CAT

无空间范围

语义分割

草地 , CAT,
树, SKY

没有对象，只有像素

对象
检测

DOG, DOG, CAT

实例分割

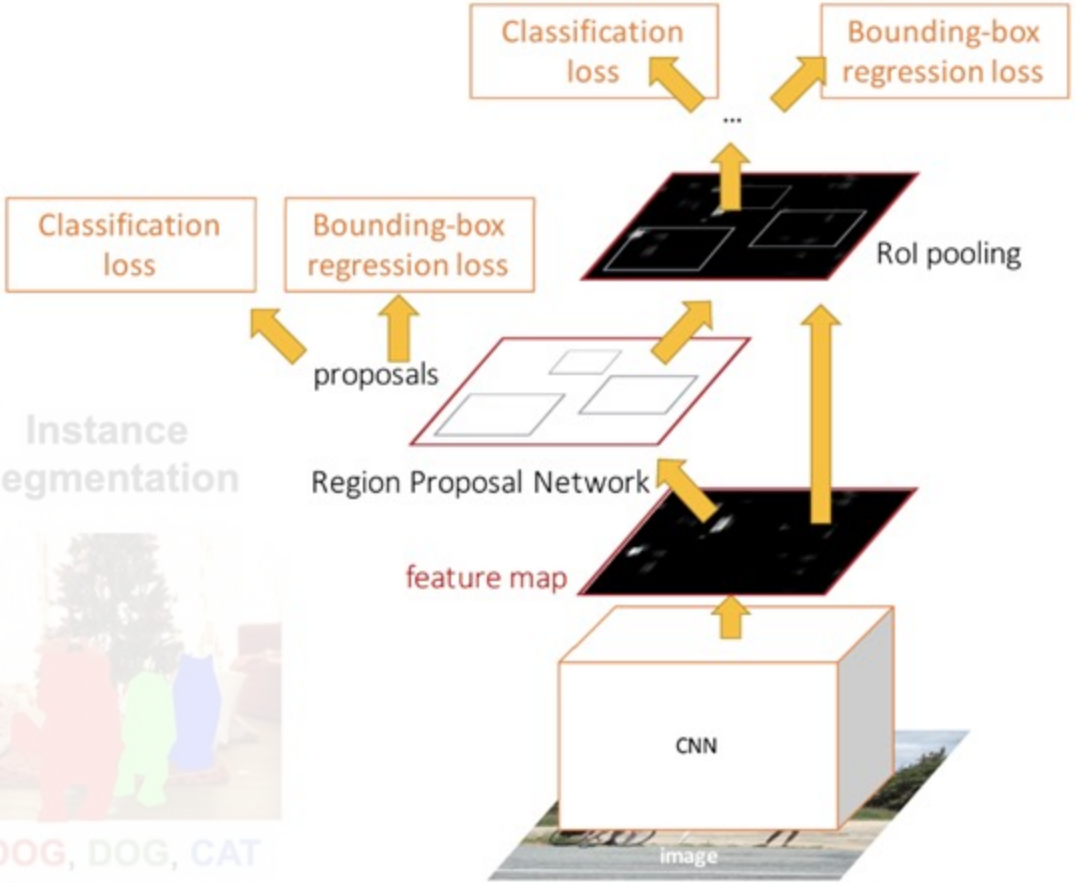


DOG, DOG, CAT

多对象

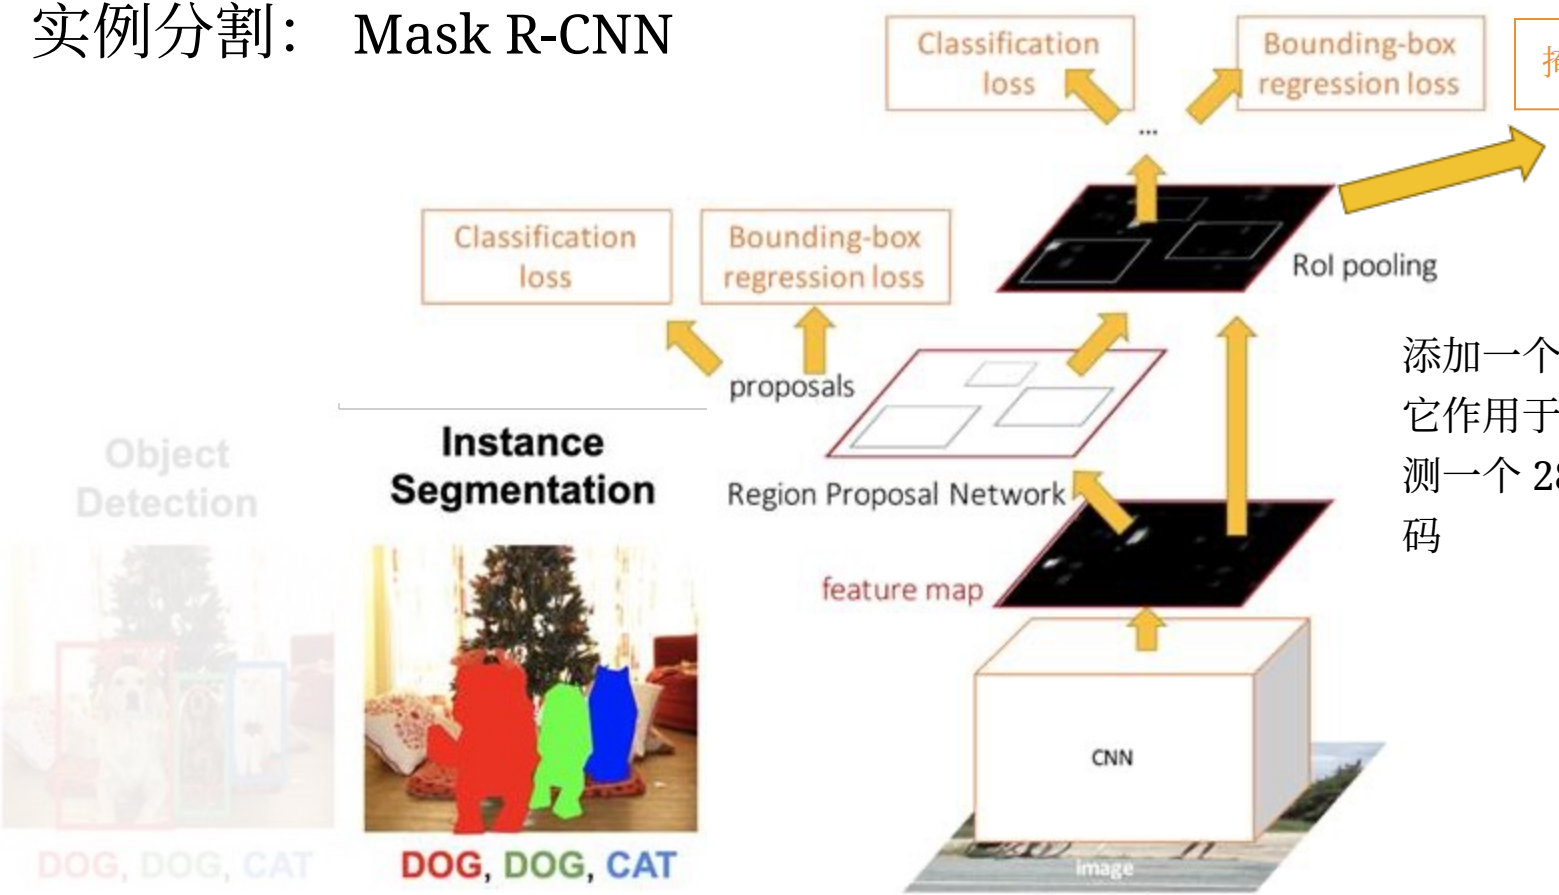
目标检测：

Faster R-CNN





实例分割： Mask R-CNN



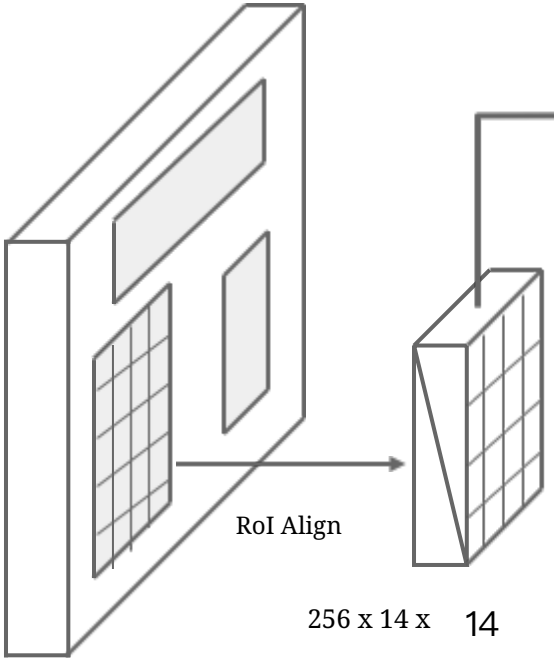
添加一个小型掩码网络，它作用于每个 RoI 并预测一个 28x28 二值掩码

He 等人，“Mask R-CNN”，ICCV 2017

Mask R-CNN



CNN
+RPN

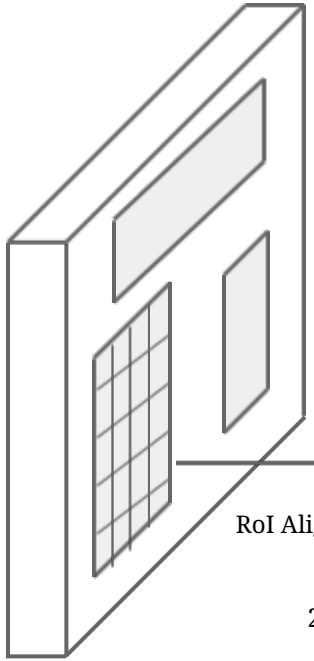


分类得分：C 边界框坐标（每类）：
4 * C

Mask R-CNN



CNN
+RPN



RoI Align

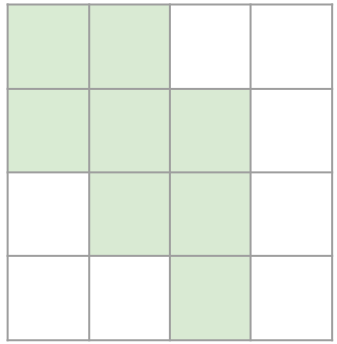
256 x 14 x 14

分类得分：C
边界框坐标（每类）：4 * C

Conv

256 x 14 x 14

Conv



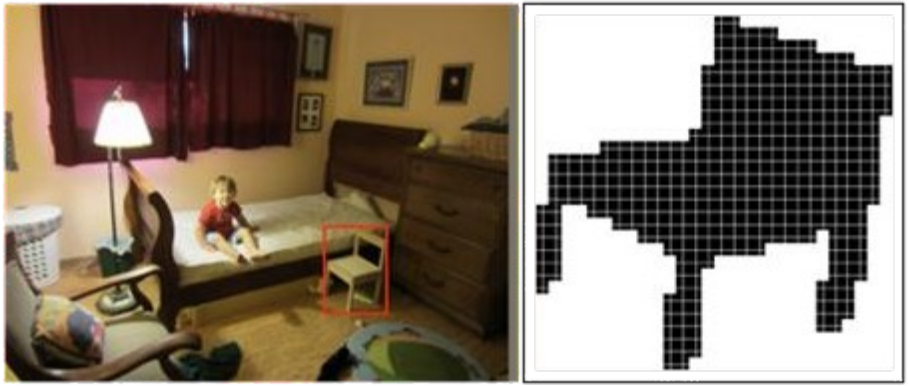
预测一个掩码，用于
C 个类别中的每一类

Cx 28 x 28

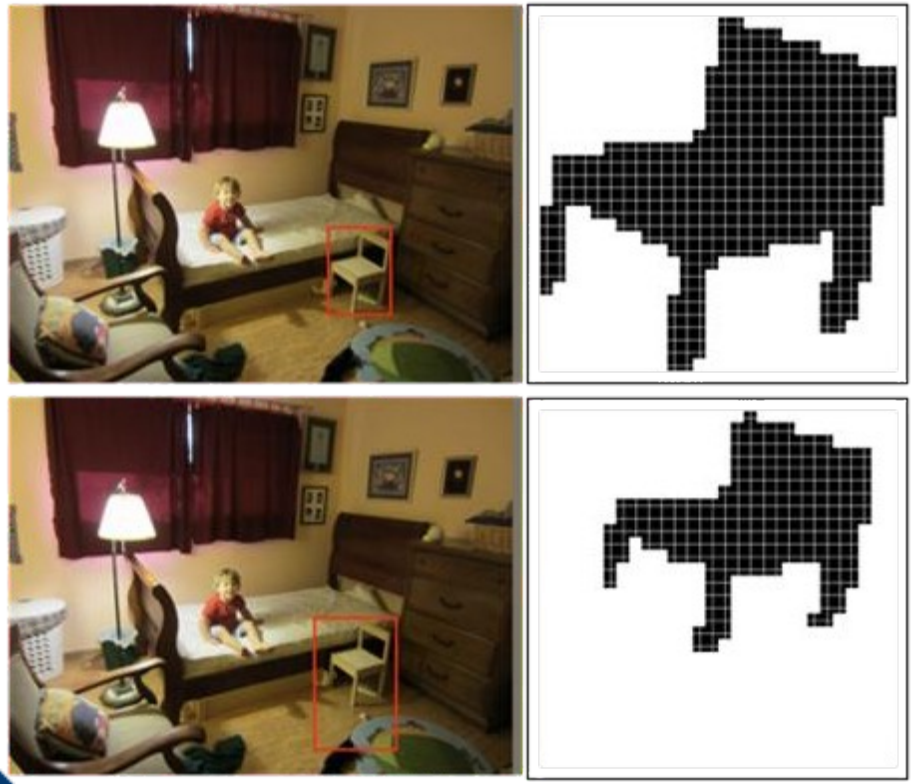


He 等人，“Mask R-CNN”，ICCV 2017

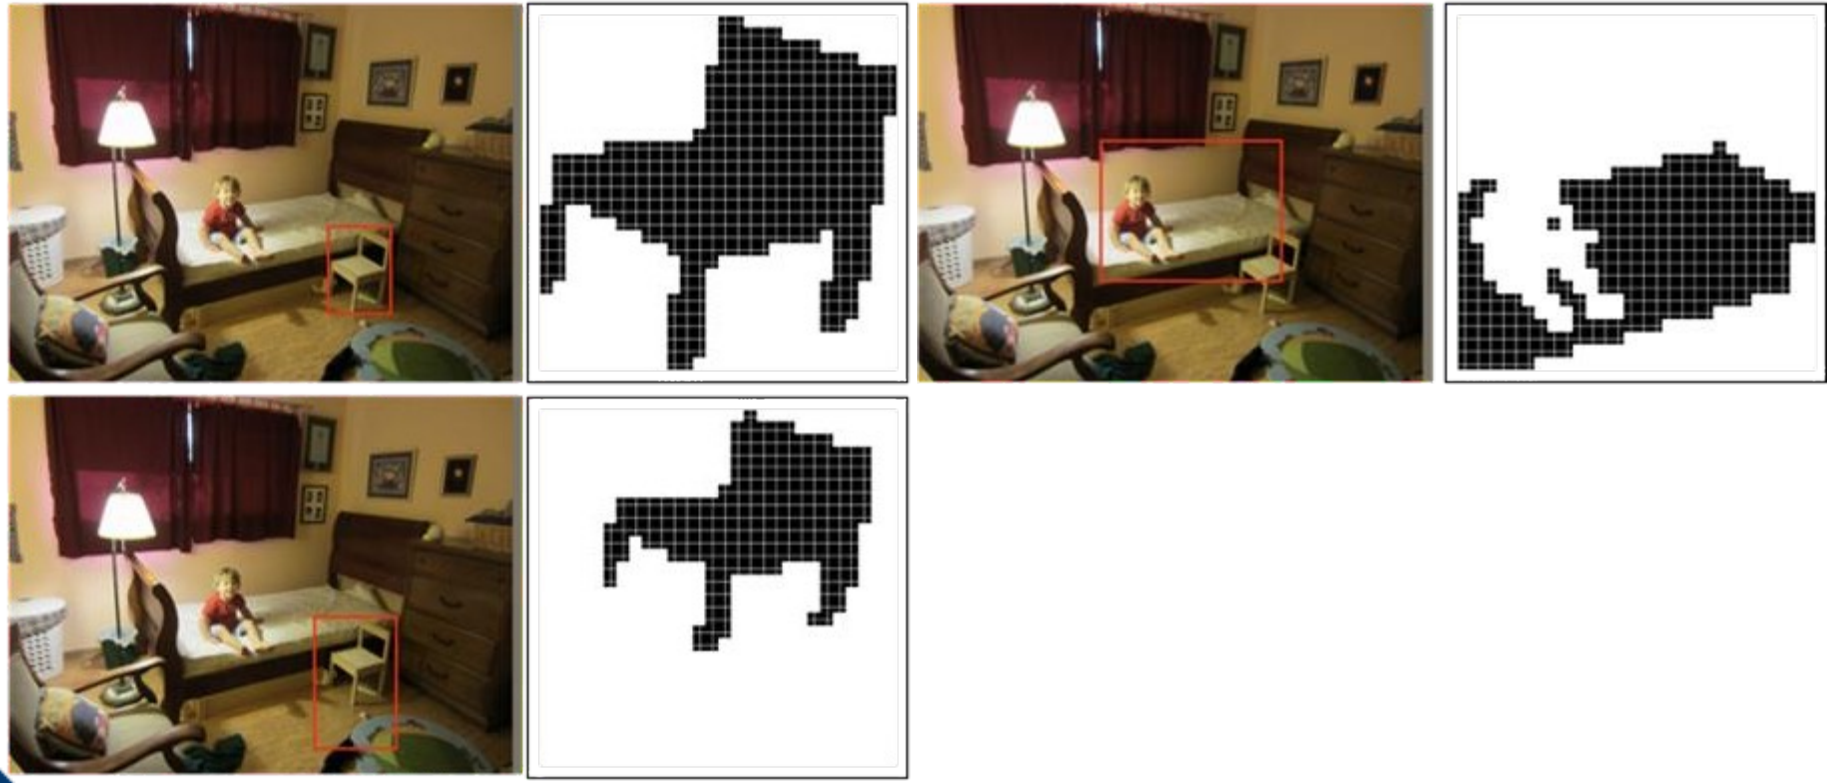
Mask R-CNN：掩码训练目标示例



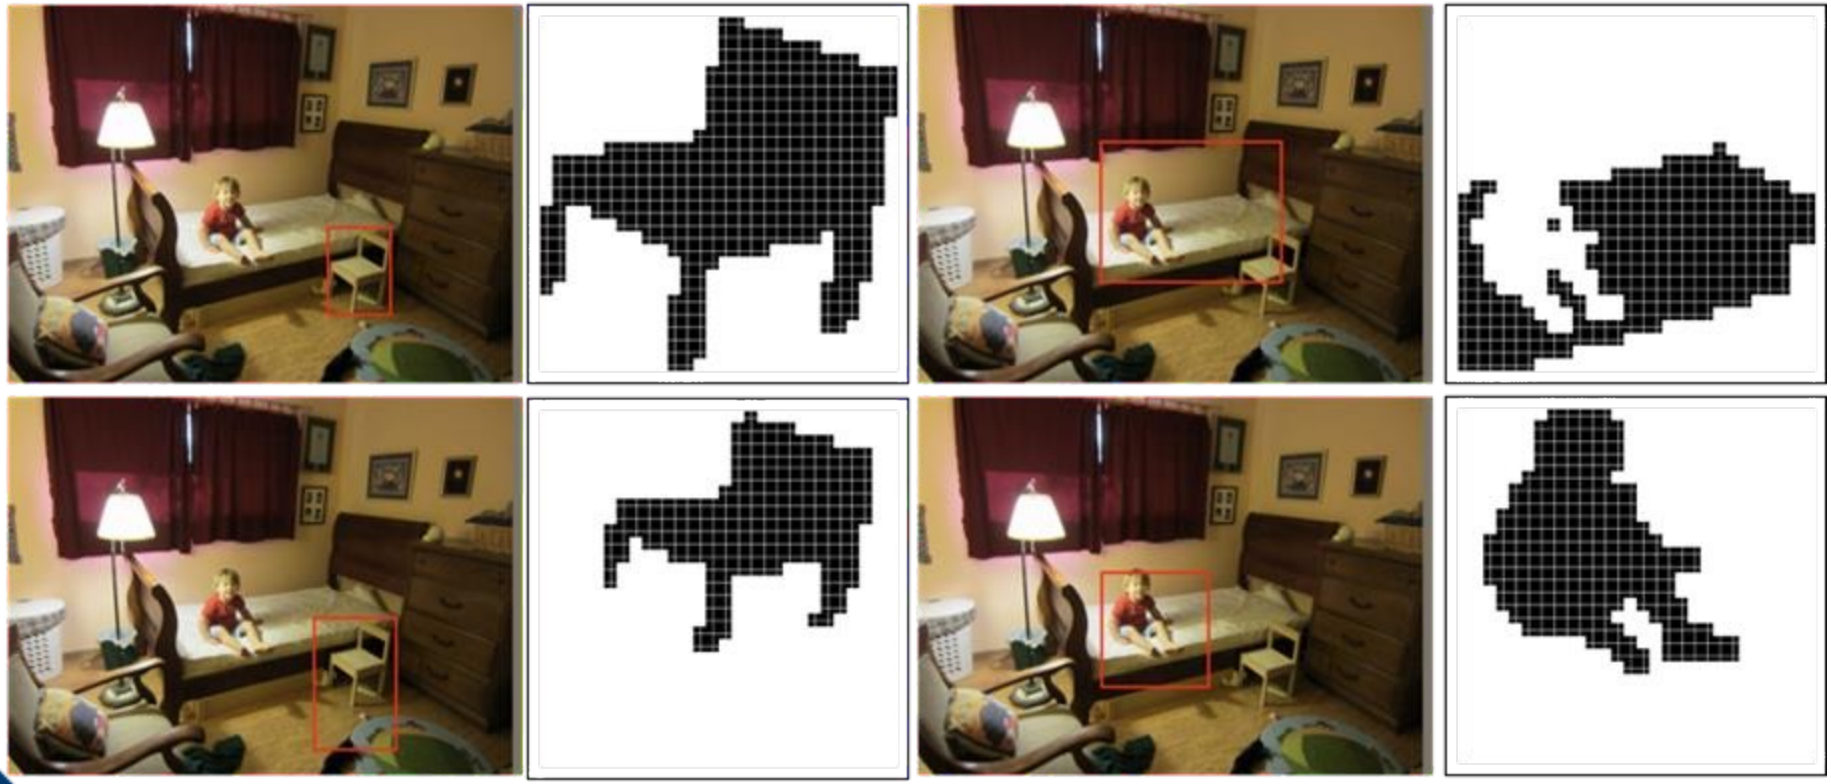
Mask R-CNN：掩码训练目标示例



Mask R-CNN：掩码训练目标示例

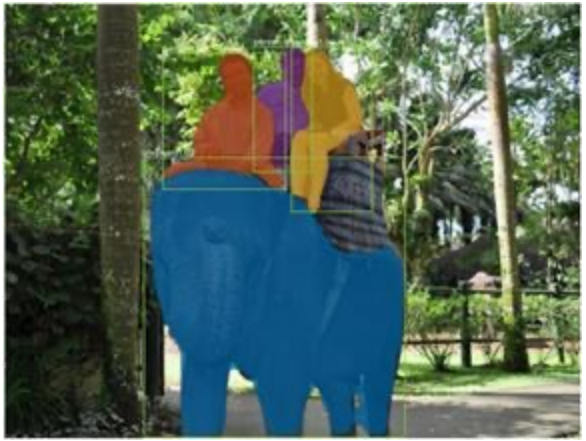


Mask R-CNN：掩码训练目标示例



Mask R-CNN：非常好的结果！



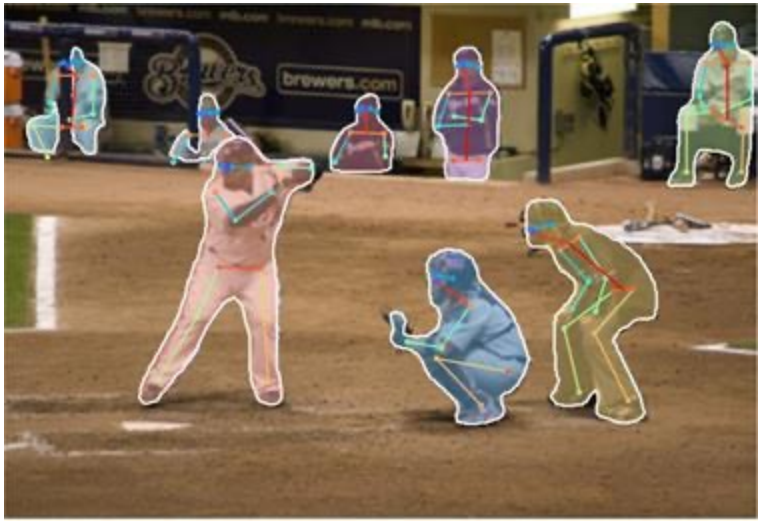




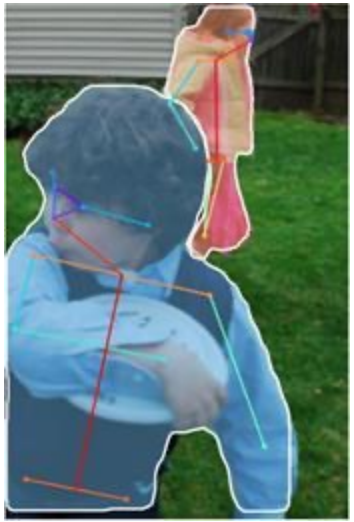


He et al, “Mask R-CNN”, ICCV 2017

Rk□y b-Caa还可进行姿态估计







回顾：许多计算机视觉任务！

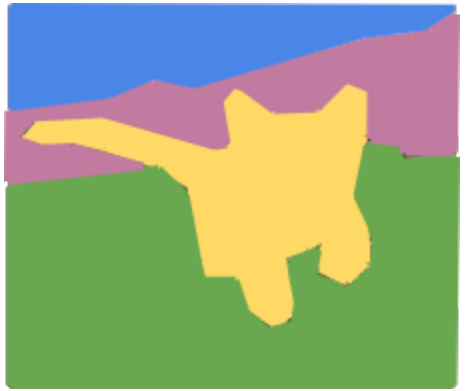
分类



CAT

无空间范围

语义分割



草地、猫、树，
S□□

没有物体，只有像素

目标检测



DOG, DOG, CAT

实例分割



狗、狗、猫

多个物体

此图像 是CC0 公有领域

今天

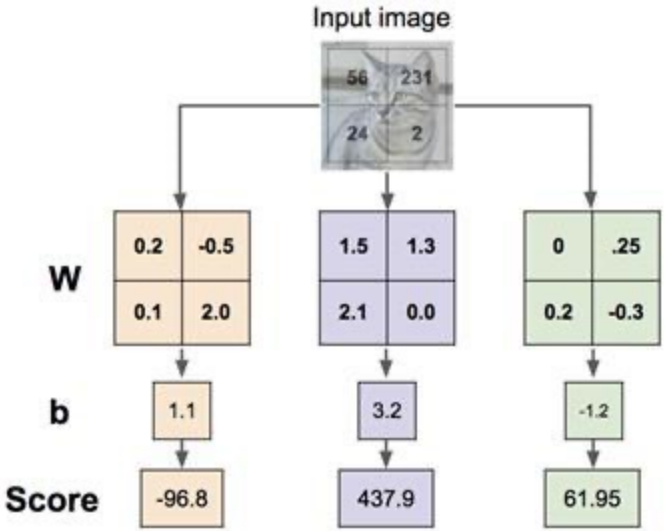
- 计算机视觉任务
  - 语义分割
  - 目标检测
  - 实例分割

- **可视化与理解**
  - **模型层可视化**
    - 显著性图
    - CAM 与 Grad-CAM



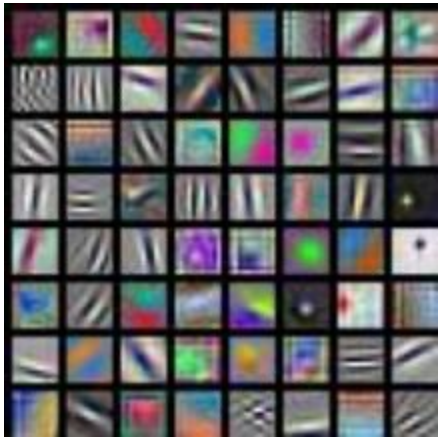
解读线性分类器：视觉视角



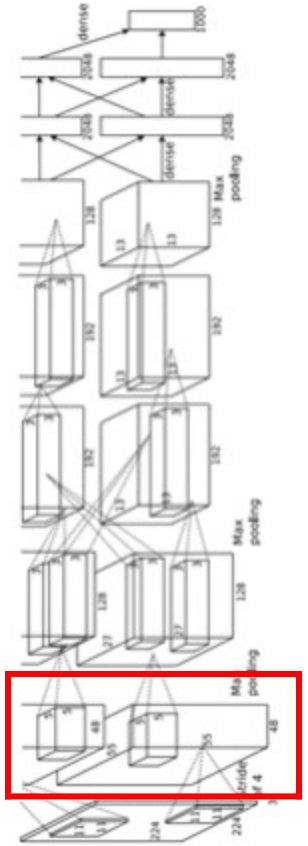




第一层：可视化滤波器

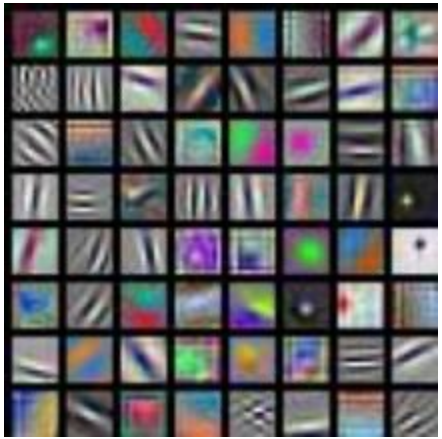


AlexNet：
64 x 3 x 11 x 11



Krizhevsky，“并行化卷积神经网络的一种奇特技巧”，arXiv 2014 He 等，“用于图像识别的深度残差学习”，CVPR 2016 Huang 等，“密集连接卷积网络”，CVPR 2017

第一层：可视化滤波器



AlexNet:
64 x 3 x 11 x 11



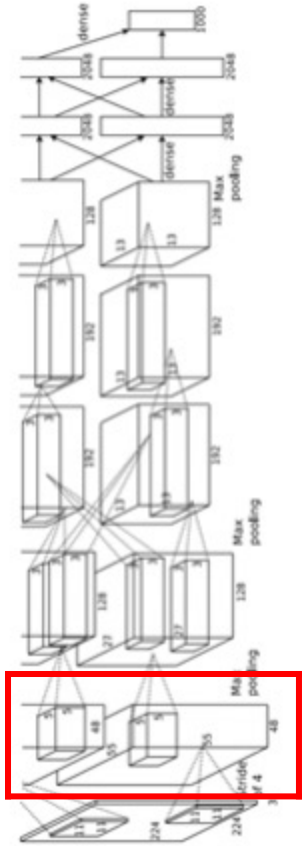
esNet15C:64
x 3 x 7 x 7



esNet1545:64
x 3 x 7 x 7



DenseNet-121:
64 x 3 x 7 x 7



Krizhevsky，“一种用于并行化卷积神经网络的奇特技巧”，arXiv 2014 He 等人，“用于图像识别的深度残差学习”，CVPR 2016 Huang 等人，“密集连接卷积网络”，CVPR 2017

今天

- 计算机视觉任务
  - 语义分割 - 目标检测 - 实例分割

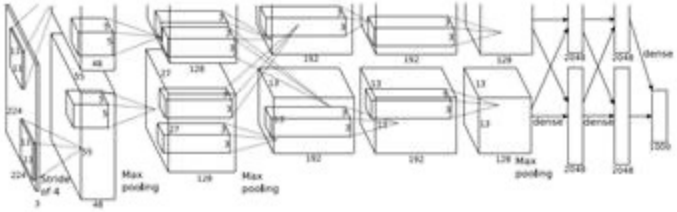
- **可视化与理解**
  - 模型层可视化 - **显著性图** - CAM & Grad-CAM

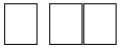


哪些像素重要：通过反向传播的显著性

前向传播：计算概率





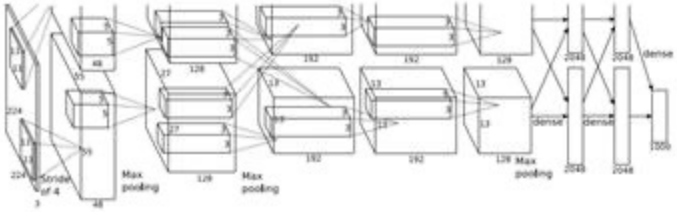


Simonyan, Vedaldi, and Zisserman, “Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps”, ICLR Workshop 2014. 图片版权归 Karen Simonyan、Andrea Vedaldi 和 Andrew Zisserman 所有，2014；经许可转载。

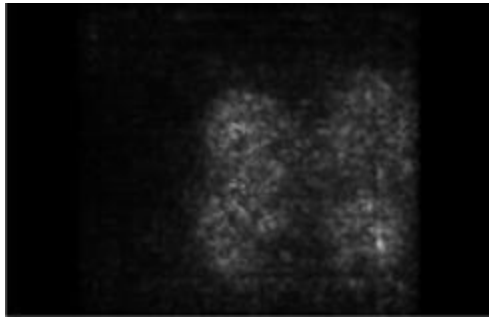
哪些像素重要：通过反向传播的显著性

前向传播：计算概率



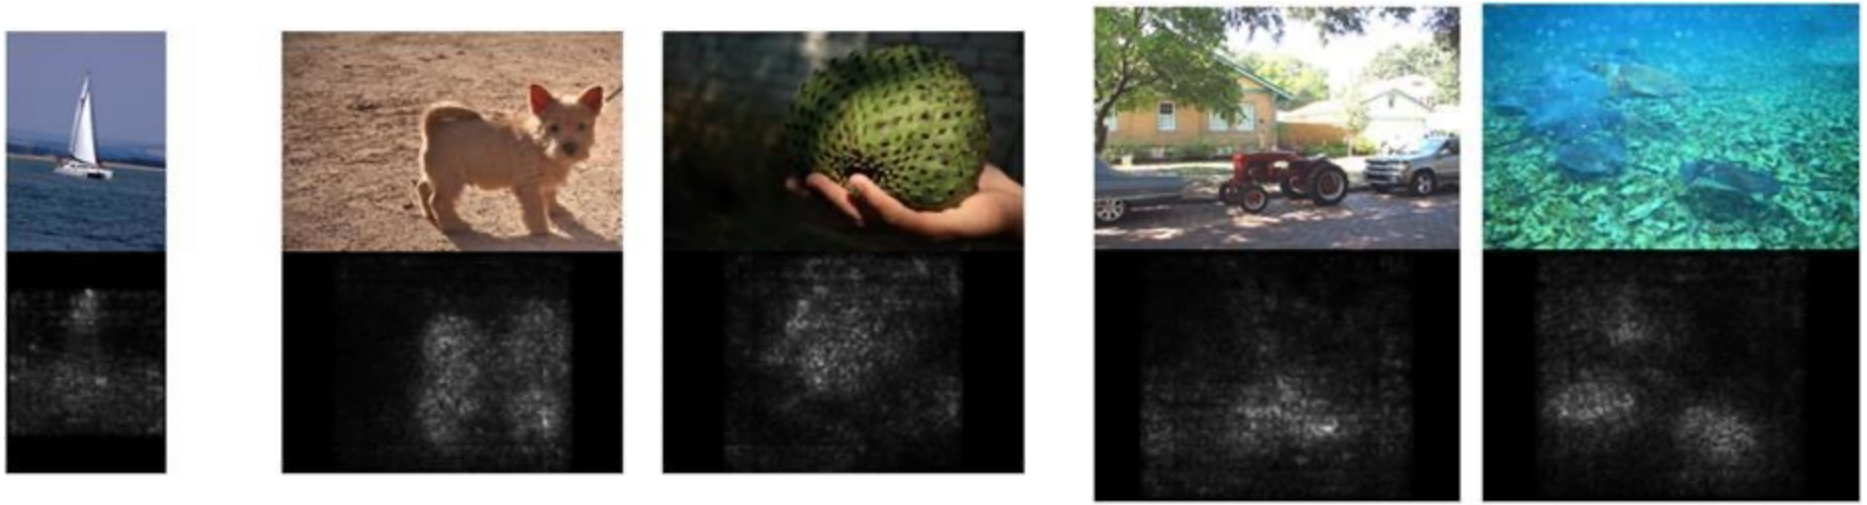


计算（未归一化的）类别分数相对于图像像素的梯度，取绝对值并在 RGB 通道上取最大值



Simonyan, Vedaldi, and Zisserman, “Deep Inside Convolutional Networks: Visualising Image Classification Models and Salien cy Maps”, ICLR Workshop 2014. 图片版权归 Karen Simonyan、Andrea Vedaldi 和 Andrew Zisserman 所有，2014；经许可转载。

显著性图



Simonyan, Vedaldi, and Zisserman，“Deep Inside Convolutional Networks: Visualising Image Classification Models and Salien cy Maps”，ICLR Workshop 2014。图片版权归 Karen Simonyan、Andrea Vedaldi 和 Andrew Zisserman 所有，2014；经许可转载。

今天

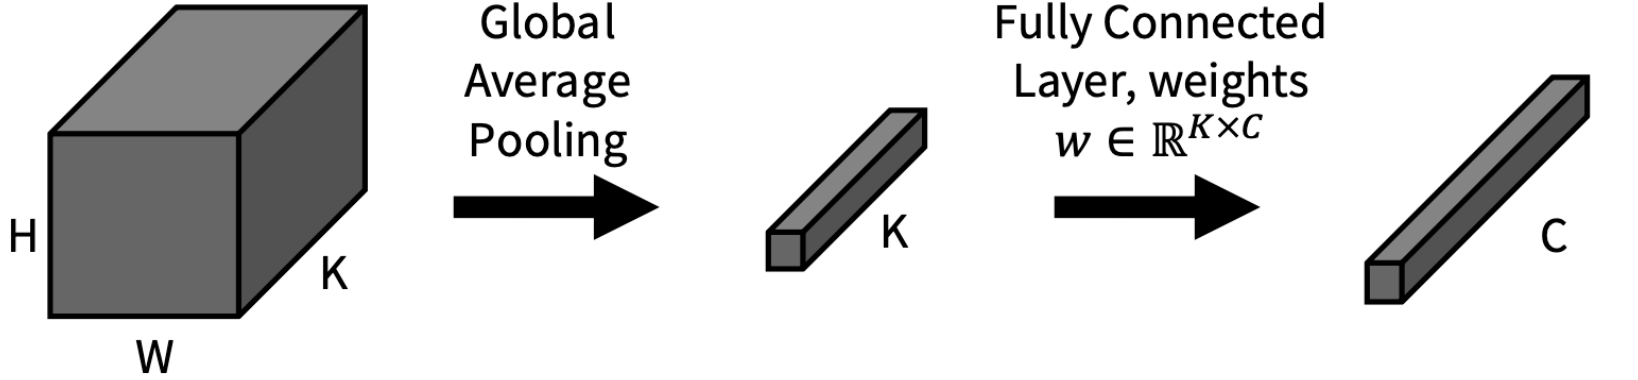
- 计算机视觉任务
  - 语义分割 - 目标检测 - 实例分割

- **可视化与理解**
  - 模型层可视化 - 显著性图 - **CAM 与 Grad-CAM**

- 基础模型与提示分割



Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

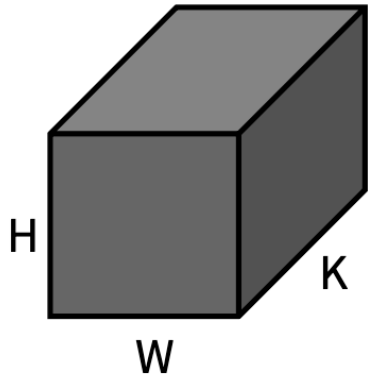
Pooled features:
$F \in \mathbb{R}^{K}$

Class Scores:
$S \in \mathbb{R}^{C}$

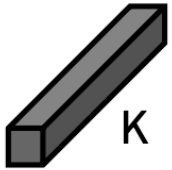


Zhou 等人，“用于判别性定位的深度特征学习”，CVPR 2016

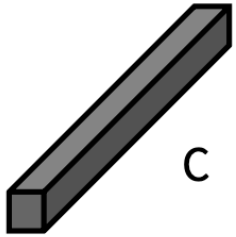
Class Activation Mapping (CAM)



Global Average Pooling



Fully Connected Layer, weights $w \in \mathbb{R}^{K \times C}$



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

Pooled features:
$F \in \mathbb{R}^{K}$

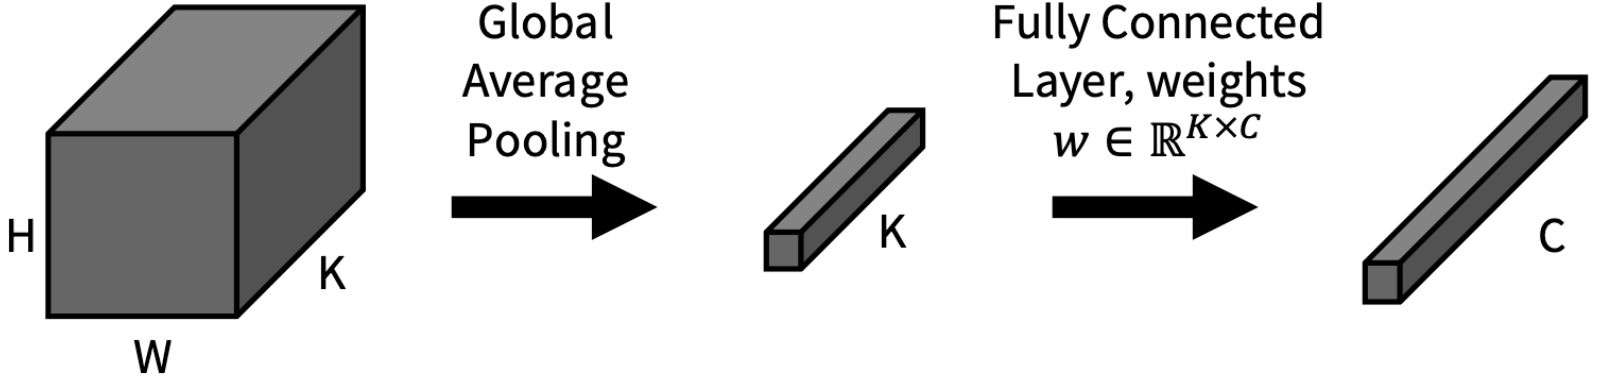
Class Scores:
$S \in \mathbb{R}^{C}$

$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k}$$



Zhou 等人，“学习用于判别性定位的深度特征”，CVPR 2016

Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

Pooled features:
$F \in \mathbb{R}^{K}$

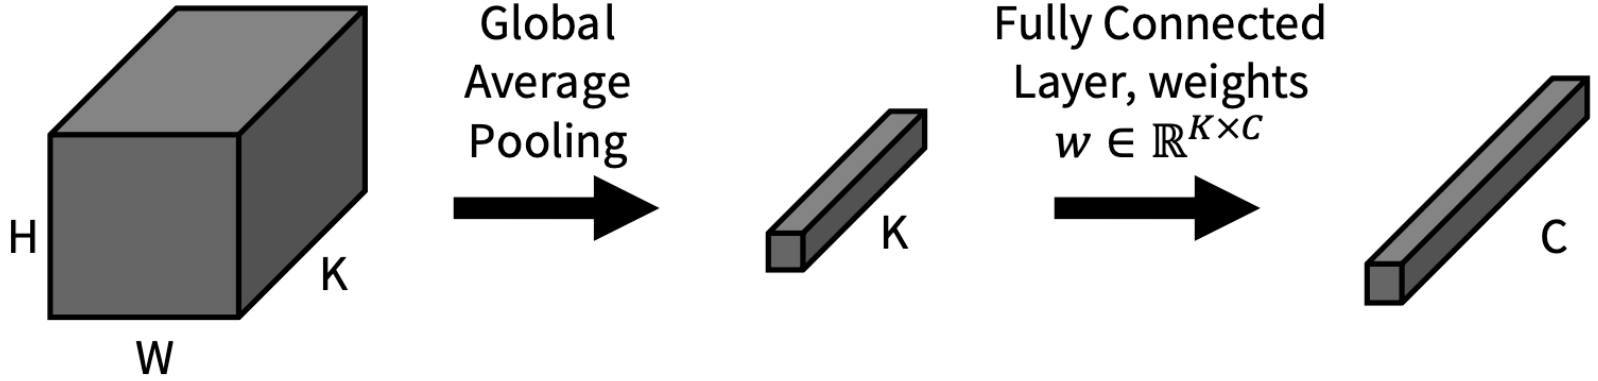
Class Scores:
$S \in \mathbb{R}^{C}$

$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k} \qquad S_c = \sum_k w_{k,c} F_k$$



Zhou et al,“Learning Deep Features for Discriminative Localization”,CVPR 2016

Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

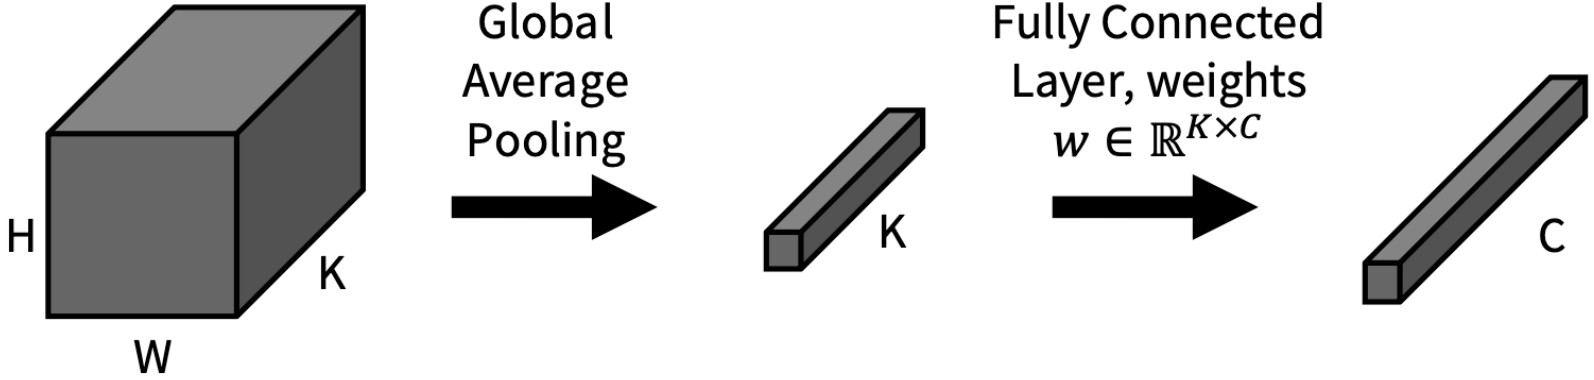
Pooled features:
$F \in \mathbb{R}^{K}$

Class Scores:
$S \in \mathbb{R}^{C}$

$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k} \qquad S_c = \sum_k w_{k,c} F_k = \frac{1}{HW} \sum_k w_{k,c} \sum_{h,w} f_{h,w,k}$$

Zhou 等人，“用于判别性定位的深度特征学习”，CVPR 2016

Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

Pooled features:
$F \in \mathbb{R}^{K}$

Class Scores:
$S \in \mathbb{R}^{C}$

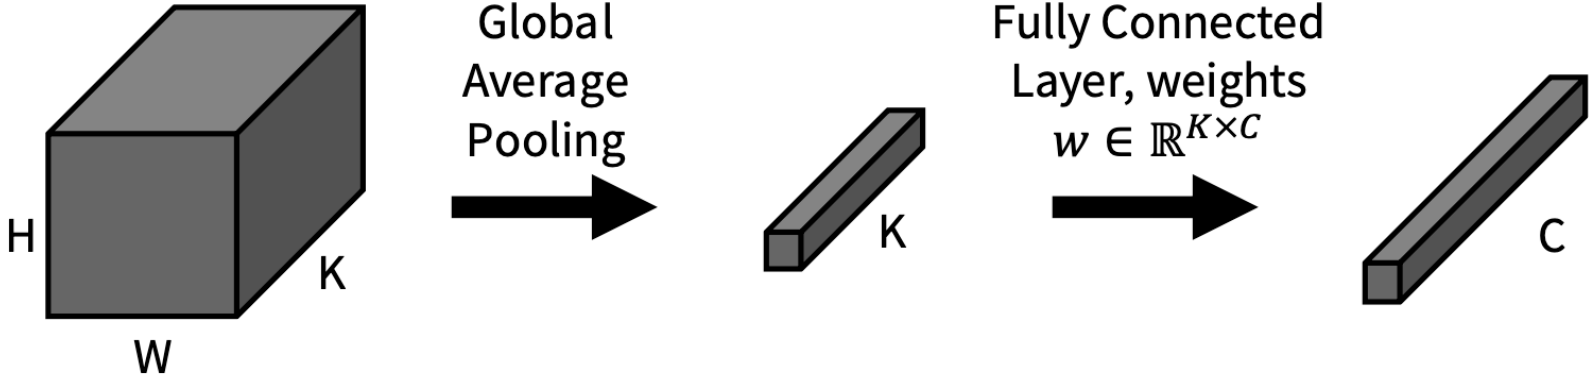
$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k}$$

$$S_c = \sum_k w_{k,c} F_k = \frac{1}{HW} \sum_k w_{k,c} \sum_{h,w} f_{h,w,k}$$

$$= \frac{1}{HW} \sum_{h,w} \sum_k w_{k,c} f_{h,w,k}$$

Zhou 等人，“用于判别性定位的深度特征学习”，CVPR 2016

Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

Pooled features:
$F \in \mathbb{R}^{K}$

Class Scores:
$S \in \mathbb{R}^{C}$

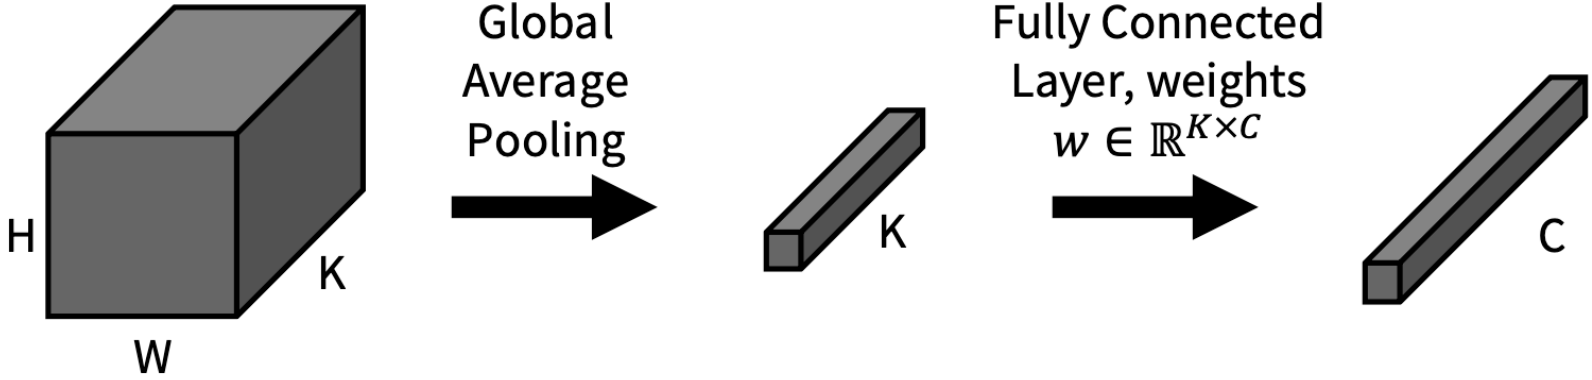
$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k}$$

$$S_c = \sum_k w_{k,c} F_k = \frac{1}{HW} \sum_k w_{k,c} \sum_{h,w} f_{h,w,k}$$

$$= \frac{1}{HW} \sum_{h,w} \sum_k w_{k,c} f_{h,w,k}$$

Zhou 等人，“用于判别性定位的深度特征学习”，CVPR 2016

Class Activation Mapping (CAM)



Last layer CNN features:
$f \in \mathbb{R}^{H \times W \times K}$

Pooled features:
$F \in \mathbb{R}^{K}$

Class Scores:
$S \in \mathbb{R}^{C}$

$$F_k = \frac{1}{HW} \sum_{h,w} f_{h,w,k}$$

$$S_c = \sum_k w_{k,c} F_k = \frac{1}{HW} \sum_k w_{k,c} \sum_{h,w} f_{h,w,k}$$

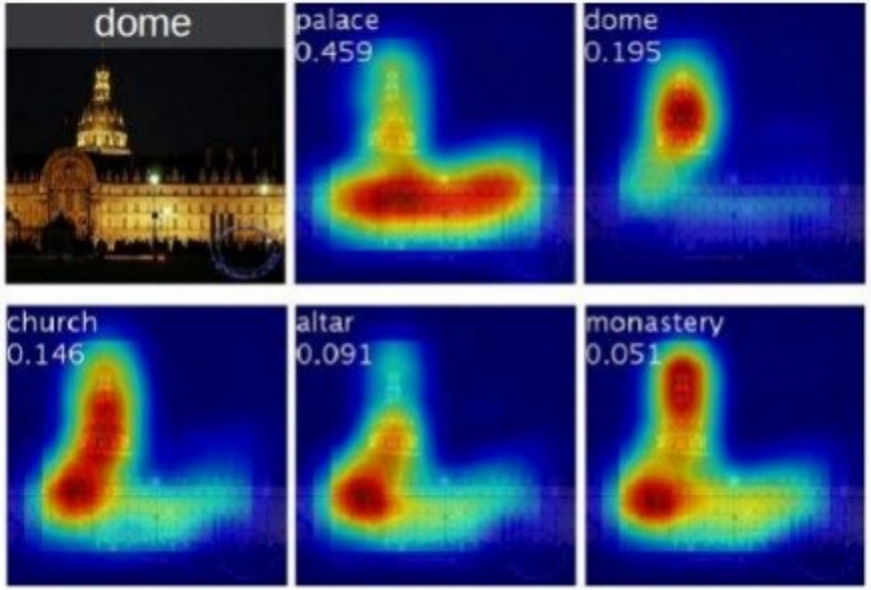
$$= \frac{1}{HW} \sum_{h,w} \sum_k \boldsymbol{w_{k,c} f_{h,w,k}}$$

Class Activation Maps:
$\boldsymbol{M \in \mathbb{R}^{C,H,W}}$

$$\boldsymbol{M_{c,h,w} = \sum_k w_{k,c} f_{h,w,k}}$$

Zhou 等人，“用于判别性定位的深度特征学习”，CVPR 2016

类激活映射（CAM）



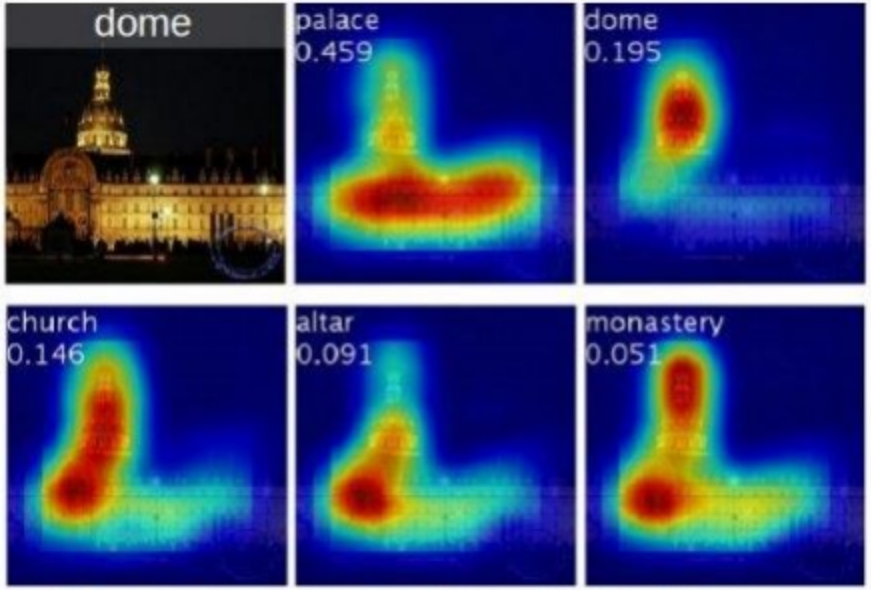
Class activation maps of top 5 predictions



Class activation maps for one object class

类激活映射 (CAM)

问题：只能应用于最后一个卷积层



Class activation maps of top 5 predictions



Class activation maps for one object class

梯度加权类激活映射（Grad-CAM）

1. 选择任意层，其激活为 A ∈ R^{□×□×□}



Selvaraju 等，“Grad-CAM：通过基于梯度的定位得到深度网络的视觉解释”，CVPR 2017

梯度加权类激活映射（Grad-CAM）

1. 选择任意层，其激活为 A ∈ R^{H×W×K}；2. 计算类别分数 S 的梯度 c 关于 A：

$$\frac{\partial S_c}{\partial A} \in \mathbb{R}$$



Selvaraju 等人，“Grad-CAM: Visual Explanations from Deep Networksvia Gradient-based Localization”，CVPR 2017

梯度加权类激活映射（Grad-CAM）

1. 任选一层，其激活为 A ∈ R^{k×u×v}
2. 计算类别得分 S_c 关于 A 的梯度：

$$\frac{\partial S_c}{\partial A} \in \mathbb{R}^{k \times u \times v}$$

3. 对梯度进行全局平均池化，以得到权重 $\alpha_k \in \mathbb{R}$

$$\alpha_k = \frac{1}{HW} \sum_{h,w} \frac{\partial S_c}{\partial A_{h,w,k}}$$



Selvaraju 等，“Grad-CAM：通过基于梯度的定位得到深度网络的视觉解释”，CVPR 2017

梯度加权类激活映射（Grad-CAM）

1. 选择任意层，其激活为 A ∈ R^{H×W×K}
2. 计算类别得分 S_c 关于 A 的梯度：

$$\frac{\partial S_c}{\partial A} \in \mathbb{R}^{H \times W \times K}$$

3. 对梯度进行全局平均池化以获得权重 $\alpha_k \in \mathbb{R}$：

$$\alpha_k = \frac{1}{HW} \sum_{h,w} \frac{\partial S_c}{\partial A_{h,w,k}}$$

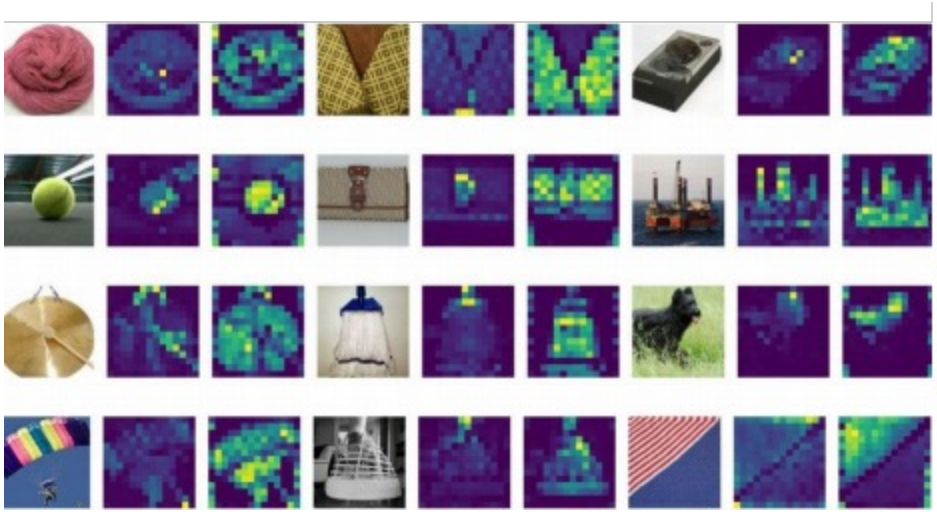
4. 计算激活图 $M^c \in \mathbb{R}^{H,W}$：

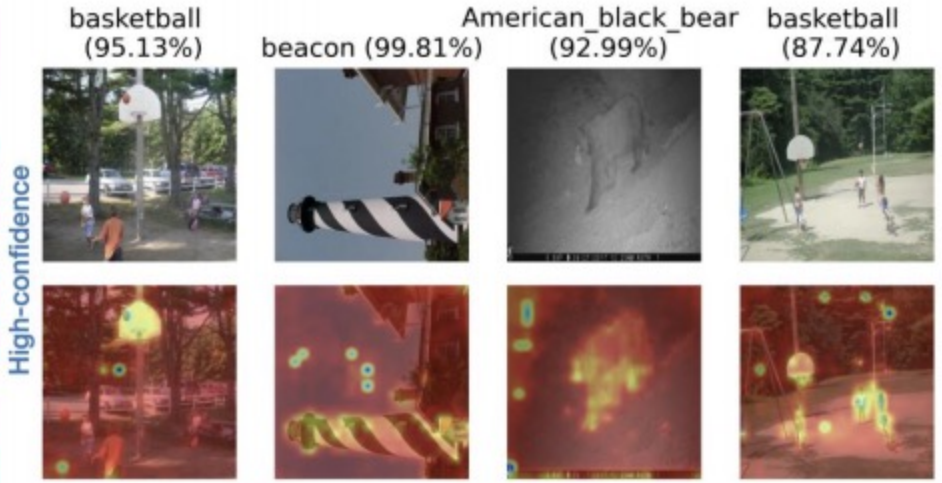
$$M^c_{h,w} = ReLU\left(\sum_k \alpha_k A_{h,w,k}\right)$$



Selvaraju 等，“Grad-CAM：通过基于梯度的定位对深度网络进行可视化解释”，CVPR 2017

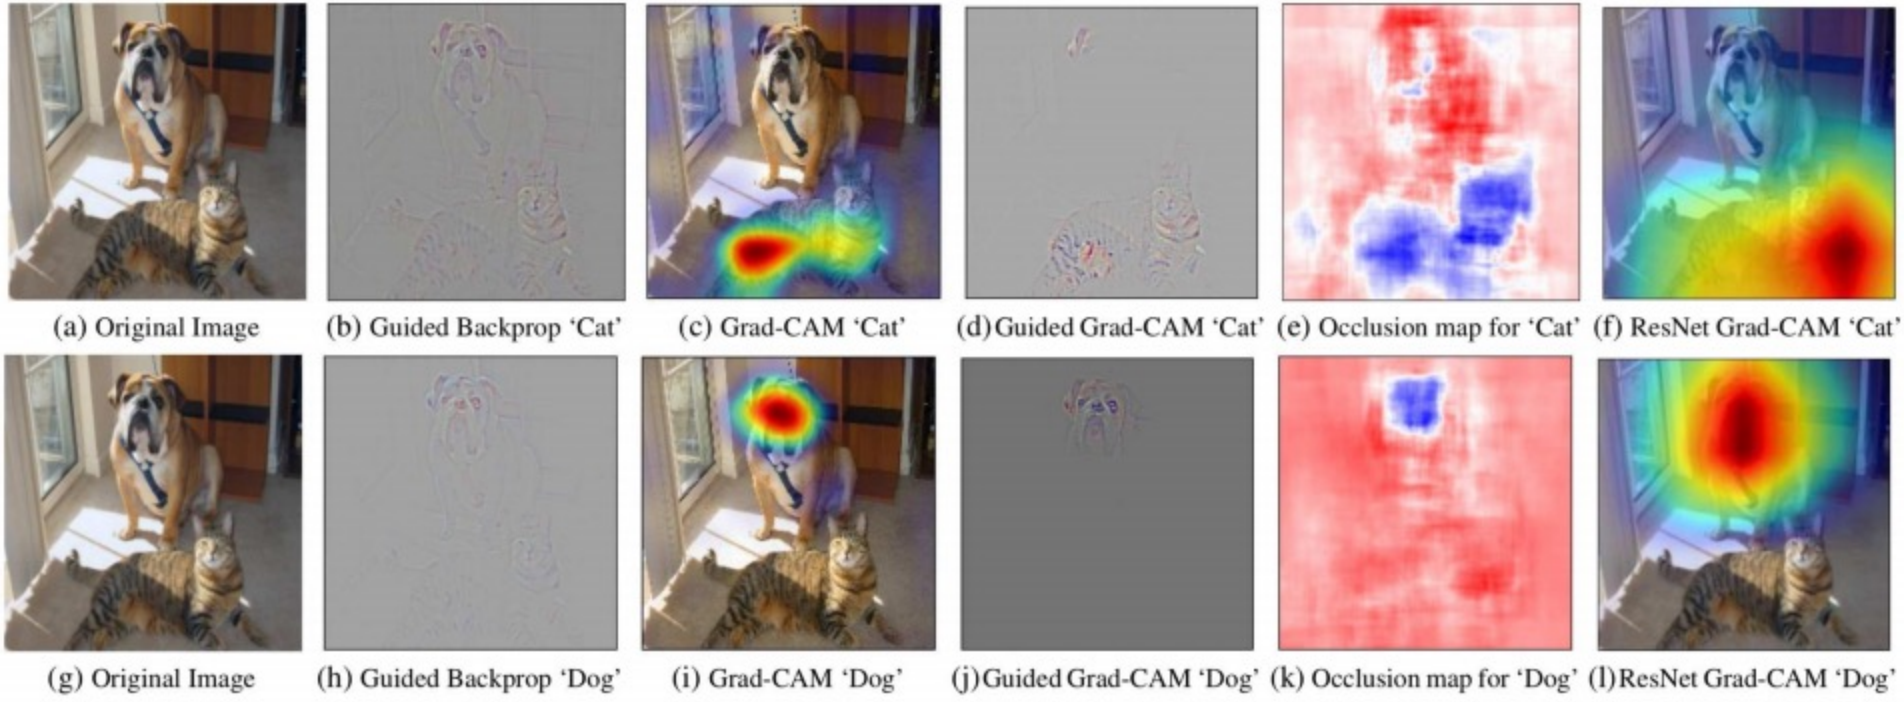
可视化 ViT 特征





Chen 等人，When Vision Transformers OutperformResnets Without Pre-training Or Strong Data Augmentations, ICLR 2022；Paul 和 Chen，Vision Transformers are Robust Learners，AAAI 2022。为教育目的复现。

梯度加权类激活映射（Grad-CAM）



(a) Original Image (b) Guided Backprop 'Cat' (c) Grad-CAM 'Cat' (d) Guided Grad-CAM 'Cat' (e) Occlusion map for 'Cat' (f) ResNet Grad-CAM 'Cat'

(g) Original Image (h) Guided Backprop 'Dog' (i) Grad-CAM 'Dog' (j) Guided Grad-CAM 'Dog' (k) Occlusion map for 'Dog' (l) ResNet Grad-CAM 'Dog'

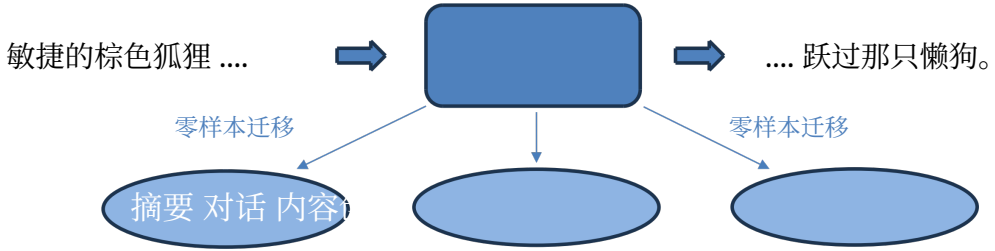
Selvaraju 等，“Grad-CAM：通过基于梯度的定位对深度网络进行可视化解释”，CVPR 2017

今天

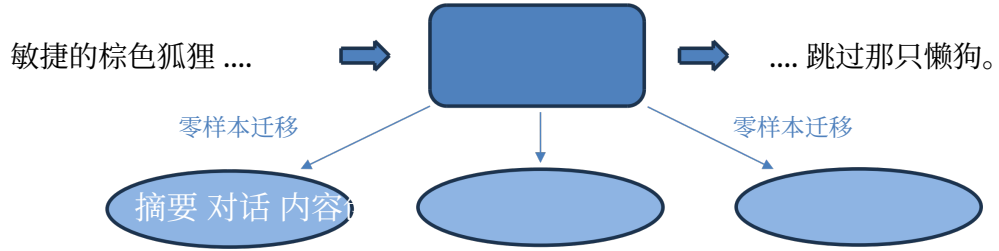
- 计算机视觉任务
  - 语义分割 - 目标检测 - 实例分割
- 可视化与理解
  - 模型层可视化 - 显著性图 - CAM 与 Grad-CAM
- **基础模型与提示分割**

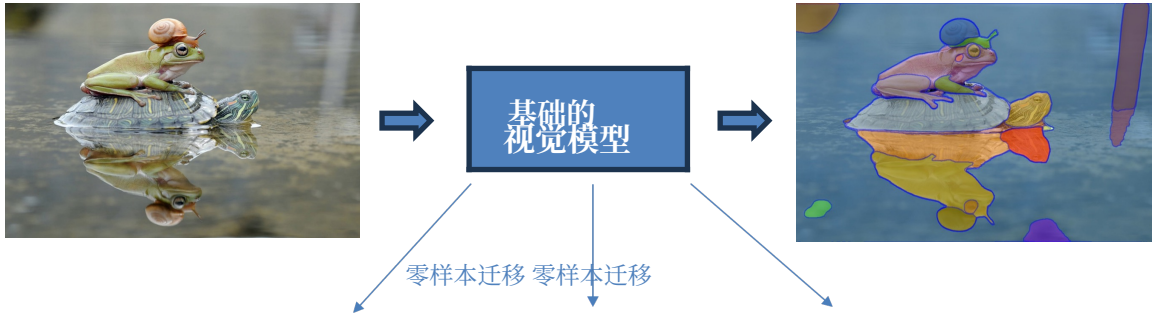


NLP中的零样本迁移提示

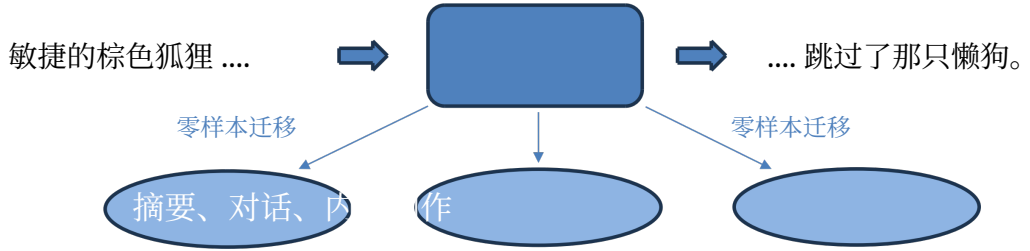


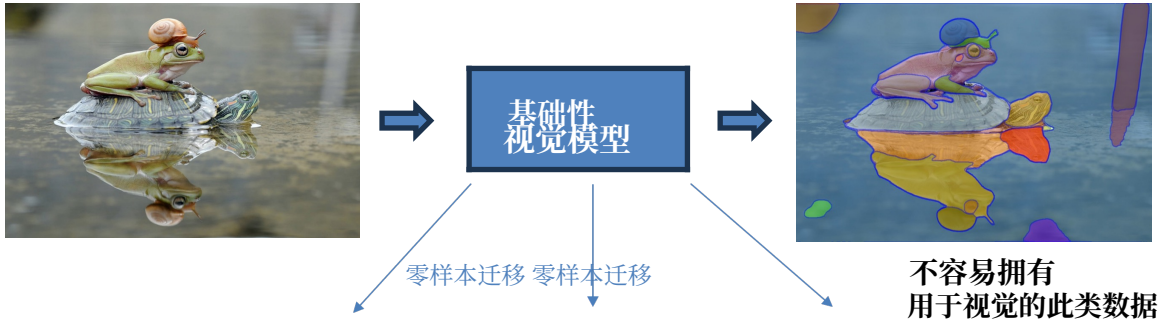
基础视觉模型





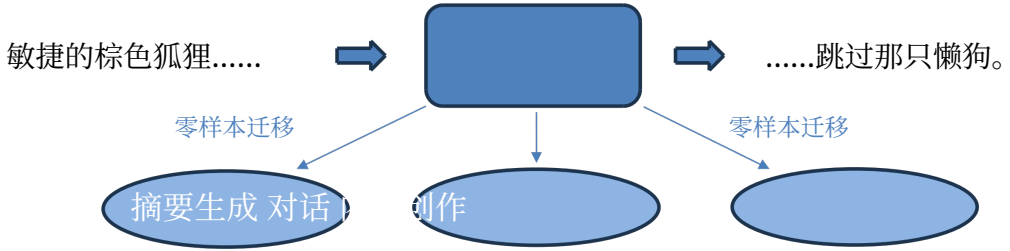
基础视觉模型：数据匮乏

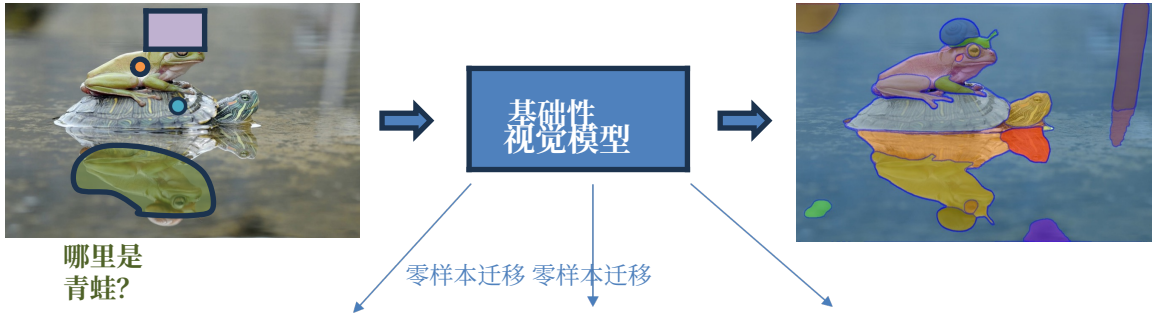




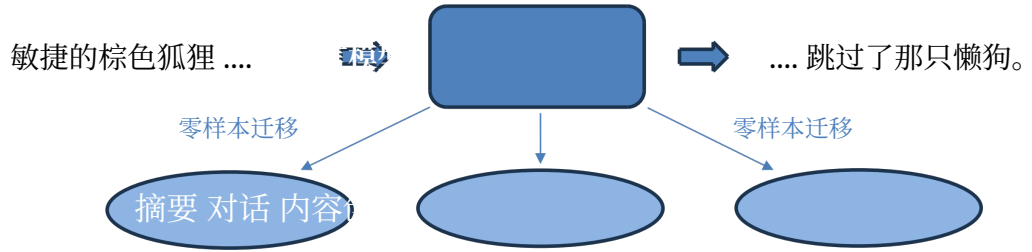
不容易拥有
用于视觉的此类数据
任务！

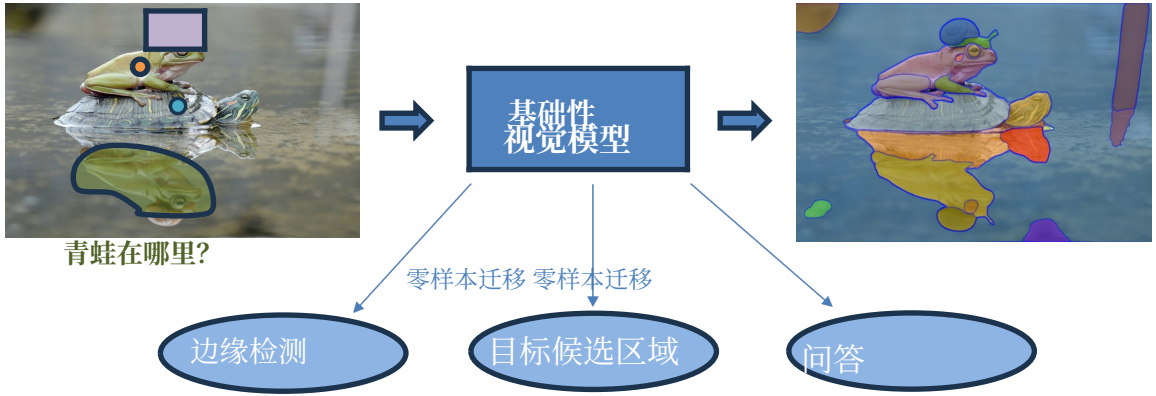
基础视觉模型：可提示分割





基础视觉模型：零样本迁移



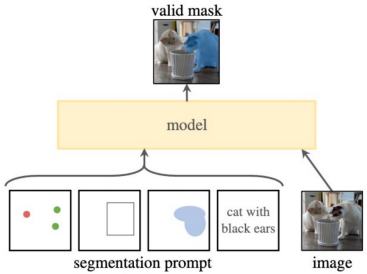


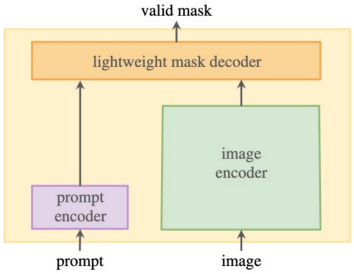
Segment Anything（基于 ViT）

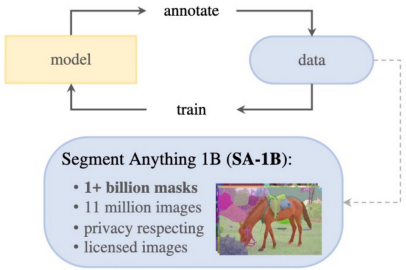
任务： 支持交互式和自动使用，并具备零样本能力泛化与复用

模型： 允许灵活的提示，支持实时使用，能够感知歧义

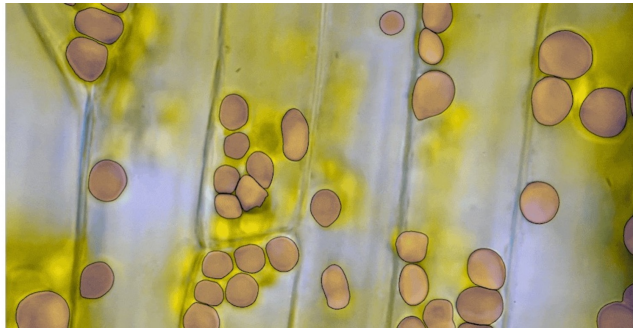
数据引擎： 模型在环数据集标注，兼顾公平性及隐私方面的考量











Segment Anything：任务

可提示分割

- 为给定项生成有效掩码
  提示作为输入
- 提示可能存在歧义，但
  始终返回有效掩码

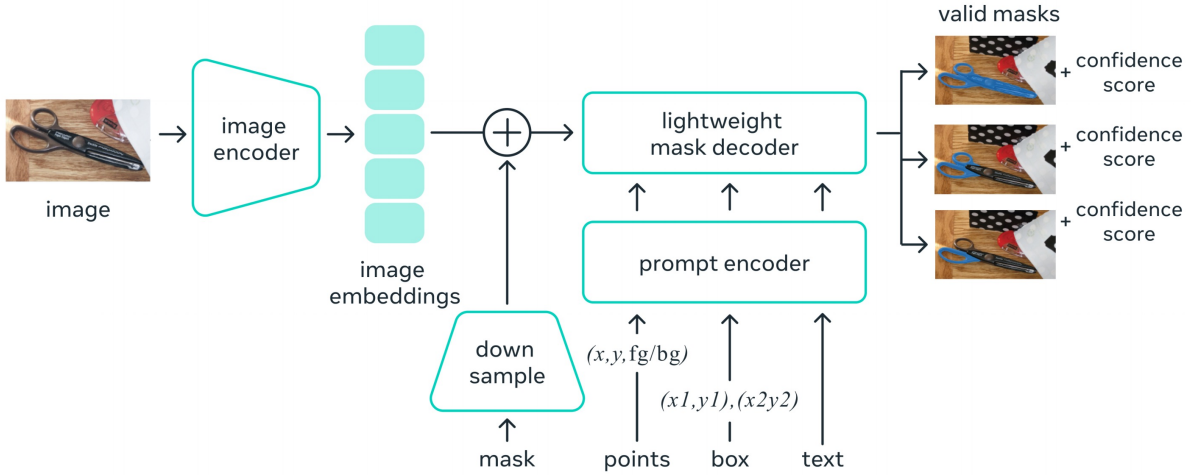
支持大规模

模型在环
数据标注

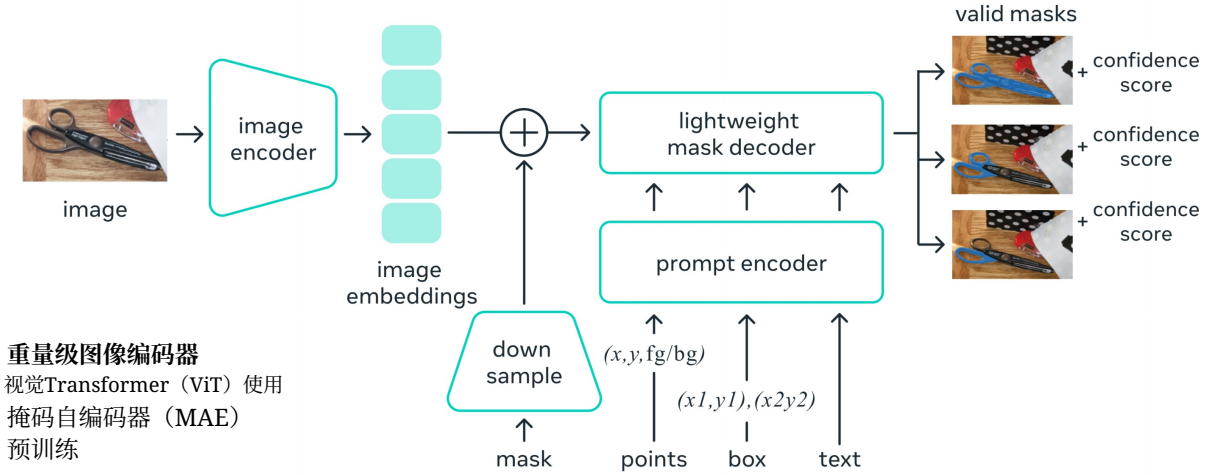
支持零样本
迁移类似于
提示工程



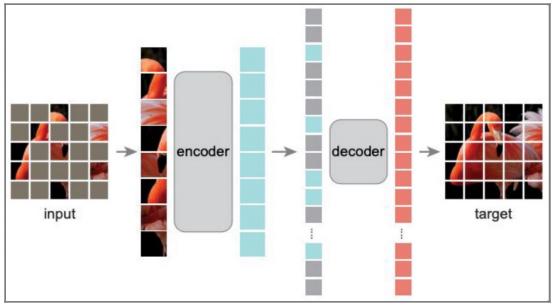
Segment Anything：通用分割模型



Segment Anything：通用分割模型

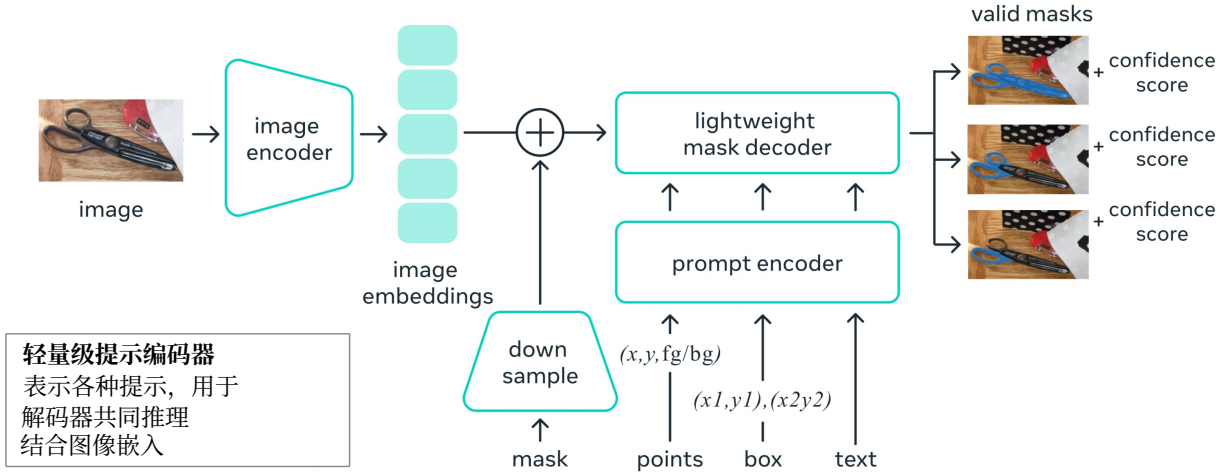


重量级图像编码器
视觉Transformer（ViT）使用
掩码自编码器（MAE）
预训练



- 在NLP中取得成功，但在视觉领域需特殊考量
- **信息：**相邻图像块更容易重建
- 编码器仅处理25%的图像块（75%掩码）
- **语义层面：**重建像素不同于词语 强解码器（文本仅需MLP），但比编码器更轻
- 处理已编码的图像块和掩码标记以预测像素
- 高容量网络中的可扩展特征学习

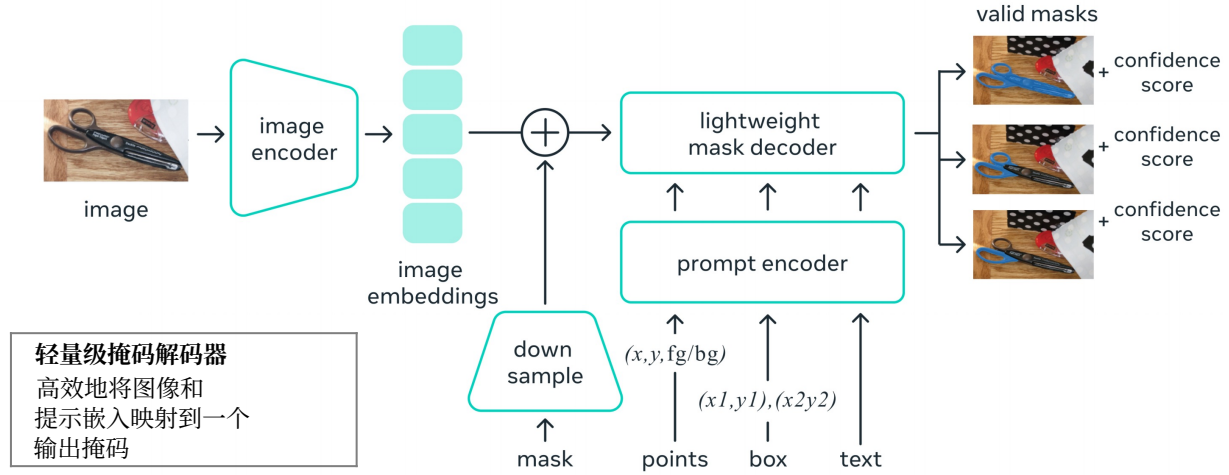
Segment Anything：通用分割模型



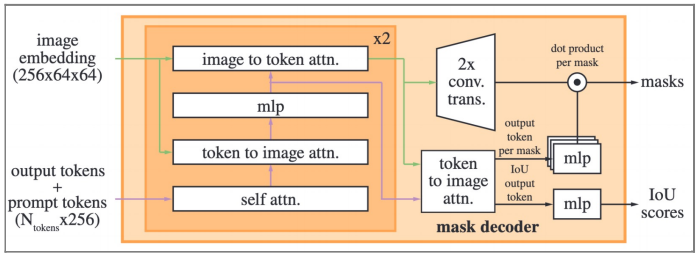
轻量级提示编码器
表示各种提示，用于解码器共同推理
结合图像嵌入

- **点：** 点位置的位置编码 + 用于前景或背景的可学习编码
- **框：** 角点的位置编码 + 哪个角点的可学习编码
- **文本：** CLIP 文本编码器
- **掩码：** 与图像嵌入进行卷积和逐元素求和

Segment Anything：通用分割模型



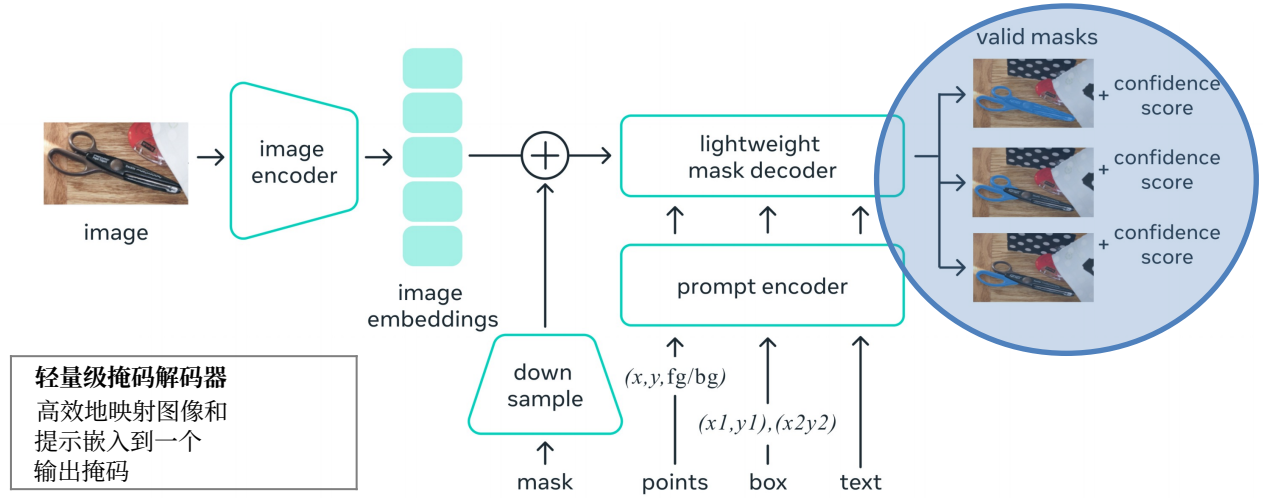
轻量级掩码解码器
高效地将图像和
提示嵌入映射到一个
输出掩码



两层 Transformer 解码器
- 提示词上的自注意力
- 从查询提示到图像的交叉注意力
- 逐点 MLP 用于非线性 从查询图像到提示的交叉注意力

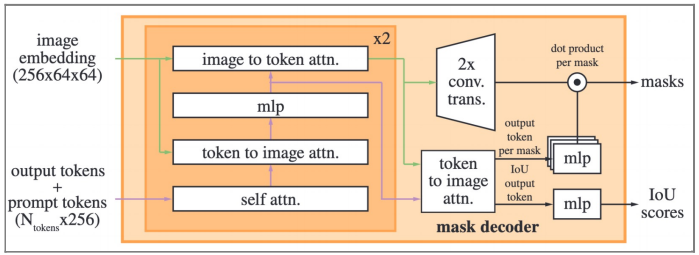
转置卷积上采样至掩码

Segment Anything：通用分割模型



轻量级掩码解码器

高效地映射图像和
提示嵌入到一个
输出掩码



预测三个掩码输出

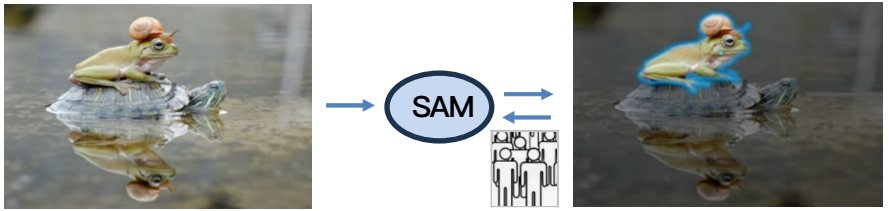
- 足以涵盖整体、部分、子部分概念
- 为每个预测的掩码生成一个输出标记
- 仅对多个掩码中的最小损失进行反向传播
- 用于 IoU 预测以对掩码进行排序的 Token

Segment Anything：模型在环数据引擎

辅助手动阶段

- 从数据集开始
- 通过多轮人工校正迭代

重新训练模型

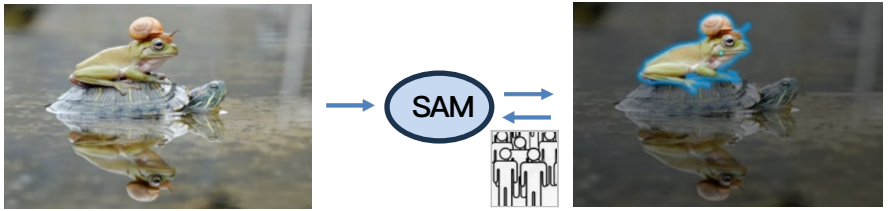


12万张图像，430万个掩码

Segment Anything：模型在环数据引擎

辅助手动阶段

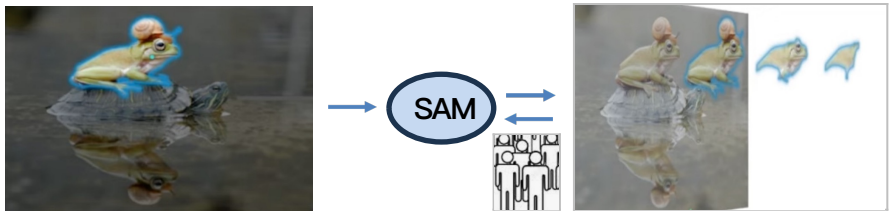
- 从数据集开始
- 通过多轮人工校正迭代重新训练模型



12 万张图像，430 万个掩码

半自动阶段

- 通过人工对当前输出进行精炼来提升多样性
- 定期重新训练模型

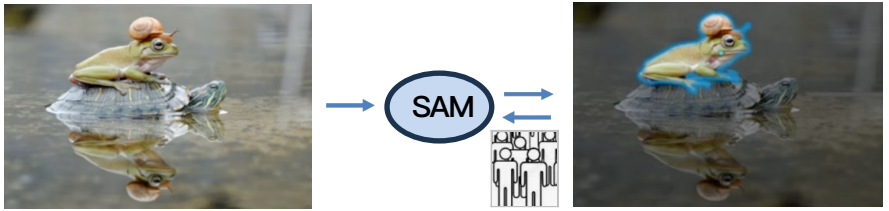


18 万张图像，590 万个掩码

Segment Anything：模型在环数据引擎

辅助人工阶段

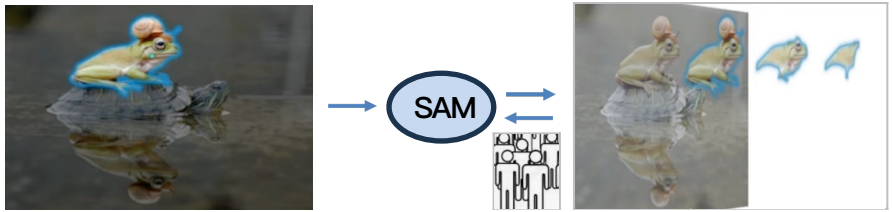
- 从数据集开始
- 通过多轮人工校正迭代重新训练模型



12万张图像，430万个掩码

半自动阶段

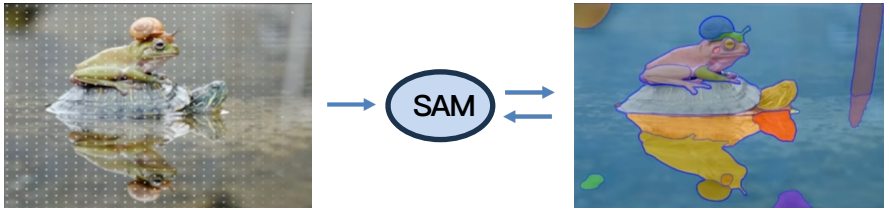
- 通过人工对当前输出进行精炼来提升多样性
- 定期重新训练模型



18万张图像，590万个掩码

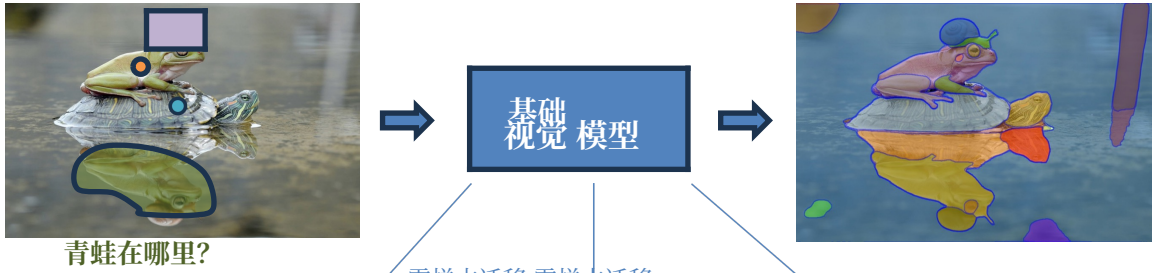
全自动阶段

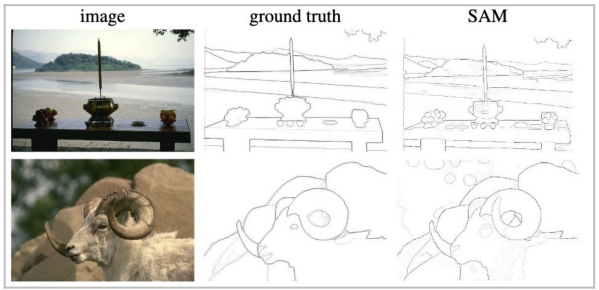
- 已训练好一个歧义感知模型
- 引入采用 32 x 32 点网格的提示
- 保留高置信度掩码（IoU 预测），执行 NMS



1100万张图像，11亿个掩码

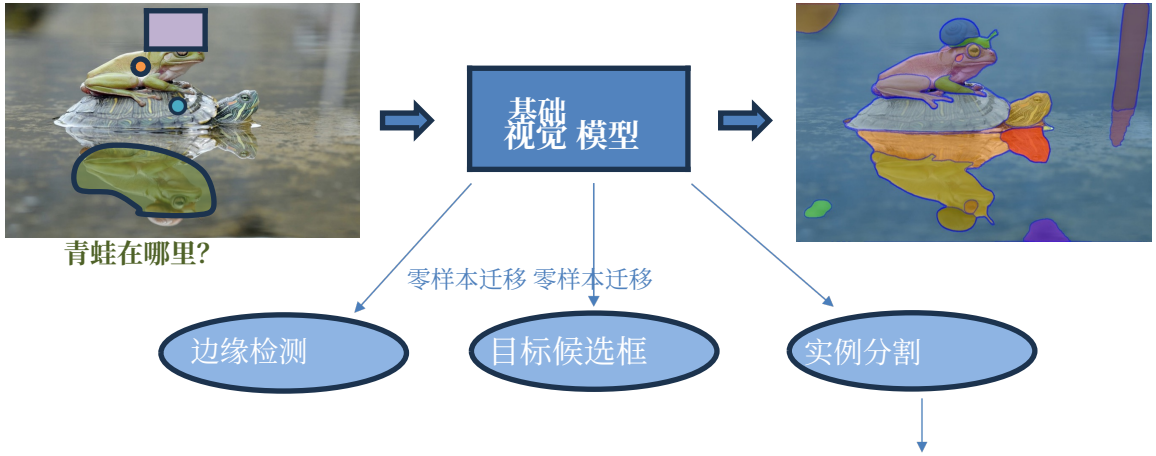
Segment Anything：通过提示实现零样本迁移





- 在 16 x 16 网格上使用提示预测掩码
- 对掩码概率图应用 Sobel 滤波器
- 滤波器输出的逐像素最大值
- 非极大值抑制

Segment Anything：通过提示实现零样本迁移



- 来自目标检测器的边界框
- 将其用作 SAM 的提示以获取掩码
- 通过馈入来细化置信度最高的掩码带框提示返回解码器

