生成模型与三维重建及前沿

Hao WANG

AI Thrust，信息枢纽

Vi ecw□uk□c□□□ i i p

计算机视觉任务

分类



CAT

无空间范围

语义分割



草，猫，树，
SKY

没有对象，只有像素

目标检测



狗，狗，猫

实例分割



狗，狗，CAT

多对象

本图像是CC0 公有领域

语义分割思路：全卷积

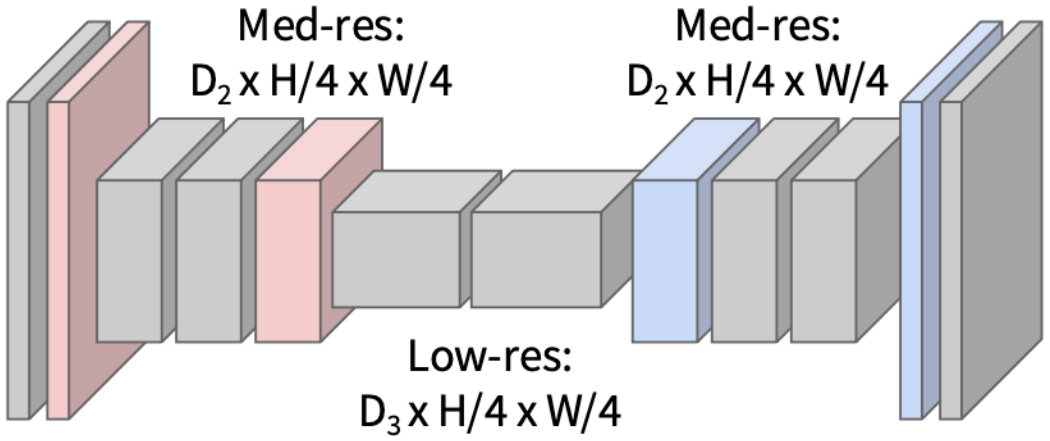
下采样：池化、跨步卷积

将网络设计为一组卷积层，并带有下采样和上采样，且都在网络内部！

上采样：???

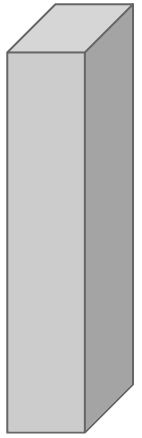


输入：
3 x H x W



高分辨率：
D x H/2 x W/2

高分辨率：
D x H/2 x □



C x H x W

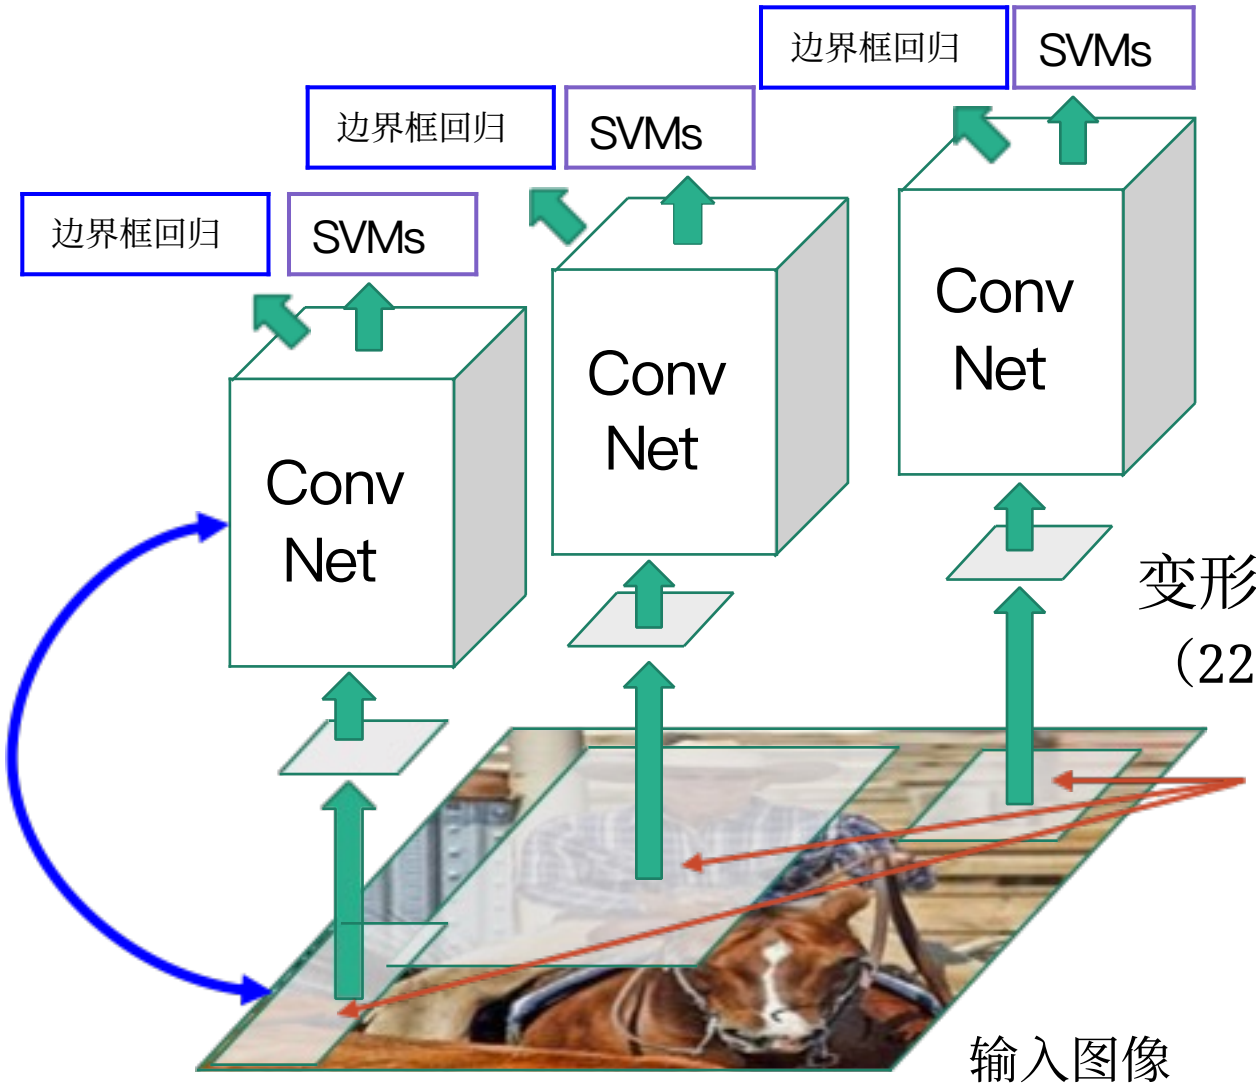


预测：
H x W

Long、Shelhamer 和 Darrell，“用于语义分割的全卷积网络”，CVPR 2015 Noh 等，“用于语义分割的学习反卷积网络”，ICCV 2015

“慢速” g -Ce e

预测对 RoI 的“修正”：4 个数字：(dx, dy, dw, dh)



使用SVMs 对区域进行分类

对每个区域进行前向传播通过 ConvNet（ImageNet 预训练）

变形后的图像区域（224x224 像素）

感兴趣区域（RoI）来自候选区域方法（~2k）

输入图像

问题：非常慢！

需要执行 □ k 独立前向传播

每张图像都要进行多次传递！

思路：将图像通过ConvNet

在裁剪之前！裁剪 该卷积特征

取而代之！

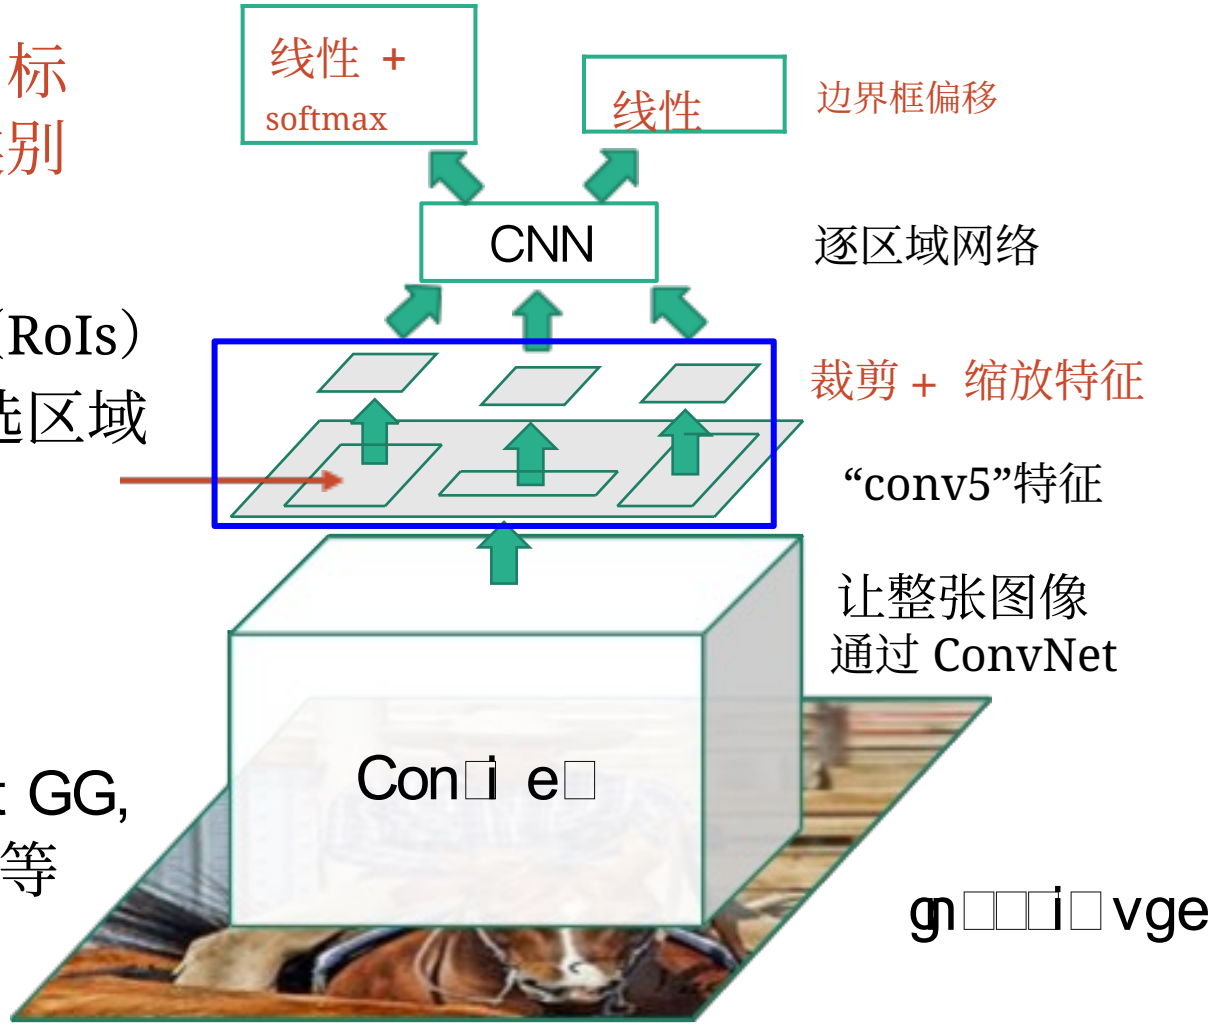
Girshick 等,“用于精确目标检测和语义分割的丰富特征层级”,CVPR 2014。图片版权 Ross Girshick，2015；来源。经许可转载。

Fast R-CNN

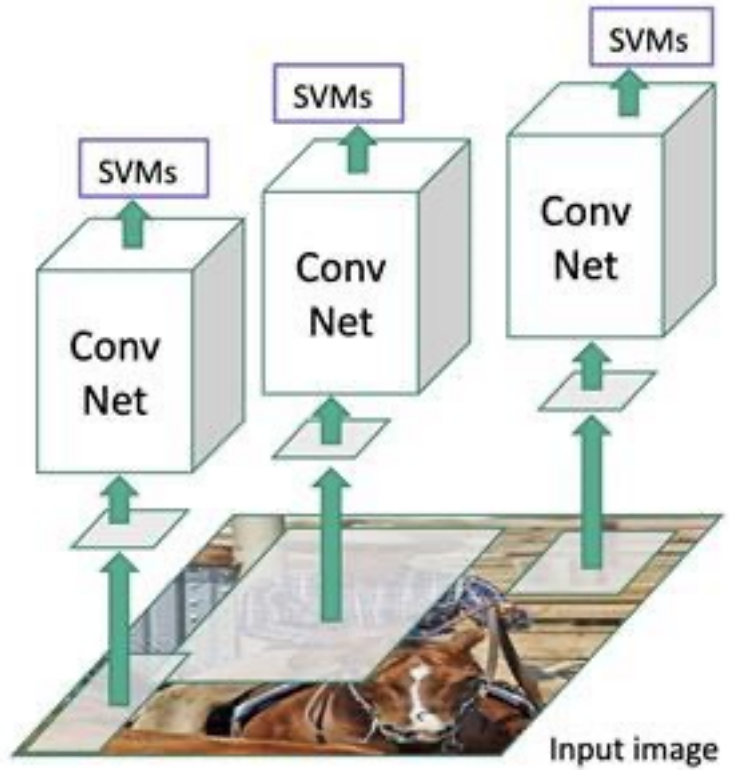
目标
类别

区域
感兴趣（RoIs）
来自候选区域
方法

“主干”
网络:
AlexNet , t GG,
ResNet 等

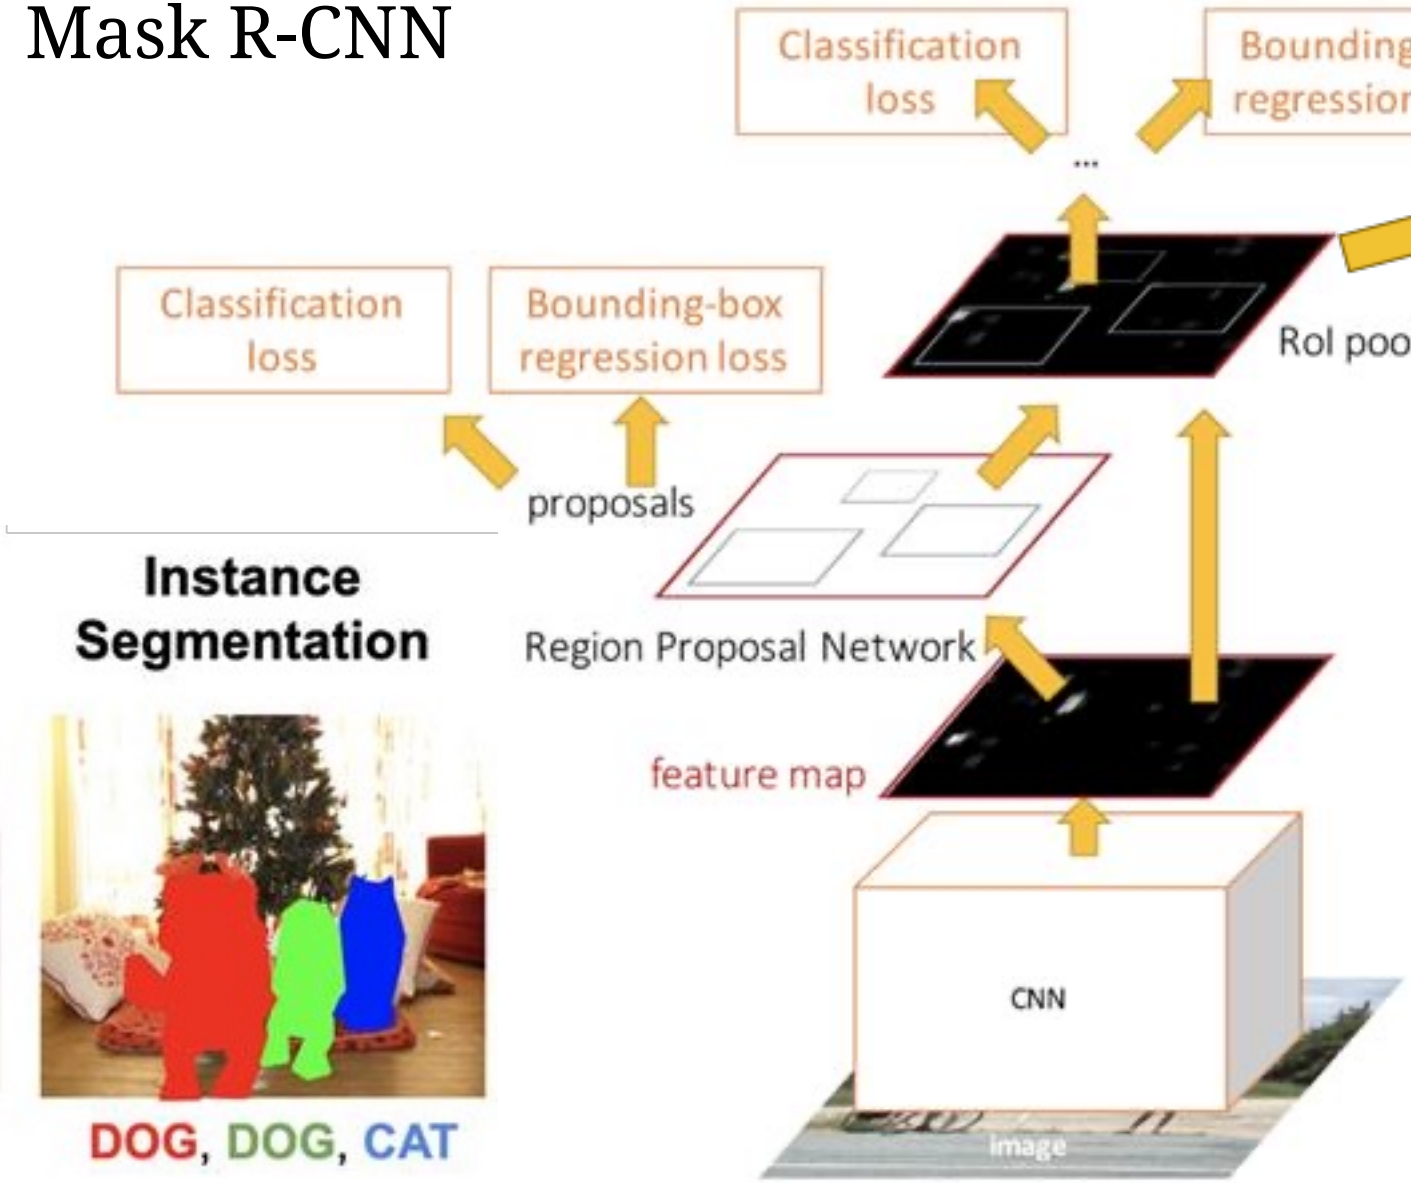


“慢速” R-CNN

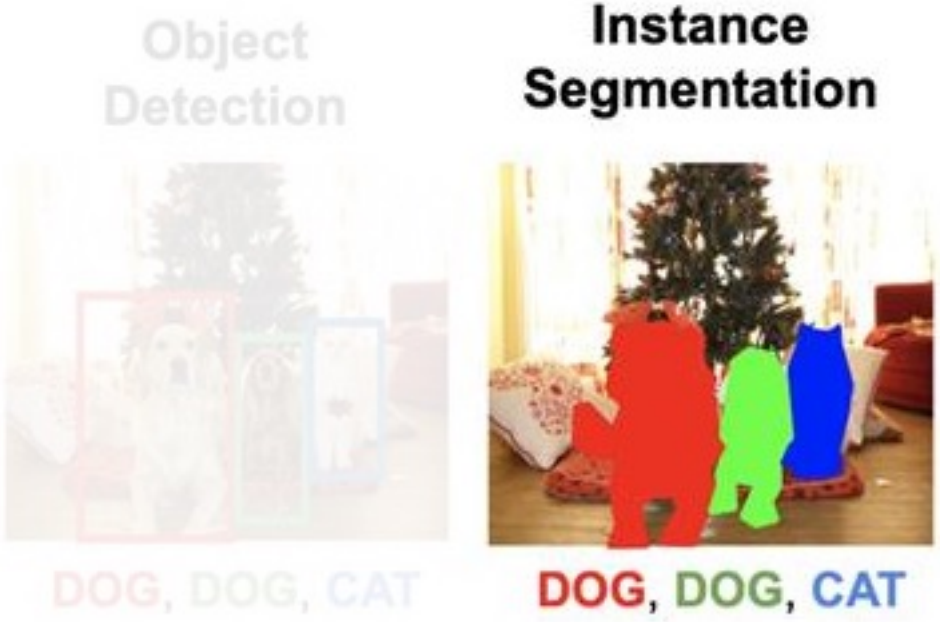


Girshick, “Fast R-CNN”, ICCV 2015。图片版权 Ross Girshick，2015；来源。经许可转载.

实例分割： Mask R-CNN



添加一个小型掩码网络，该网络对每个 RoI 进行操作，并预测一个 28x28 二值掩码

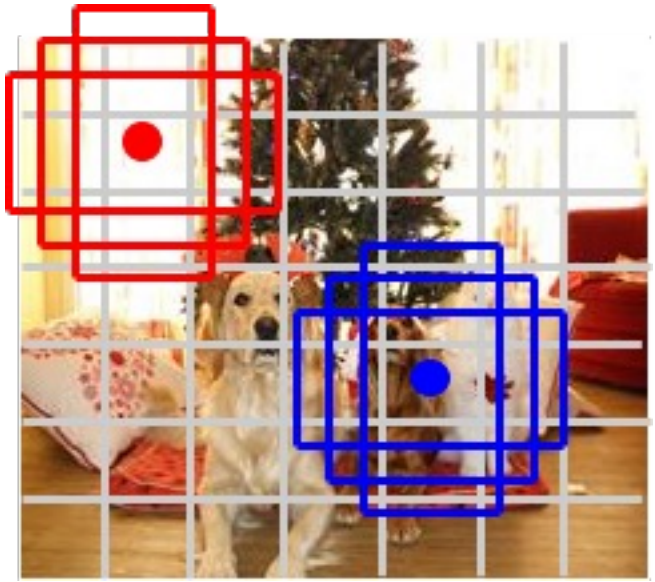


He 等人，“Mask R-CNN”，ICCV 2017

单阶段目标检测器：YOLO / SSD / RetinaNet



输入图像 3 x H x W



将图像划分为 7 x 7 网格

设想一组以每个网格单元为中心的基准框。这里 B □=

在每个网格单元内：

t 从 B 个中的每一个进行回归基础框到最终框，具有 5 个数字：(dx, dy, dh, dw, confidence)

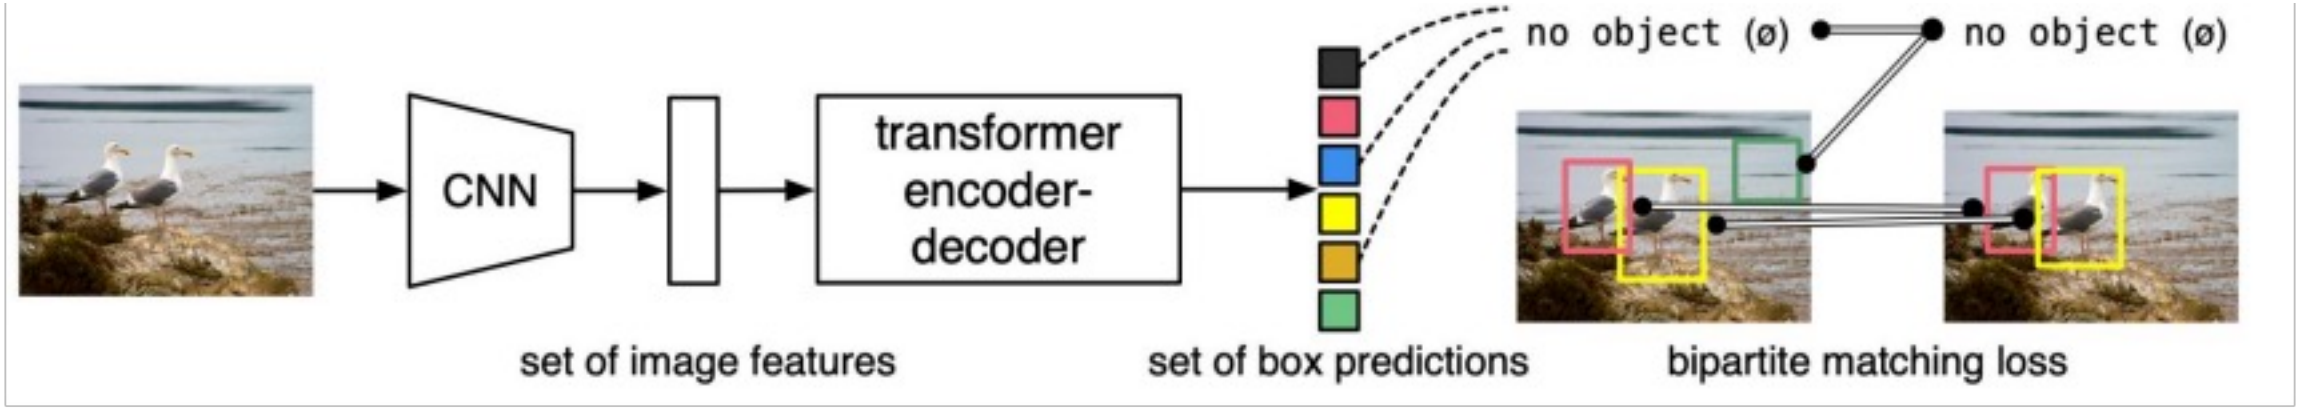
t 为 C 个中的每一个预测分数类别（包括将背景作为一个类别）

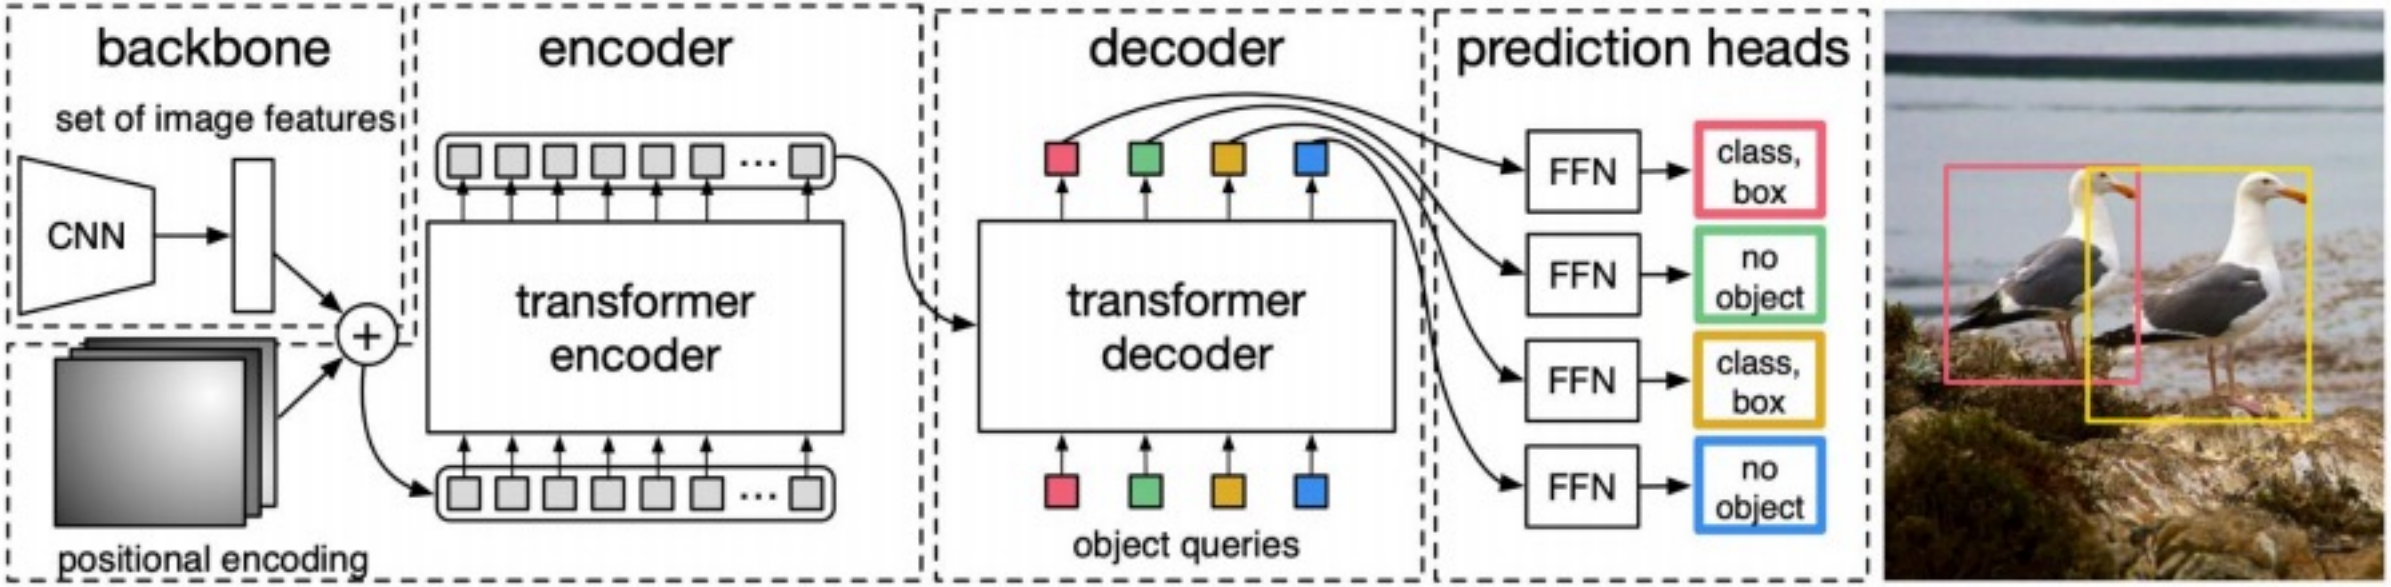
t 看起来很像 RPN ，□□t 类别特定的！

输出：7 x 7 x (5 * B T C)

Redmon 等，“你只看一次：统一的实时目标检测”，CVPR 2016 Liu 等，“SSD：单次 MultiBox 检测器”，ECCV 2016 Lin 等，“用于密集目标检测的 Focal Loss”，ICCV 2017

基于 Transformer 的目标检测：DETR



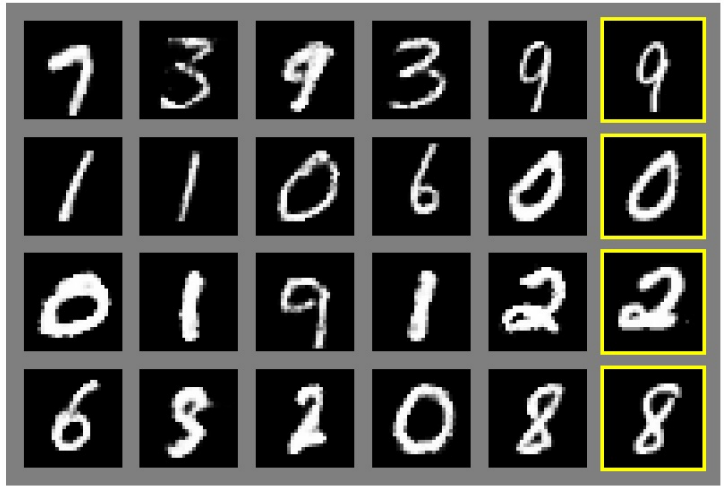


Carion 等，“基于 Transformer 的端到端目标检测”，ECCV 2020

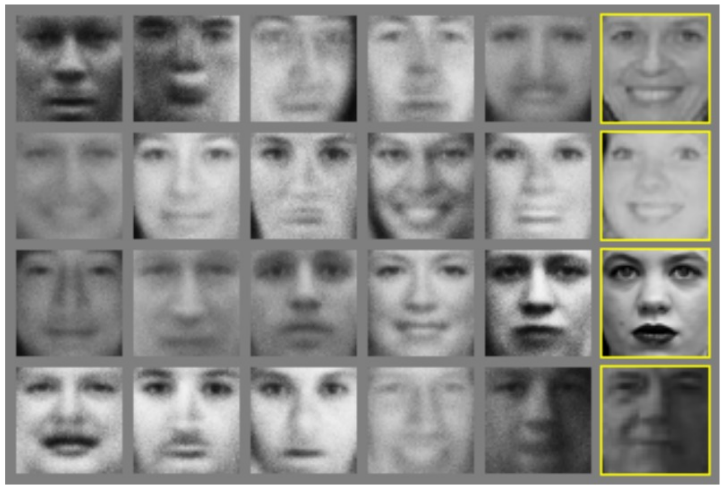
你知道当前最好的视觉生成模型是什么吗?



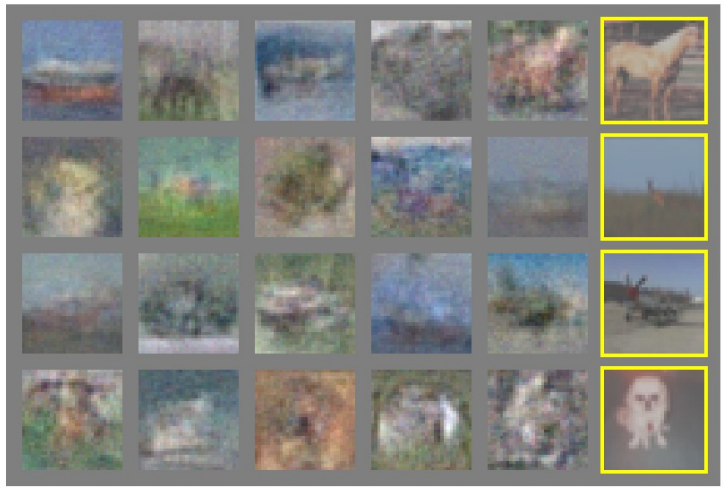
What it …a2 iv ?? ?ma 12 aow?



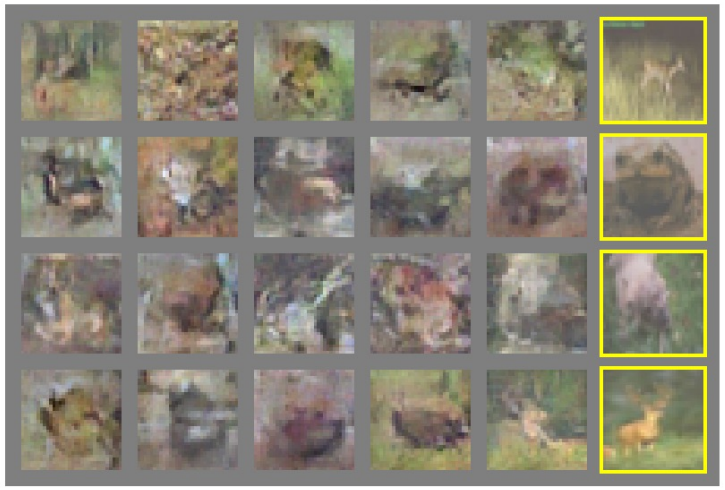
a)



b)



c)

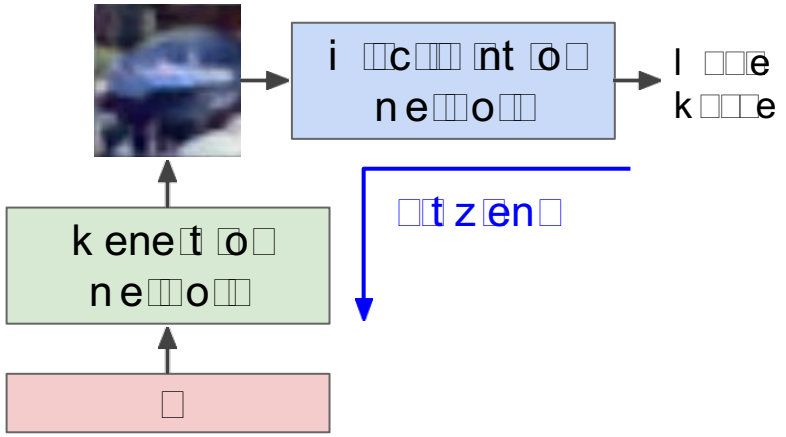


d)

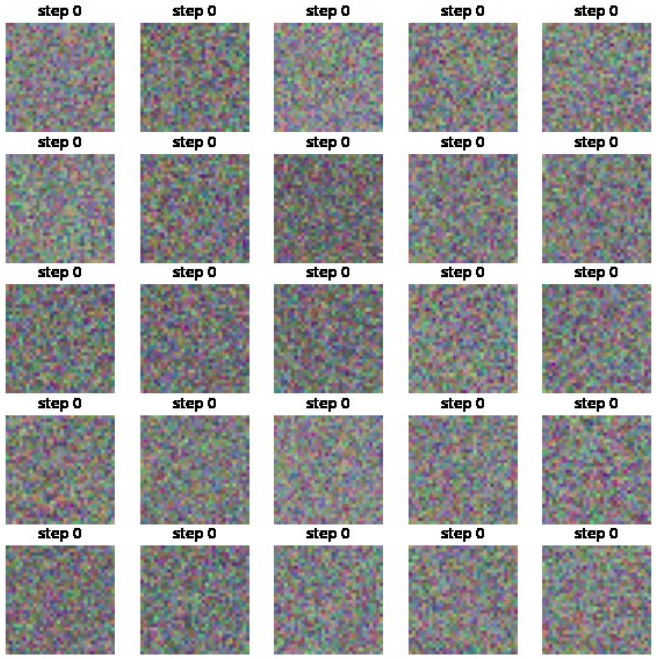
我们在此采用什么方法?



变分自编码器



Generative
Adversarial Networks



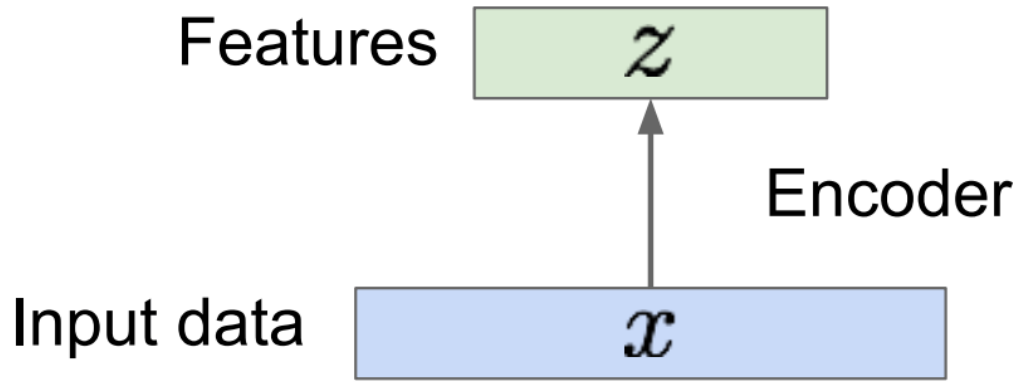
Diffusion Model

ac oc□ut cr□A□□ui t euf i

先介绍一些背景：自编码器

从无标注训练数据中学习特征表示的无监督方法

借助编码器（CNN/全连接层），我们提取数据中有意义变异因素的特征



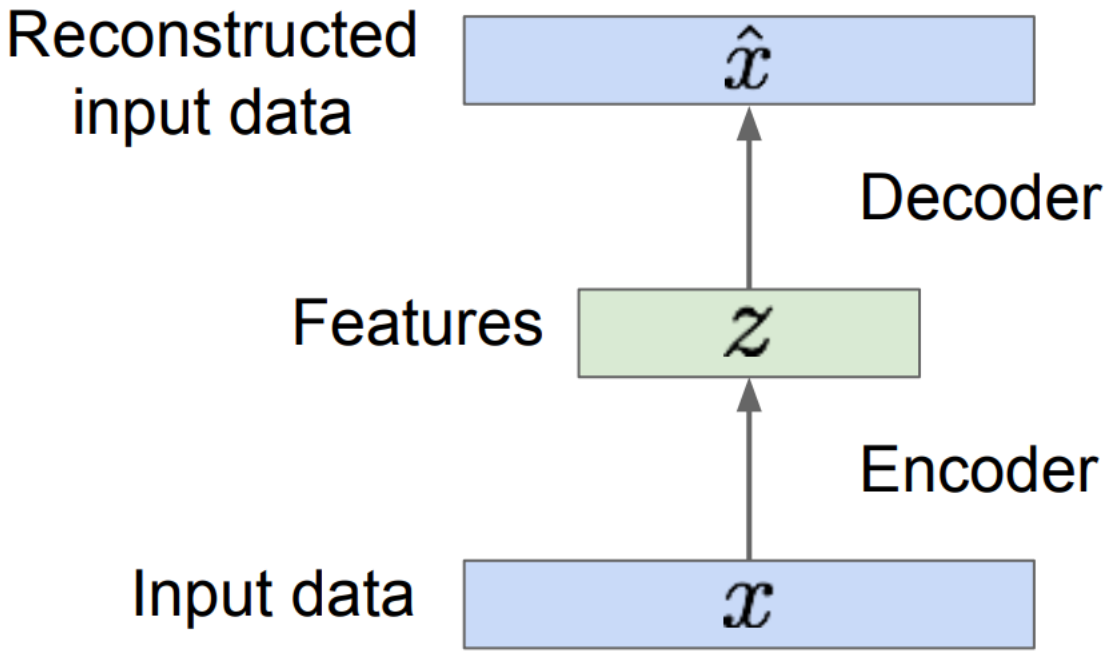


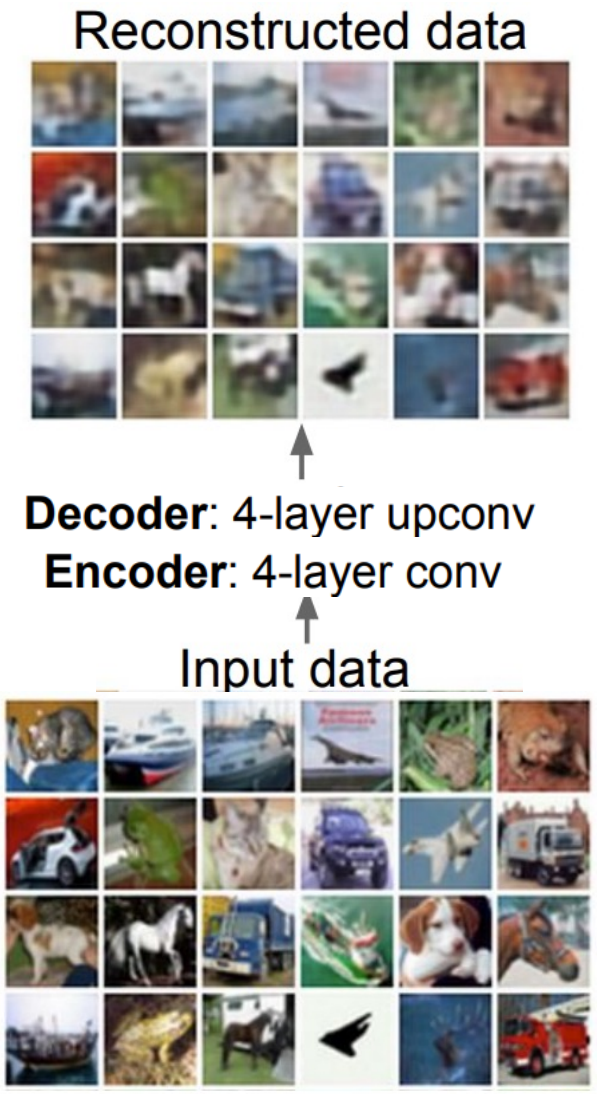
Some background first: Autoencoders

如何学习这种特征表示?

Training objective:

- 特征可用于重建原始数据“自编码”——即编码自身

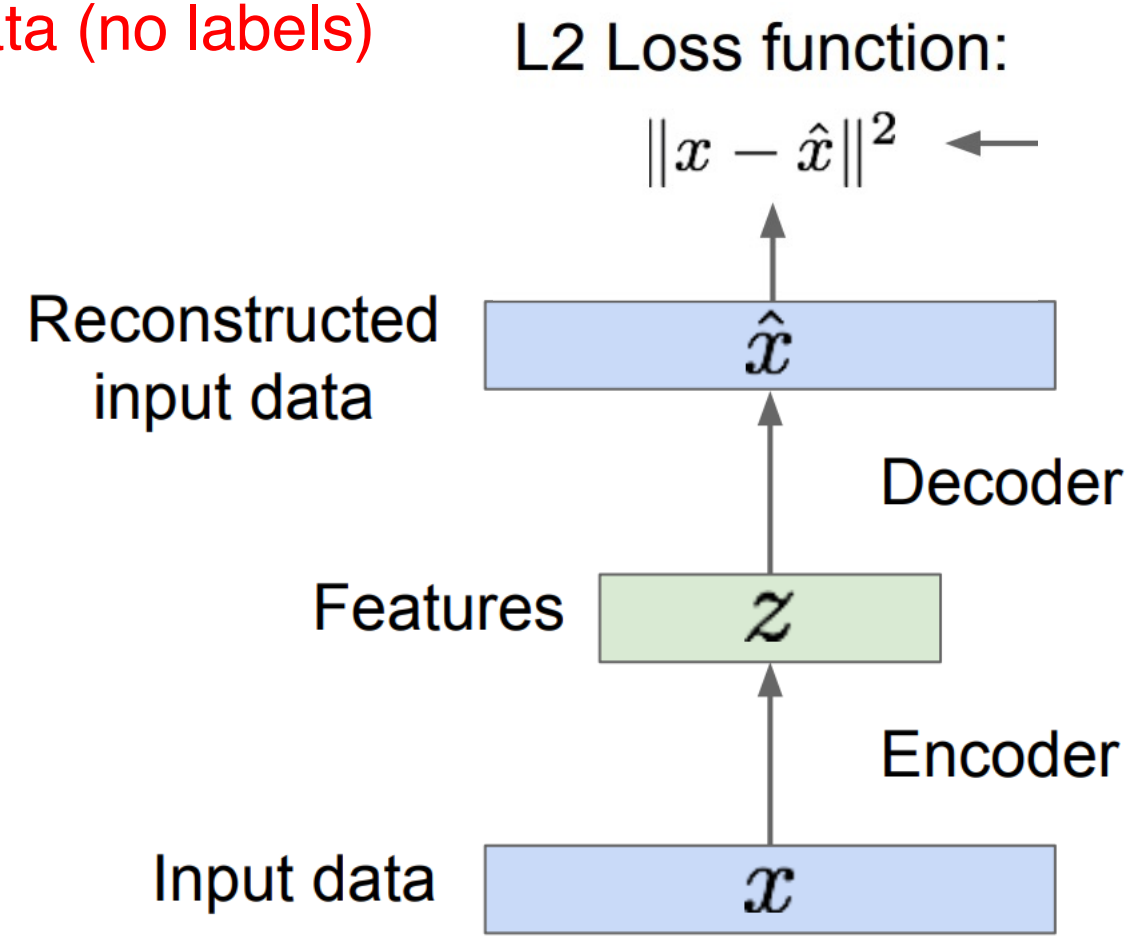


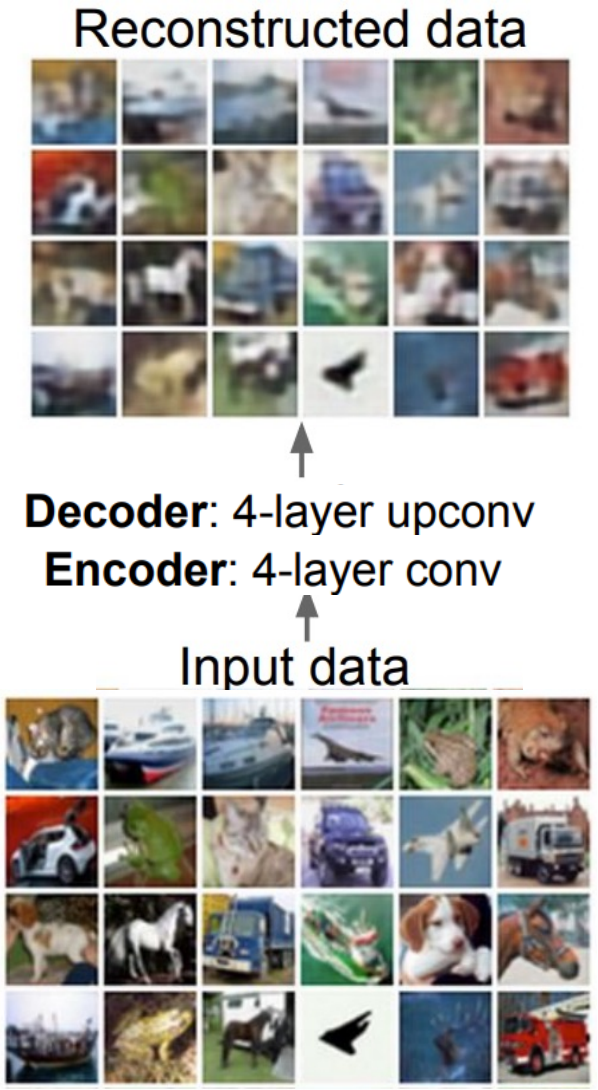


Some background first: Autoencoders

学习到的特征可用于重建原始数据

data (no labels)

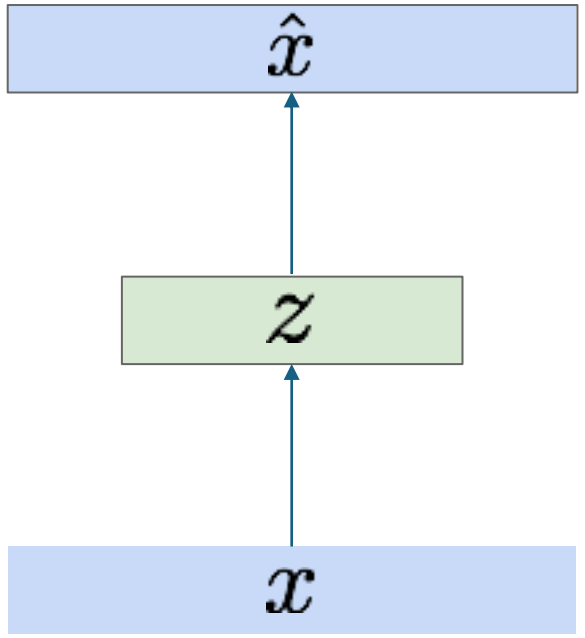




先介绍一些背景知识：自编码器

i 2 i o□□ u□ct□o□K

$$\|x - \hat{x}\|^2$$



特征

输入数据

应用：

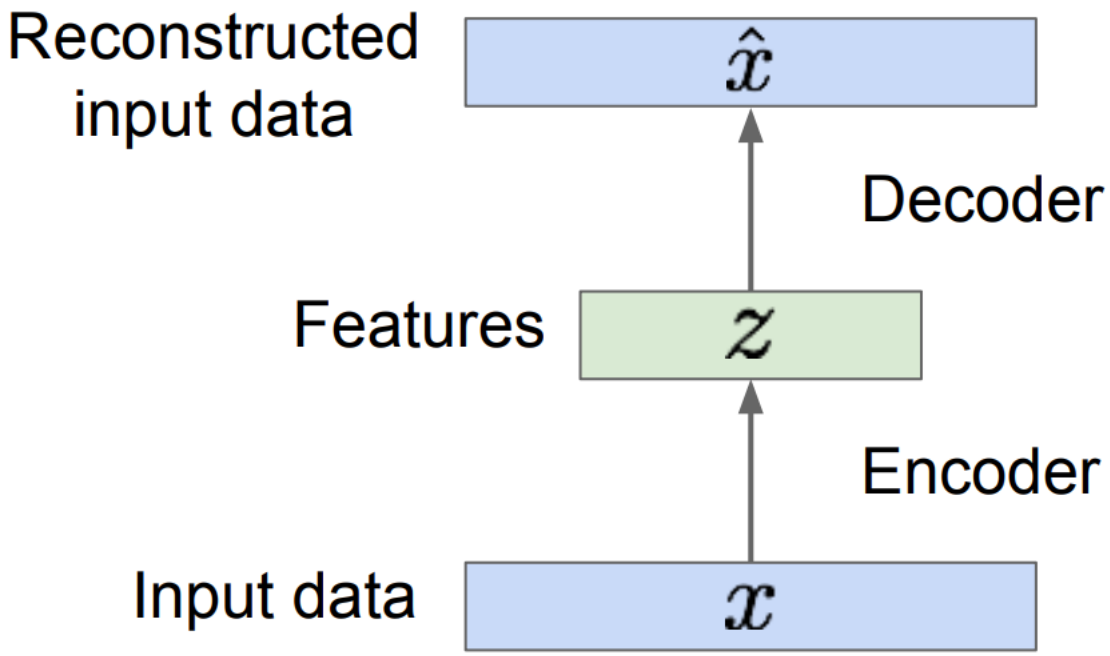
降维

特征学习

Auxiliary learning

□

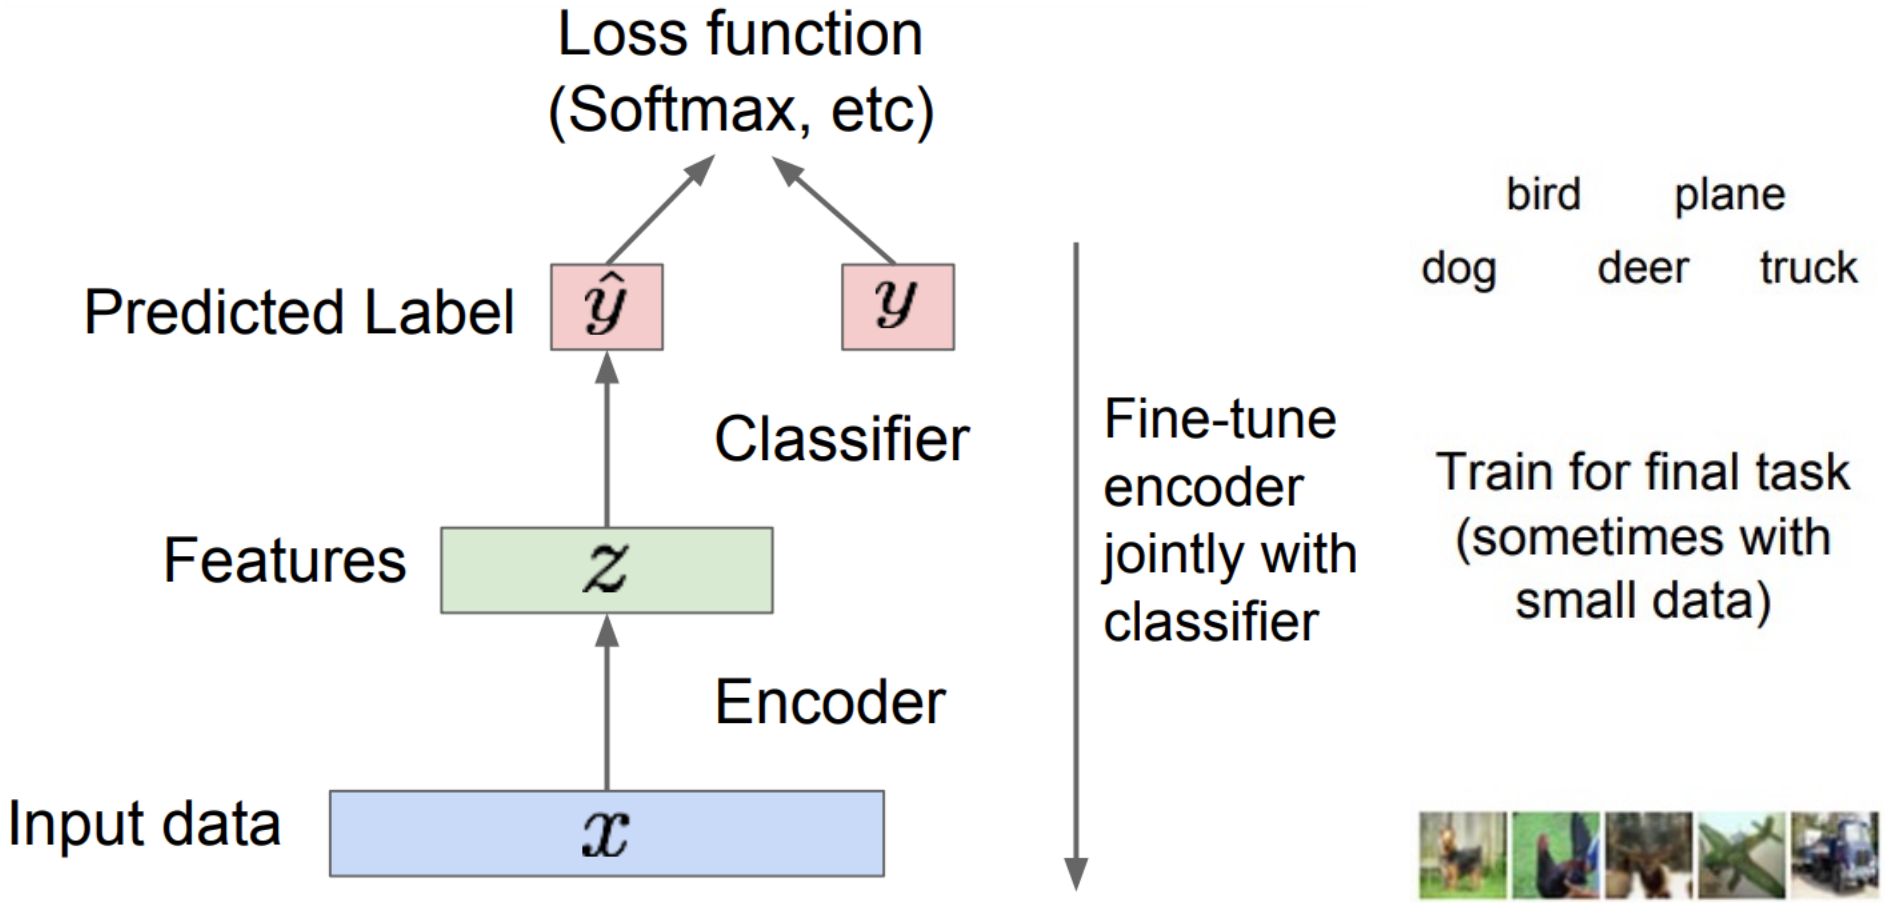
Some background first: Autoencoders



After training, throw away decoder

先介绍一些背景：自编码器

编码器可以
用于初始化一个
有监督 模型



传统自编码器的问题

背景：

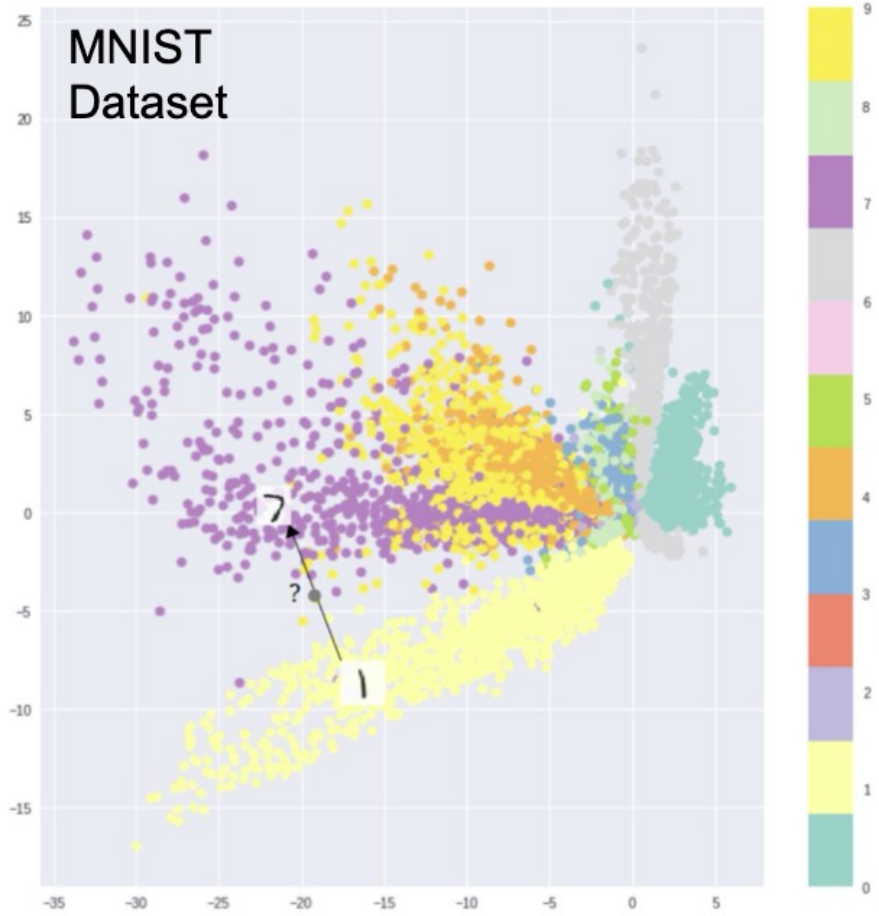
□如果你只是复现相同的图像，这没问题。

□ 如果我们不想复现你输入的同一张图像。你希望从连续潜在空间对输入图像生成变体。

问题：

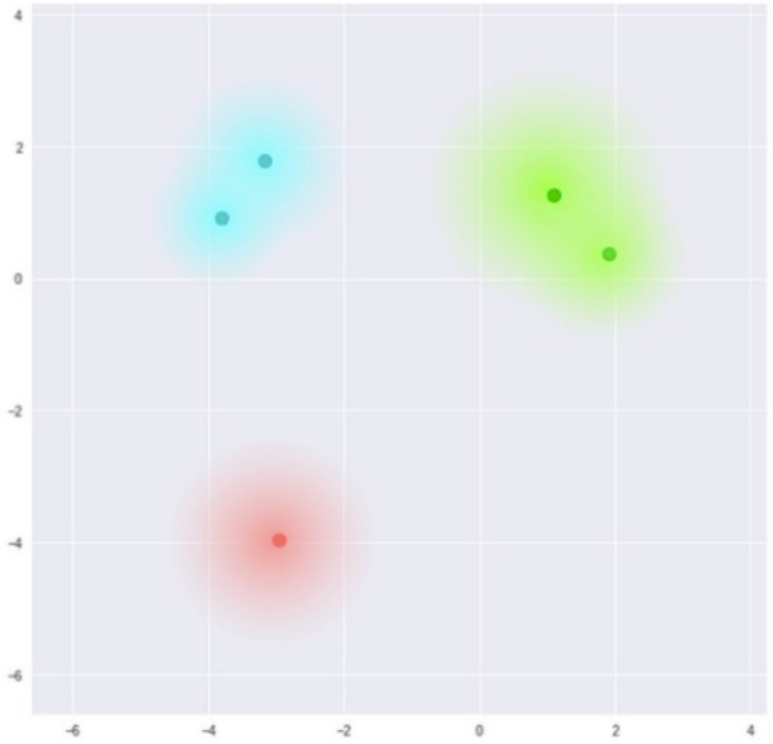
□ 编码后的向量可能不连续，或者无法轻松插值。

□ 由于不连续性（例如簇之间的间隙），解码器将很容易生成不真实的输出。

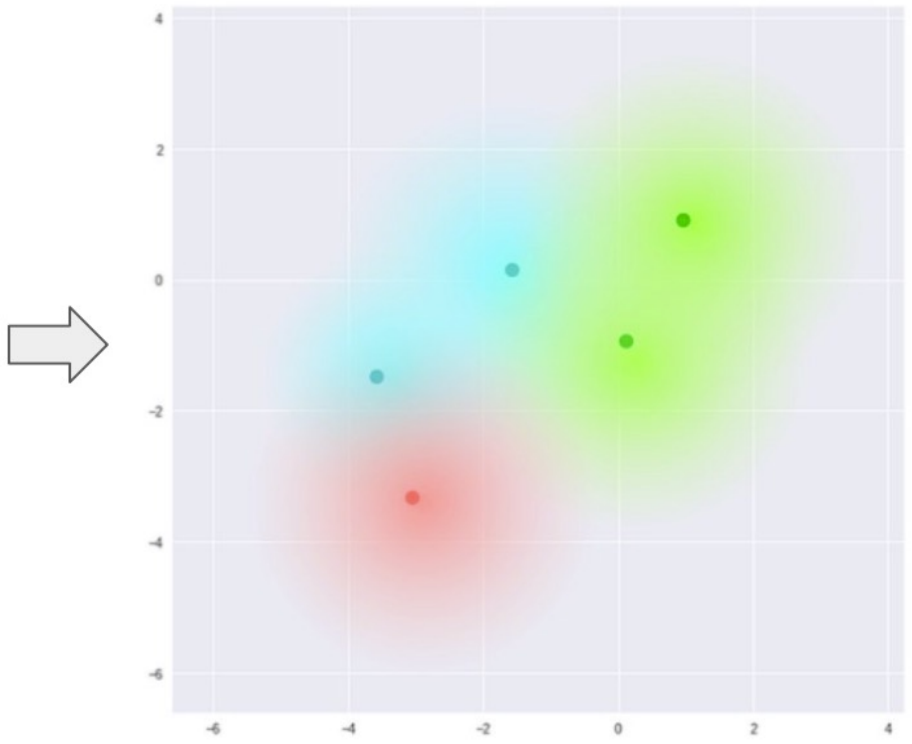


从二维空间可视化编码

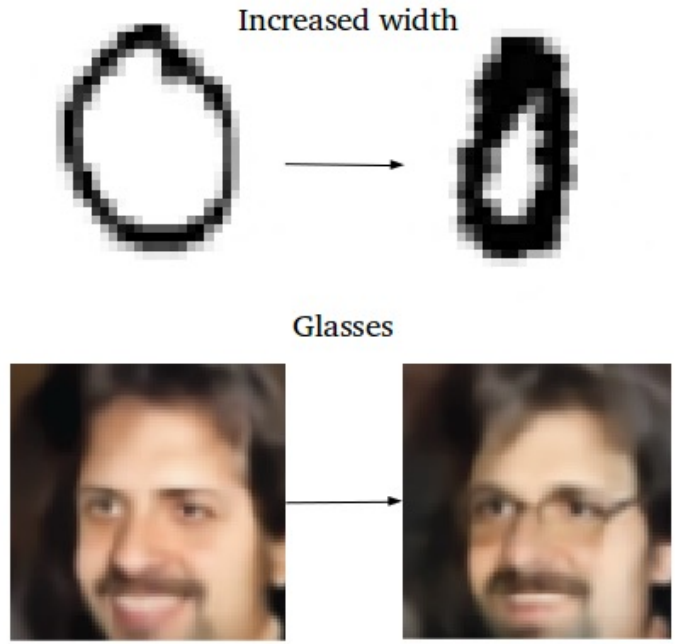
传统自编码器的问题



Autoencoders



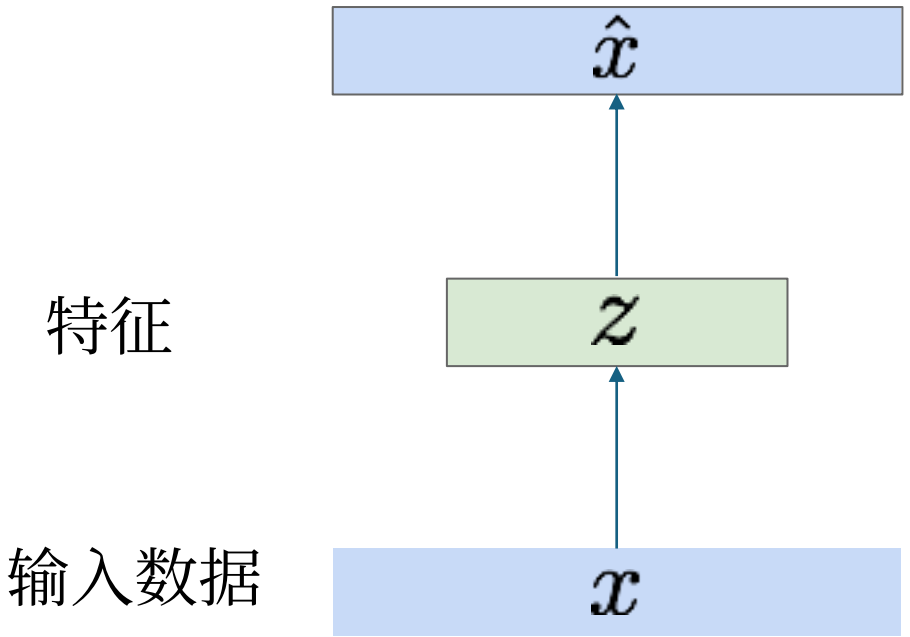
What we require



先介绍一些背景：自编码器

L2 损失函数：

$$\|x - \hat{x}\|^2$$



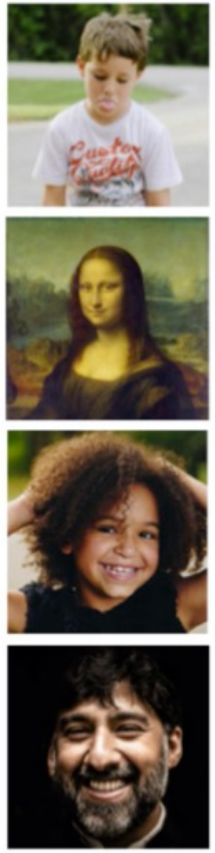
应用：

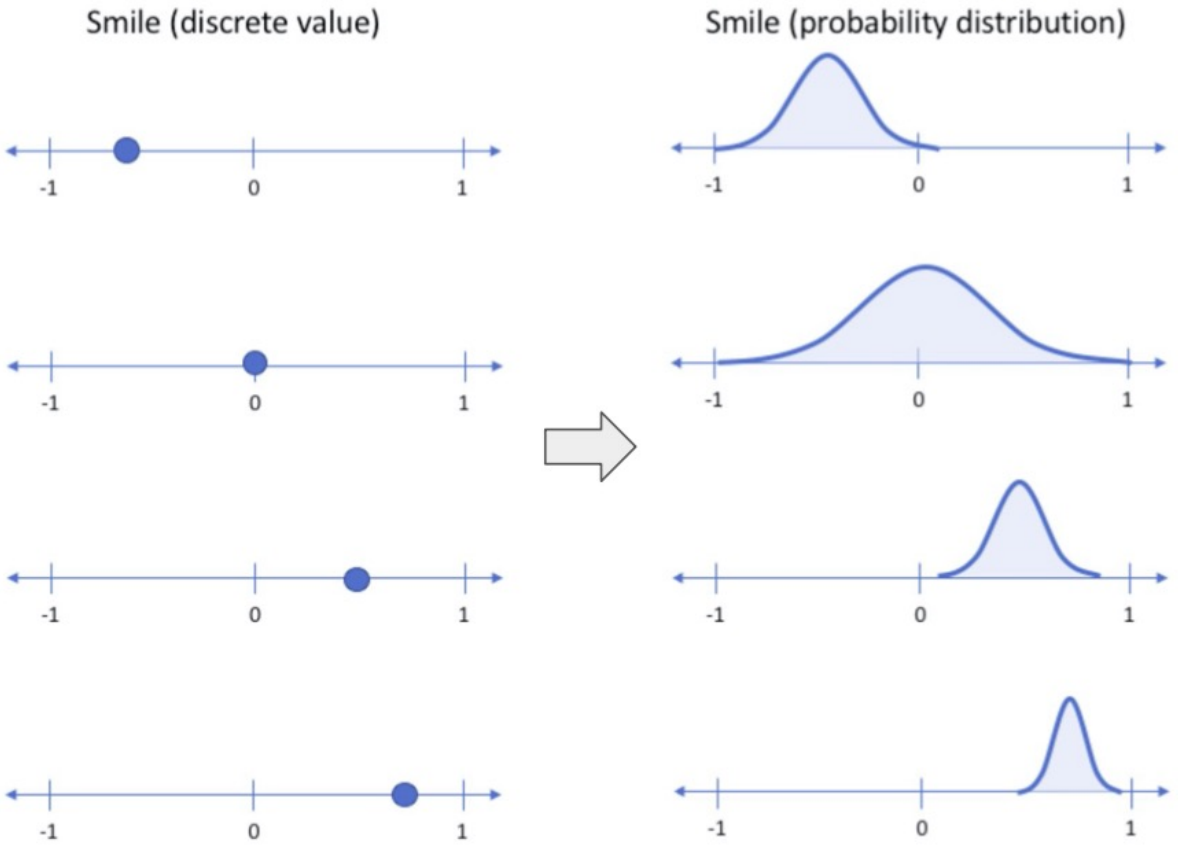
降维 特征学习 辅助学习 ...

Sut □e cu□t ge□erute □e□ □muge□ □rom u□ uutoe□coder3

我们如何使自编码器成为 **生成模型**?

VAE：与传统自编码器的关键区别





假设：

给定一个样本 X_k，对于 X_k，我们有一个专属分布 $P(Z|X_k)$

如何构造高斯分布？

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

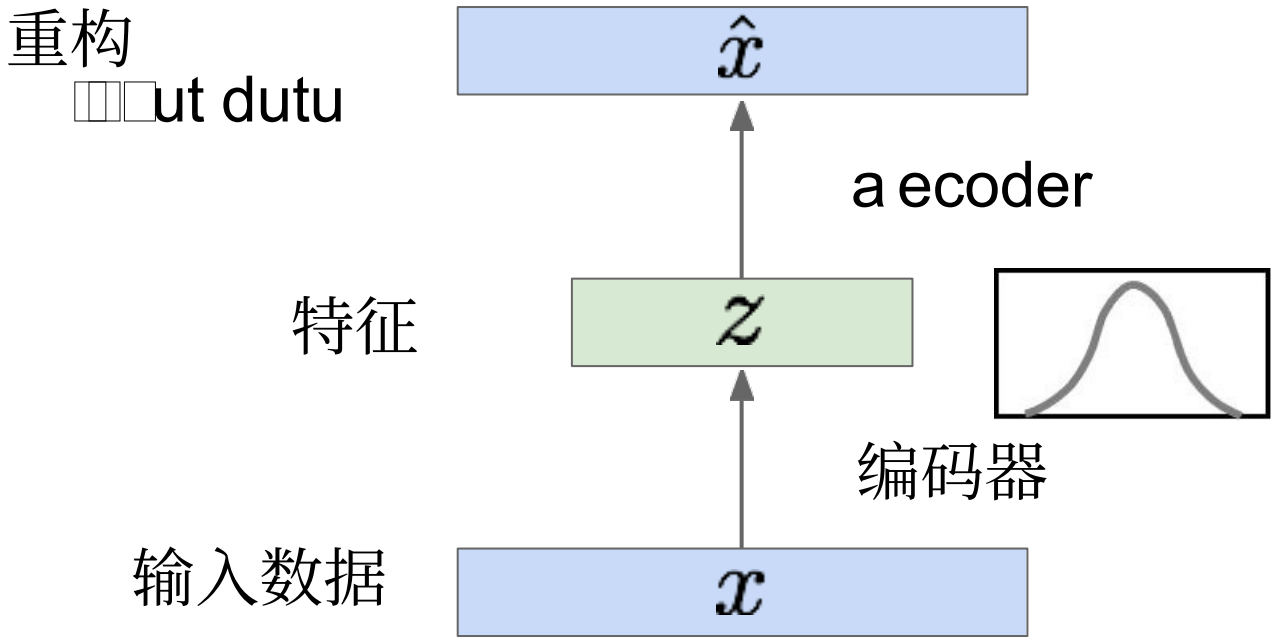
- μ = mean (center of the distribution)
- σ = standard deviation (spread of the distribution)

变分自编码器是对自编码器的一种概率化变体；从均值和方差中采样以计算潜在样本

JJ 的变分自编码器博客

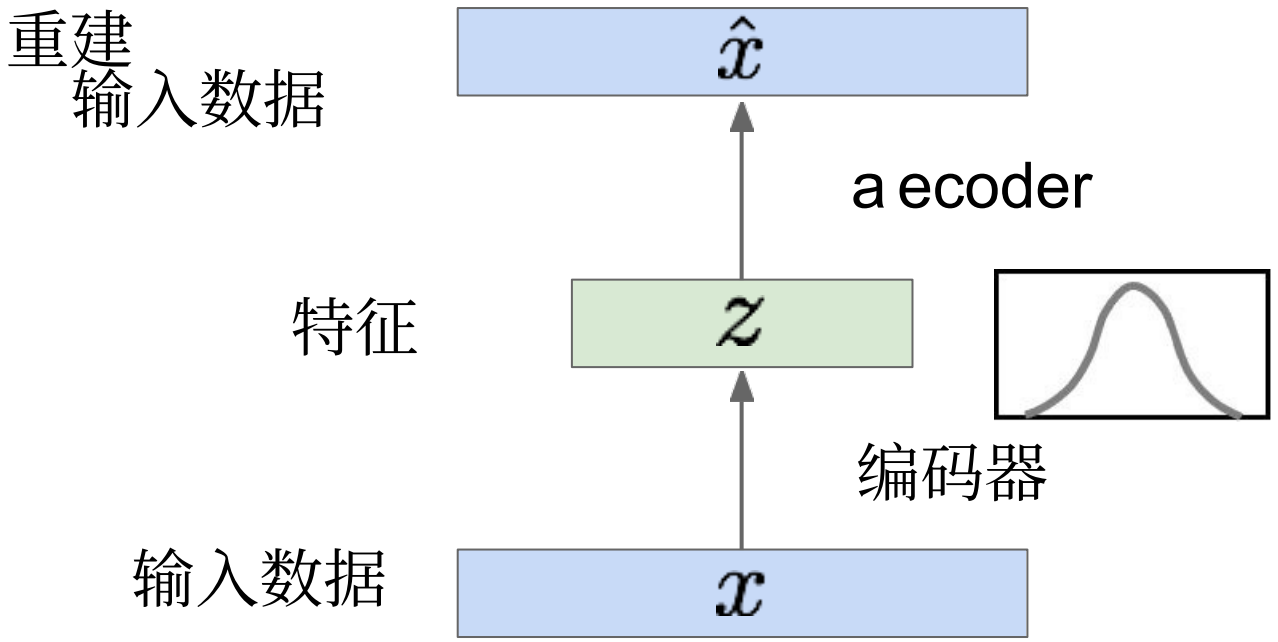
变分自编码器

假设潜在特征服从高斯分布。



变分自编码器

假设潜在特征服从高斯分布



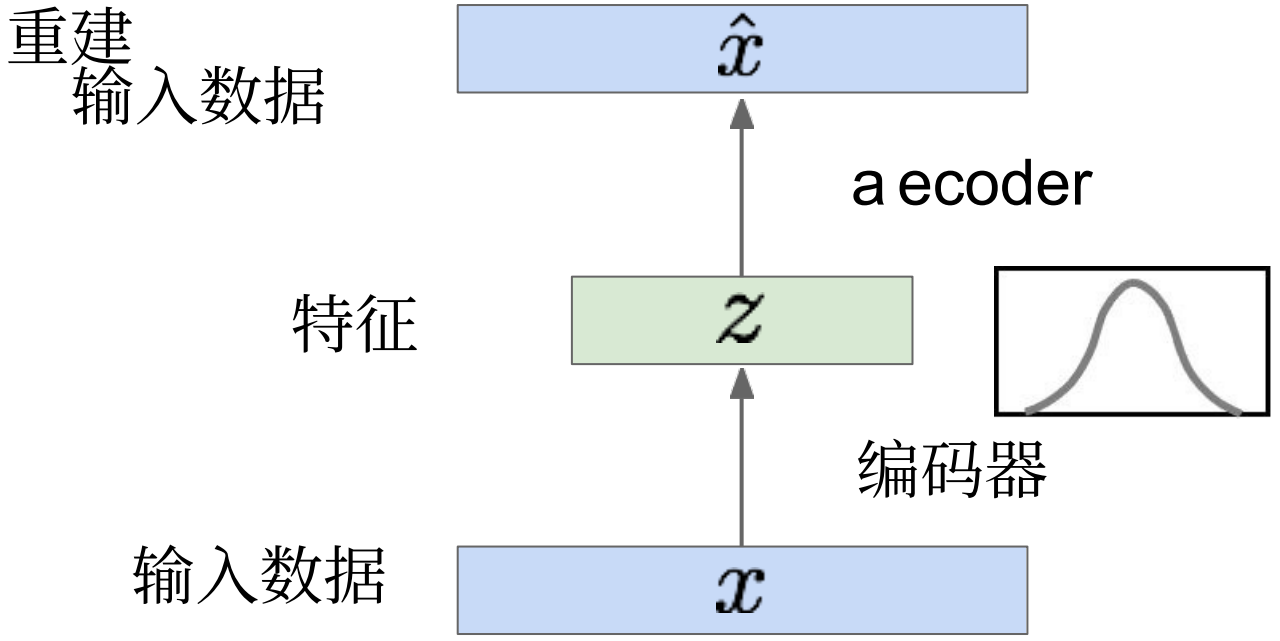
然后通过以下方式完成生成

1. 从高斯分布中采样 z。

变分自编码器

假设潜在特征服从高斯分布





然后，生成通过以下方式完成：

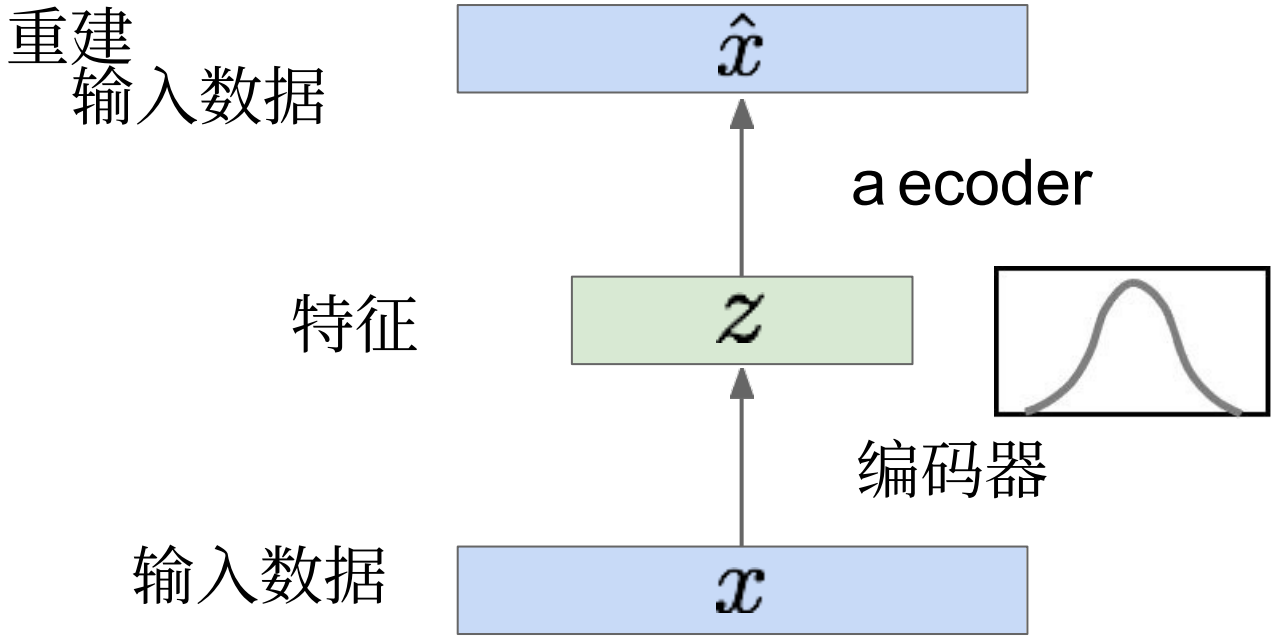
1. 从高斯分布中采样 z。

2. 将 z 前向传播到解码器以得到生成结果。

变分自编码器

假设潜特征服从高斯分布





然后，生成按以下方式进行

1. 从高斯分布中采样 z。

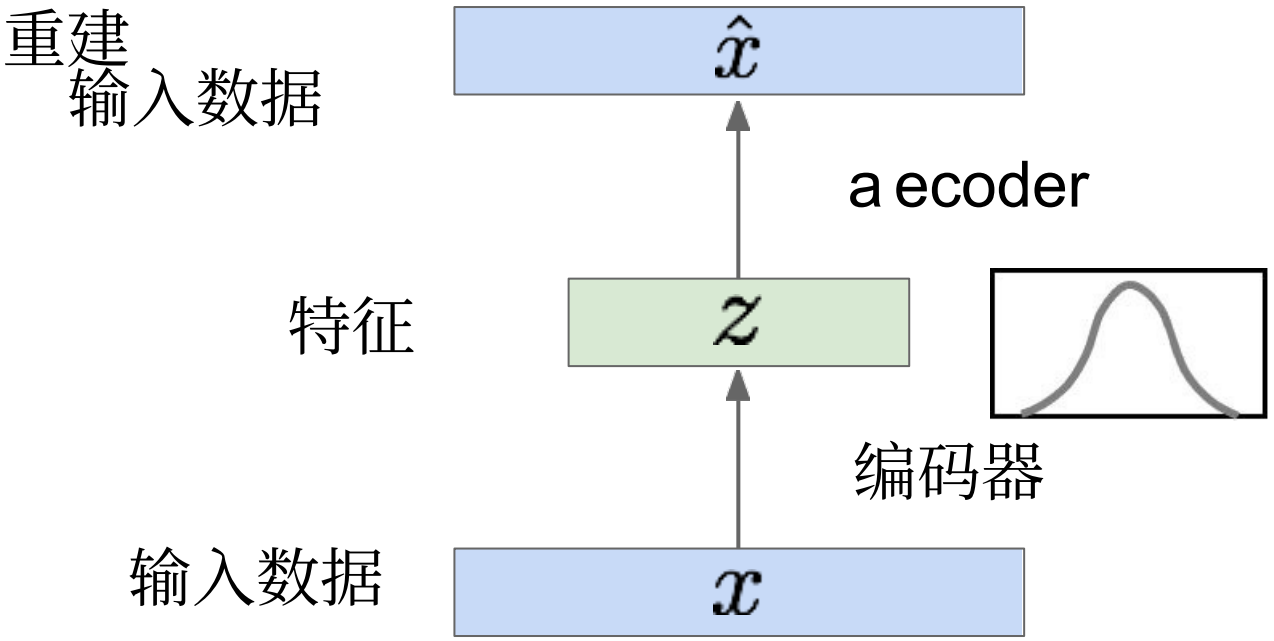
2. 将 z 前向传播到解码器，以获取生成结果。

关键问题：我们如何强制特征 z 服从高斯分布?

变分自编码器

关键问题：我们如何强制特征 z 服从高斯分布？





正则化：

$$L = \left|\left|x - \hat{x}\right|\right|^2 + D_{KL}\left(q(z|x)||p(z)\right)$$

这里D_{KL} 表示 KL 散度。$q(z|x)$：潜在分布。$p(z)$：标准高斯分布。

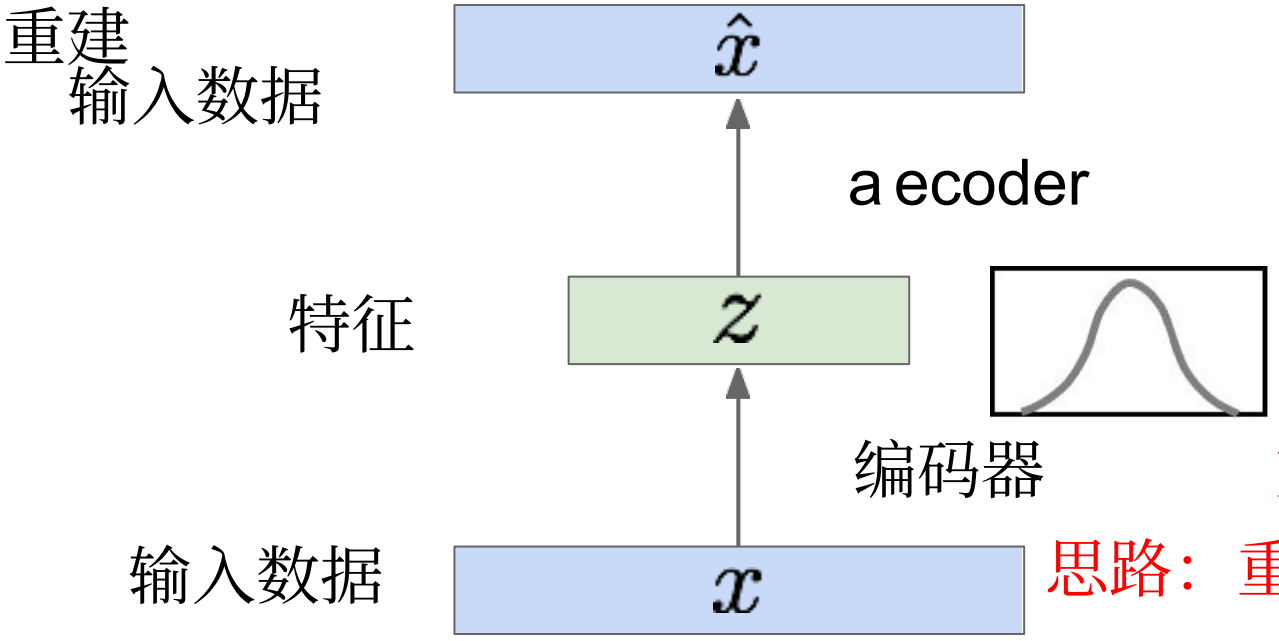
How to compute $D_{KL}\left(q(z|x)||p(z)\right)$?

难点：z 是确定性的。但 $p(z)$ 是一个分布。如何衡量它们的损失?

变分自编码器

关键问题：我们如何使特征 z 服从高斯分布？





正则化：

$$L = \left|\left|x - \hat{x}\right|\right|^2 + D_{KL}\left(q(z|x)||p(z)\right)$$

这里 D_{KL} 表示 KL 散度。$q(z|x)$：潜在分布。$p(z)$：标准高斯分布。

如何计算 D_{KL} $q(z|x)||p(z)$?

思路：重参数化技巧。

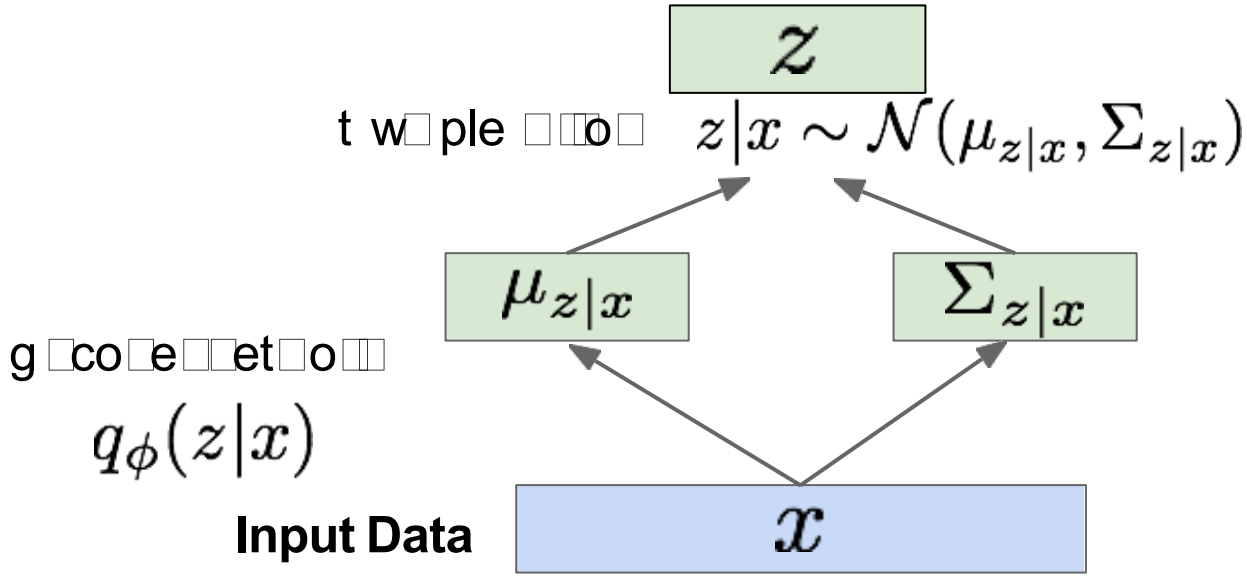
$$z = \mu + \sigma \cdot \varepsilon$$

其中 ε 从标准高斯分布中采样。

da1iatiwatA. twmvi wt m12

现在，正则化项可通过下式计算：

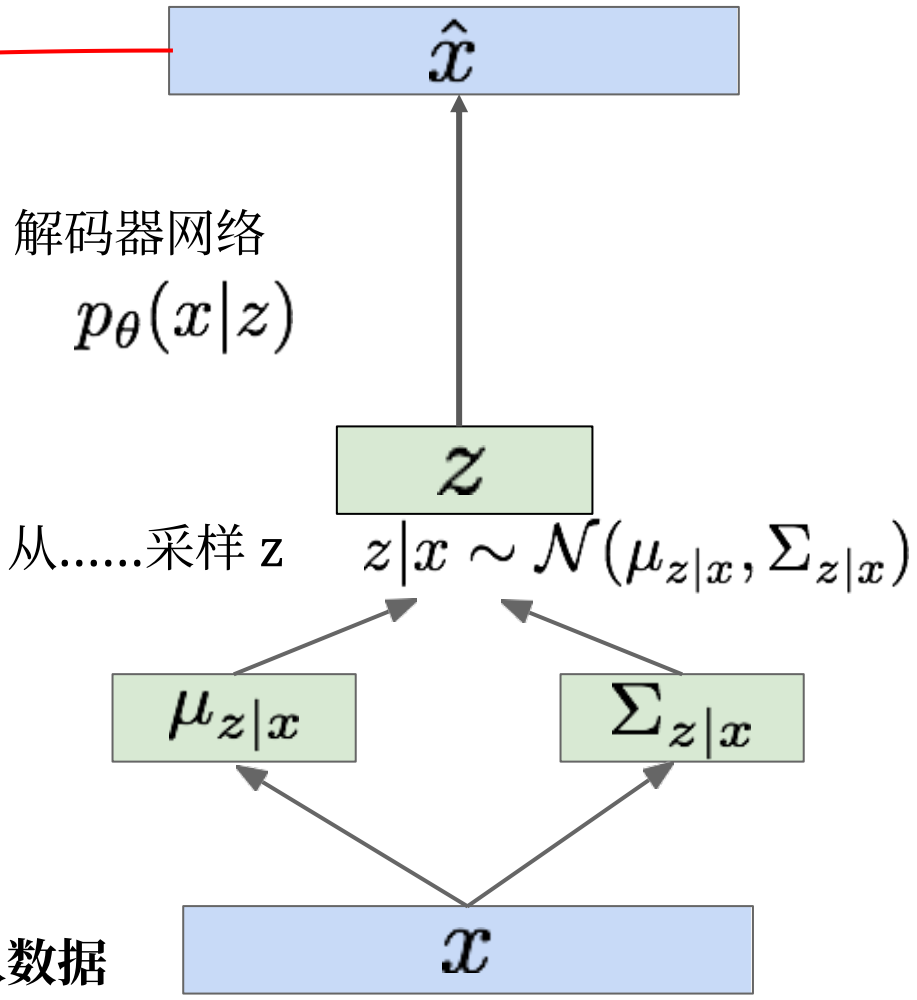
$$D_{KL}\big(q(z|x)||p(z)\big) = \frac{2}{\cdot}\hat{} \sum_{i=1}^{n} \big(__i^2 + \mu_i^2 - 2 - \log __i^2\big)$$



变分自编码器

最大化原始数据的似然
正在重建的输入

$$L = \left|\left|\ \ \ \ \ \ \ \ \right|\right|^2 + D_{KL}\left(q(z|x)||p(z)\right)$$



https://colab.research.google.com/drive/1C[illegible]kIFH7p8g8p7eNDtf5sgt25o4dXb?usp=sharing

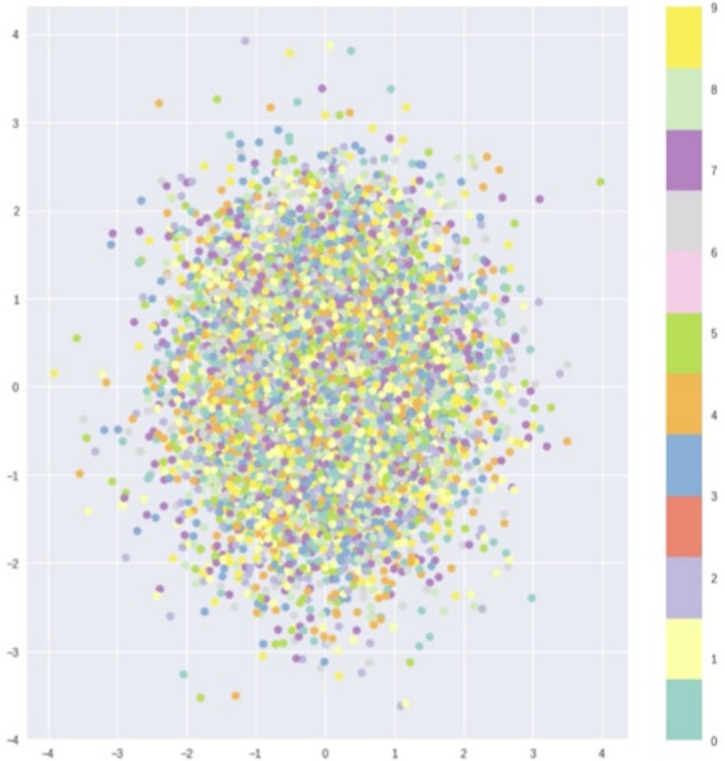
Priors on the latent distribution

Inferred latent distribution

Fixed prior on laten distribution

$$D(q_\phi(z|x) \,||\, p(z)) = -\frac{1}{2}\sum_{j=0}^{k-1}(\sigma_j + \mu_j^2 - 1 - \log \sigma_j)$$

KL-divergence between the two distributions



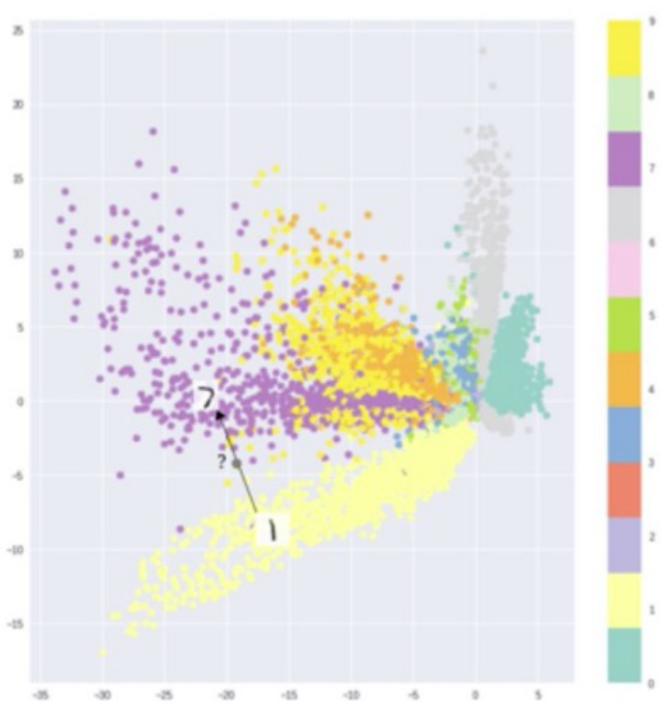
Common choice of prior:

$p(z) = \mathcal{N}(\mu = 0, \sigma^2 = 1)$

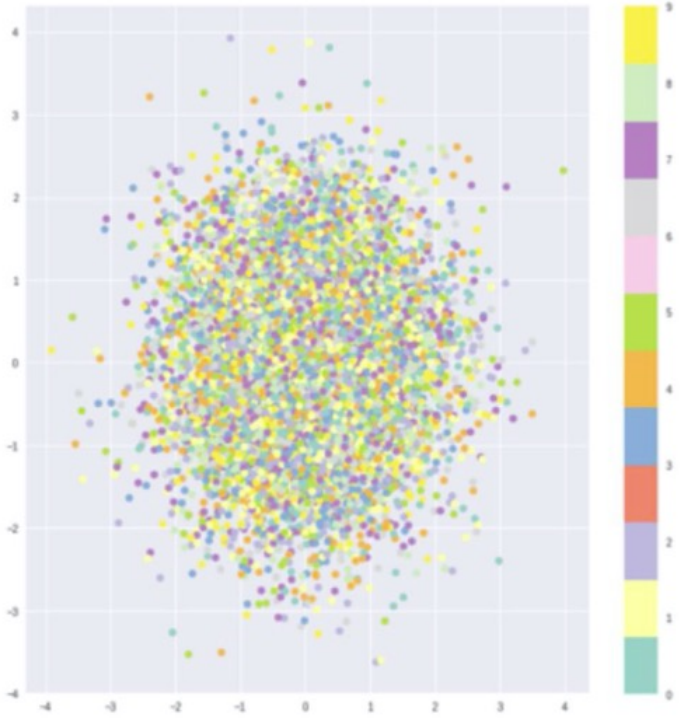
- Encourages encodings to distribute encodings evenly around the center of the latent space
- Penalize the network when it tries to “cheat” by clustering points in specific regions (ie. memorizing the data)

VAE Optimization

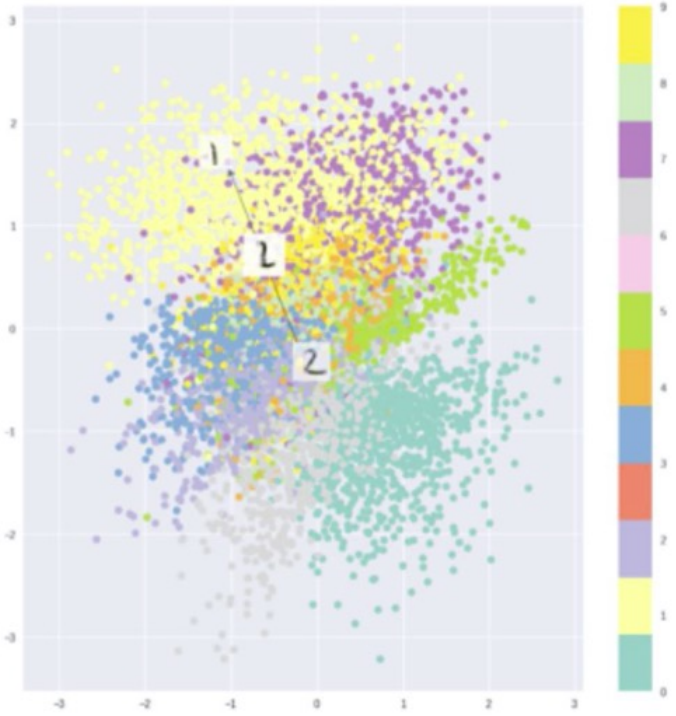
Only reconstruction loss



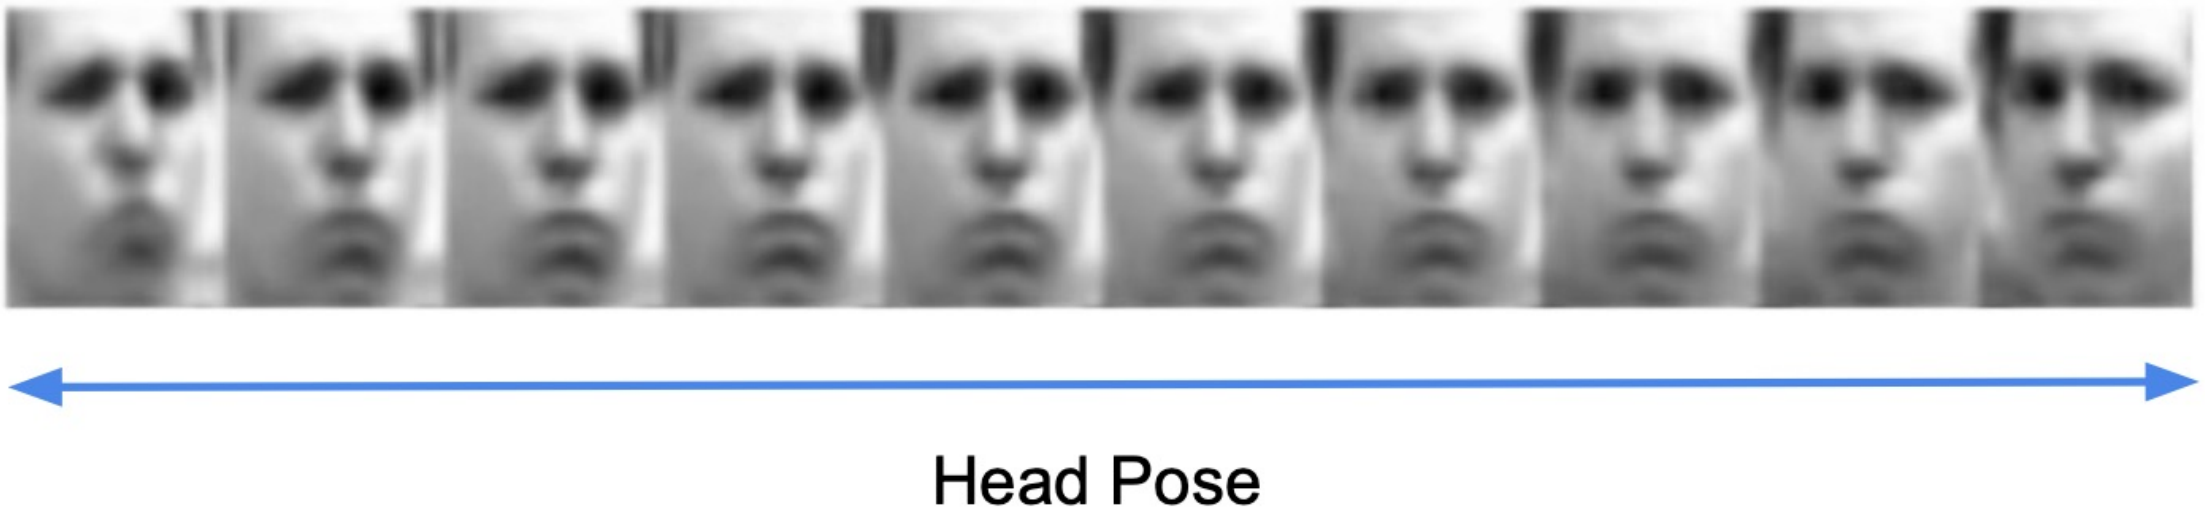
Only KL divergence



Combination

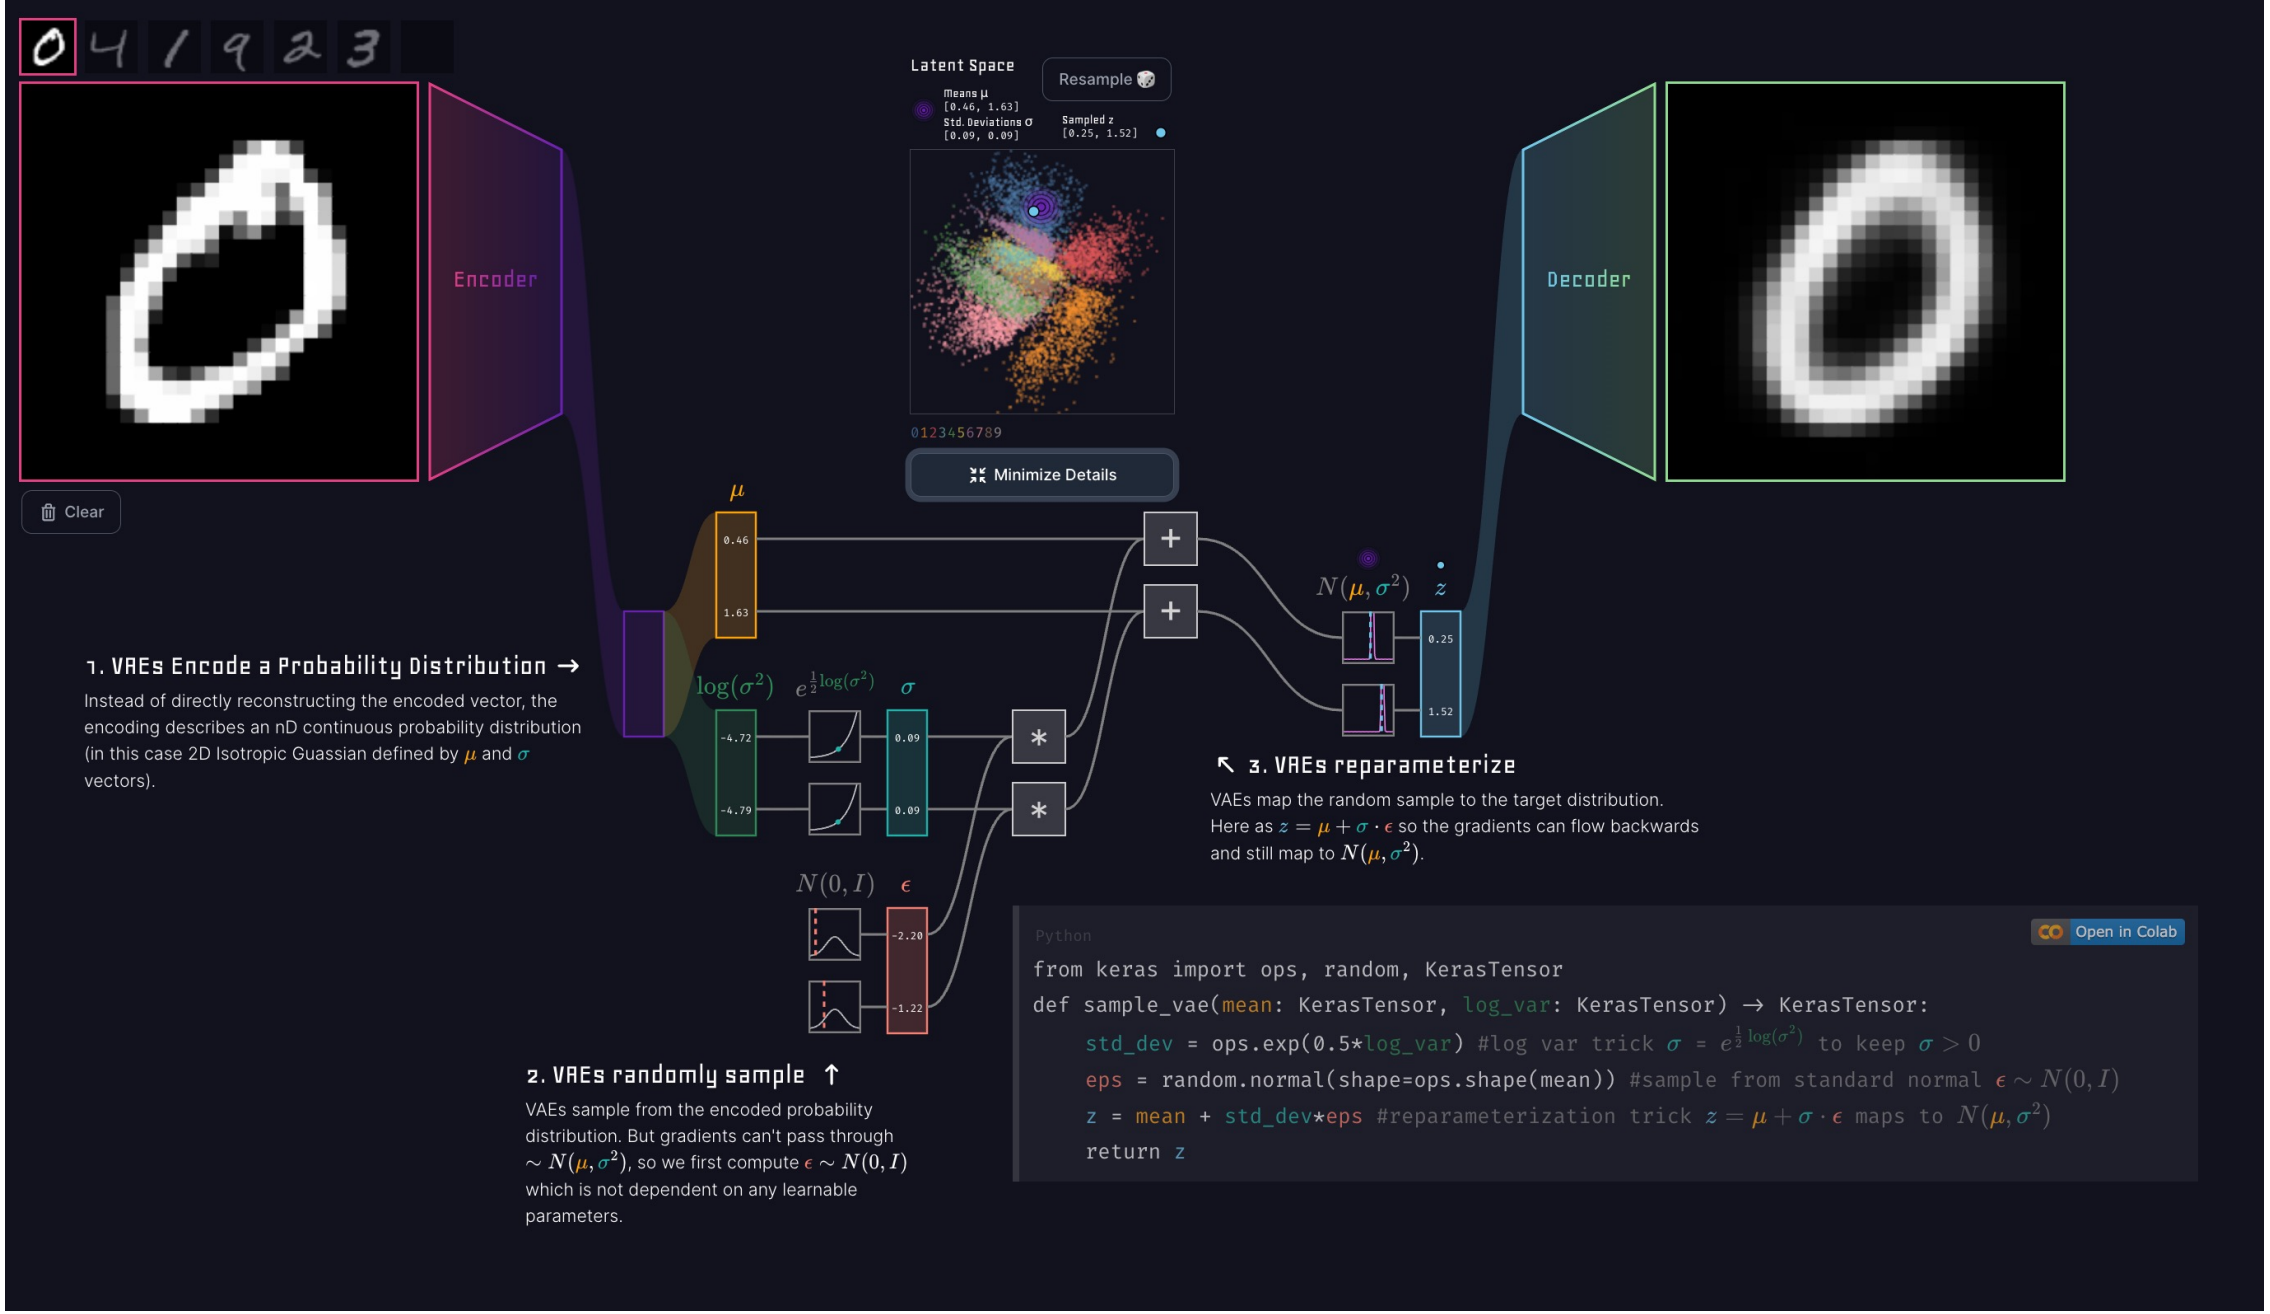


VAE：潜在扰动



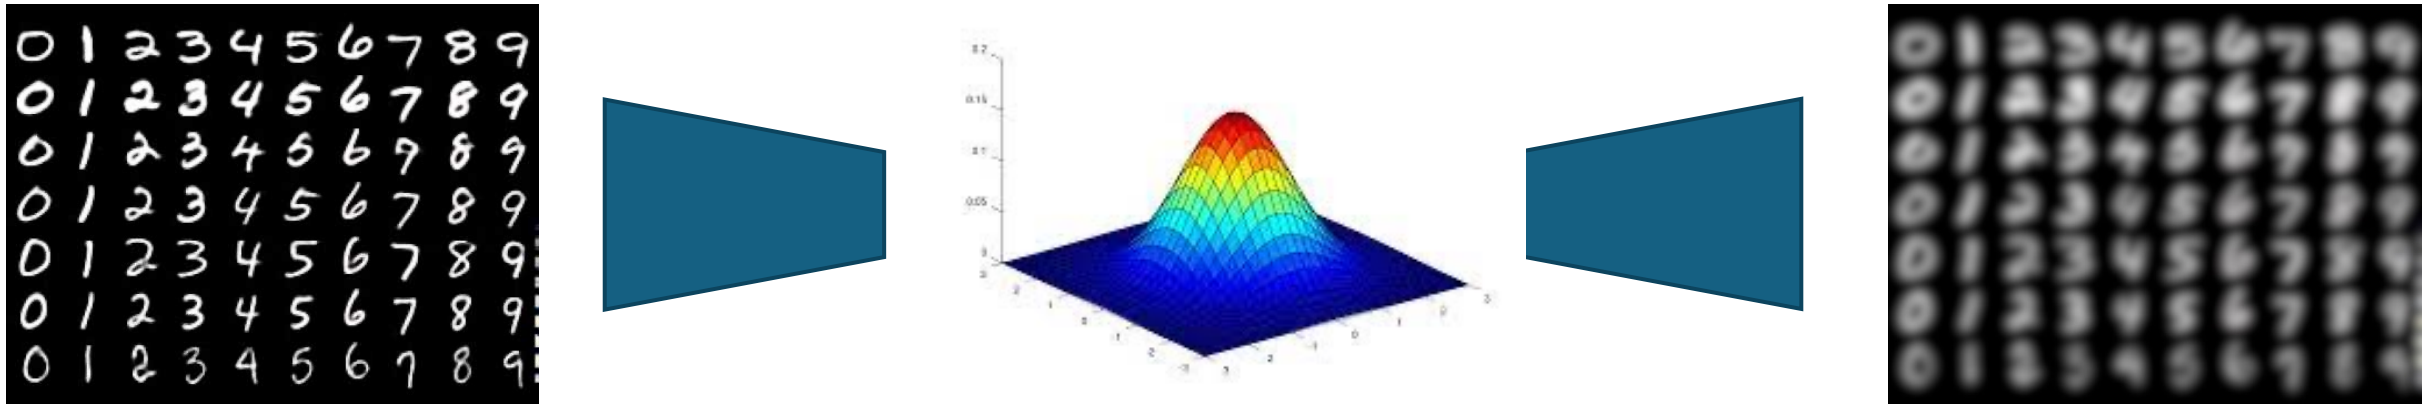
z 的不同维度编码了不同的可解释潜在特征

https://colab.researc h.google.com/drive/1cBumzL8jnfENDMykNFsx06os-xZv2pa t



https://www.donnybertucci.com/project/vae-explainer

为什么模糊?

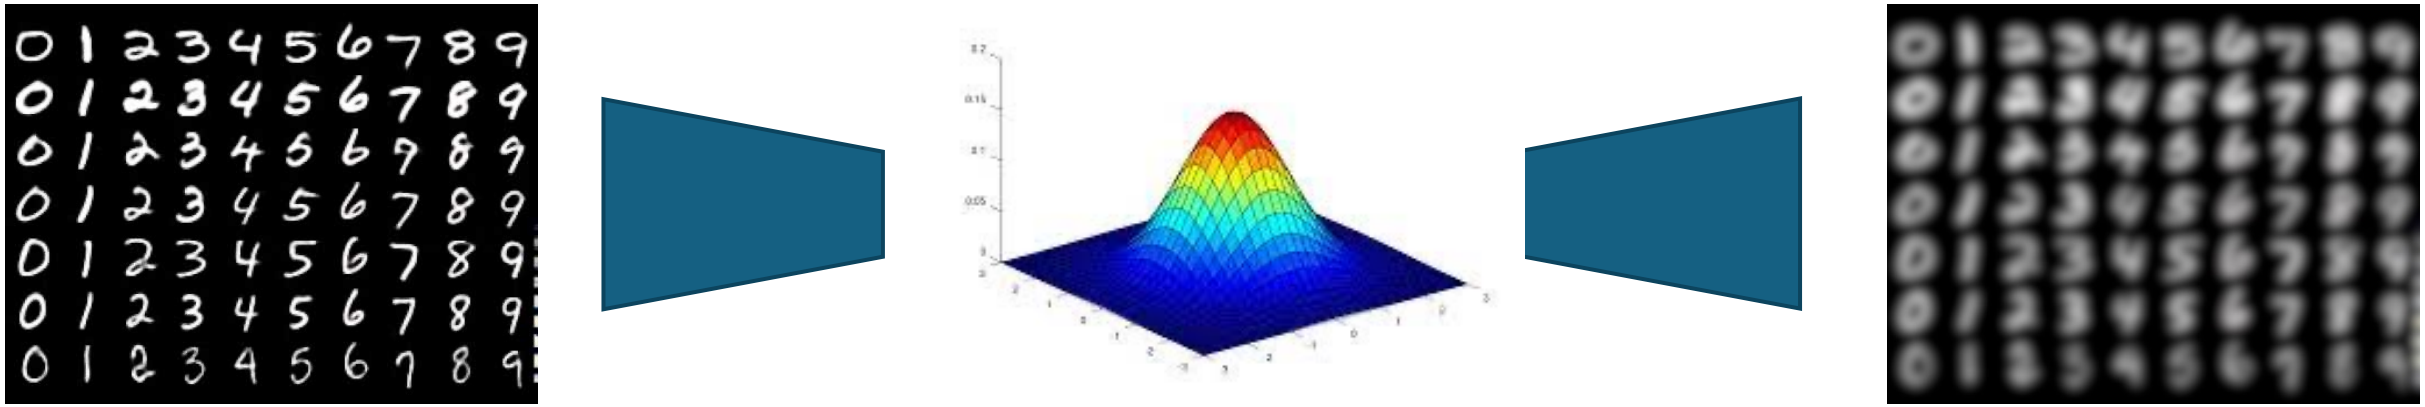


一个原因：**平均效应**。
我们的数据通常具有多个模式（例如，mnist 中的 ）。VAE 强制将 **多模式**数据分布转换为 **单模式**高斯分布。因此，它可能通过平均这些模式的特征来表示它们。在生成阶段，它可能生成位于不同模式“之间”的样本，这些样本可能模糊。

此外，**像素-　　级重建损失** 也会导致平均效应

Generative Adversarial Networks (GANs)

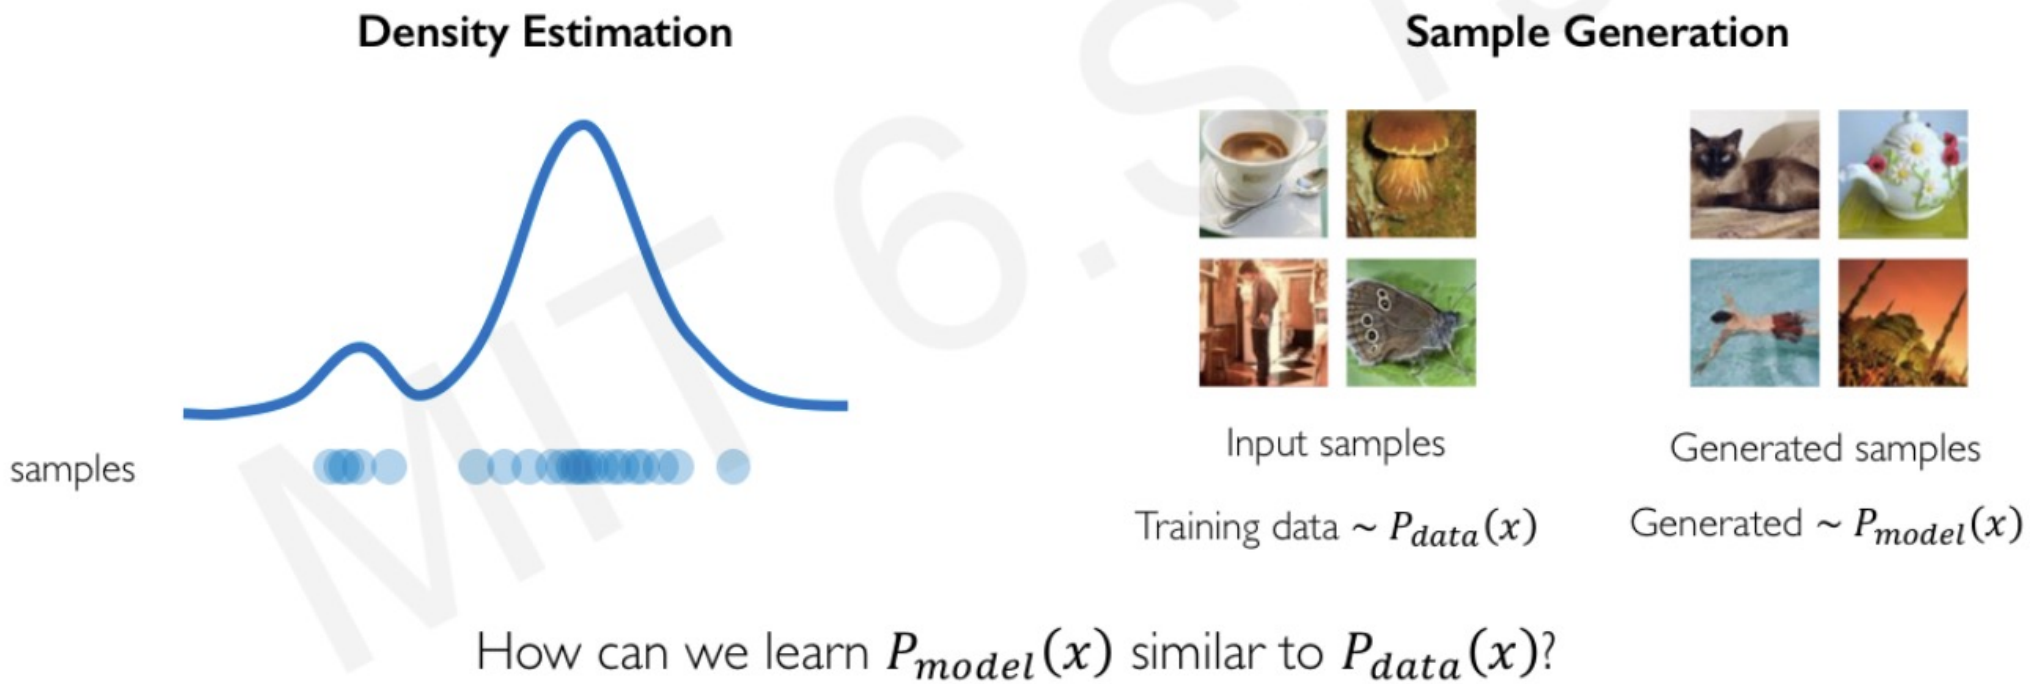
dAE?omvm1atm1 2au ytm2 ha:mtiu itm1 l i:m12it??



GAN 解决了这个问题。

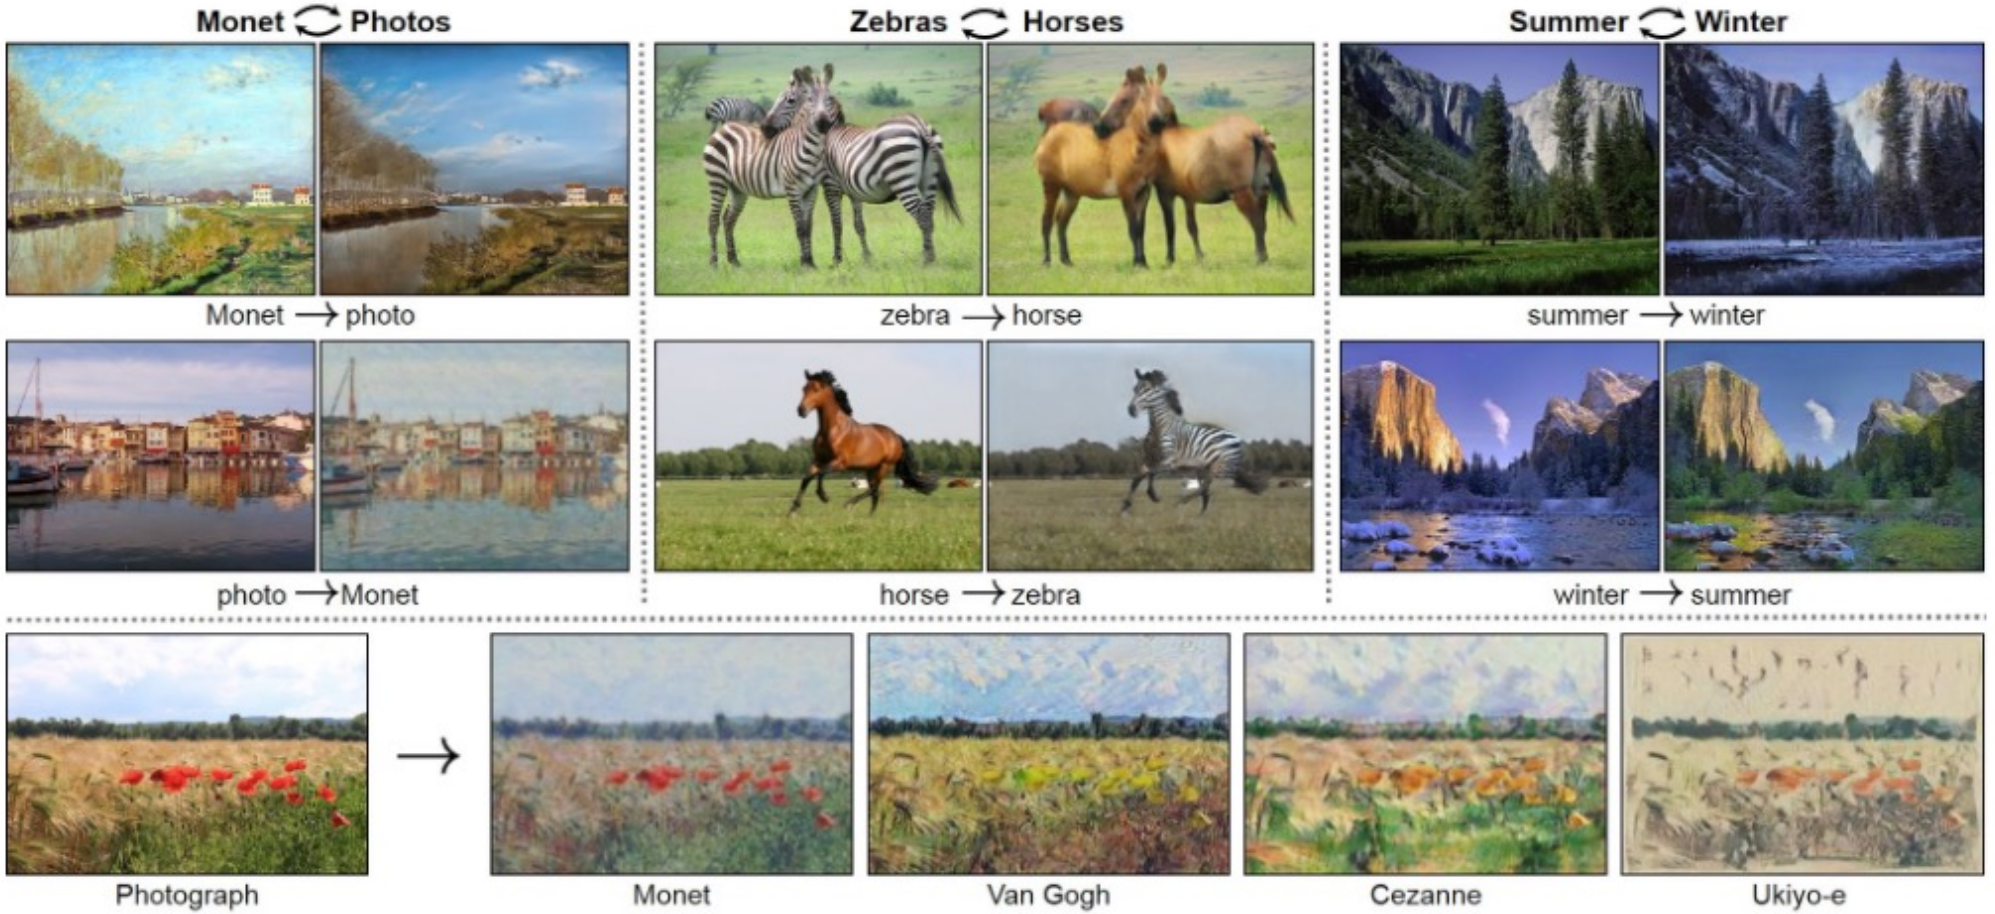
Generative Models

目标：从某种分布中抽取训练样本作为输入，并学习一个表示该分布的模型



生成模型

给定训练数据，从同一分布中生成新样本

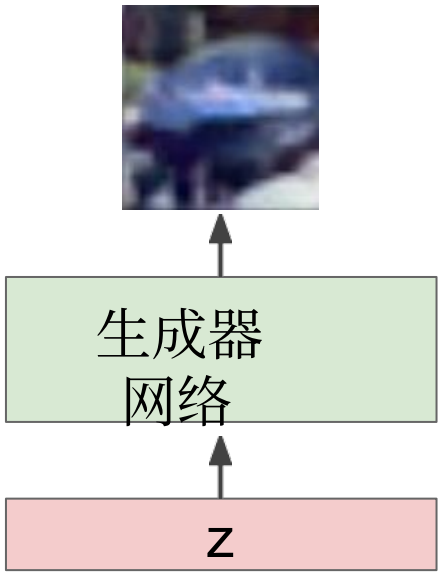


生成对抗网络

Ian Goodfellow 等，“Generative Adversarial Nets”，NIPS 2014

输出：来自训练分布的样本

输入：随机噪声

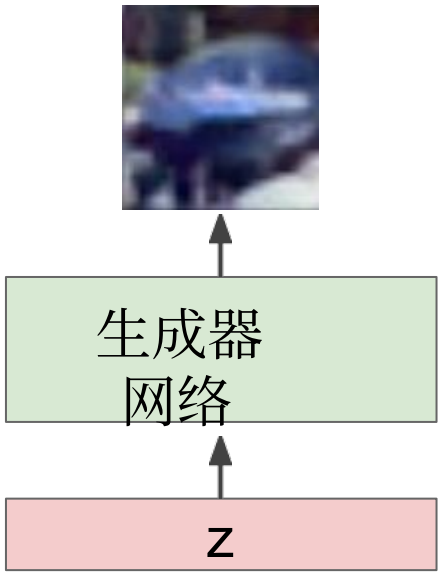


生成对抗网络

Ian Goodfellow 等， “Generative Adversarial Nets”， NIPS 2014

我们不知道哪个样本 z 映射到哪张训练图像——R 无法通过重建训练图像来学习

输出：采样自训练图像分布



输入：随机噪声

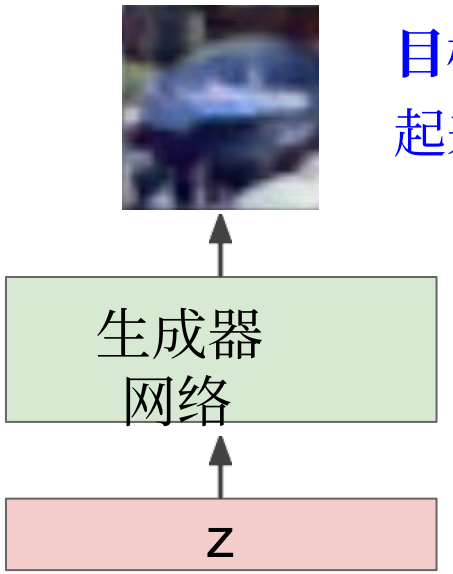
来自 高斯分布

生成对抗网络

Ian Goodfellow 等，“生成对抗网络”，NIPS 2014

我们不知道哪个样本 z 映射到哪张训练图像 -R 无法通过重建训练图像来学习

输出：来自训练图像分布的样本



目标：生成的图像应当看起来“真实”

Input: Random no□z
•□om b au□□an d□t□s ut□on

生成对抗网络

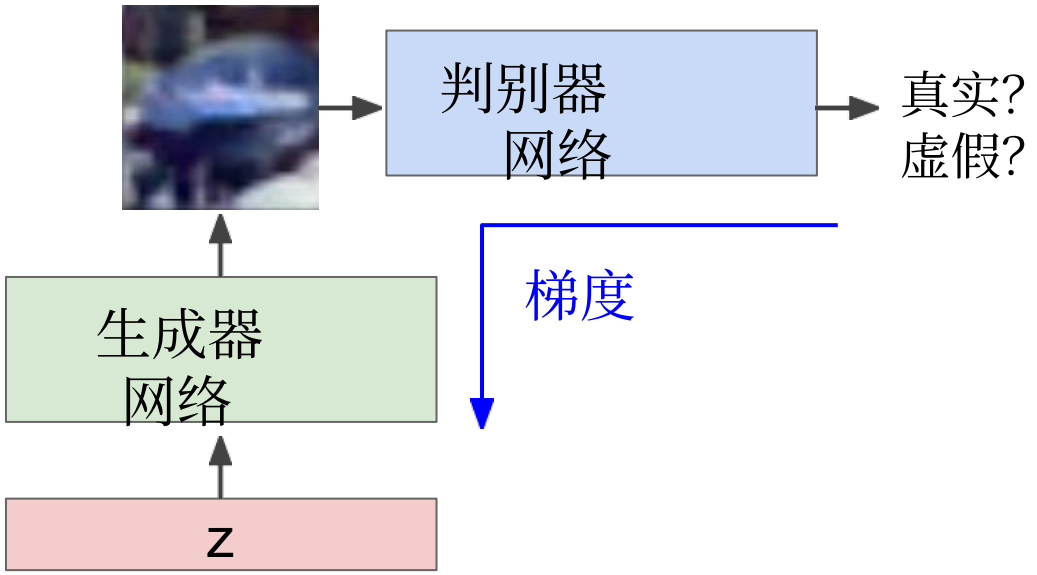
Ian Goodfellow 等，“Generative Adversarial Nets”，NIPS 2014

我们不知道哪个样本 z
映射到哪张训练图像 -R
无法通过重建训练图像
来学习

解决方案：使用判别器网络来判断生成的图像是否在数据分布内（“真实”）

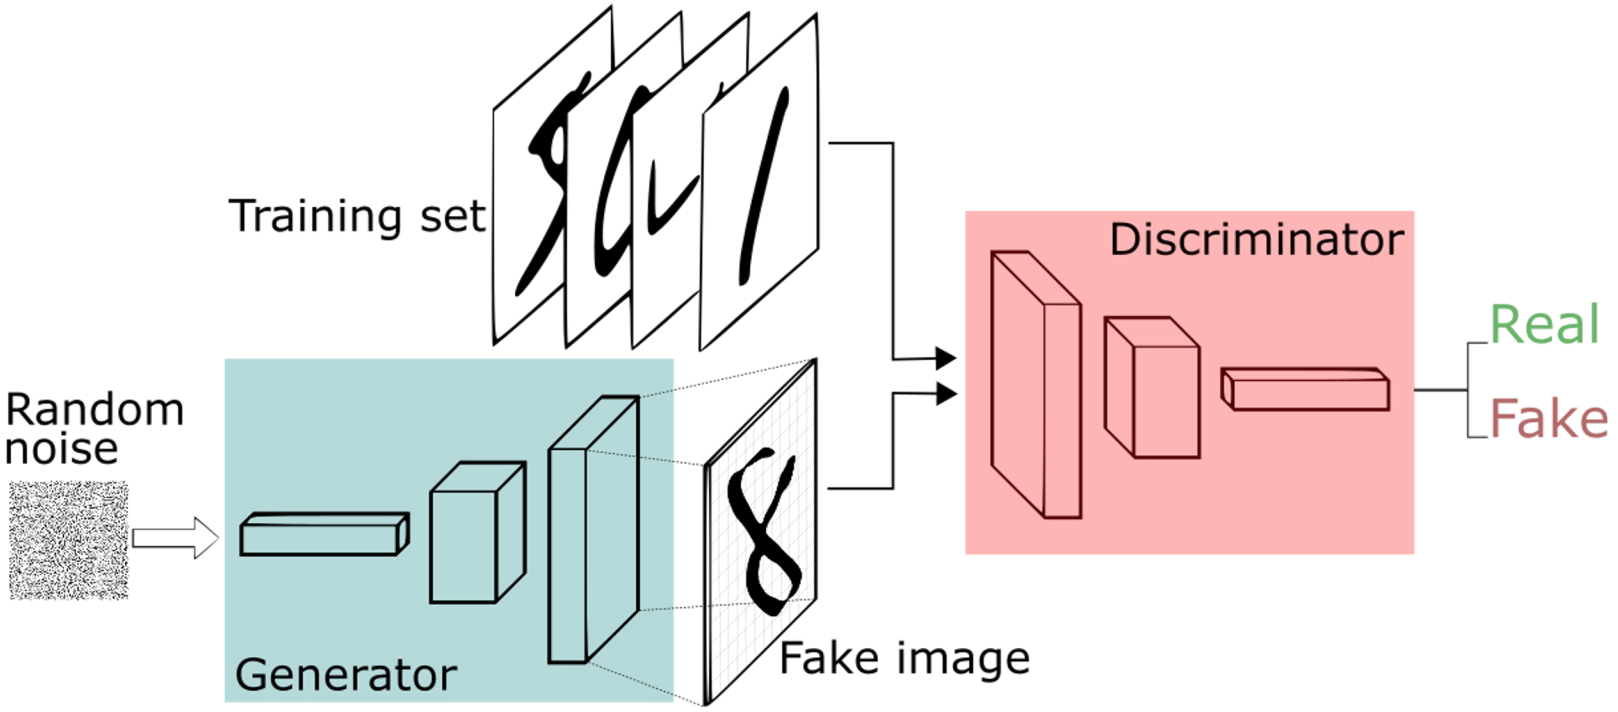
输出：采样自训练图像分布

输入：来自 高斯分布的随机噪声



训练GANs：双人博弈

GANs 是一种通过让两个神经网络相互竞争来构建生成模型的方法。



对于每个批次（步骤）

1. 训练 D，固定 G；2. 训练 G，固定 D，试图欺骗 D，告诉 D 假图像是真实的

训练GAN：双人博弈

Ian Goodfellow 等，“生成对抗网络”，NIPS 2014

判别器网络：试图区分真实图像和假图像 **生成器网络**：试图通过生成看起来真实的图像来欺骗判别器

在**极小极大博弈中联合训练**

极小极大目标函数：

$$\min_{\theta_g} \max_{\theta_d} \left[\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z))) \right]$$

生成器目标 判别器目标

训练 GANs：双人博弈

Ian Goodfellow 等，“生成对抗网络”，NIPS 2014

判别器网络：试图区分真实图像和虚假图像 **生成器网络**：试图通过生成看起来逼真的图像来欺骗判别器

在**极小极大博弈**中联合训练

判别器输出真实图像的似然度，取值范围为 (0,1)

极小极大目标函数：

$$\min_{\theta_g} \max_{\theta_d} \left[\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z))) \right]$$

f isc i i wto output
o ewl wtwx

f isc i i wto output o
e e wte w e wtwk) D

训练 GANs：双人博弈

Ian Goodfellow 等，“生成对抗网络”，NIPS 2014

判别器网络：尝试区分真实图像与虚假图像 **生成器网络**：通过生成看起来真实的图像来欺骗判别器

在**极小极大博弈**中联合训练

判别器输出真实图像的似然，取值在 (0,1) 内

极小极大目标函数：

$$\min_{\theta_g} \max_{\theta_d} \left[\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z))) \right]$$

$D_{\theta_d}(x)$：判别器输出对于真实数据 x

$D_{\theta_d}(G_{\theta_g}(z))$：判别器输出，针对生成的假数据 G(z)

训练 GAN：双人博弈

Ian Goodfellow 等，“生成对抗网络”，NIPS 2014

判别器网络：尝试区分真实图像与虚假图像 **生成器网络**：通过生成看起来真实的图像来欺骗判别器

在 **极小极大博弈** 中联合训练

判别器输出真实图像的似然，取值在 (0,1) 内

极小极大目标函数：

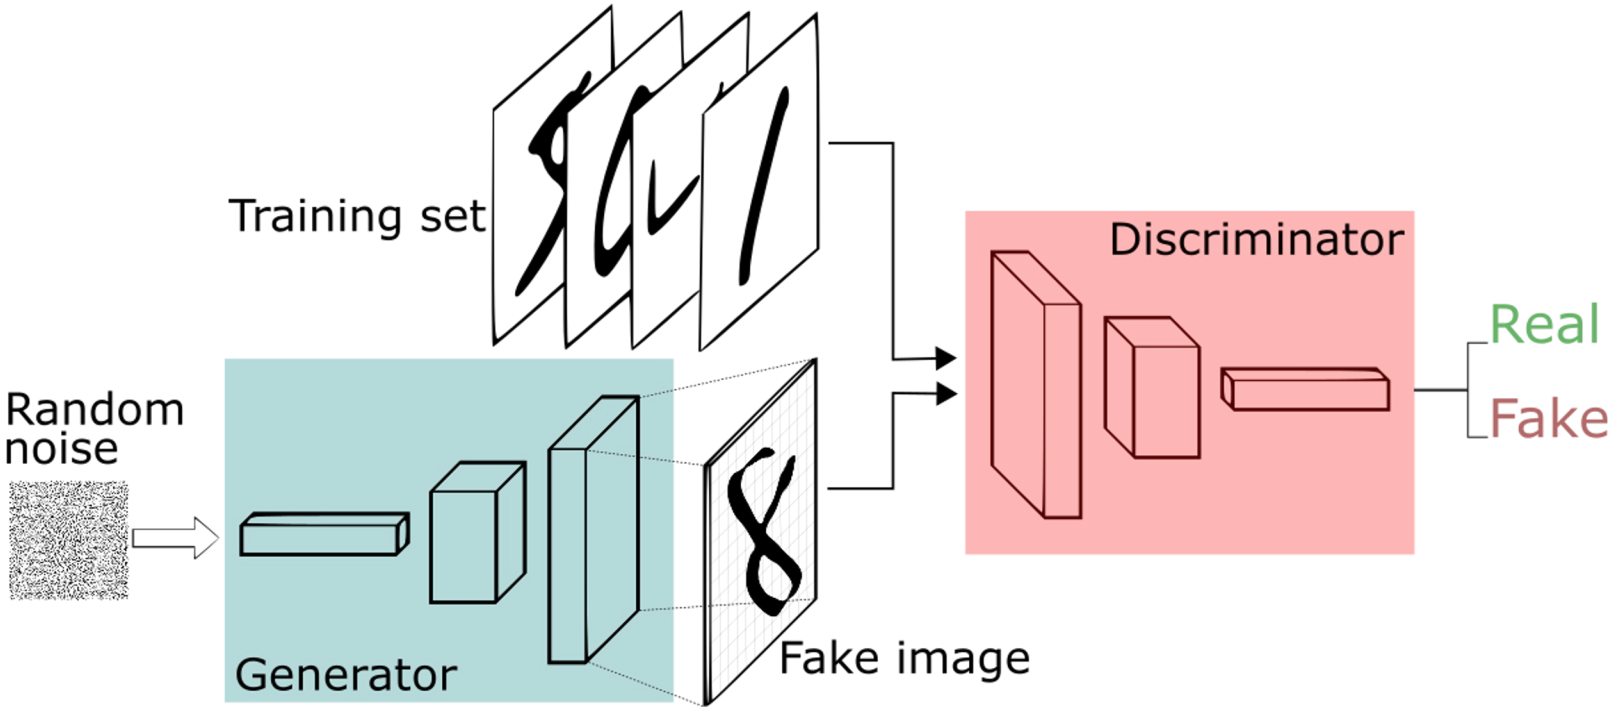
$$\min_{\theta_g} \max_{\theta_d} \left[\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z))) \right]$$

判别器输出对于真实数据 x

判别器针对……的输出生成的假数据 G(z)

训练 GAN：双人博弈

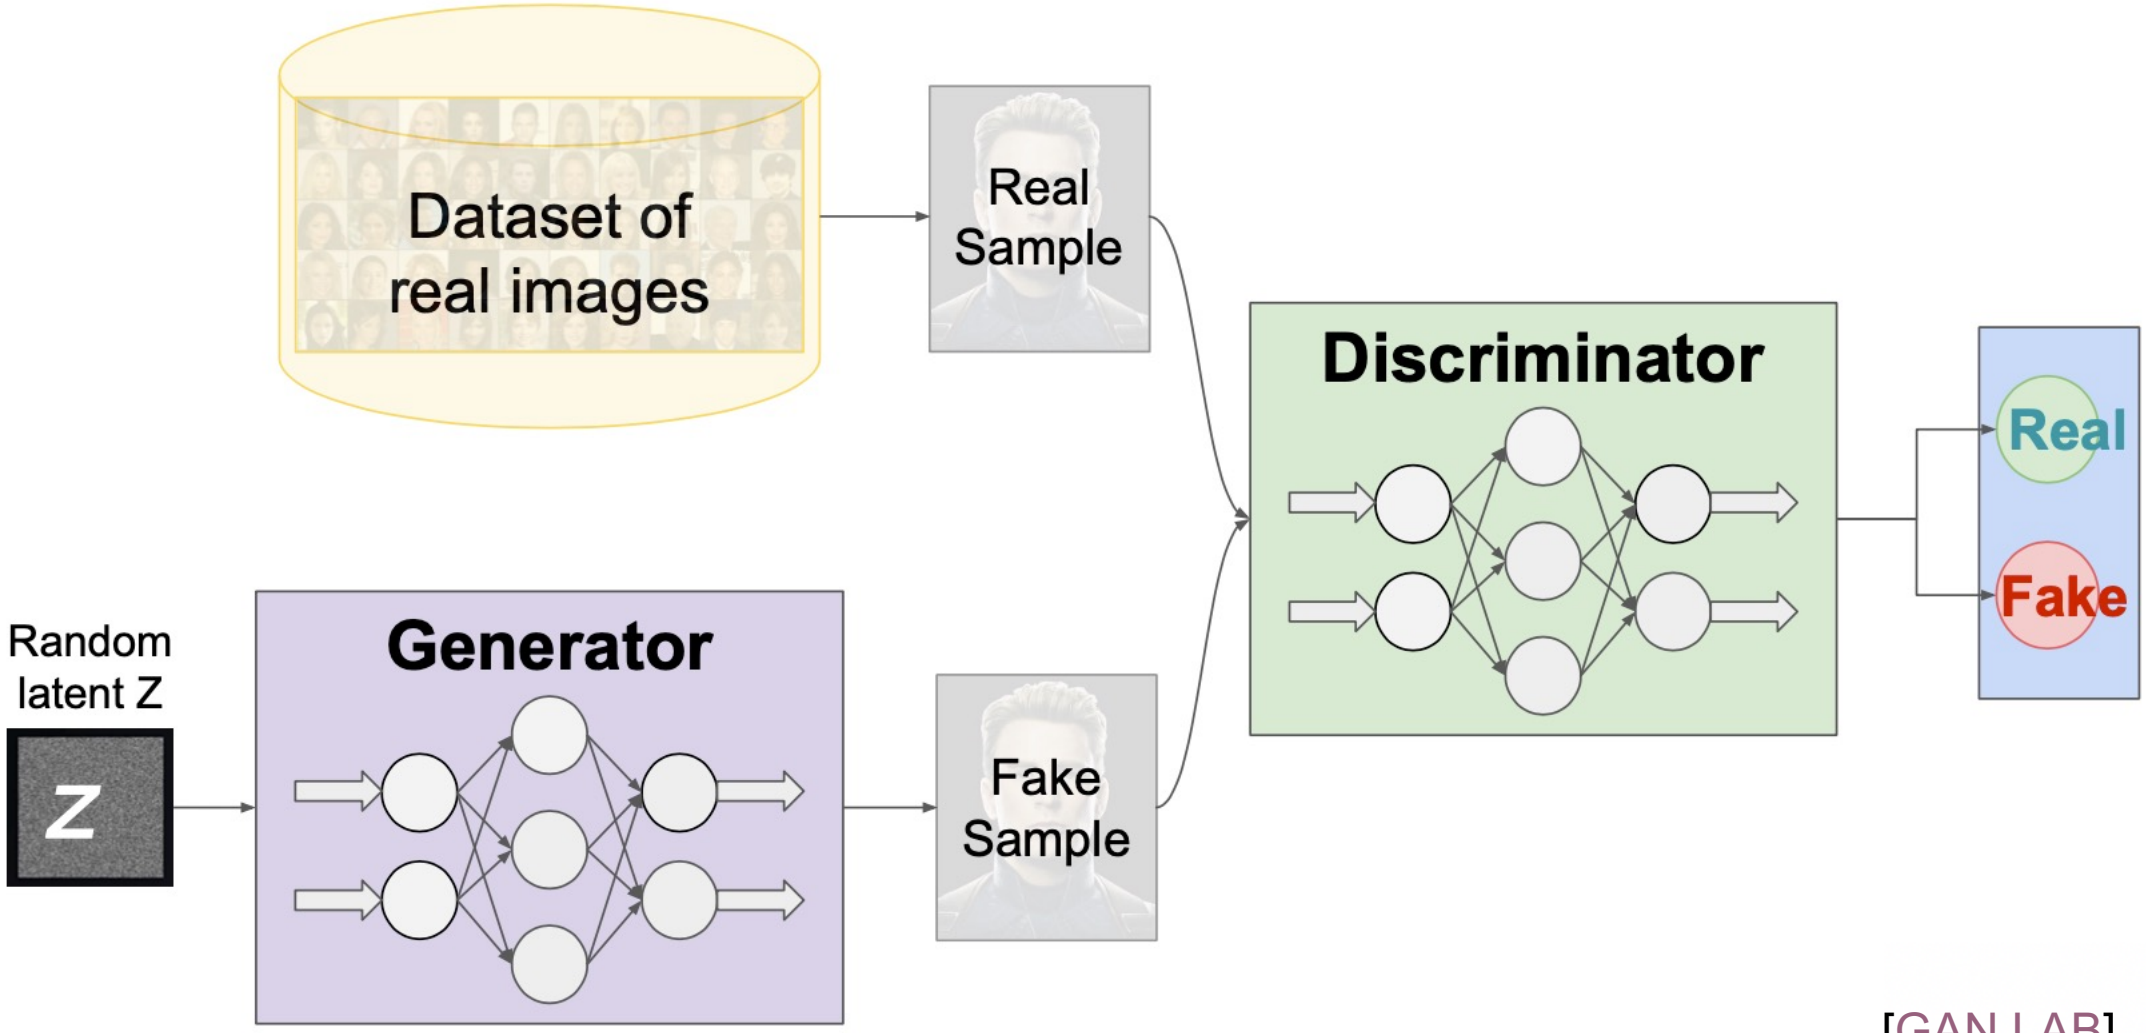
GANs 是一种通过让两个神经网络相互竞争来构建生成模型的方法。



对每个批次（步骤）

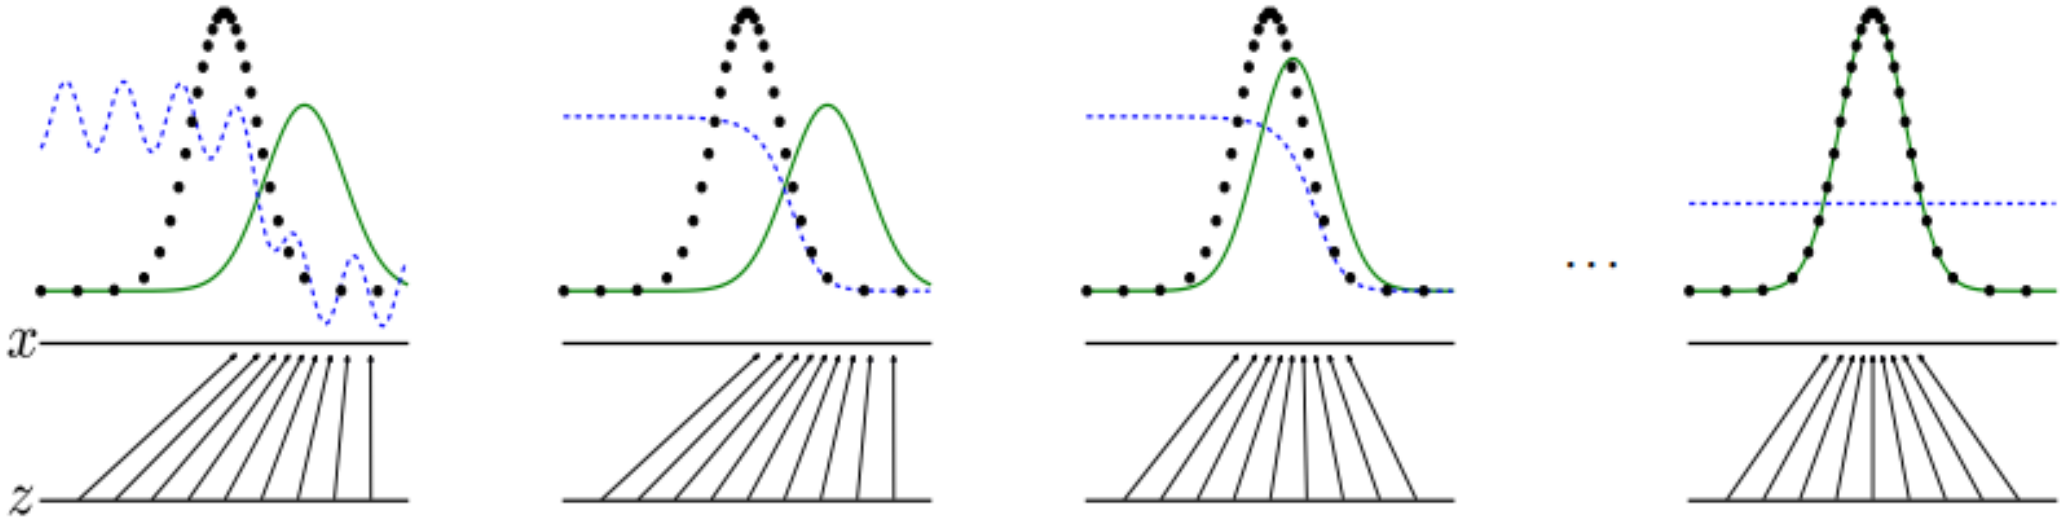
1. 训练 D，固定 G 2. 训练 G，固定 D，尝试欺骗 D，告诉 D 假图像是真实的

I Ae □: C□t n□□□ N□ n□t □



[GAN LAB]

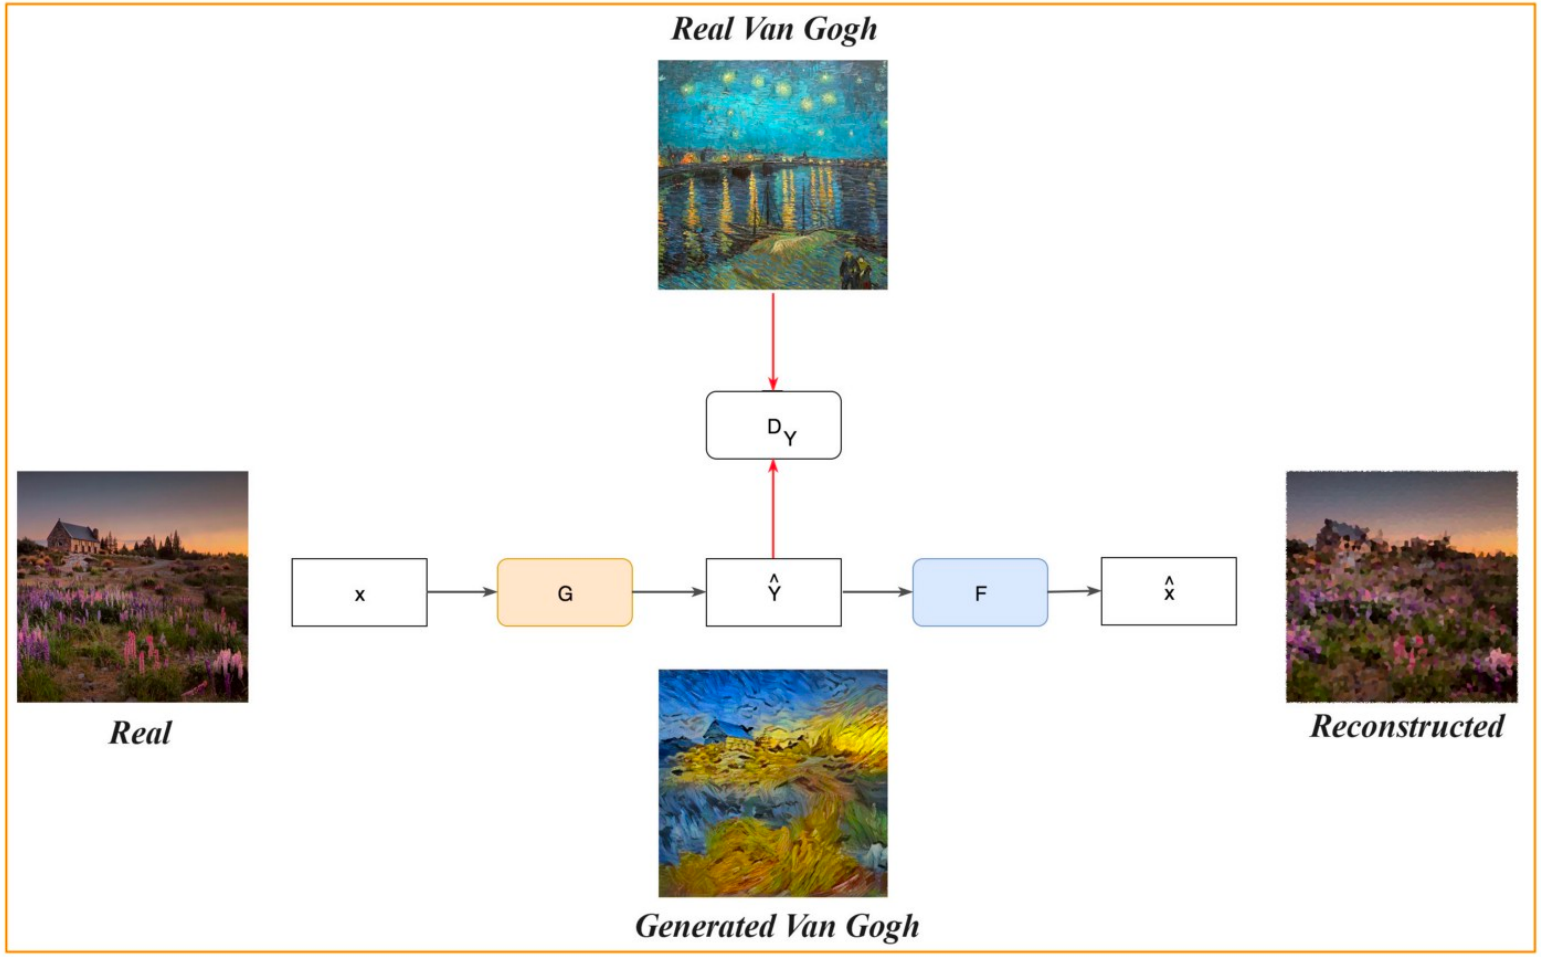
GAN：学习一种分布



这是GAN论文中首次发表的图，展示了GAN学习将均匀噪声映射到正态分布。

• 黑色点表示真实数据点 • 绿色曲线是 GAN 生成的分布，• 蓝色曲线是判别器对某个样本位于该区域为真实的置信度。• 这里 **x** 表示样本空间，**z** 表示潜在空间。（来源：Goodfellow 2014）

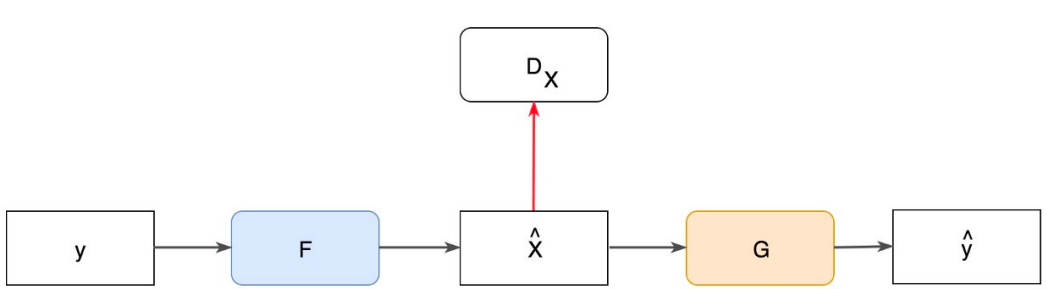
CycleGAN

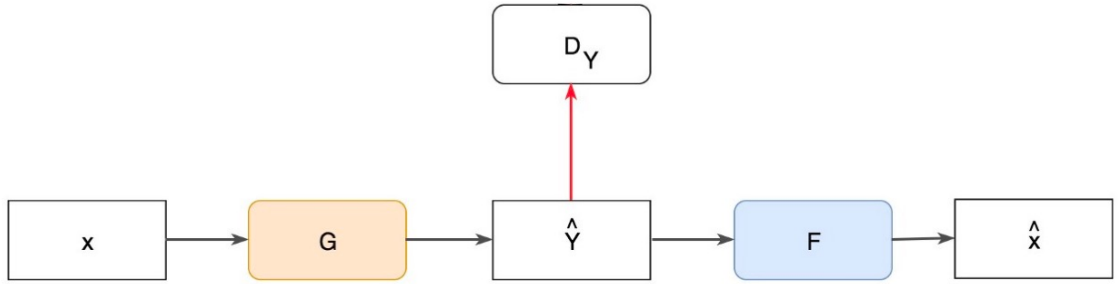


We build three networks

• 生成器***G*** 用于将真实图像转换为梵高风格图片。 • 生成器***F*** 用于将梵高风格图片转换为真实图像。 • 判别器 ***D*** 用于识别真实或生成的梵高图片。

CycleGAN





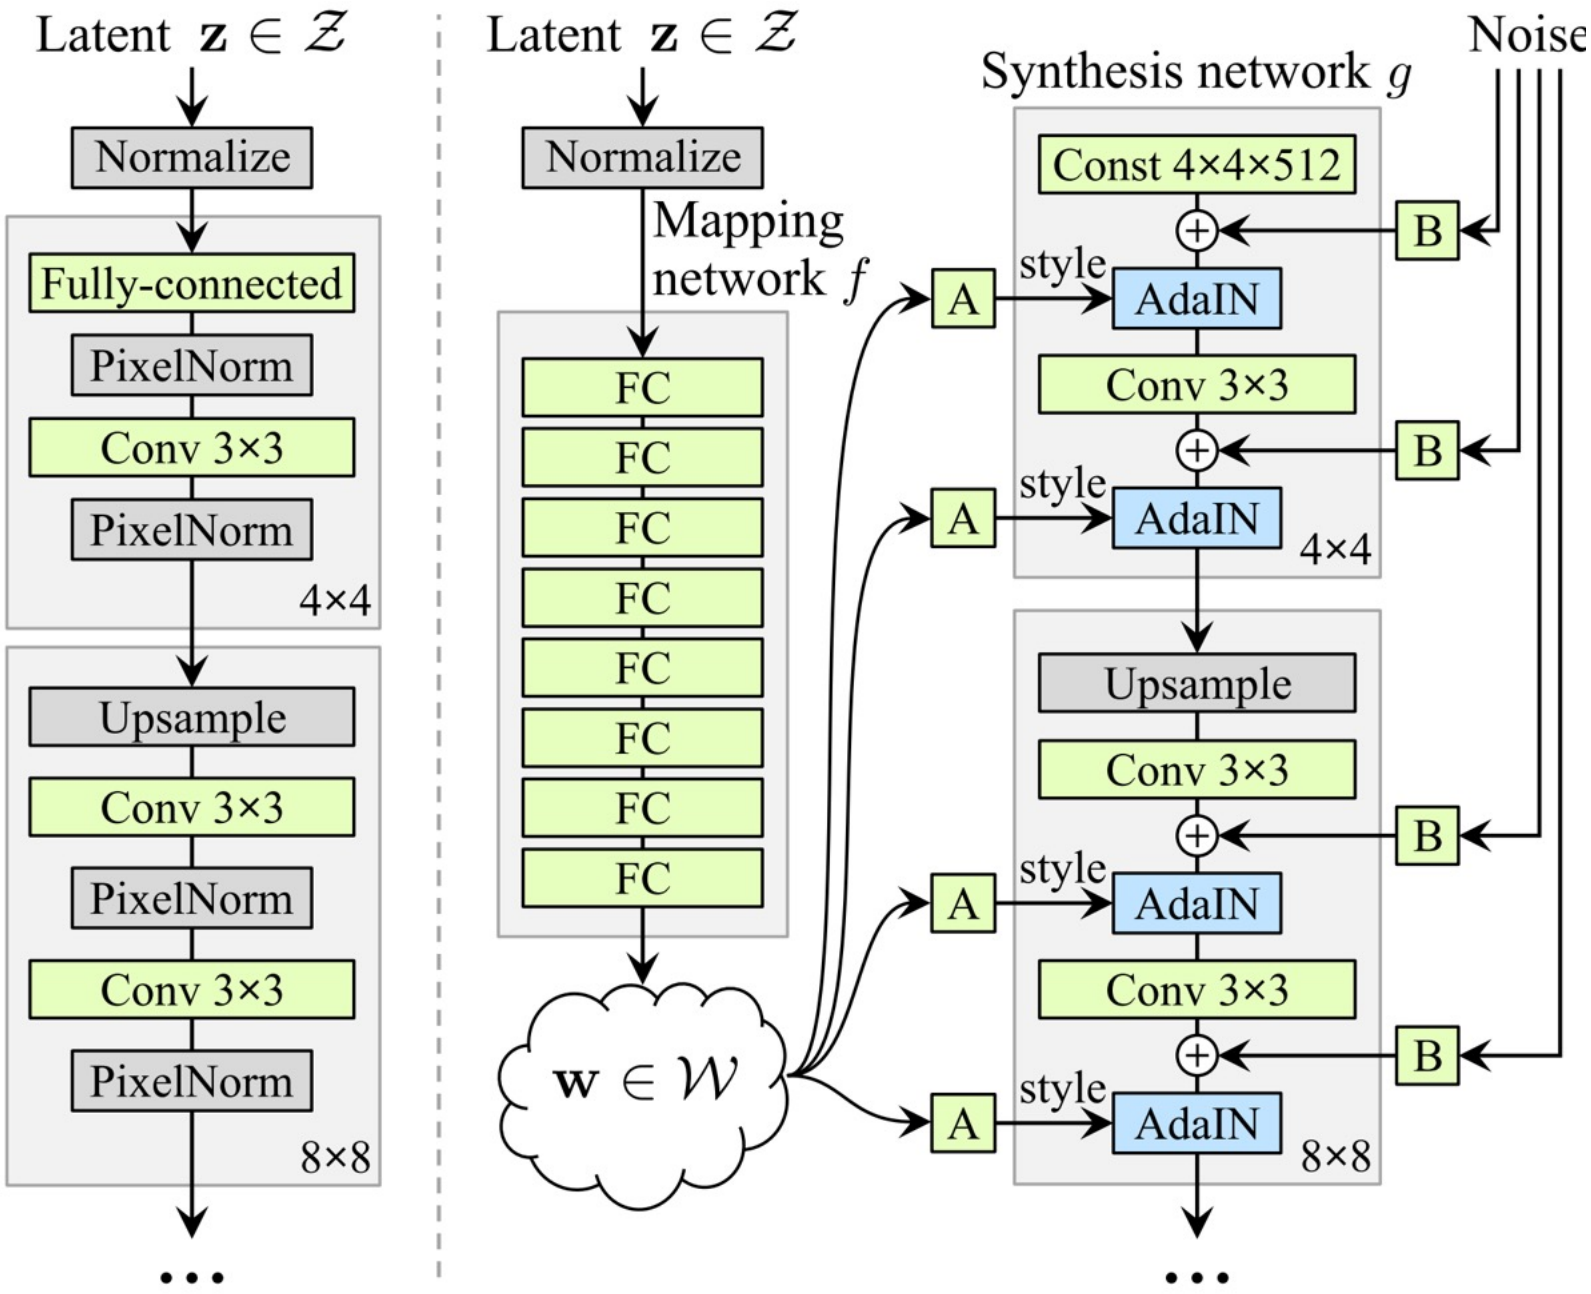
Cycle consistency loss:

$$\mathcal{L}_{\text{cyc}}(G, F) = \mathbb{E}_{x \sim p_{\text{data}}(x)}[\|F(G(x)) - x\|_1] + \mathbb{E}_{y \sim p_{\text{data}}(y)}[\|G(F(y)) - y\|_1]$$

Adversary loss:

$$\mathcal{L}_{\text{GAN}}(G, D, X, Y)$$
$$\textit{For } G, \text{ minimize } \mathbb{E}_{x \sim p_{\text{data}}(x)}[(D(G(x)) - 1)^2]$$
$$\textit{For } D, \text{ minimize } \mathbb{E}_{y \sim p_{\text{data}}(y)}[(D(y) - 1)^2] + \mathbb{E}_{x \sim p_{\text{data}}(x)}[D(G(x))^2]$$

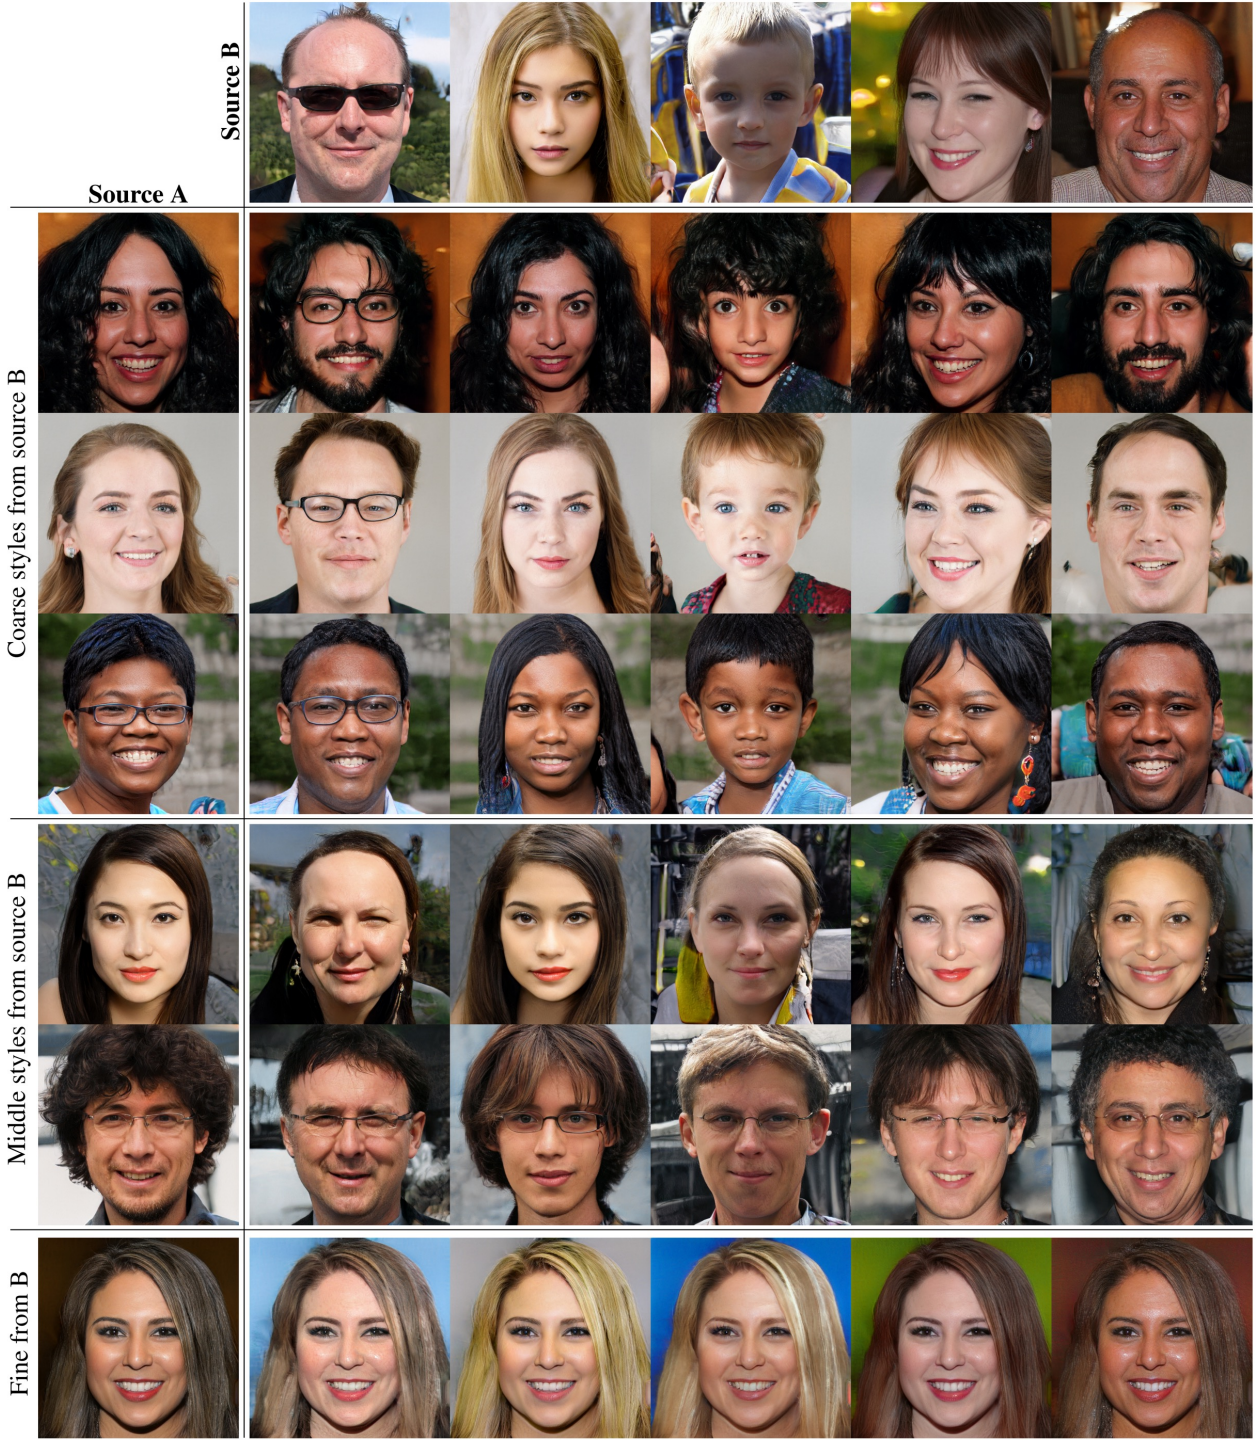
f ??3sNAd



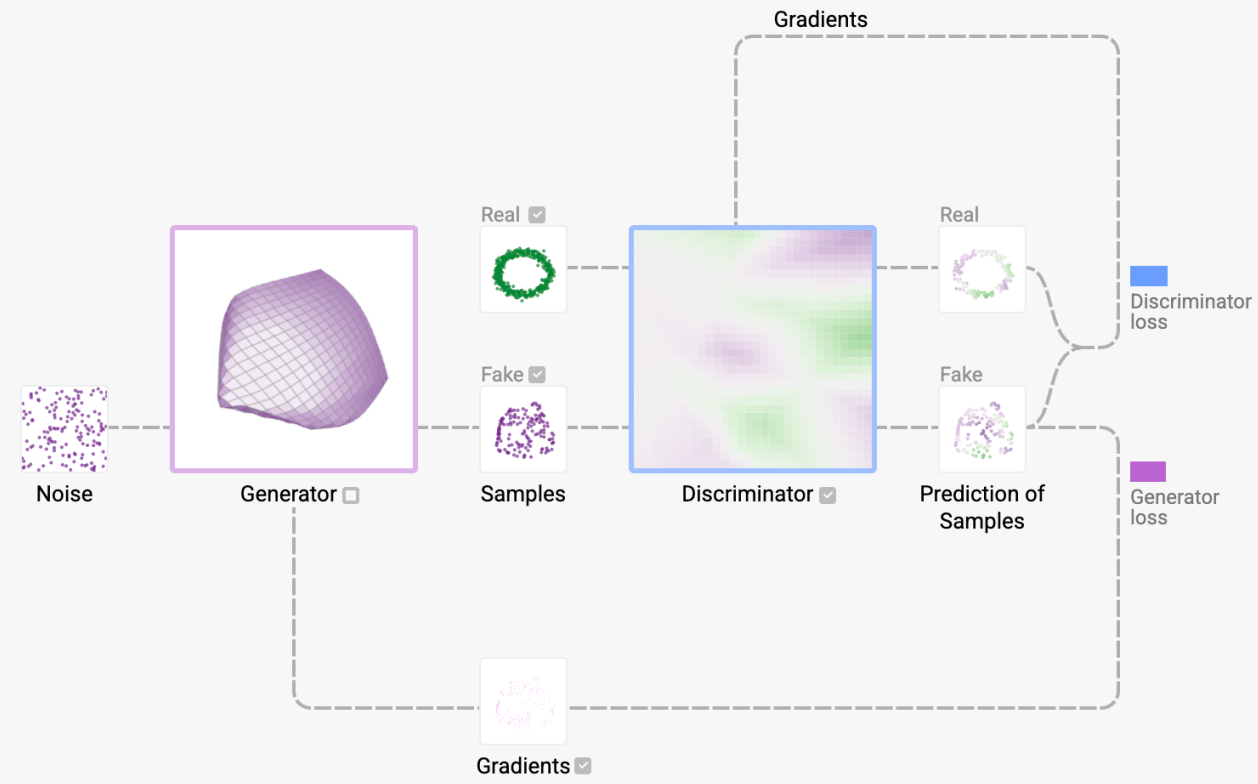
(a) Traditional

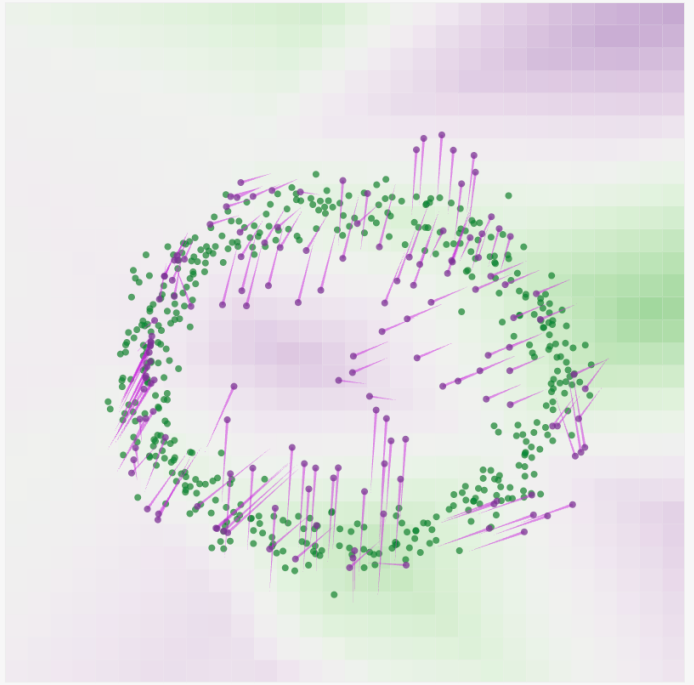
(b) Style-based generator

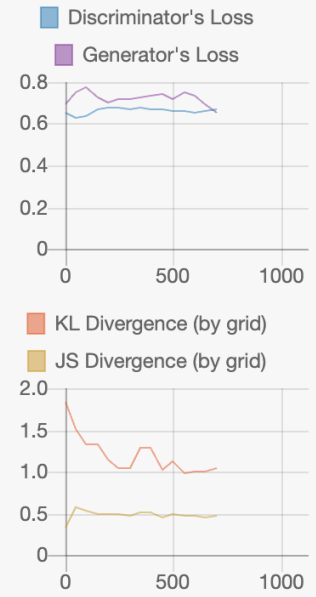



Source B
Source A
Coarse styles from source B
Middle styles from source B
Fine from B

问题：收敛性差！

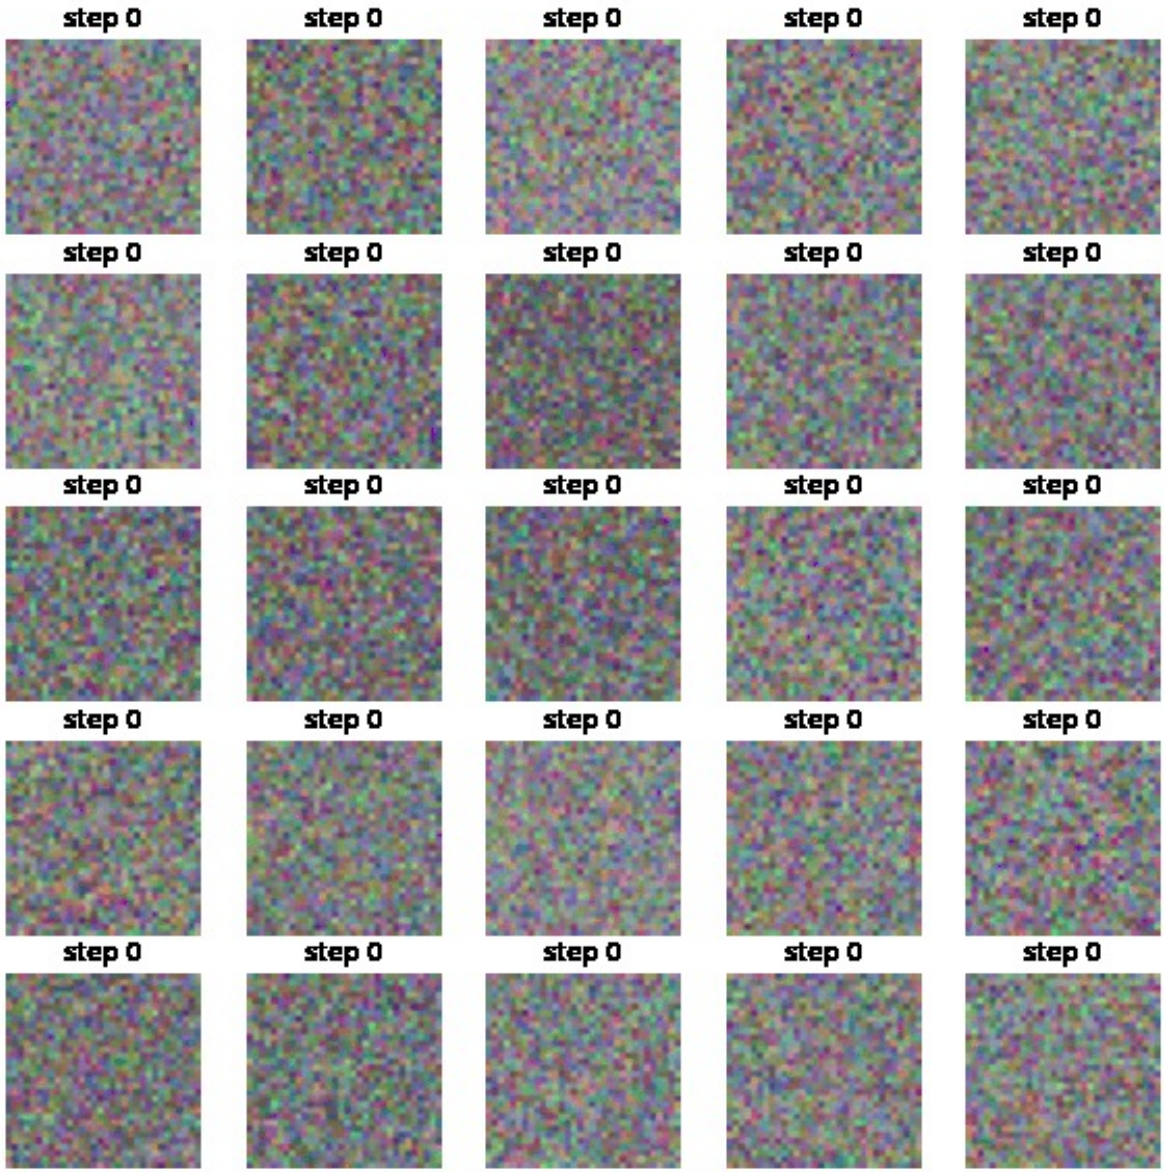




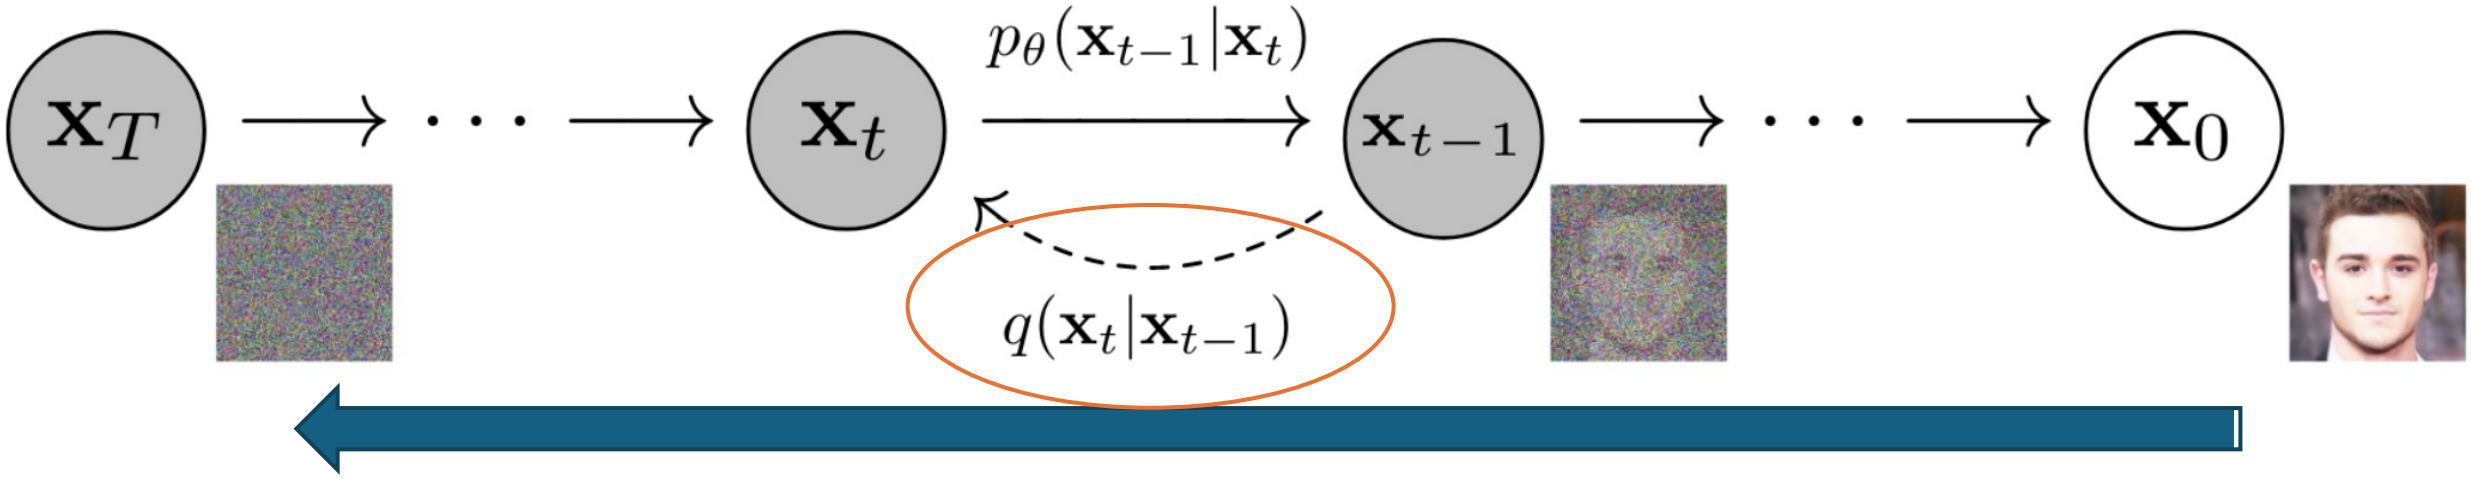


https://poloclub.github.io/ganlab/

M tt?? ???S ?os?


step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0
step 0

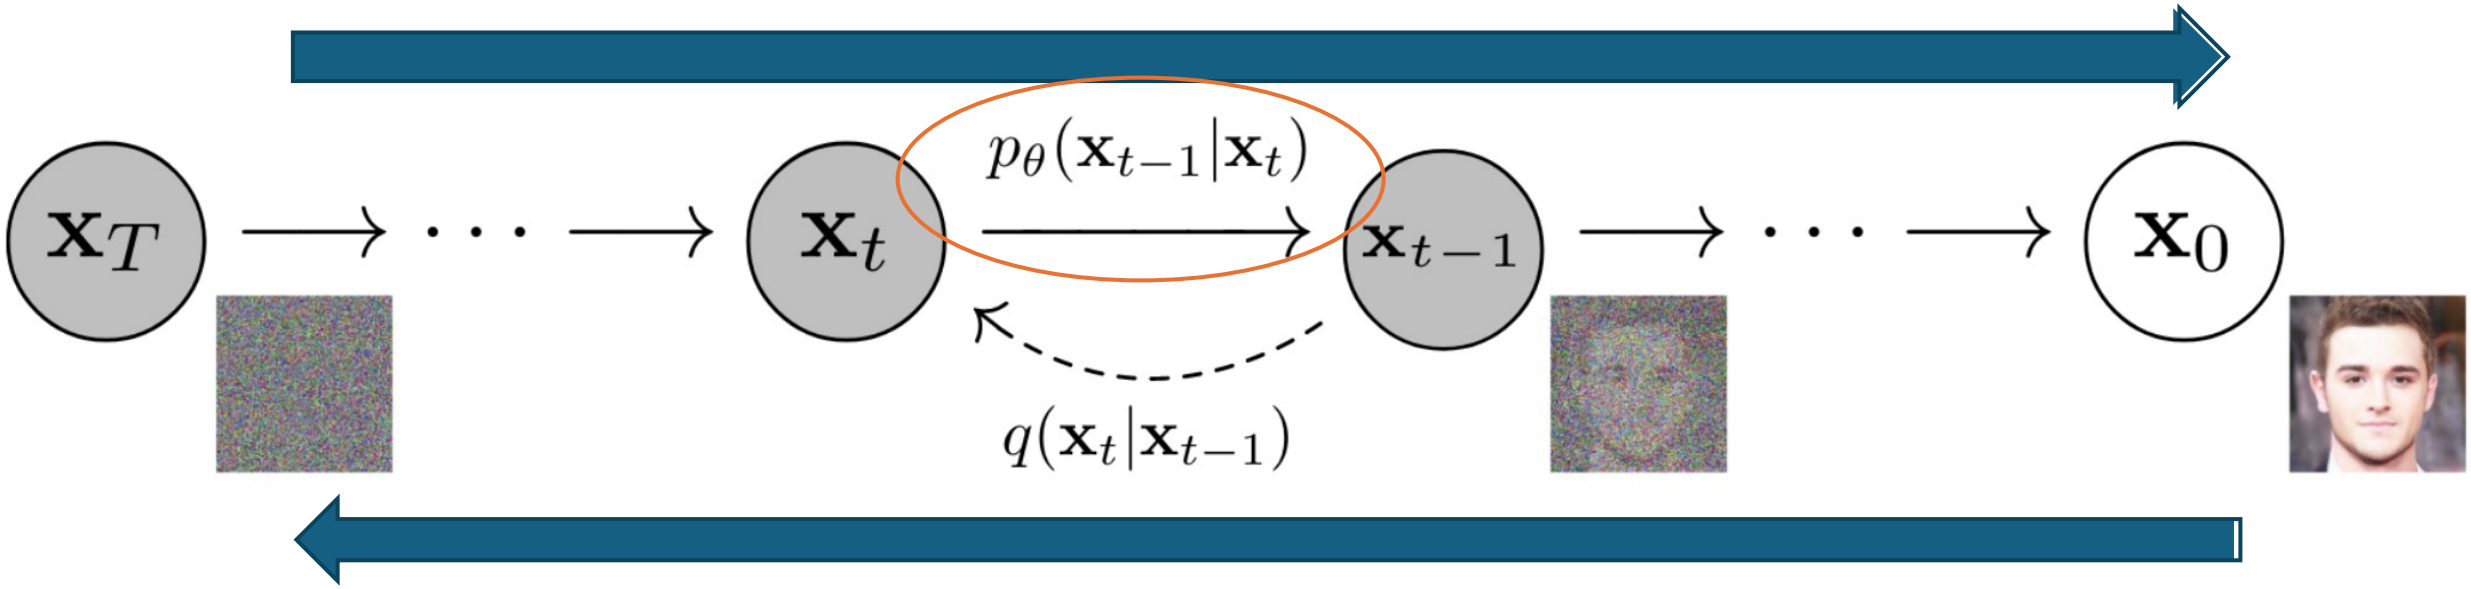
S s?h?o



corward diffusion process: progressivel? destro? structure in real data

方法

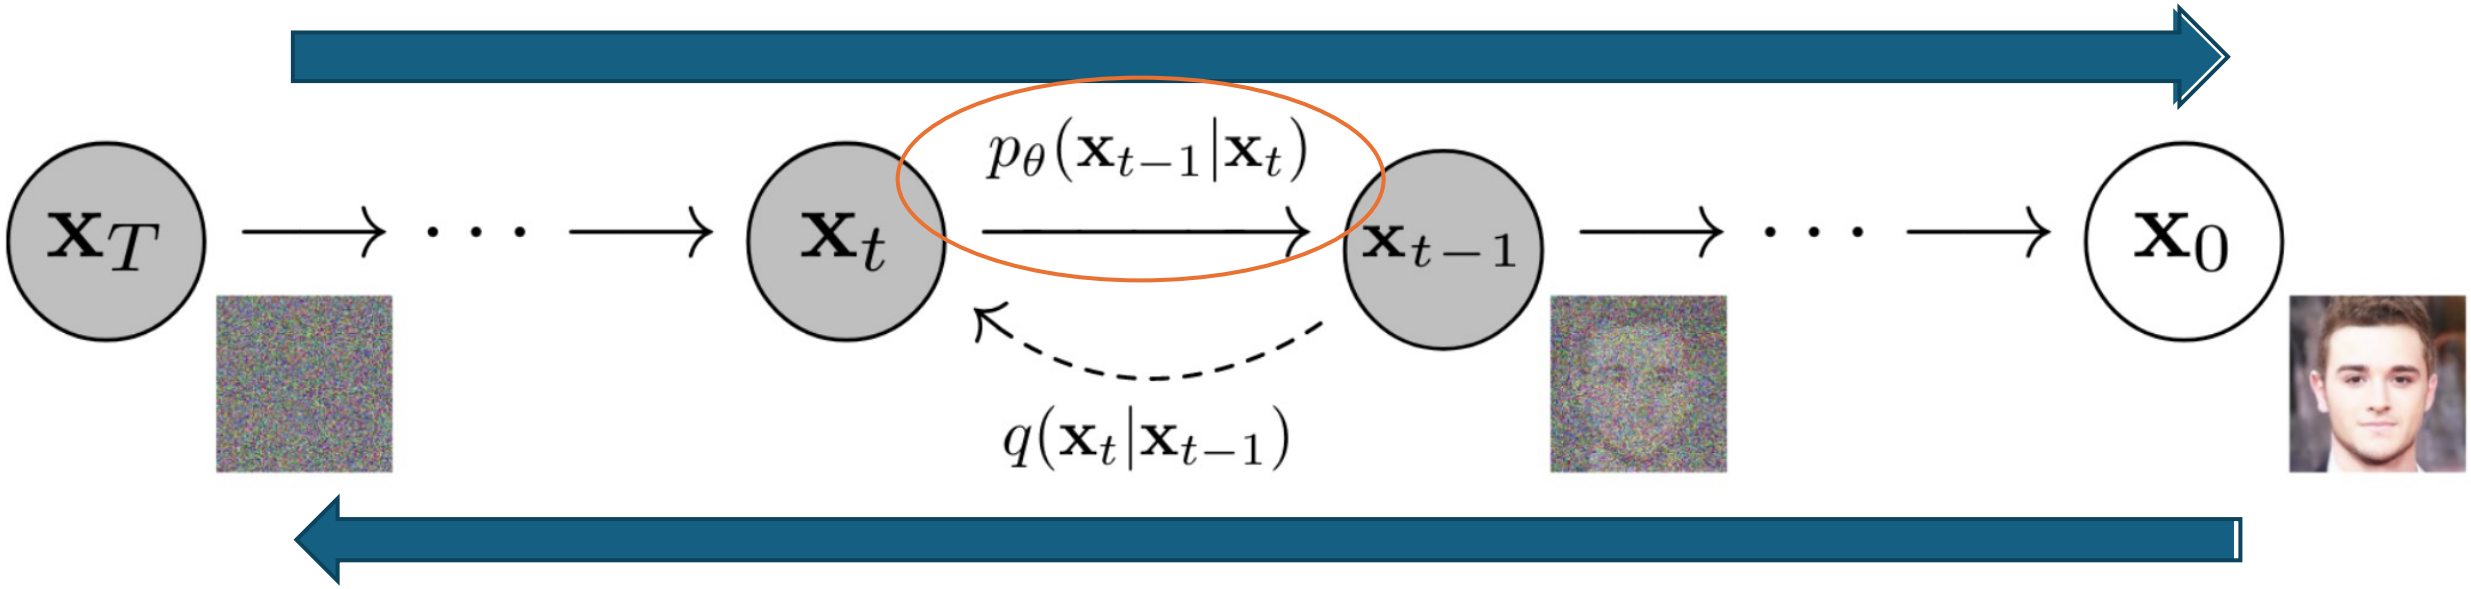
逆向扩散过程：逐步重建数据



前向　　扩散过程：逐步破坏真实数据中的结构　　a

方法

逆向扩散过程：逐步重建数据



前向　　扩散过程：逐步破坏真实数据中的结构　　a

思路：将复杂的映射函数分解为多个可处理的步骤。

方法

前向扩散过程

x_0真实数据



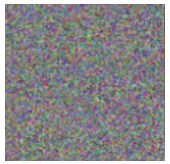
步骤 1 $x_1 = \sqrt{1-\beta_1}\, x_0 + \sigma_1 \epsilon, \quad \epsilon \in N(0,1)$



步骤 2 $x_2 = \sqrt{1-\beta_2}\, x_1 + \sigma_2 \epsilon,$

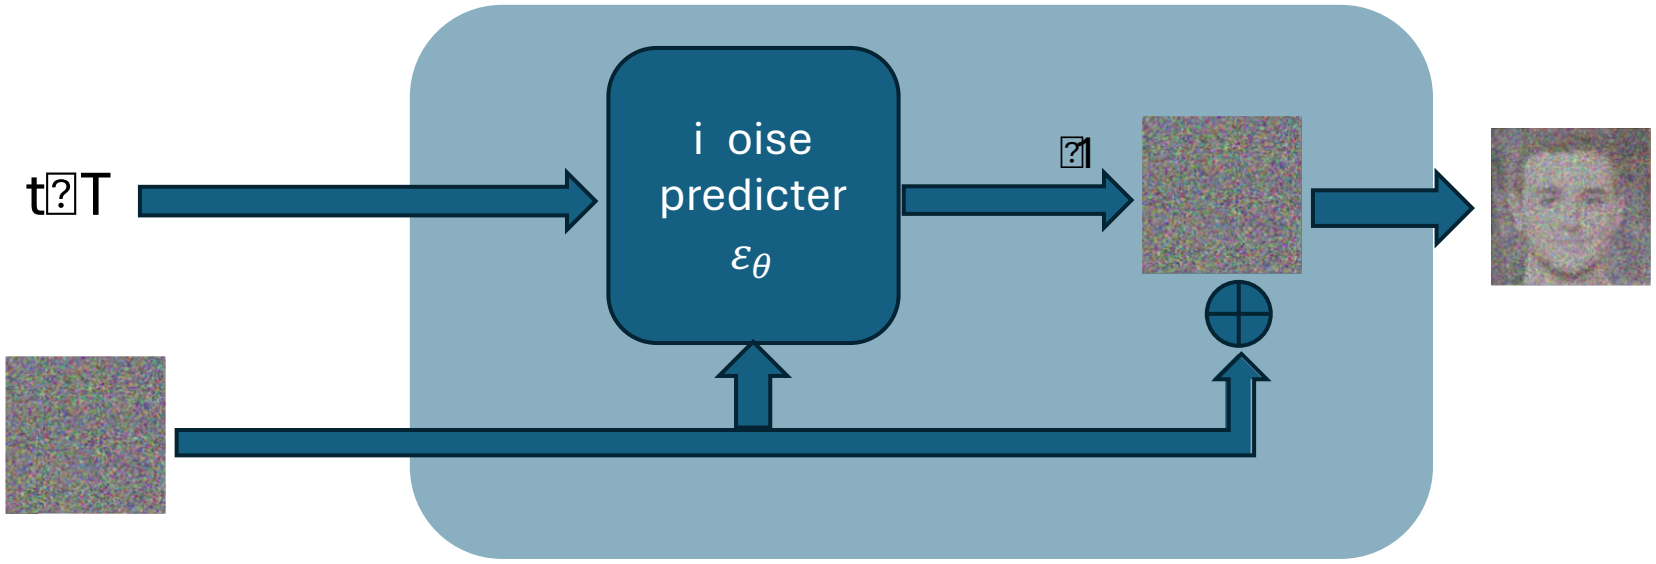


... 步骤 T $x_T = \sqrt{1-\beta_T}\, x_{T-1} + \sigma_T \epsilon,$



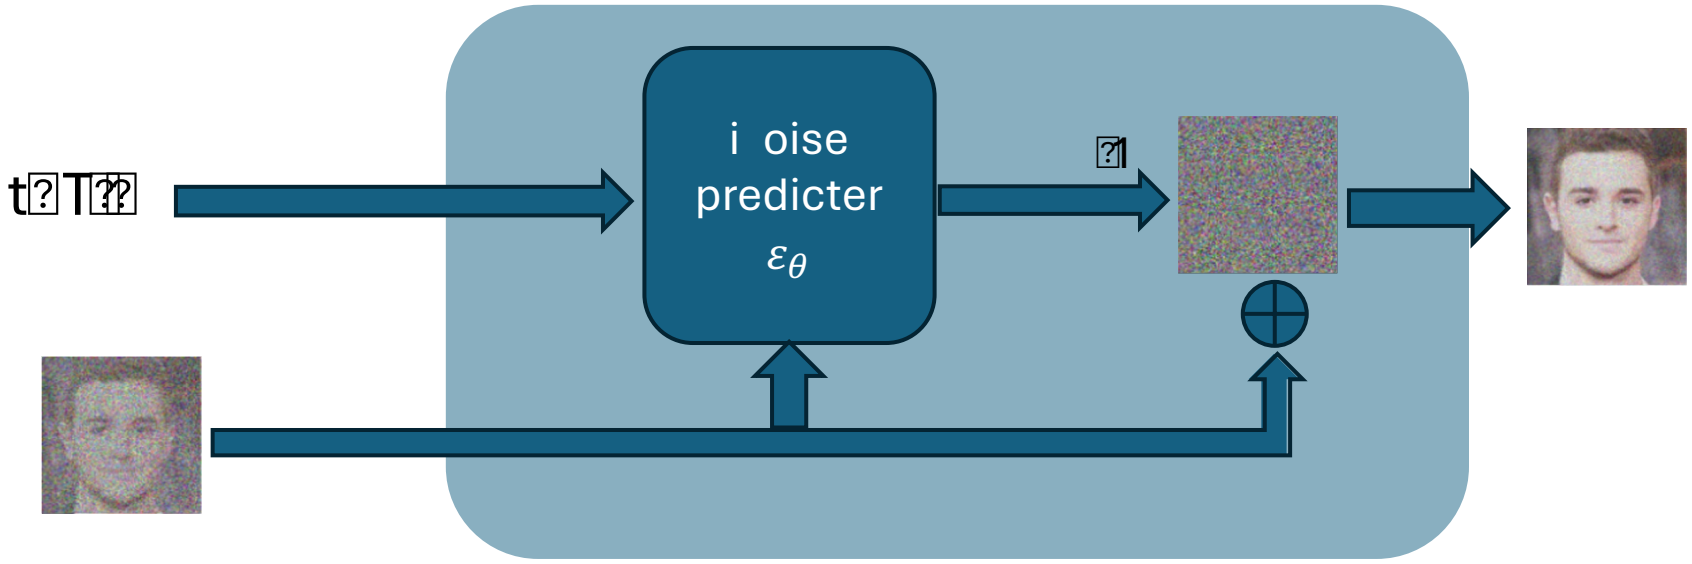
S s h o

dr r pus ur or



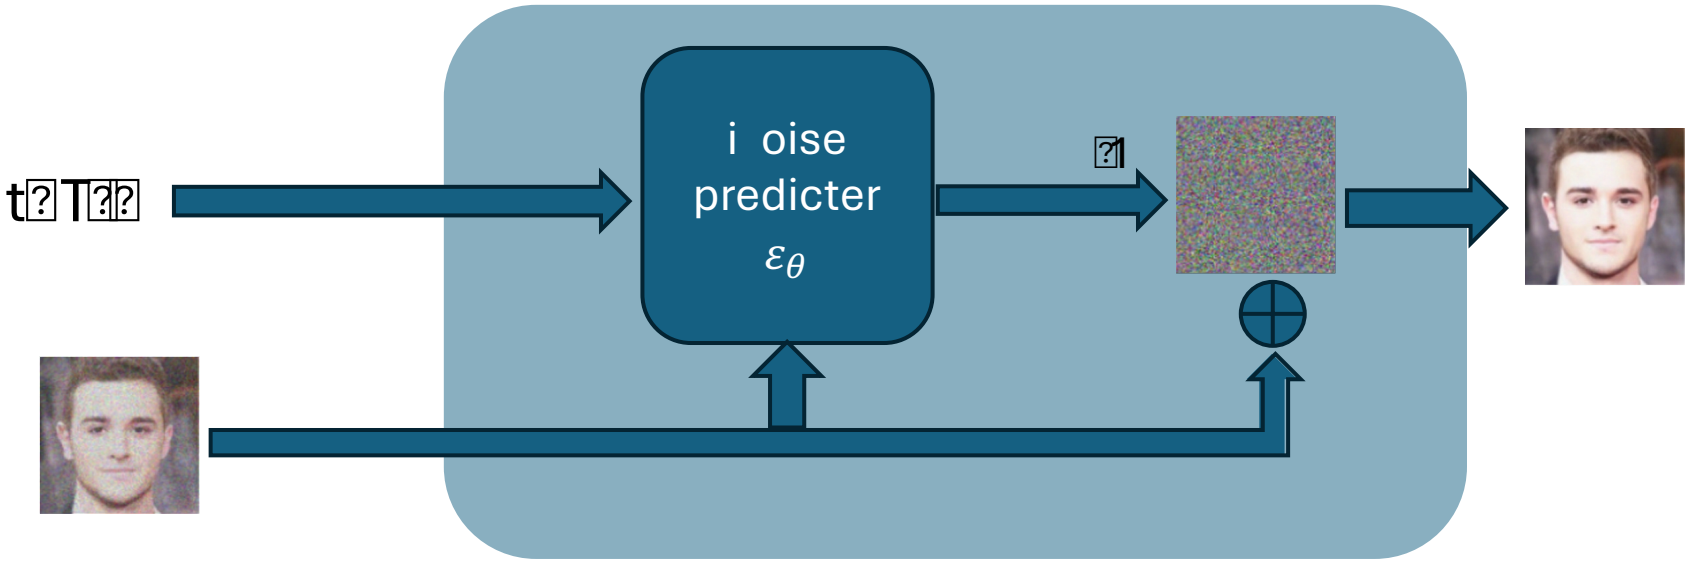
S s h o

dr r pus u or



S s?h?o

dr ?r ???pus?u?????or ??



方法

逆向扩散过程

$$\alpha_t = 1 - \beta_t, \bar{\alpha}_t = \prod_{s=1}^{T} \alpha_s$$

第 T 步 x_T

$\epsilon_\theta\ x_T, t$ 由神经网络参数化

第 T-1 步 $$x_{T-1} = \frac{1}{\sqrt{1-\beta_T}}\left(x_T - \frac{\beta_T}{\sqrt{1-\bar{\alpha}_T}}\epsilon_\theta(x_T, T)\right) + \sigma_T \epsilon$$

去除由神经网络估计的噪声

一个随机性项，它引入更多多样性

超出本课程范围。此处无需理解

方法

逆转扩散过程

$$\alpha_t = 1 - \beta_t, \bar{\alpha}_t = \prod_{s=1}^{T} \alpha_s$$

步骤 T x_T

ϵ_θ x_T, t 由神经网络参数化

步骤 T-1 $$x_{T-1} = \frac{1}{\sqrt{1-\beta_T}}\left(x_T - \frac{\beta_T}{\sqrt{1-\bar{\alpha}_T}}\epsilon_\theta(x_T, T)\right) + \sigma_T\epsilon$$

去除由神经网络估计的噪声

一个随机性项，它引入更多多样性

Step □ $$x_0 = \frac{1}{\sqrt{1-\beta_1}}\left(x_1 - \frac{\beta_1}{\sqrt{1-\bar{\alpha}_1}}\epsilon_\theta(x_1, T)\right) + \sigma_1\epsilon$$

超出本课程范围。此处无需理解

Algorithm 1 Training

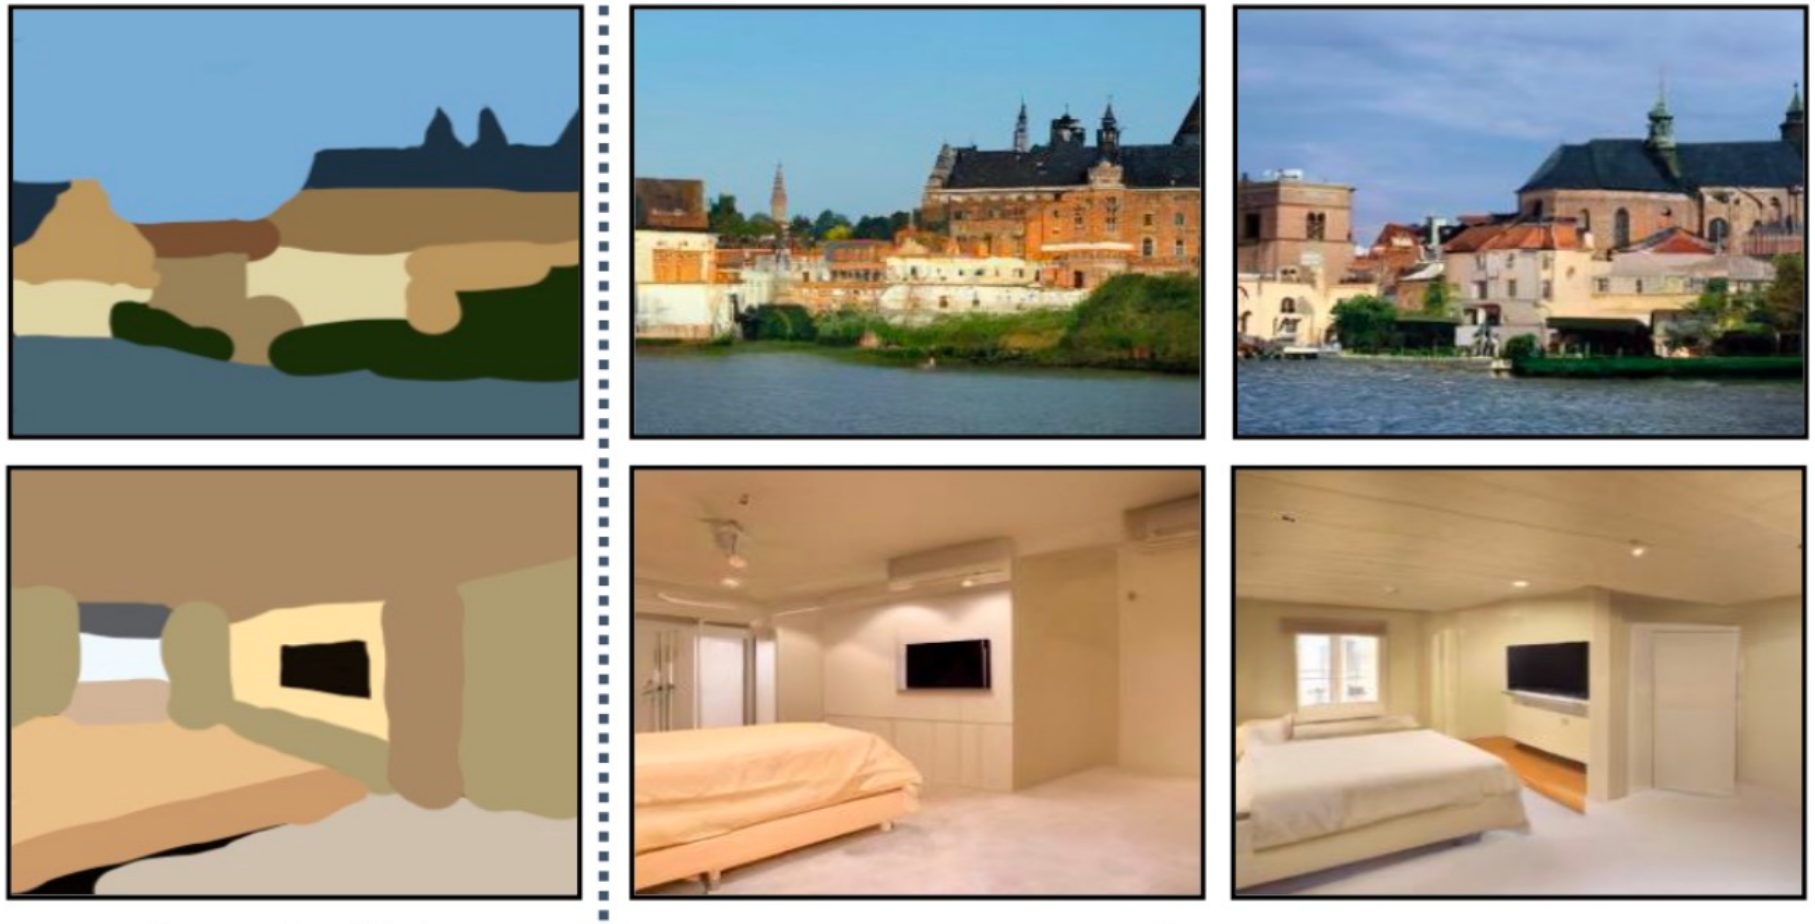
1: **repeat**
2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
3: $t \sim \text{Uniform}(\{1, \dots, T\})$
4: $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
5: Take gradient descent step on
$$\nabla_\theta \left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}, t) \right\|^2$$
6: **until** converged

Algorithm 2 Sampling

1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
2: **for** $t = T, \dots, 1$ **do**
3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$
4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$
5: **end for**
6: **return** $\mathbf{x}_0$

超出本课程范围。此处无需理解。

Stroke Painting to Image

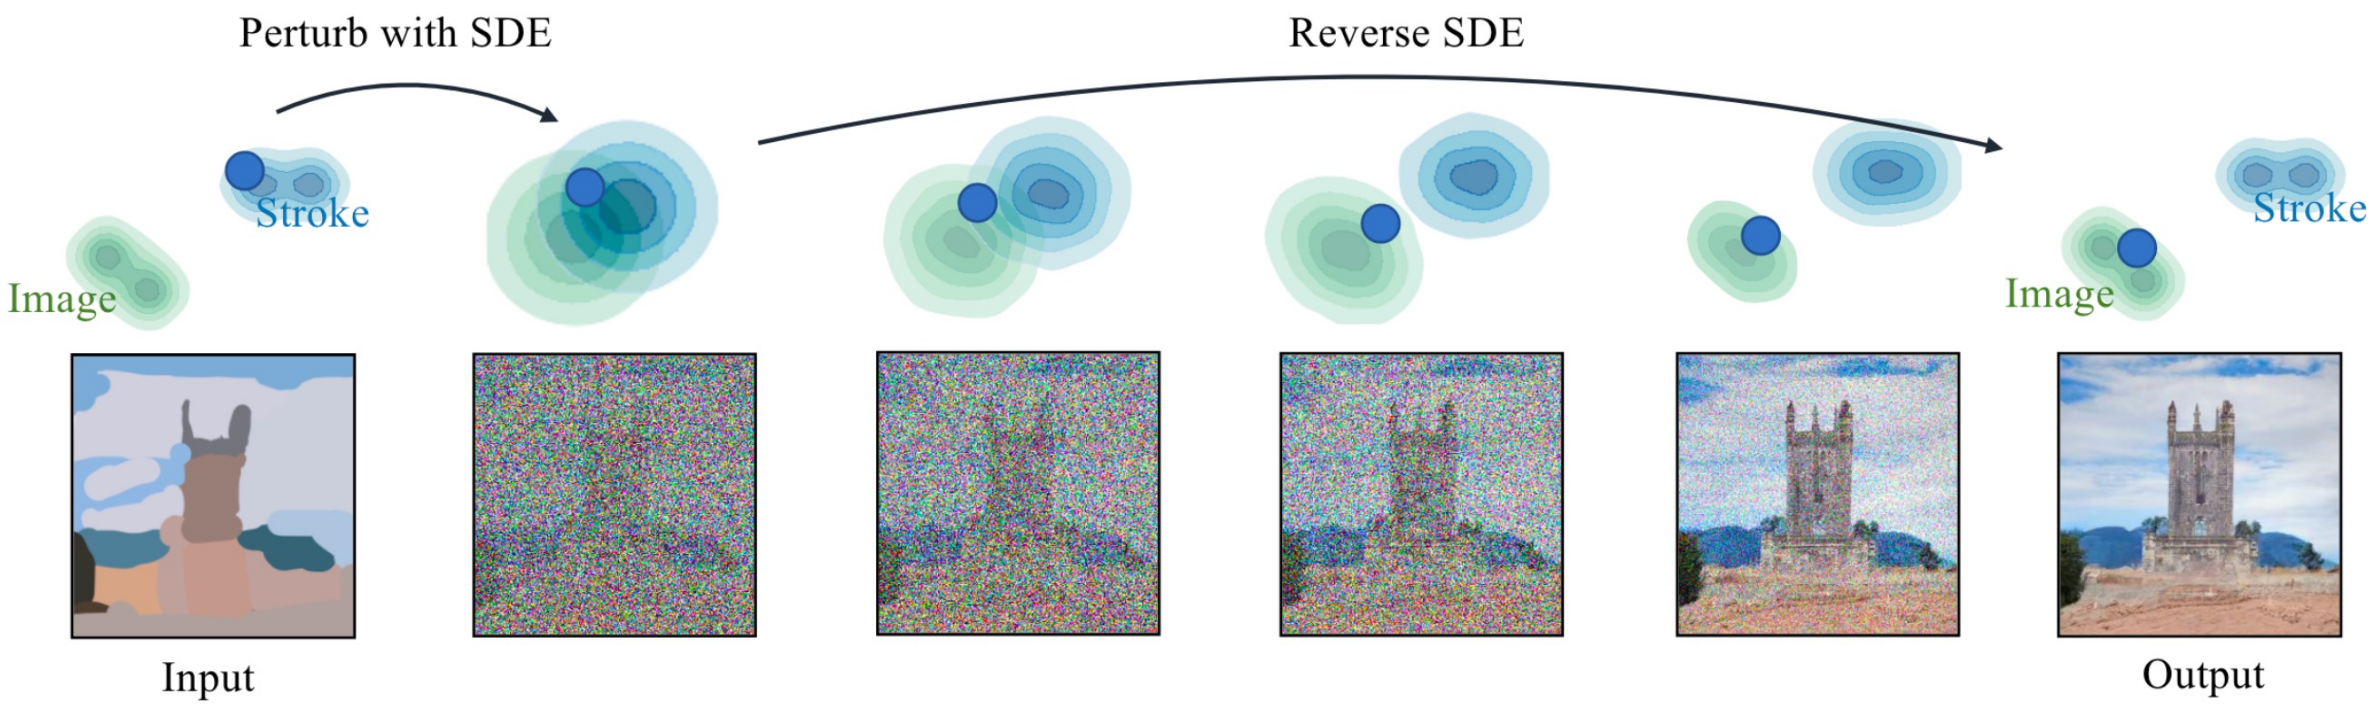


Input (guide)

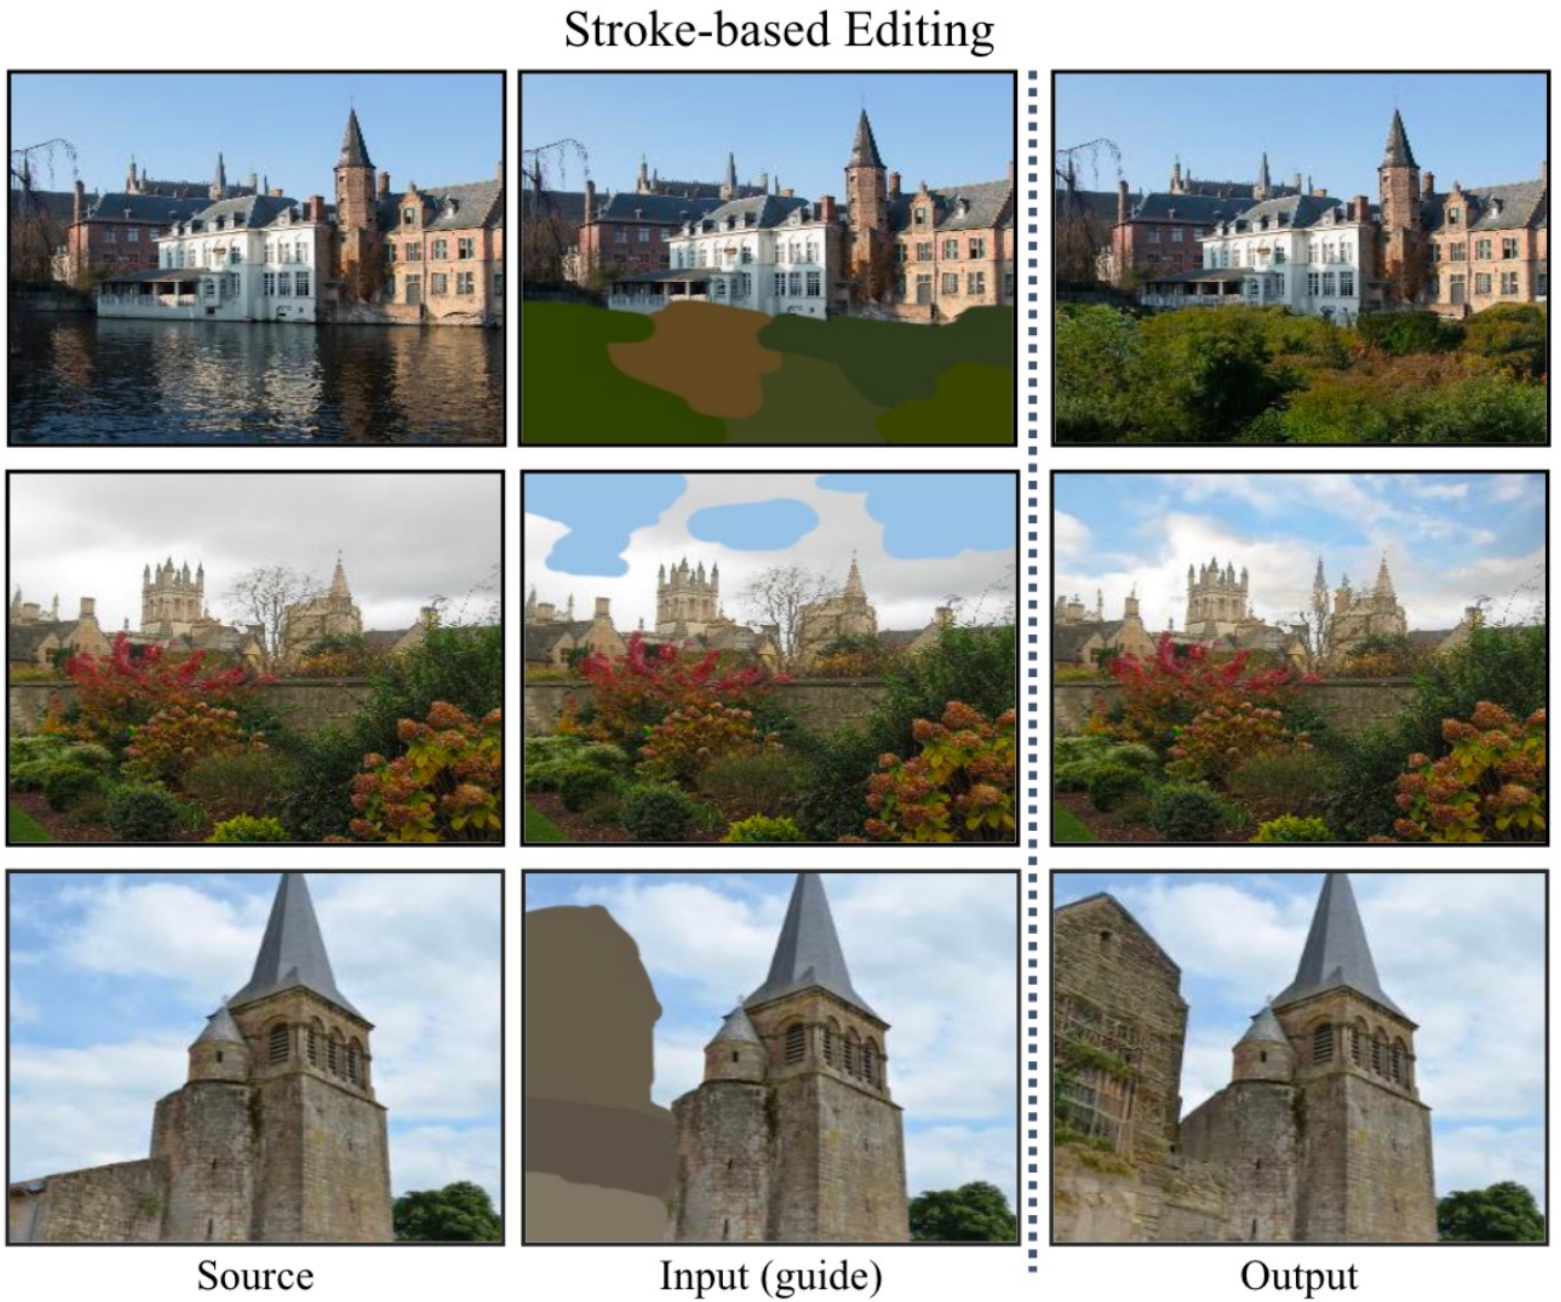
Output

ii ea

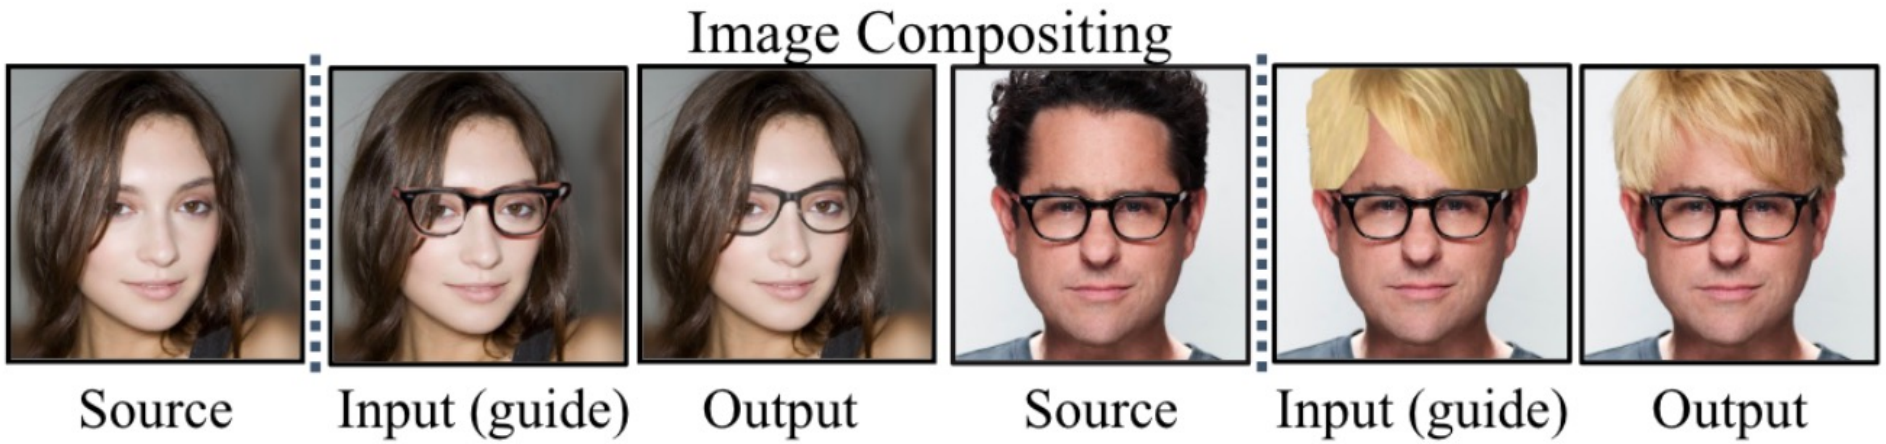
A w : t. n r u -nt r p ptss t. w . pr u



Applications

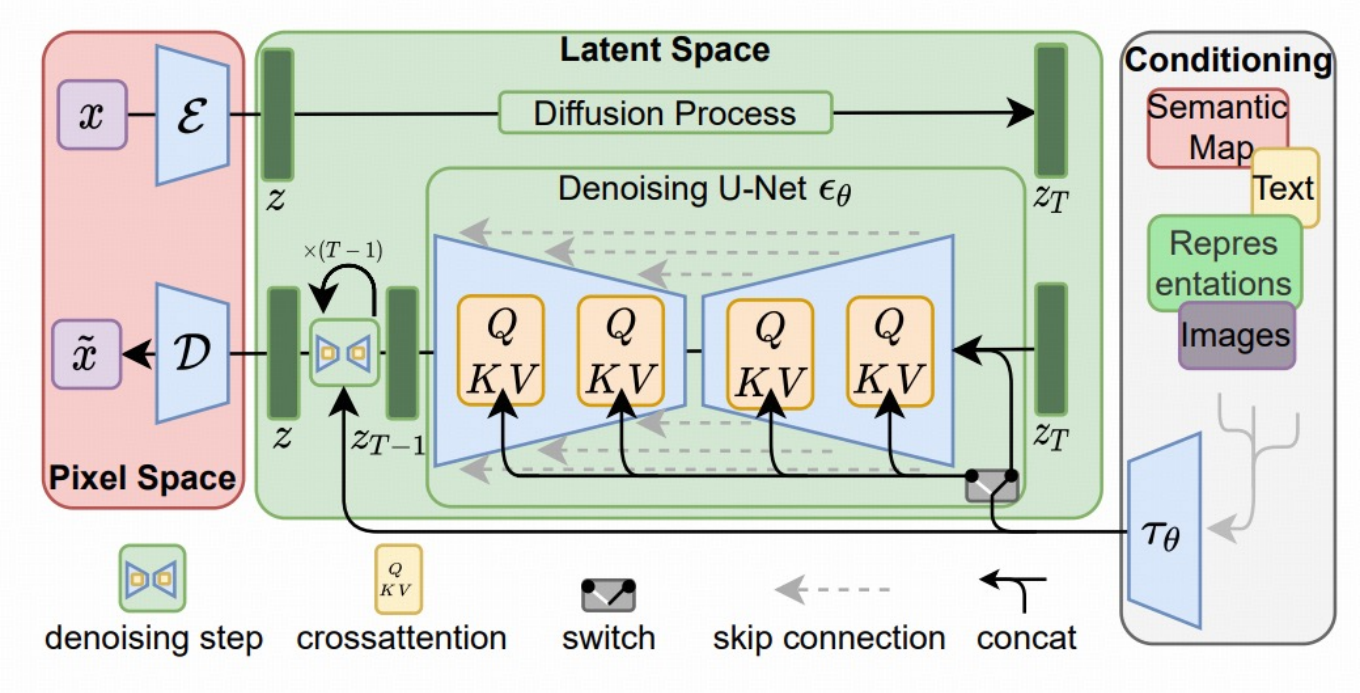


Applications

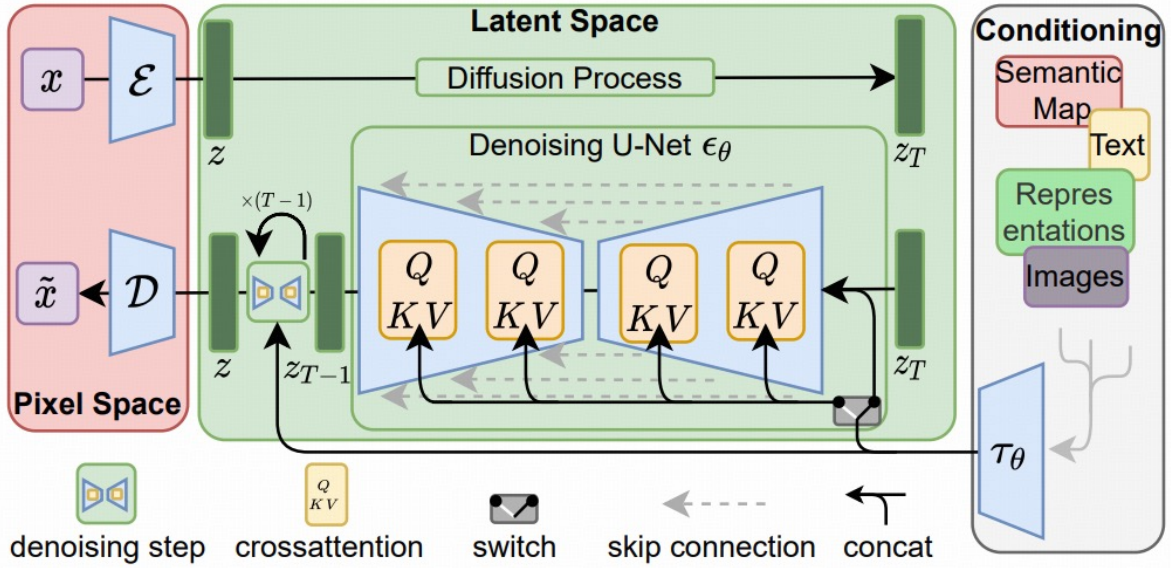


最先进的生成模型与应用

- 文本到图像生成 □Stable Diffusion 系列（Runway、Stability AI）
  - □ **SD-1、SD-1.5、SD-2**
    - Control Net
    - SD-XL
  - □ SD□□



Stable Diffusion 如何工作：T



- The droblem: Generating images directly
  非常庞大且速度缓慢。
- 解决方案（自编码器）
- 去噪 U-Net：它完全在潜在空间中运行。它从含噪潜在张量开始，迭代地逐步预测并去除噪声，以恢复干净的图像表示。
- 条件化（引导输出）：文本提示、语义图或参考图像会通过领域特定编码器。U-Net 在各层使用交叉注意力机制，使 U-Net 在决定如何对图像去噪时能够“查看”文本提示。

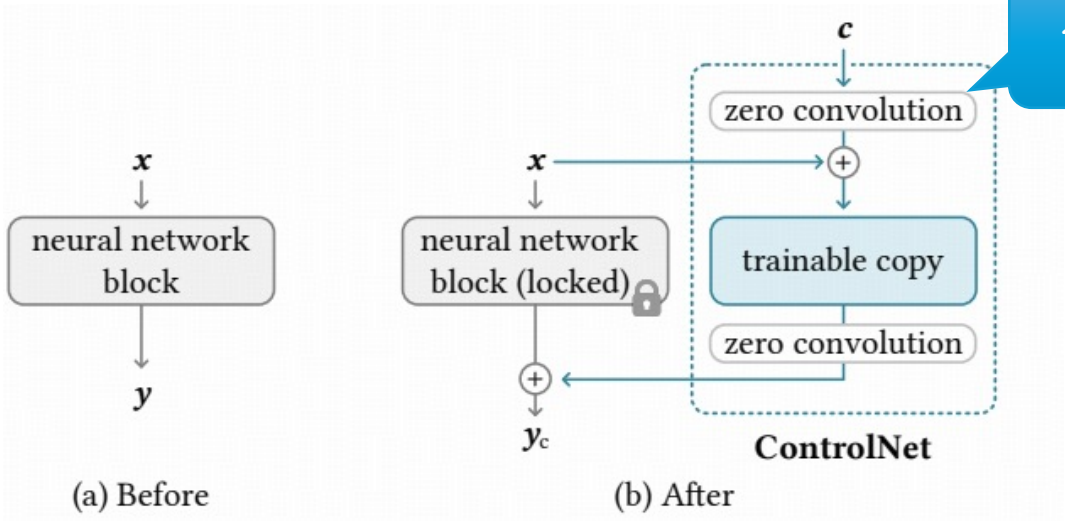
ControlNet：驯服扩散过程

- 文本的局限性：很难用词语描述角色的确切姿势或房间的确切透视线条。
- C□□□□□□l e□：它是一种神经网络架构，可“锁定”预训练的扩散模型，并添加该模型编码层的可训练副本。
- 视觉条件控制：ControlNet 允许你向 U-Net 输入严格的空间条件，而不仅仅是文本。
- 常见用例：
  - OpenPose：从参考照片中提取骨架，以迫使 AI 以完全相同的姿势绘制角色。
  - Canny 边缘：将简单草图转换为完全渲染的、照片级逼真的图像，同时严格遵循草图线条。
  - 深度图：控制生成场景的3D空间布局。

最先进的生成模型与应用

- 文本到图像生成
  - Stable Diffusion 系列
    - SD-1, SD-1.5, SD-2
      - **Control Net**
      - SD-XL
    - SD-3

它是什么?





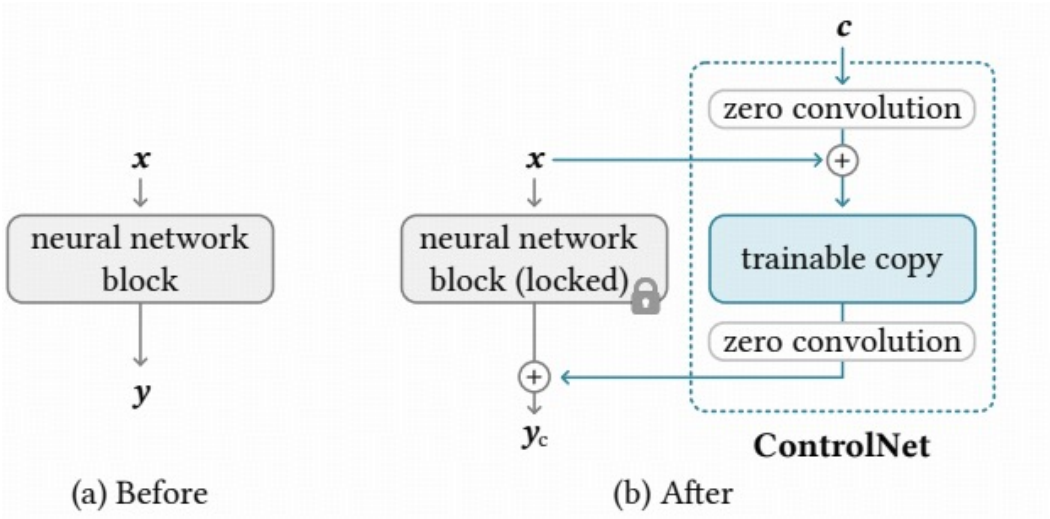
最先进的生成模型与应用

零卷积 □×□ 卷积
层，其中权重和偏置都
初始化为零)

Ø 保留基座模型的知识：在训练的最开始（迭代
0），Zero Conv 层的输出恰好为 0。

□$_c$ □ □ □ControlNet (□)

Ø 保护梯度：即使权重从零开始，**梯度** 也不为零。





Source image
(for canny edge detection)



Canny edge (input)



Generated images (output)



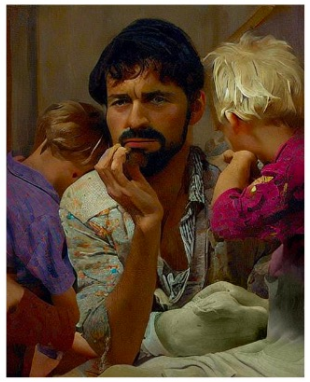


Input (Canny Edge)

Default

Automatic Prompt

User Prompt







“a man with beard sitting with two children”

“mother and two boys in a room, masterpiece, artwork”

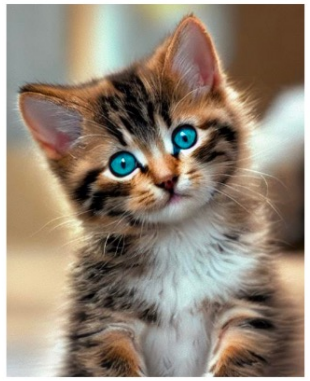


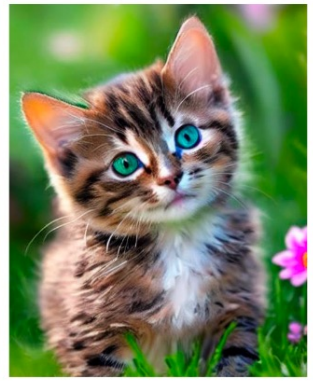




“a man in a suit and tie”

“a man in a white suit and tie”

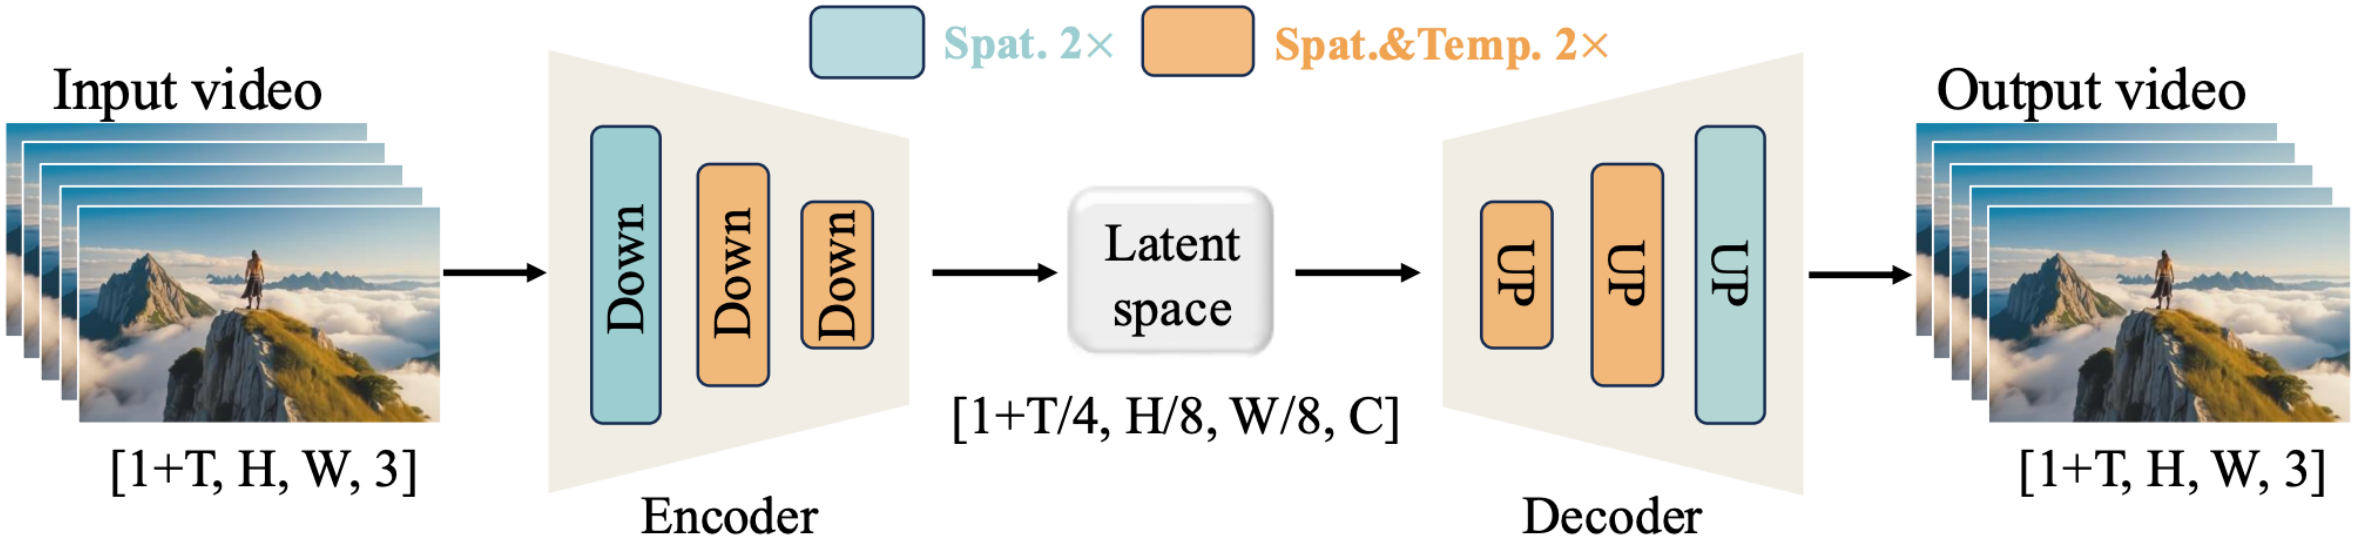



“a cat with blue eyes in a room”

“a cute cat in a garden, masterpiece, detailed wallpaper”

视频生成



WAN：开放且先进的大规模视频生成模型

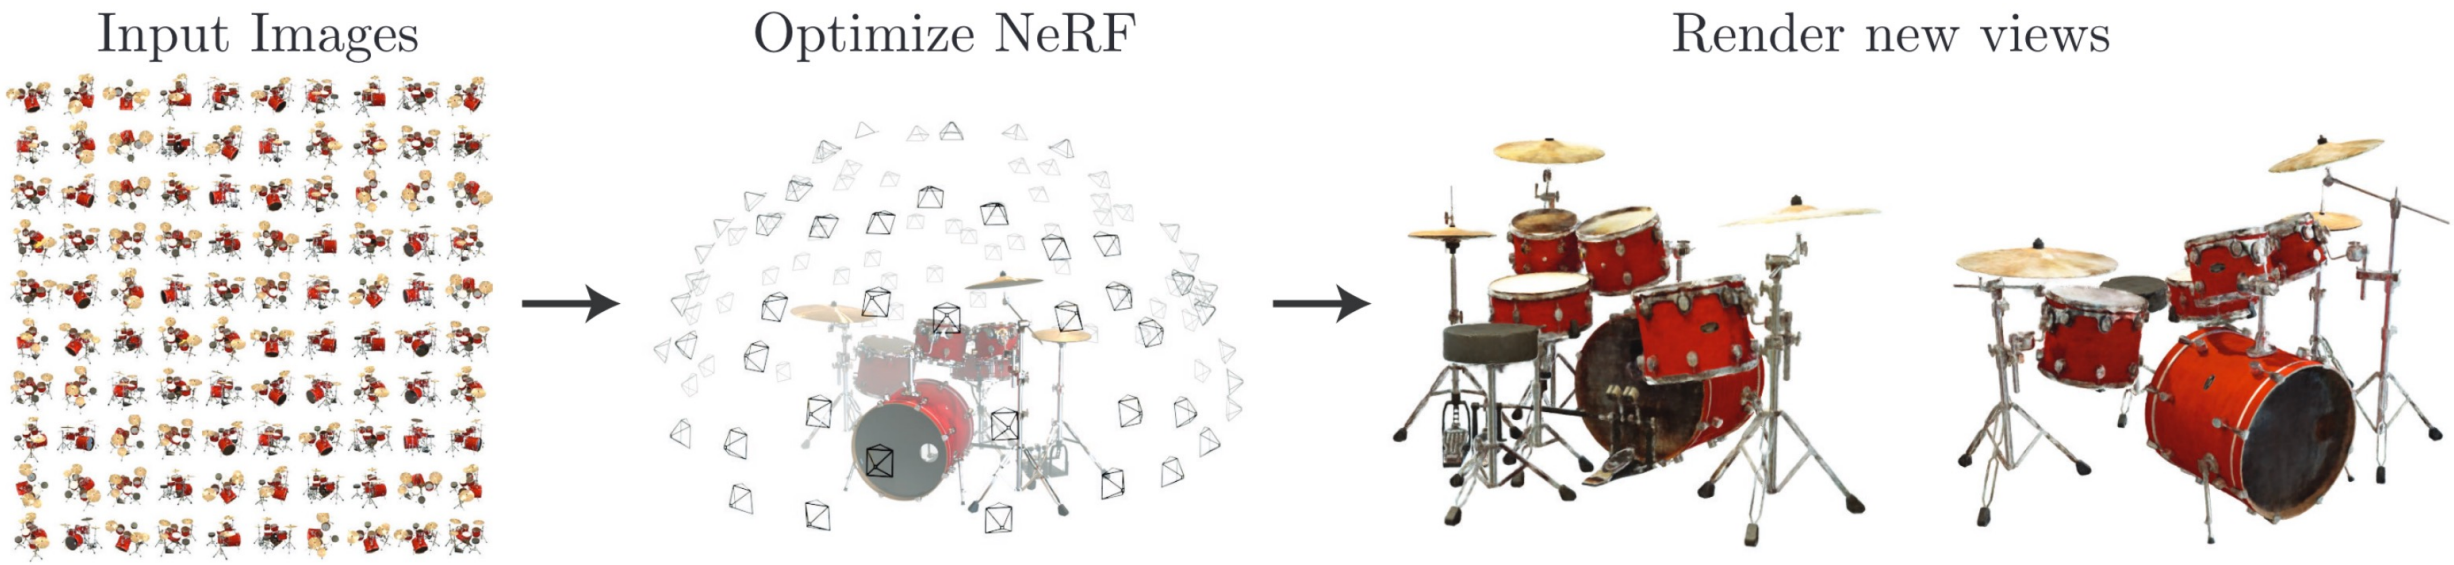




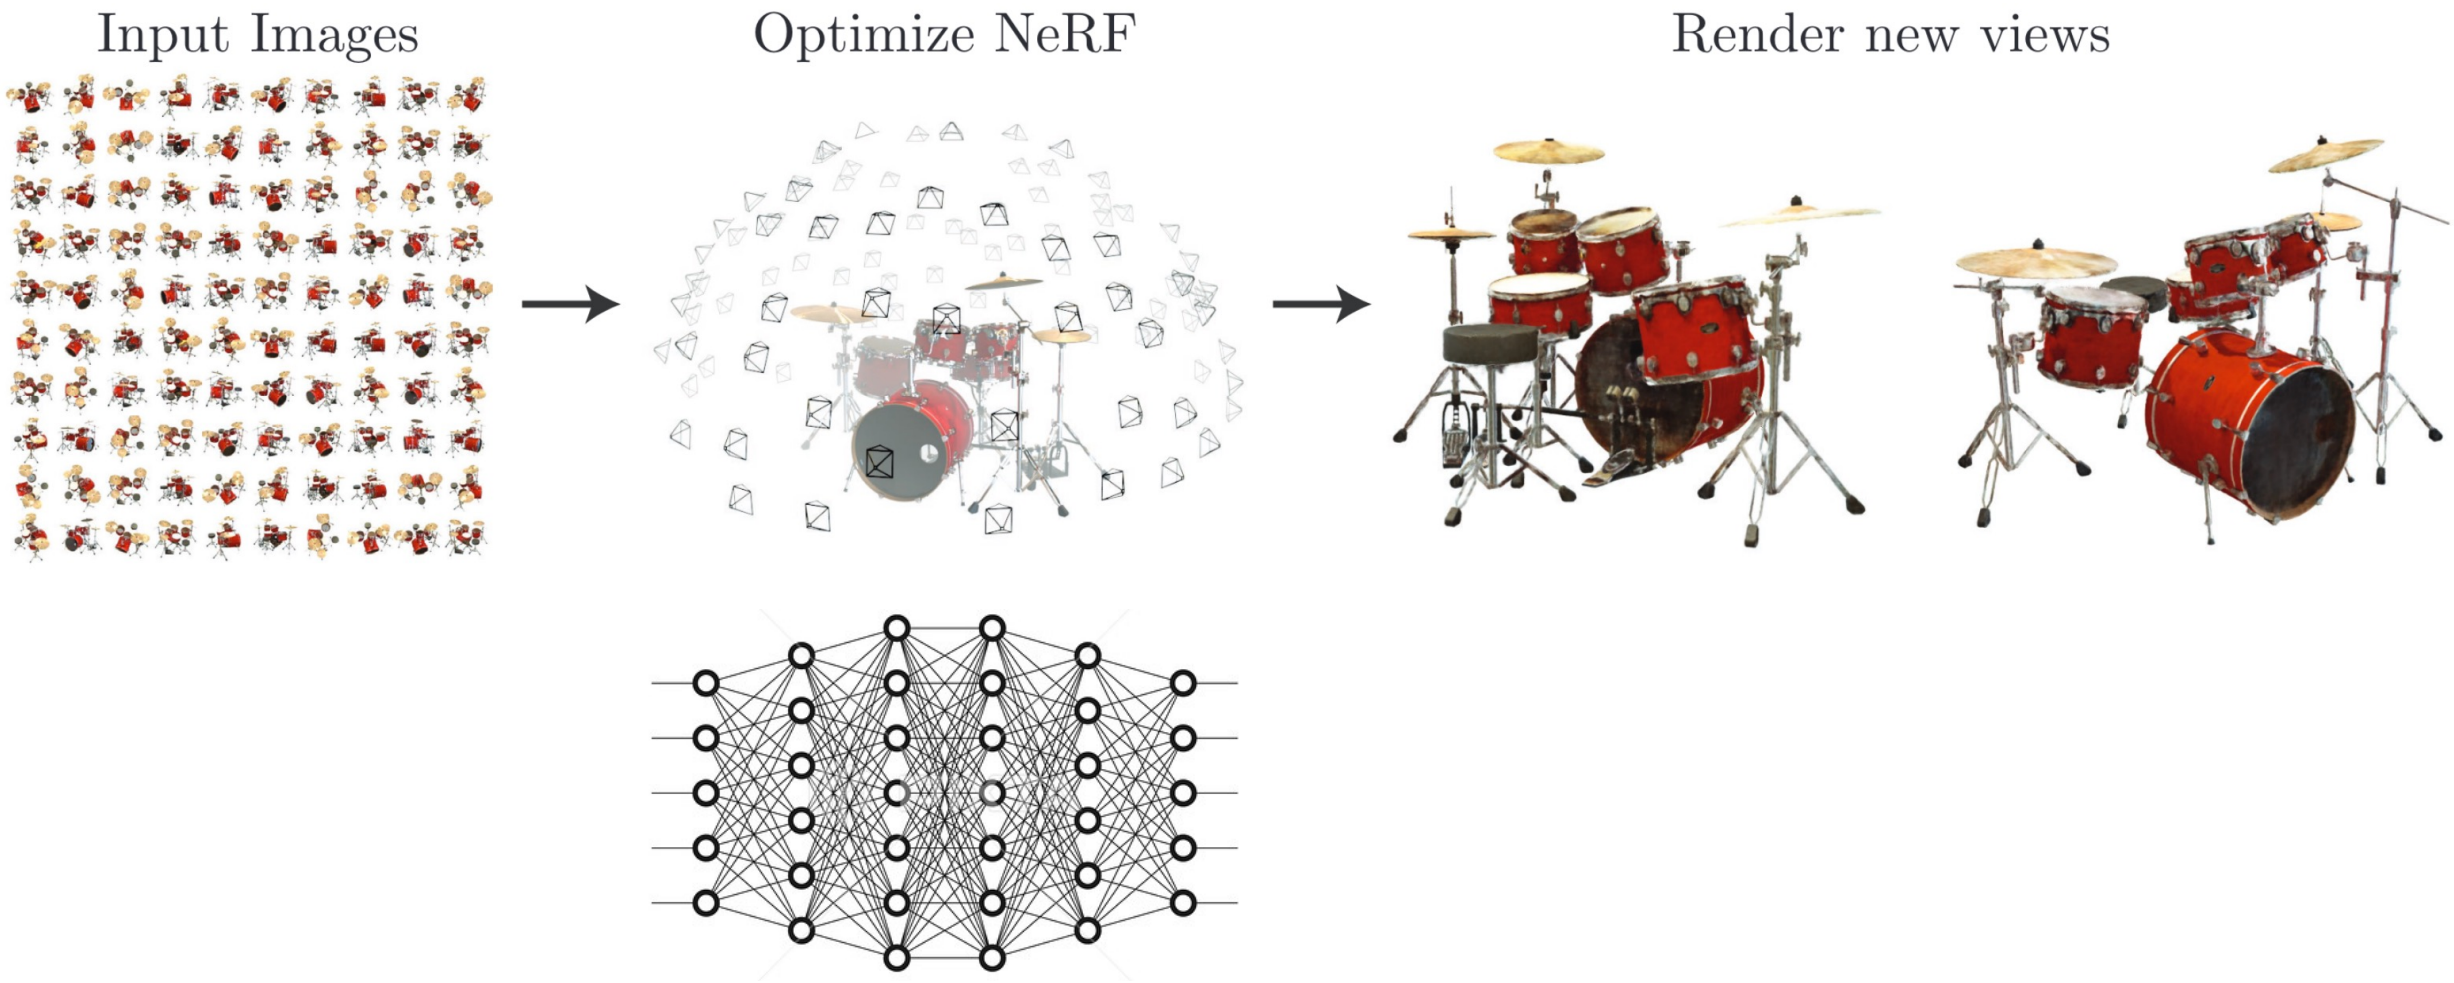
3D Reconstruction

它解决的问题

基于一组图像获得场景表示。

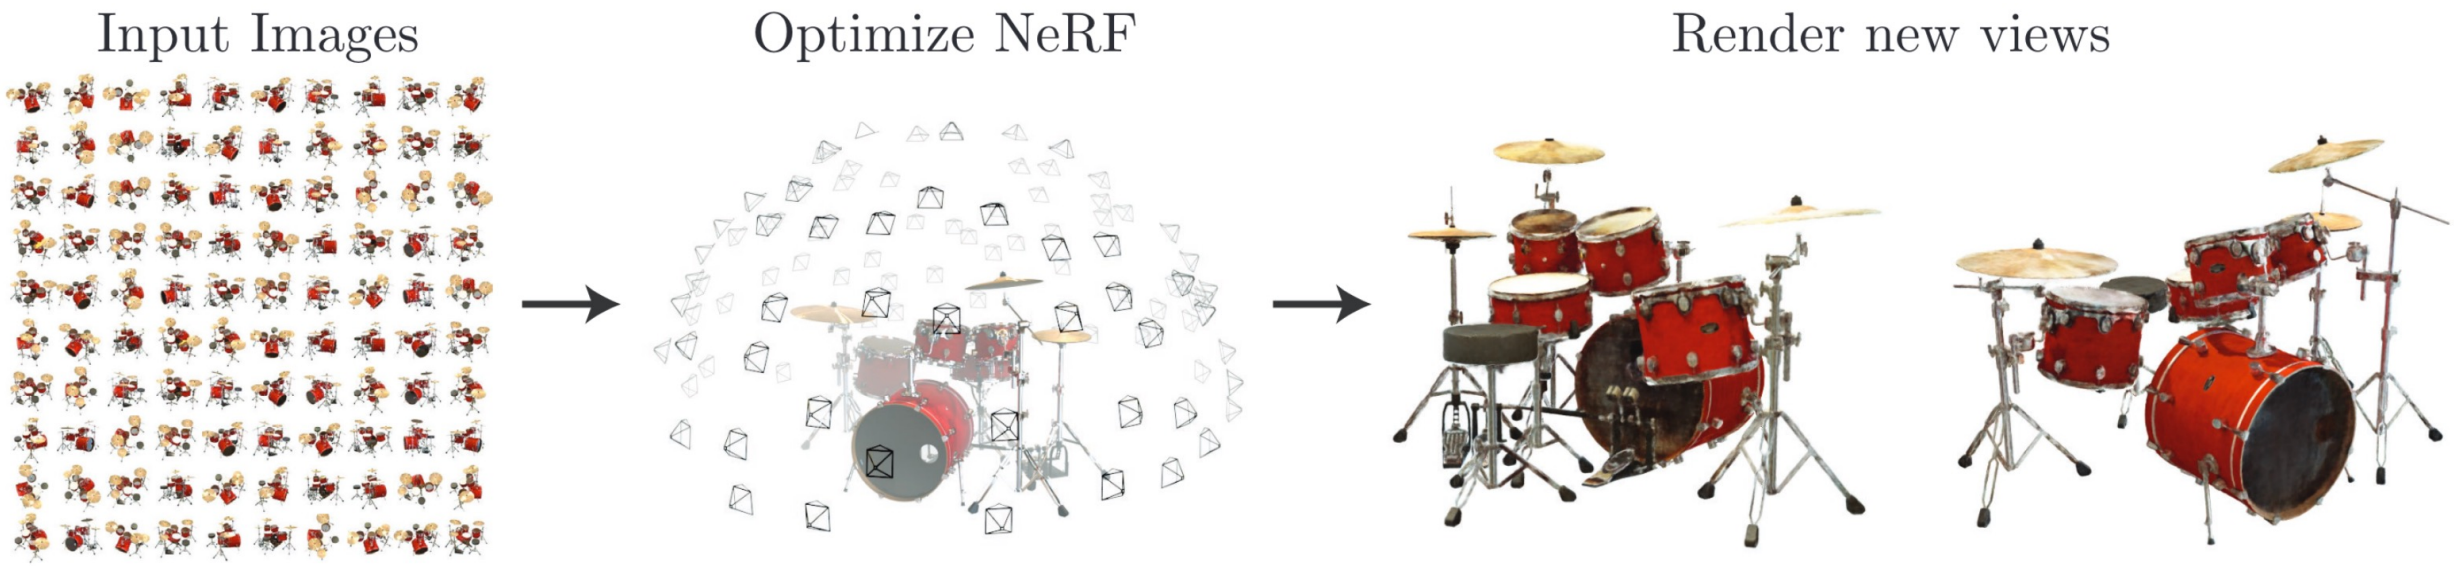


它解决的问题

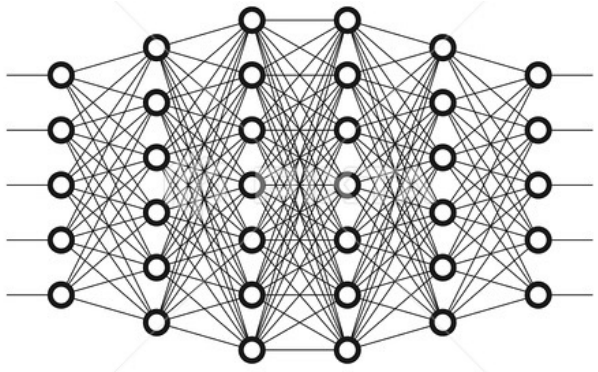


使用神经网络来表示场景

它解决的问题



$(x, z, z, \mu, \mathbf{3})$

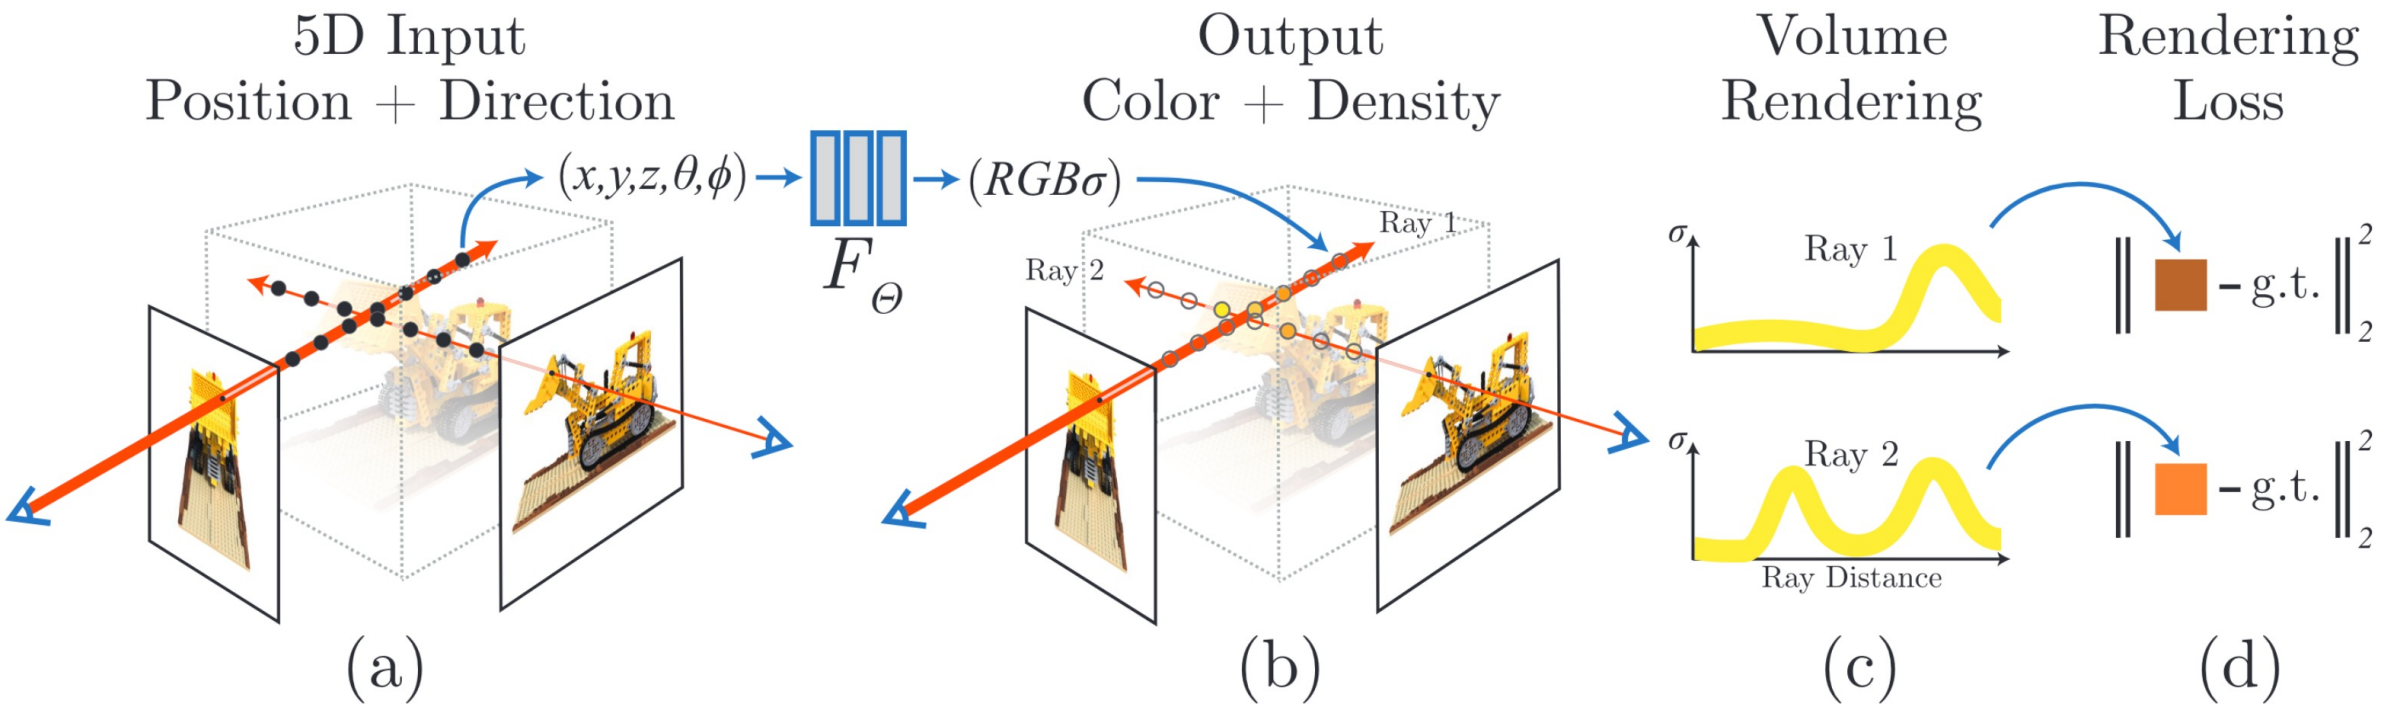


(t, i, d, σ)

使用神经网络表示场景

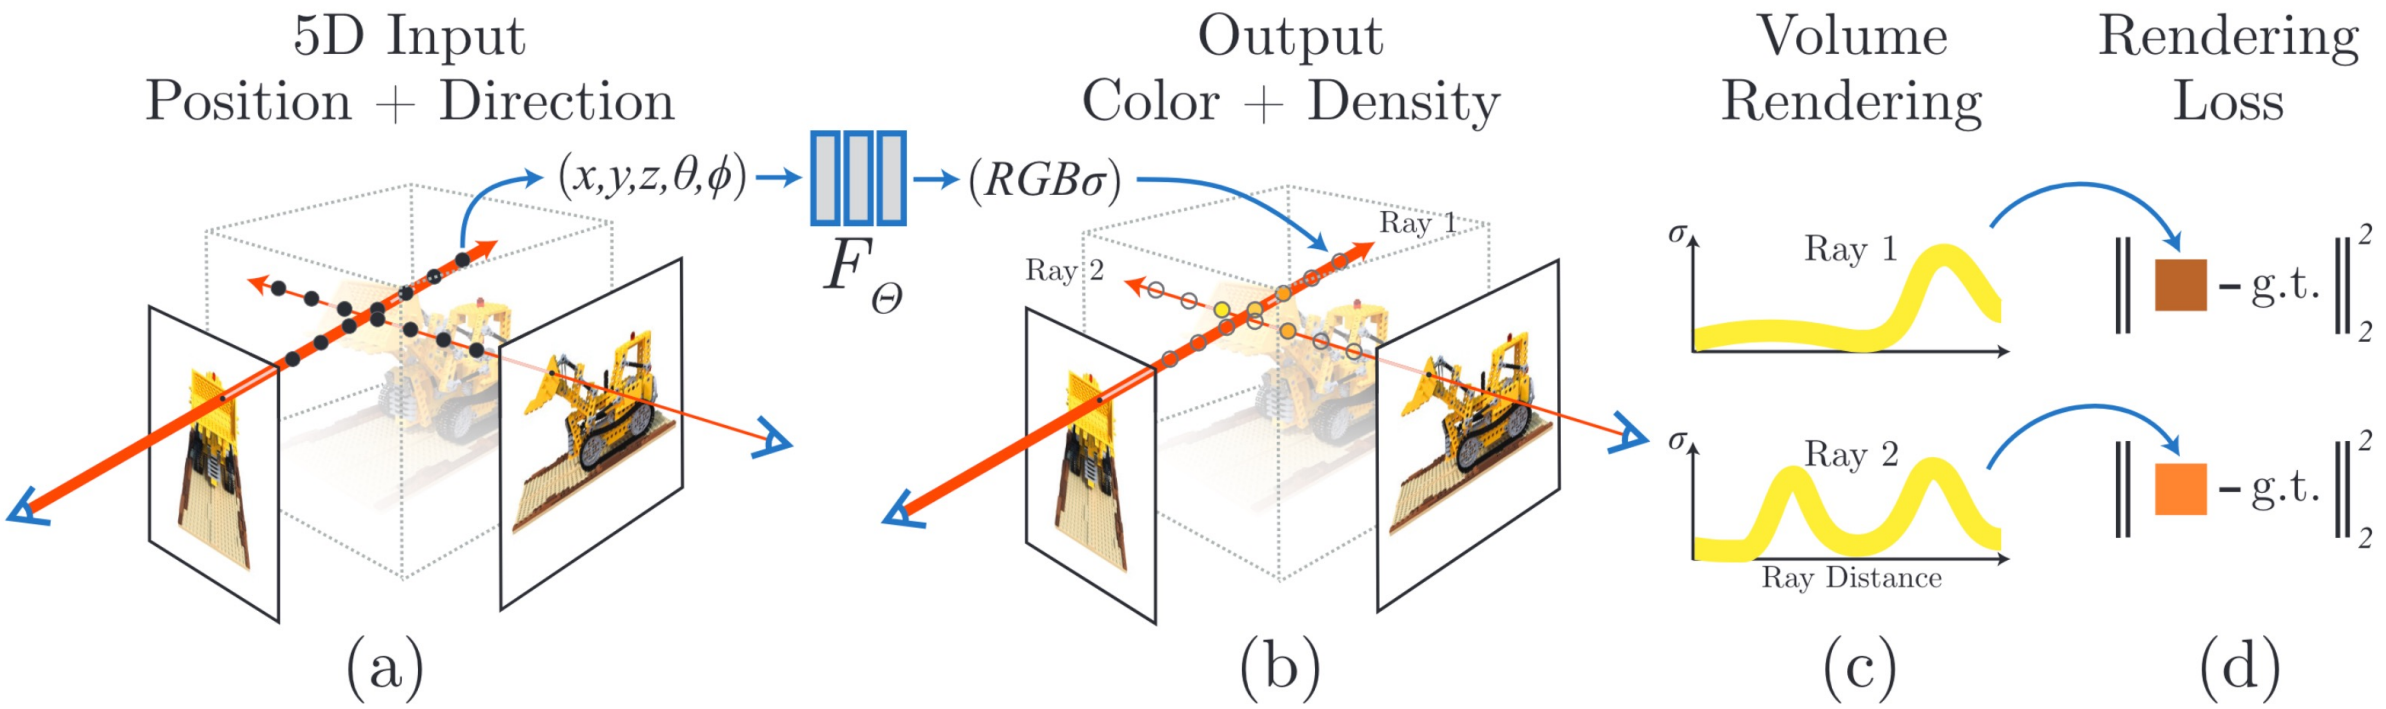
基本思想

概述


5D Input
Position + Direction
(x,y,z,θ,ϕ)
F_Θ
Output
Color + Density
$(RGB\sigma)$
Ray 1
Ray 2
Volume
Rendering
Rendering
Loss
σ
Ray 1
Ray 2
Ray Distance
g.t.
(a)
(b)
(c)
(d)

基本思想

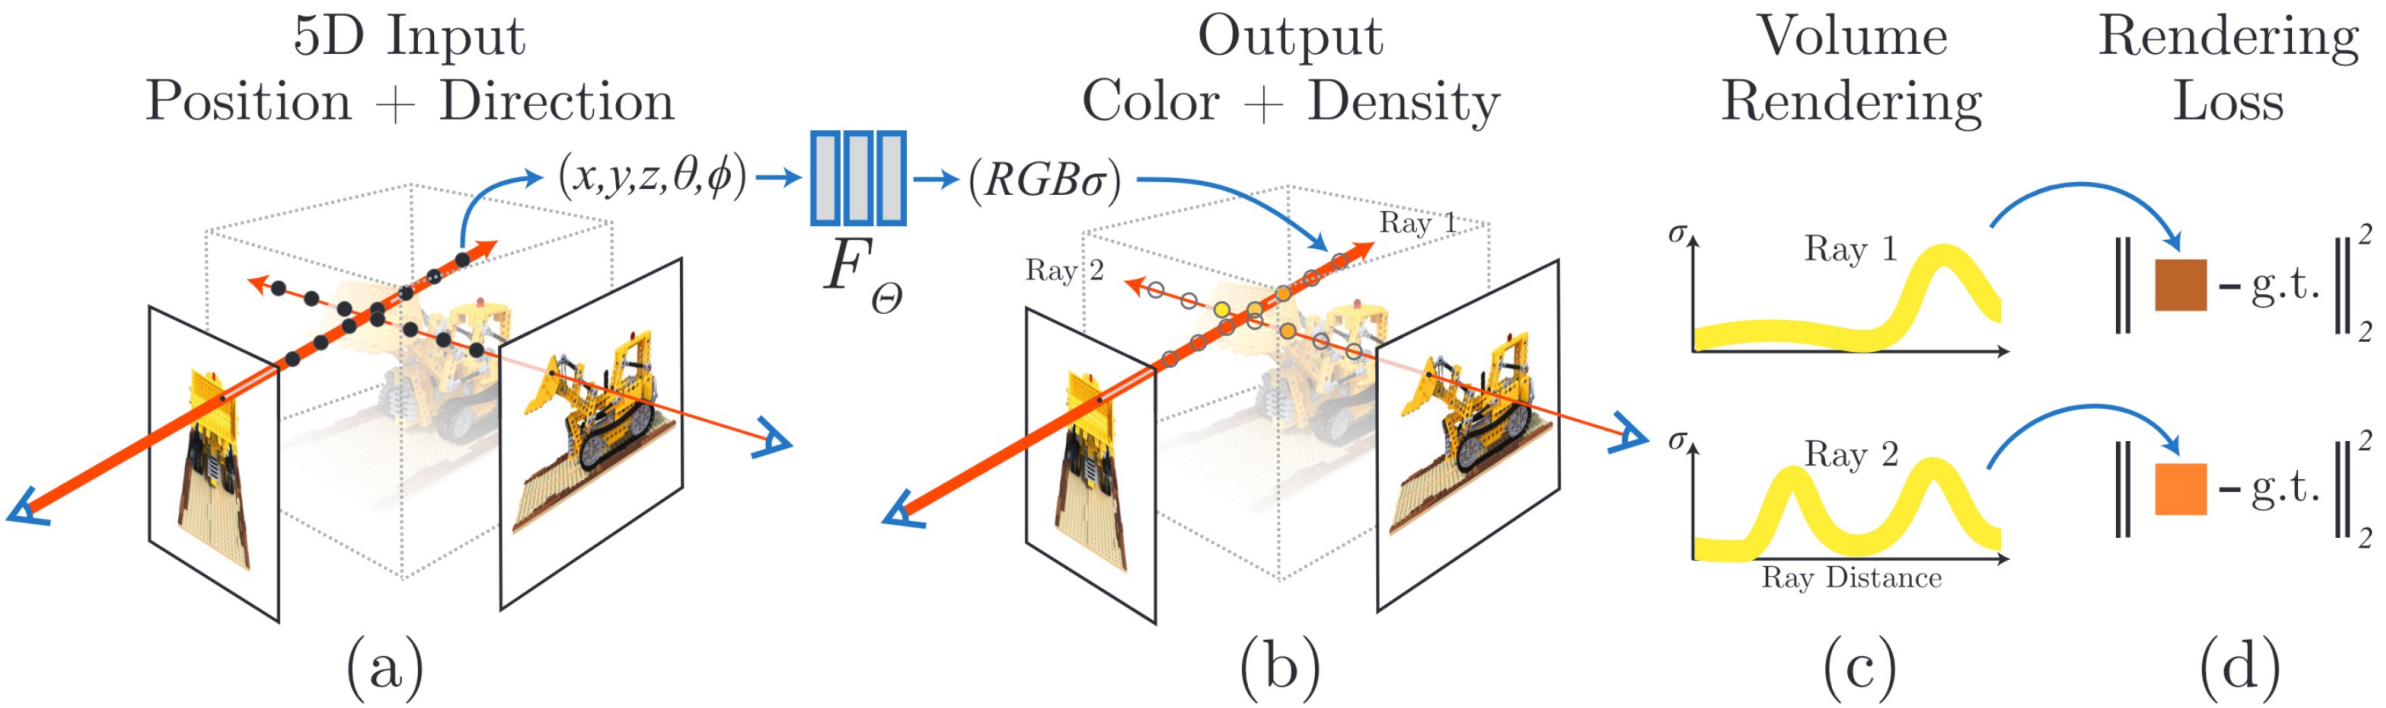
概述



沿相机光线采样

基本思想

概述

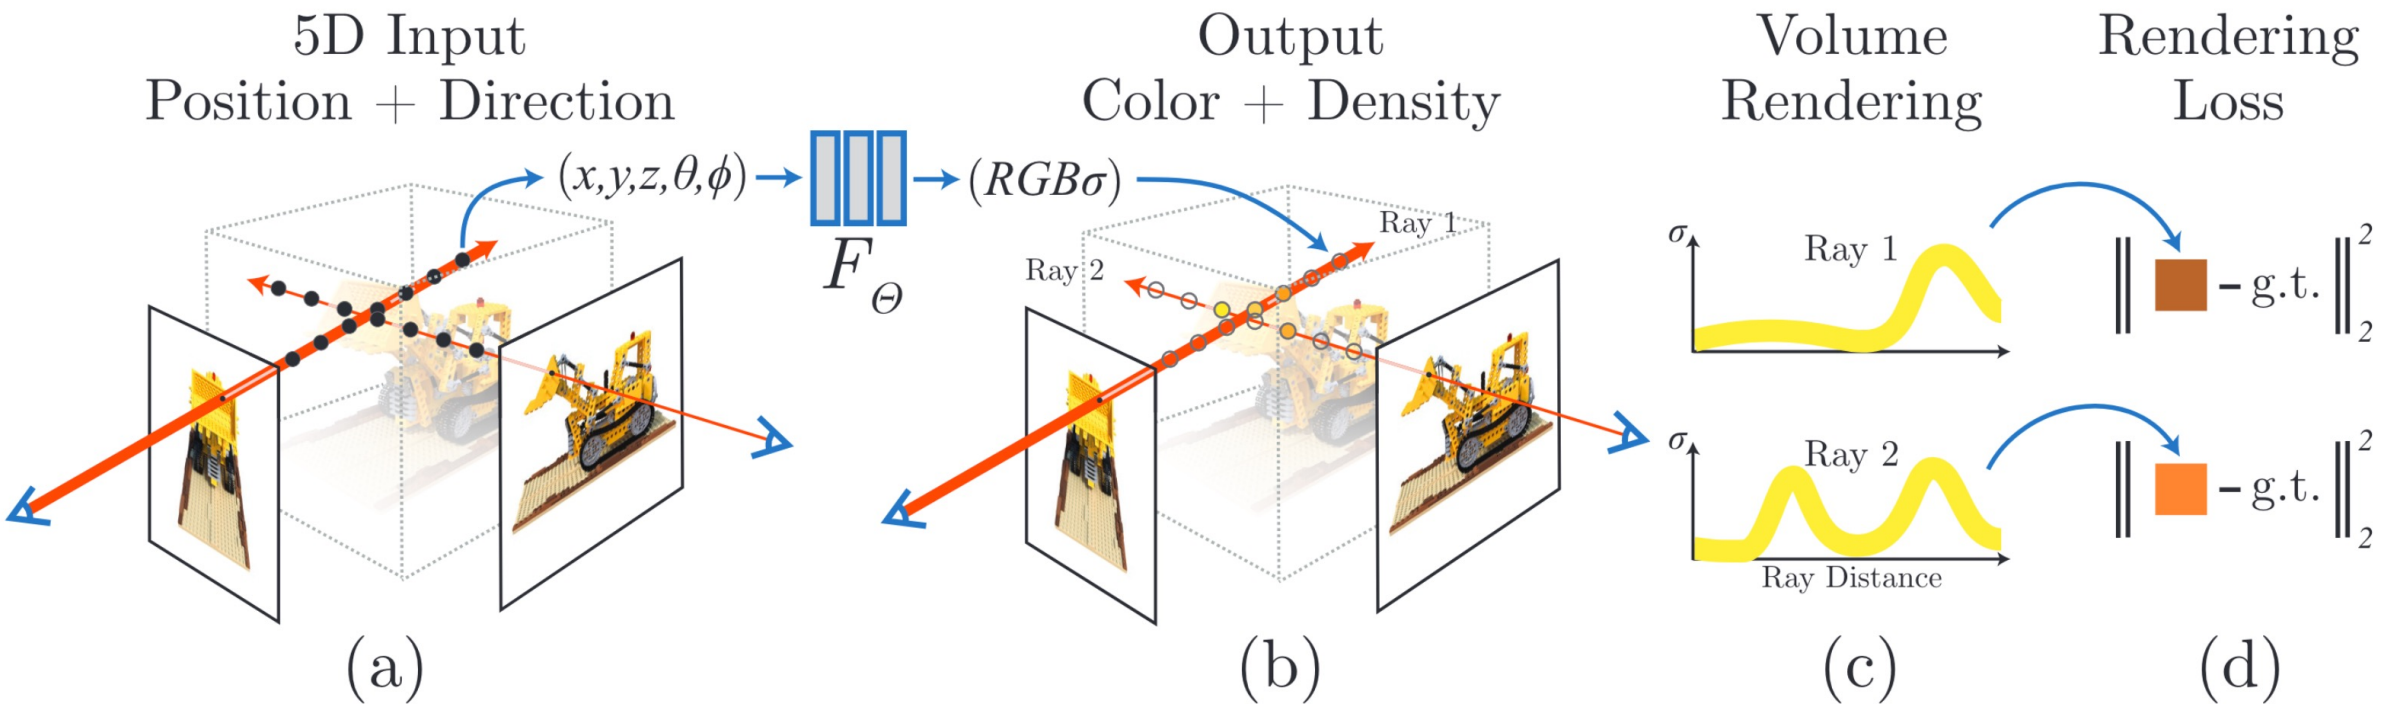


沿相机光线采样

使用 MLP 预测颜色和体积密度

基本思想

概述



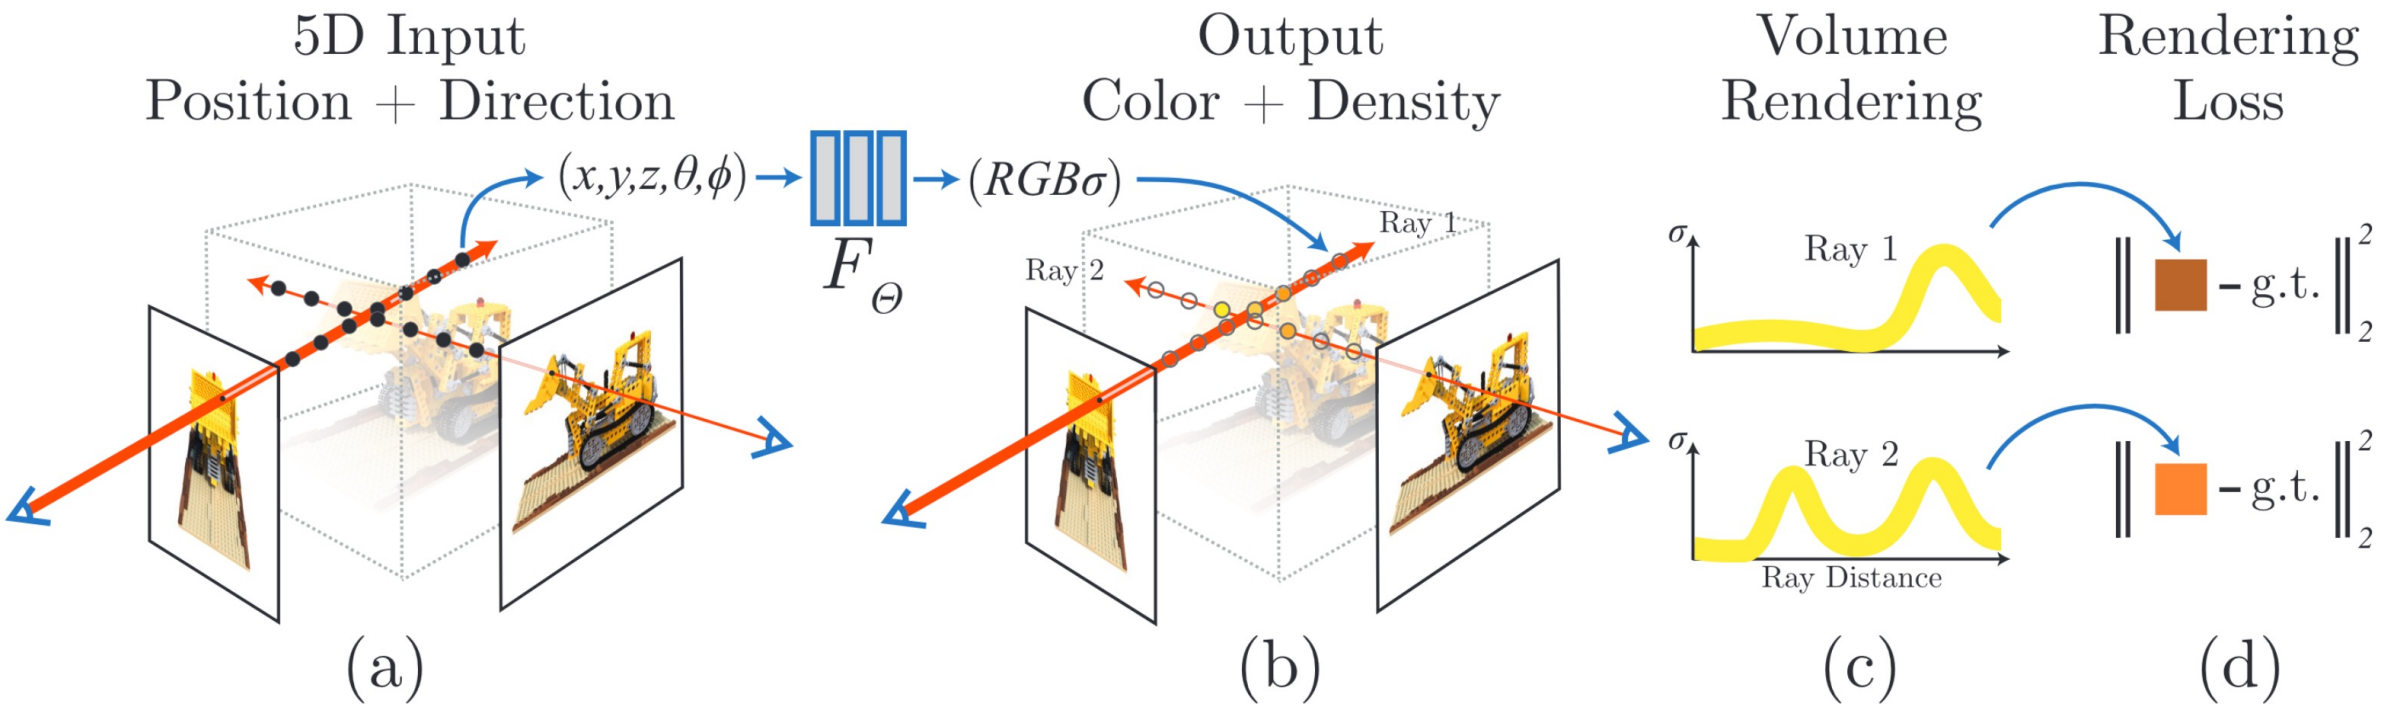
沿相机光线采样

使用 MLP 预测颜色和体积密度

将光线上的点合成一幅图像

基本思想

概述



沿相机光线采样

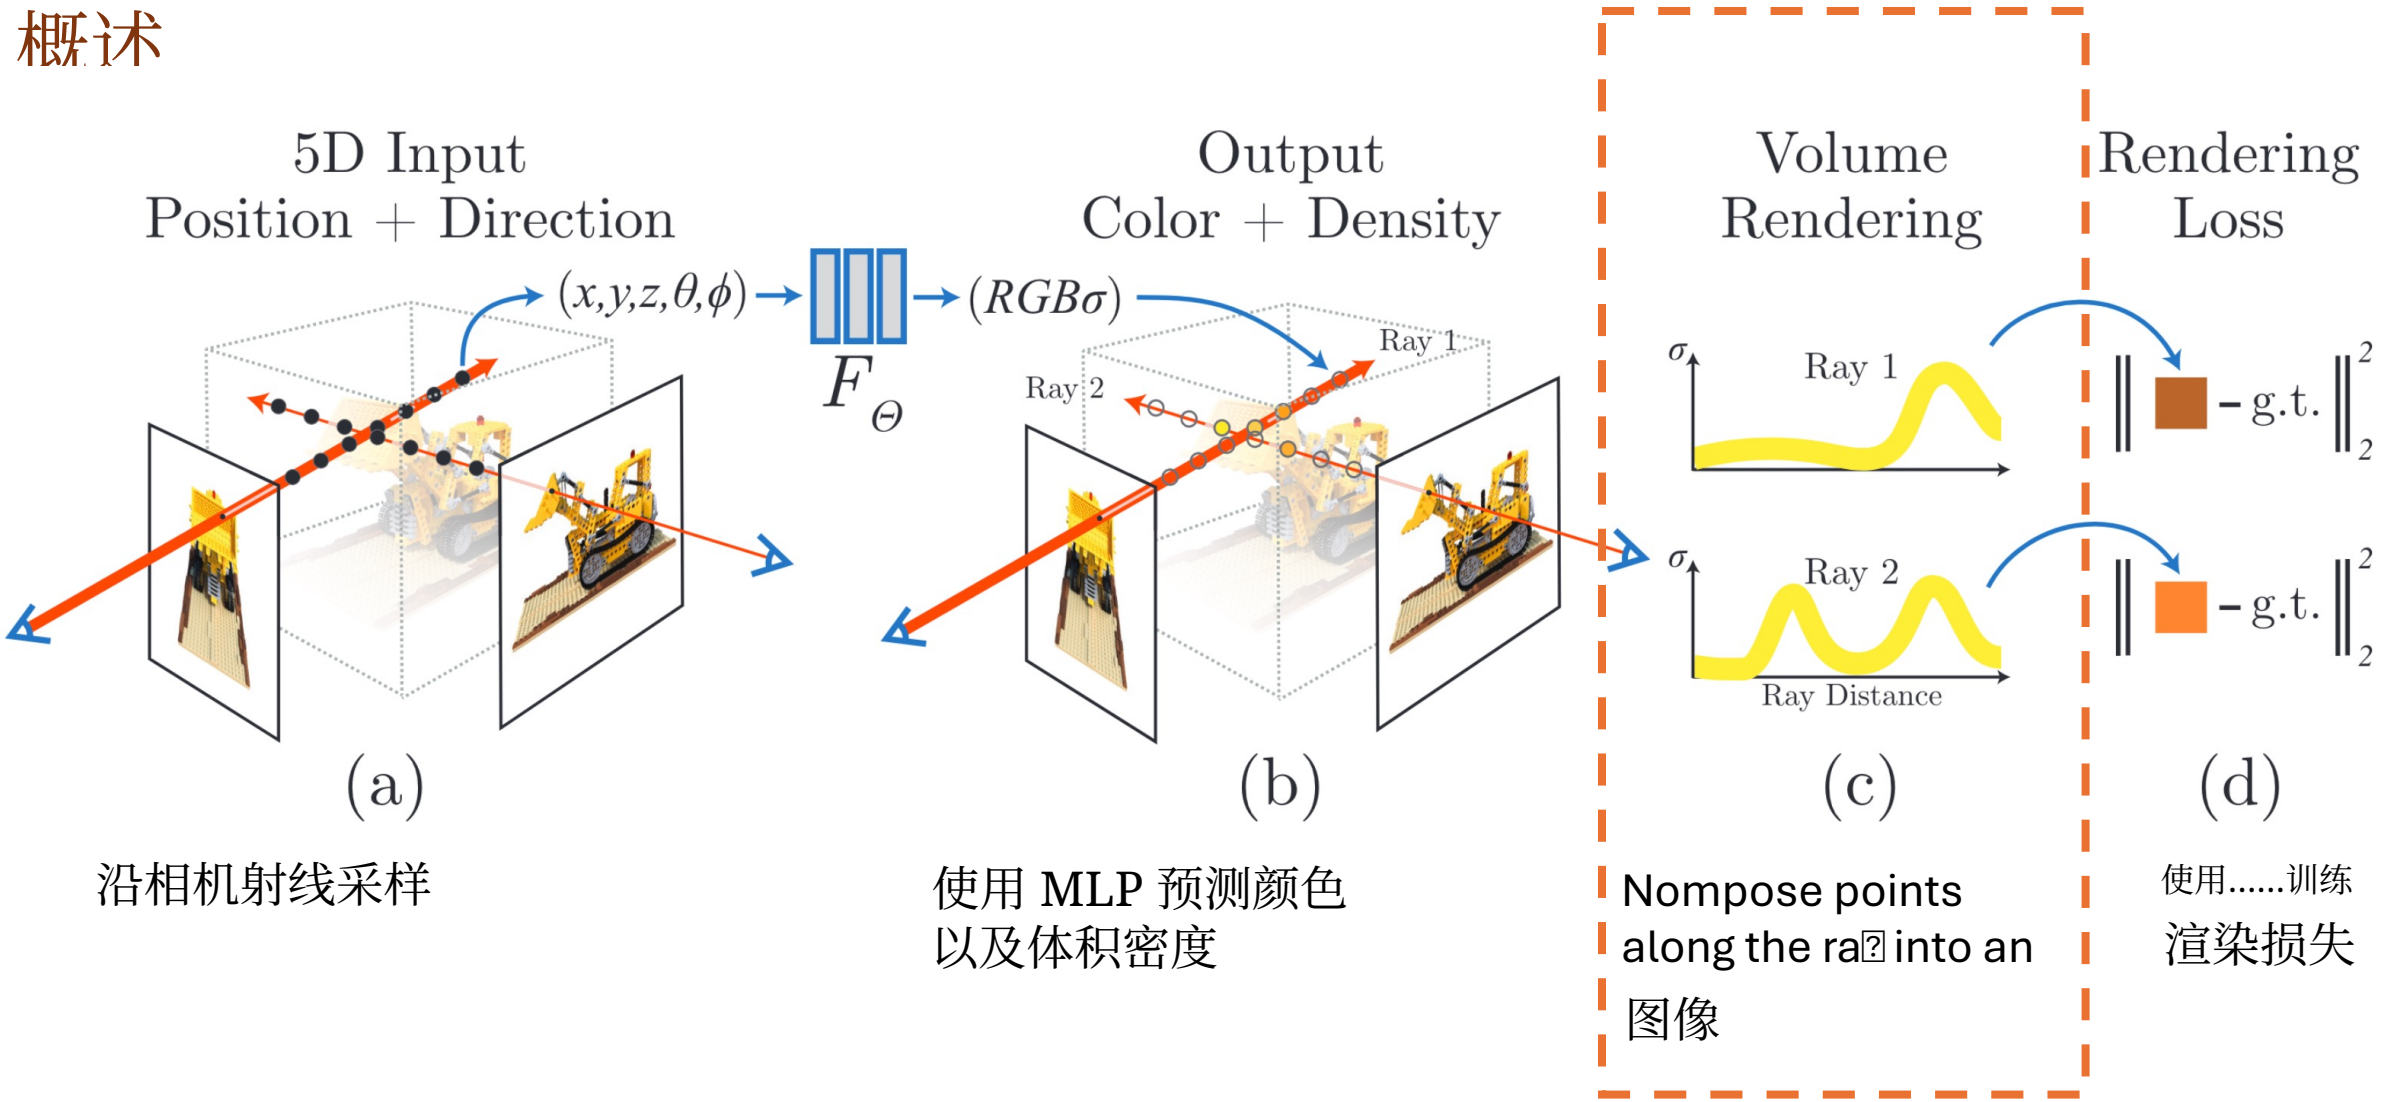
使用 MLP 预测颜色和体积密度

合成点
沿光线变成一个
图像

使用.....训练
渲染损失

基本思想

概述



沿相机射线采样

使用 MLP 预测颜色
以及体积密度

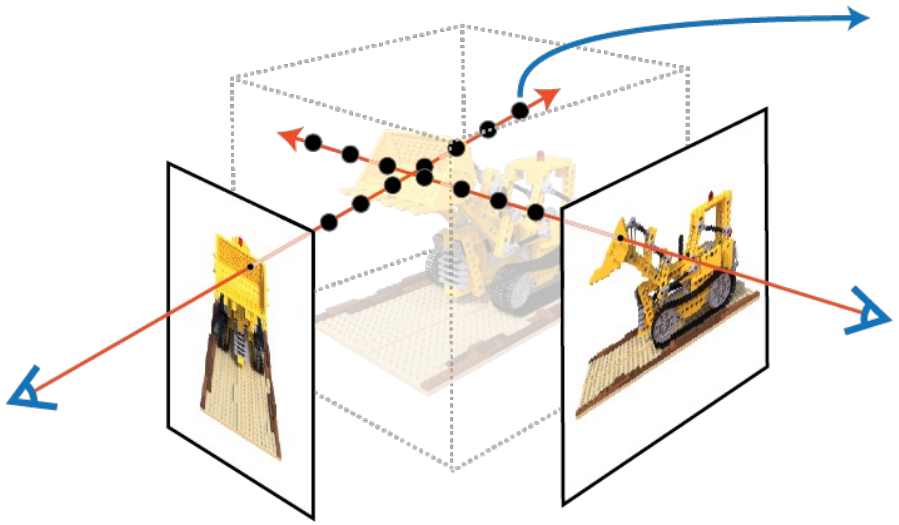
Nompose points
along the ra⍰ into an
图像

使用……训练
渲染损失

基本思想

体渲染

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t), \mathbf{d})dt\,, \text{ where } T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))ds\right)$$

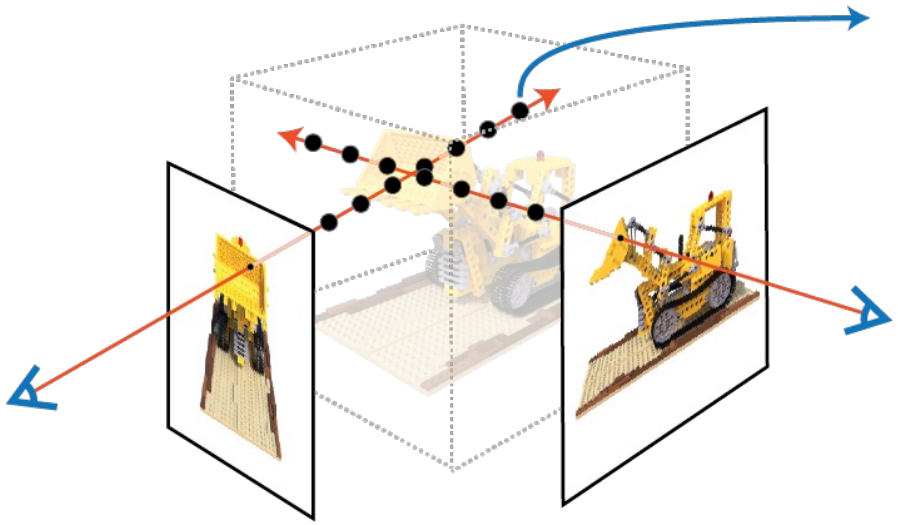


$\boldsymbol{r}$ t → x, y, z 射线中的第 t 个点 $\boldsymbol{r}$

基本思想

体渲染

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t), \mathbf{d})dt\,, \text{ where } T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))ds\right)$$



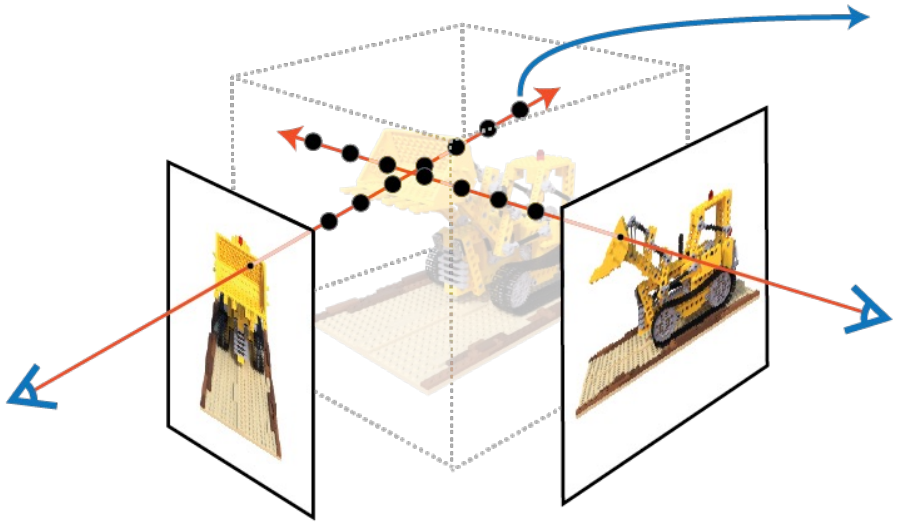
$\boldsymbol{r}(t) \to (x, y, z)$　射线 $\boldsymbol{r}$ 中的第 t 个点

$\sigma(\boldsymbol{r}(t)) \to [0, 1]$　体积密度

基本思想

体渲染

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t), \mathbf{d})dt\,, \text{ where } T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))ds\right)$$



$\boldsymbol{r}$ t → x, y, z 射线中的第 t 个点 $\boldsymbol{r}$

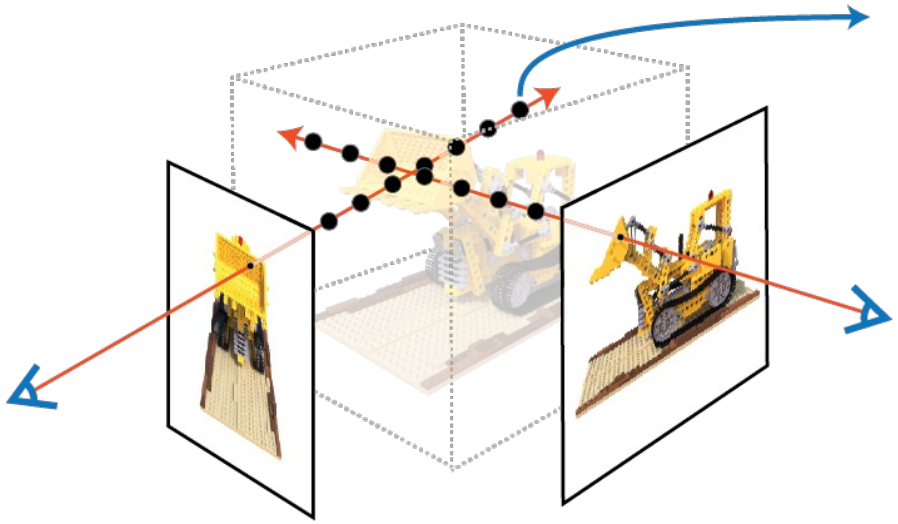
σ $\boldsymbol{r}$ t → 0,1 体积密度$\boldsymbol{c}$ $\boldsymbol{r}$ t,

d → r, g, b 颜色

基本思想

体渲染

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t), \mathbf{d})dt\,, \text{ where } T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))ds\right)$$



$\boldsymbol{r}\ t \rightarrow x, y, z$ 射线中的第 t 个点 $\boldsymbol{r}\sigma\ \boldsymbol{r}\ t \rightarrow 0,1$ 体积密度

$\boldsymbol{c}\ \boldsymbol{r}\ t, d \rightarrow r, g, b$ 颜色 $T(t) \rightarrow [1, 0]$ 射线在未击中任何其他粒子的情况下传播的概率

□G Ga. ssian cpla ing





实时渲染



□□□□ Fdg





为什么选择
3DGS

点云 / 体素： 离散且易于编辑，但视觉上稀疏（点）或内存占用大（体素）。

网格： 连续表面，但固定的拓扑结构使得基于梯度的优化变得困难。

SDF（有符号距离场）： 拓扑灵活，但难以捕捉高频纹理和复杂细节。

NeRF： 高质量渲染，但由于密集光线采样而慢得令人痛苦。

为什么选择 3DGS

点云 / 体素： 离散且易于编辑，但在视觉上稀疏（点）或内存占用高（体素）。

网格：具有连续表面，但固定拓扑使基于梯度的优化变得困难。

SDF（有符号距离场）：拓扑灵活，但难以捕捉高频纹理和复杂细节。

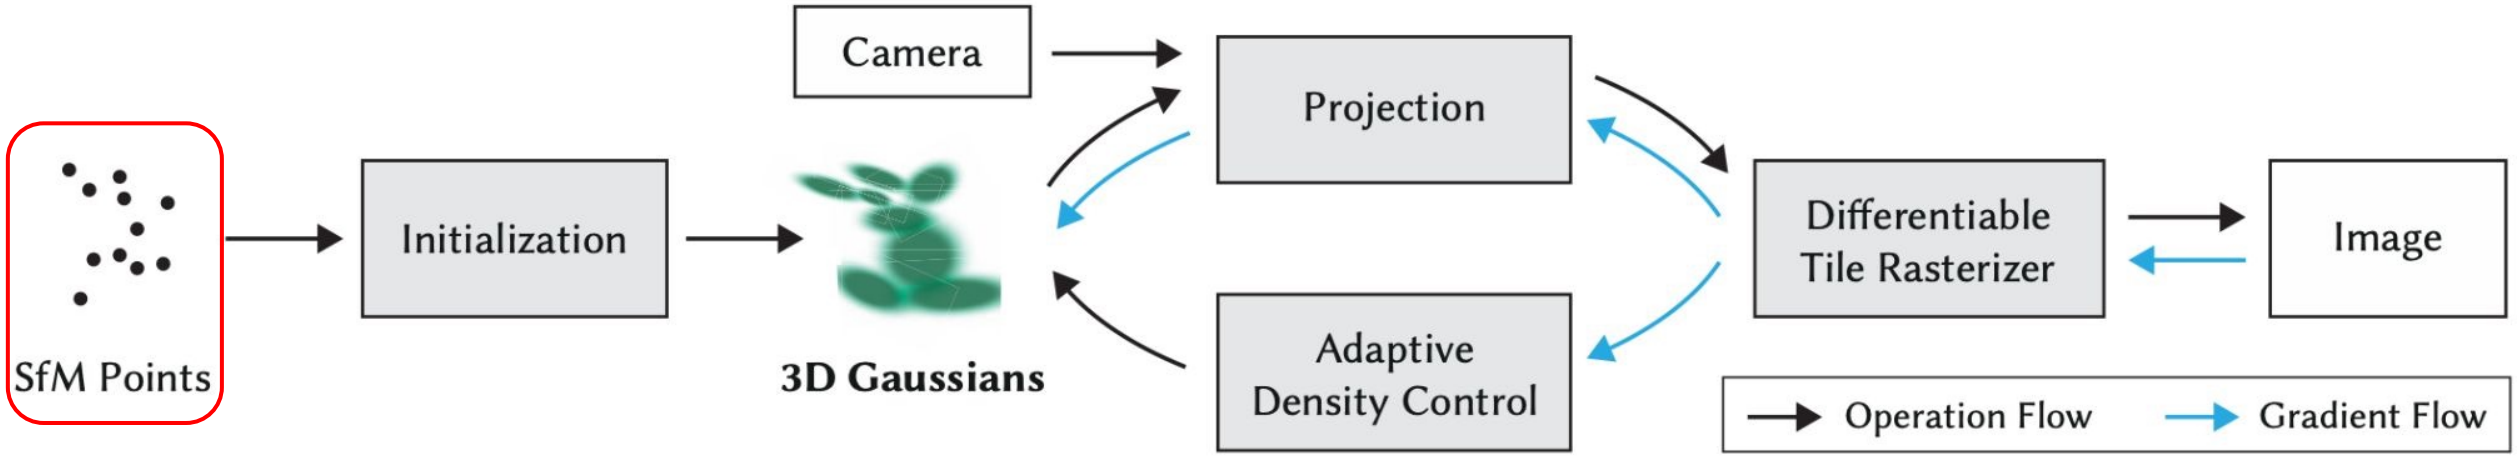
NeRF：渲染质量高，但由于密集光线采样而极其缓慢。

3DGS：

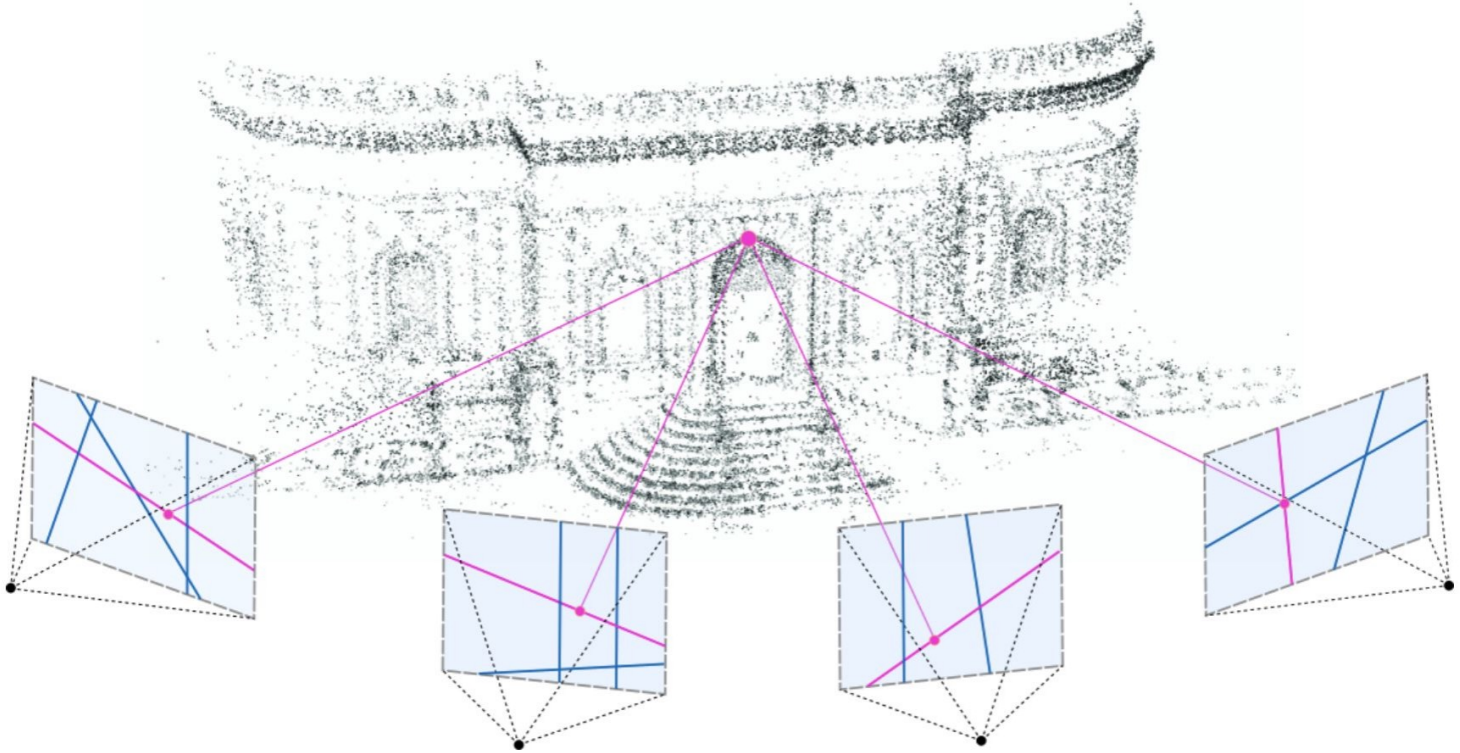
- 实时高保真渲染——□□□□ FPS。
- Rxplicit pepresentation□ flexible and easy to update.
- 完全可微流水线——高度可优化。

3GGc aipeline

运动恢复结构



Structure-from-Motion



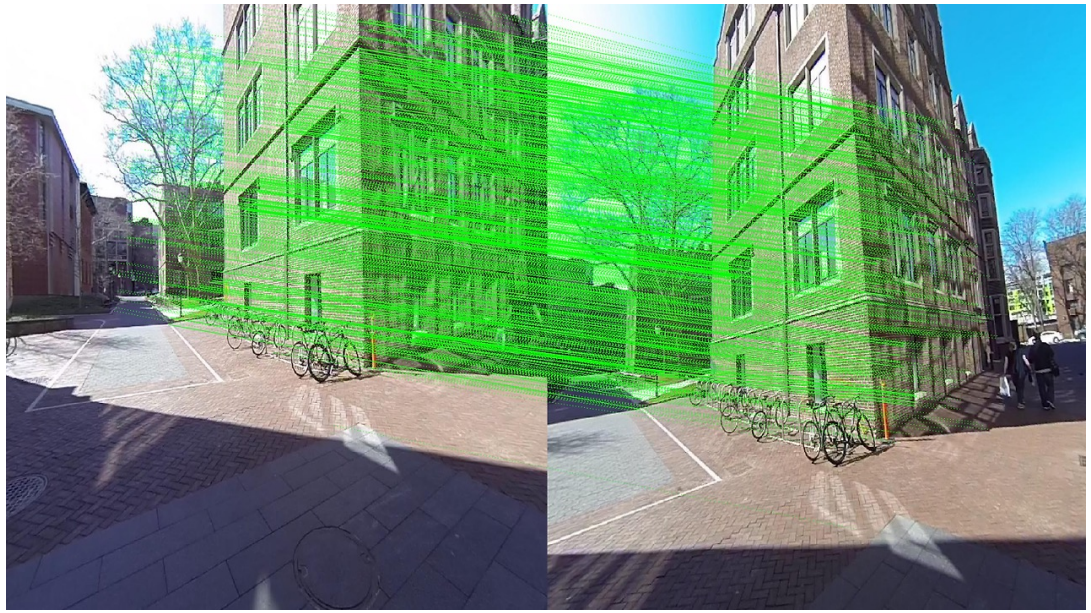
目标：在训练 3D 高斯之前，我们需要从一组 2D 图像中同时估计 3D 结构（稀疏点）和相机参数（□, □, □）。

一个经典却复杂的算法。更多详情，请参阅：Str□- t□re□from□n otion s e□isite=

COLMAP 官方文档

运动恢复结构

特征匹配



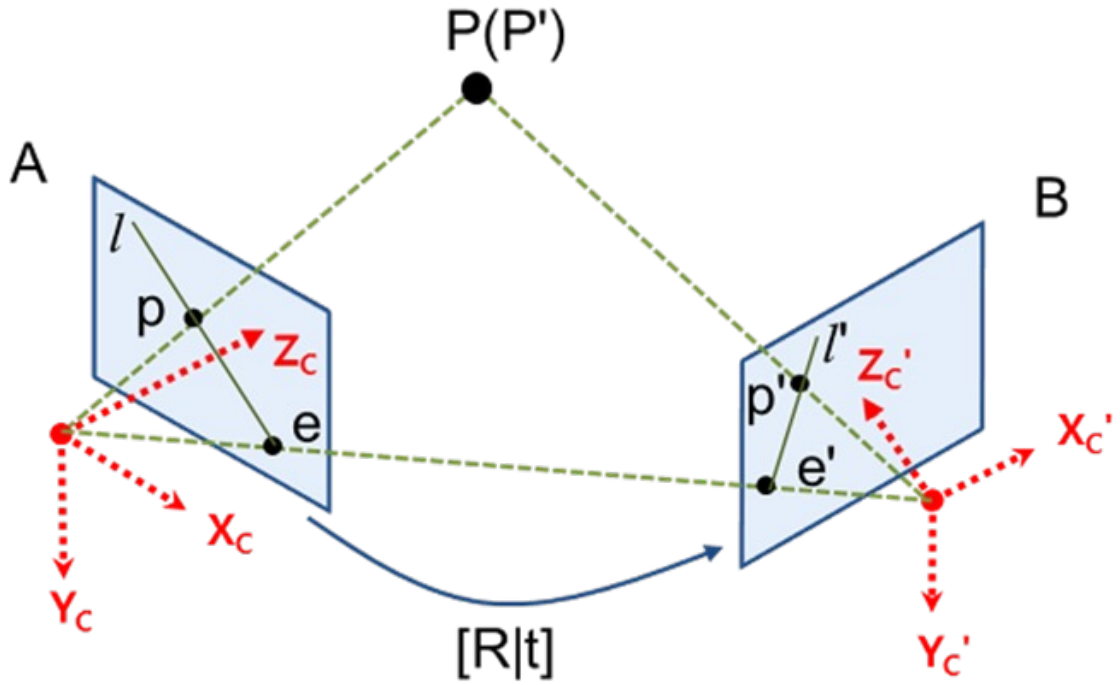
提取：检测鲁棒关键点（例如，SIFT，）。需要有纹理的表面。

匹配：基于视觉相似度对点进行配对。

问题： 会生成许多错误匹配（外点）。

运动恢复结构

几何验证



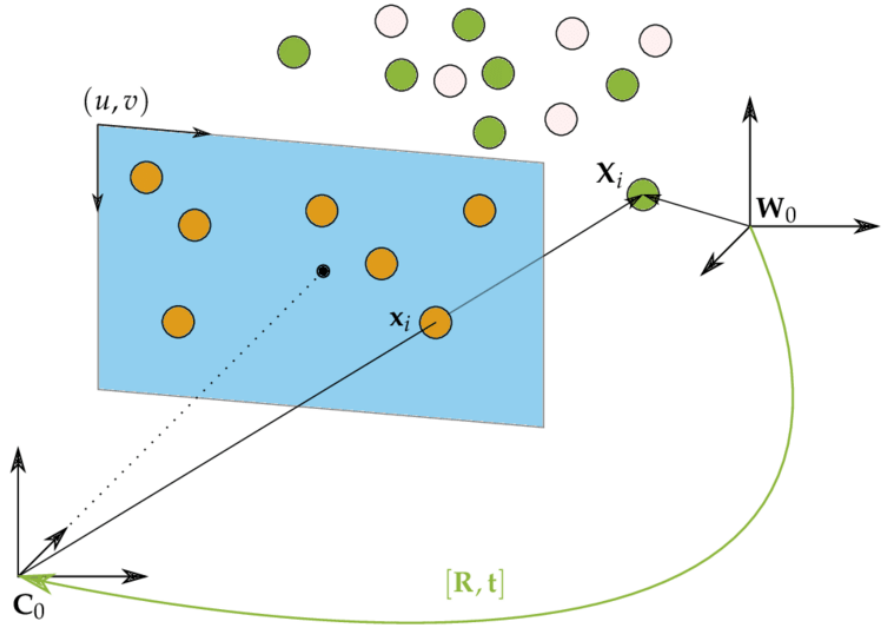
目标：滤除错误　　利用数学约束的匹配（外点）　　.

规则：对极几何——物理点必须满足三维空间约束。

滤波器： RANSAC算法——迭代地寻找数学上正确的匹配。**结果：** 仅保留真实匹配（内点）。

运动恢复结构

图像配准



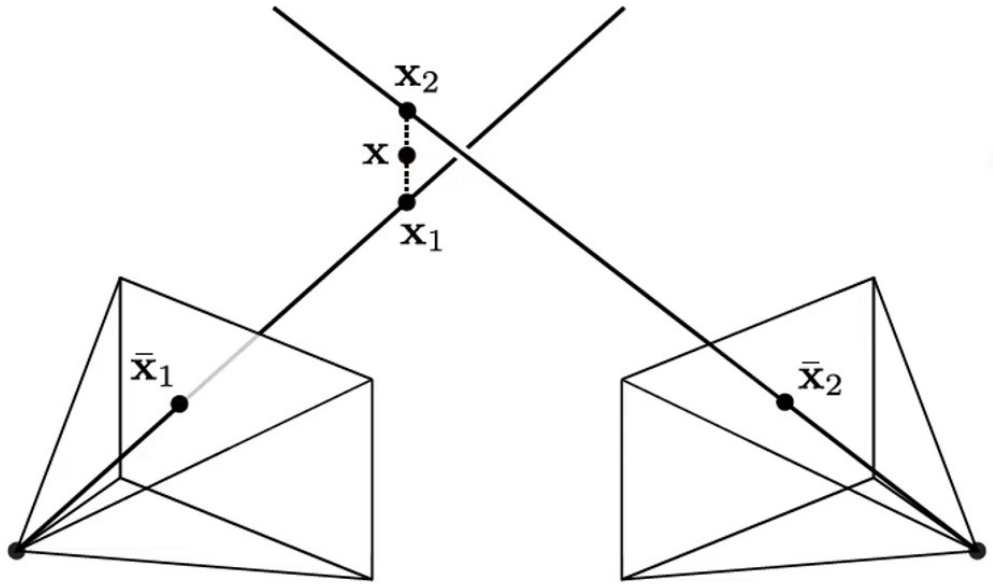
初始化： 从一对高质量的两幅图像开始，构建初始三维地图。

处理（新图像配准）： 使用已知三维点及其对应的二维像素位置来计算新相机的位姿。

算法：PnP（Perspective-n-Point）。

运动恢复结构

三角化



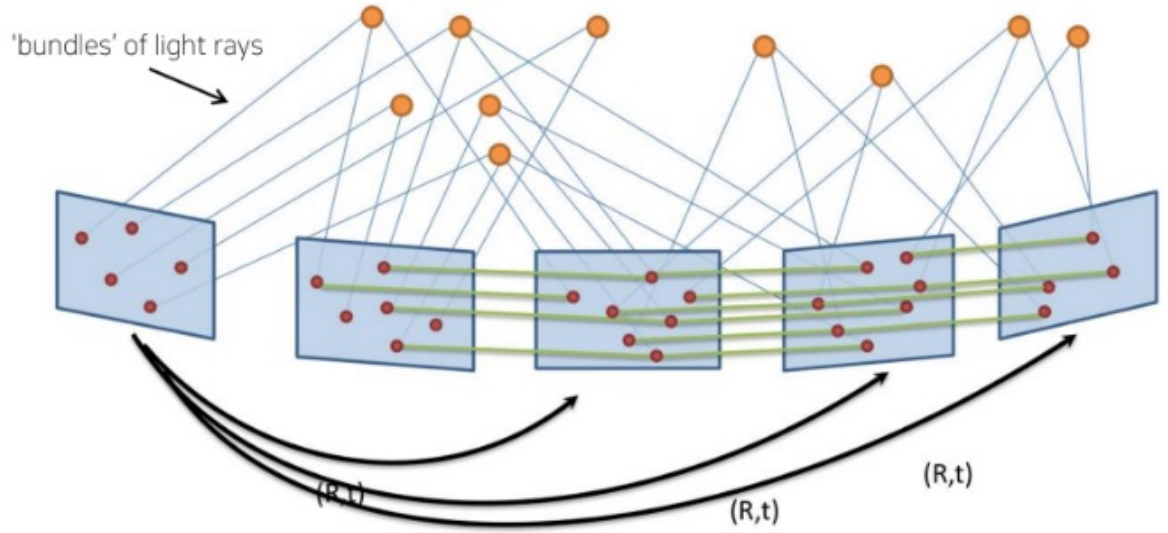
目标：确定匹配特征的精确三维坐标。

机制：对源自多个已知相机位置的视觉射线进行求交。

现实： 由于噪声，光线很少能完美相交，因此需要数学近似来寻找最近点。

运动恢复结构

光束法平差（BA）



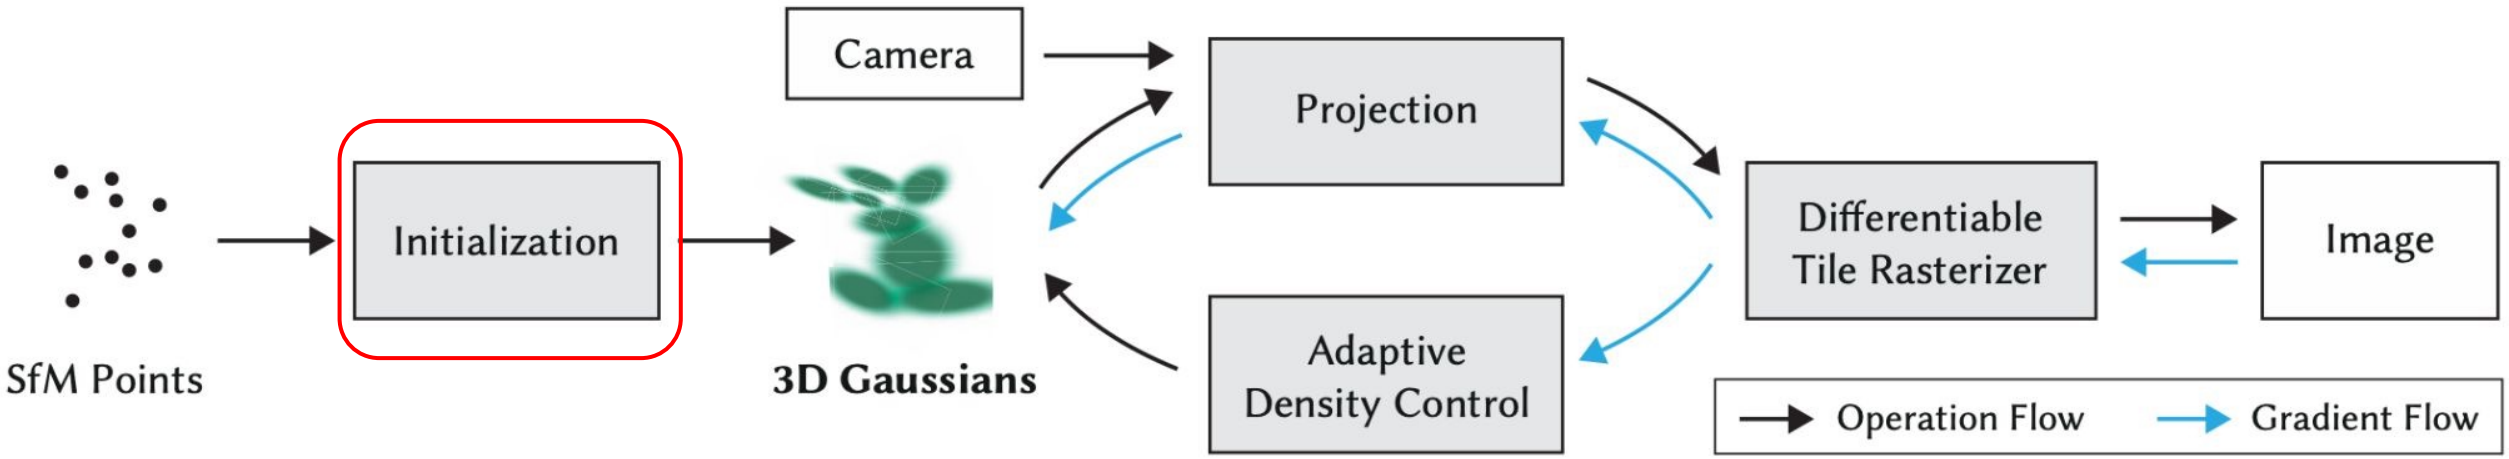
目标：同时联合优化所有相机位姿和三维点位置。

优化目标：最小化重投影误差（观测到的二维像素与投影后的三维点之间的距离）。

最终输出：相机位姿 稀疏点云（3DGS 的起点！）

3GGc aipeline

初始稀疏点云



Phi ial c pare aoin Dlo. i s

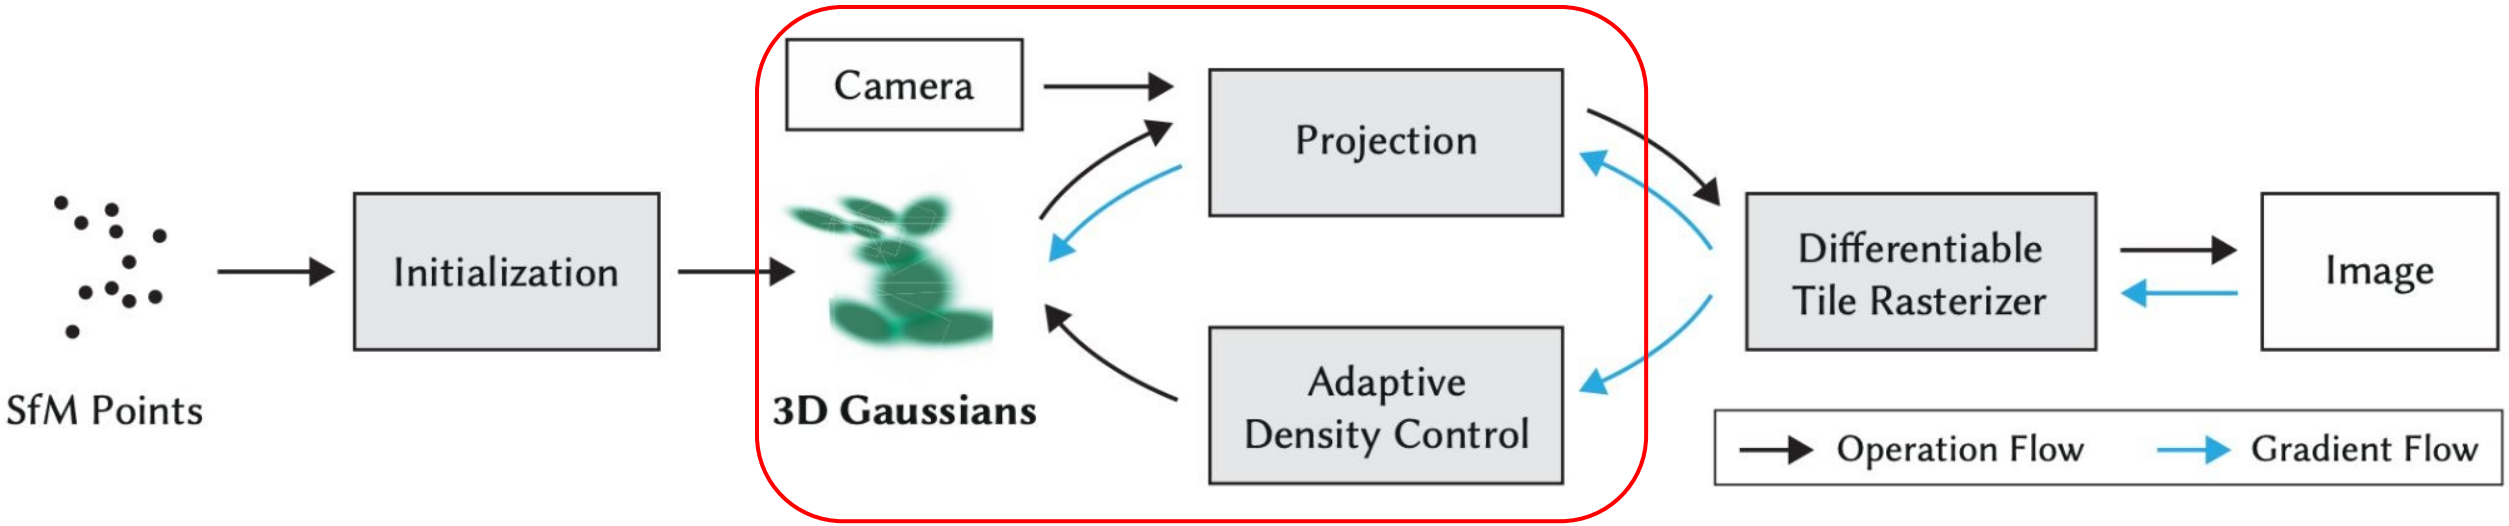




SfM 稀疏点云充当场景的初始“骨架”。

Training aipeline

3D 高斯优化

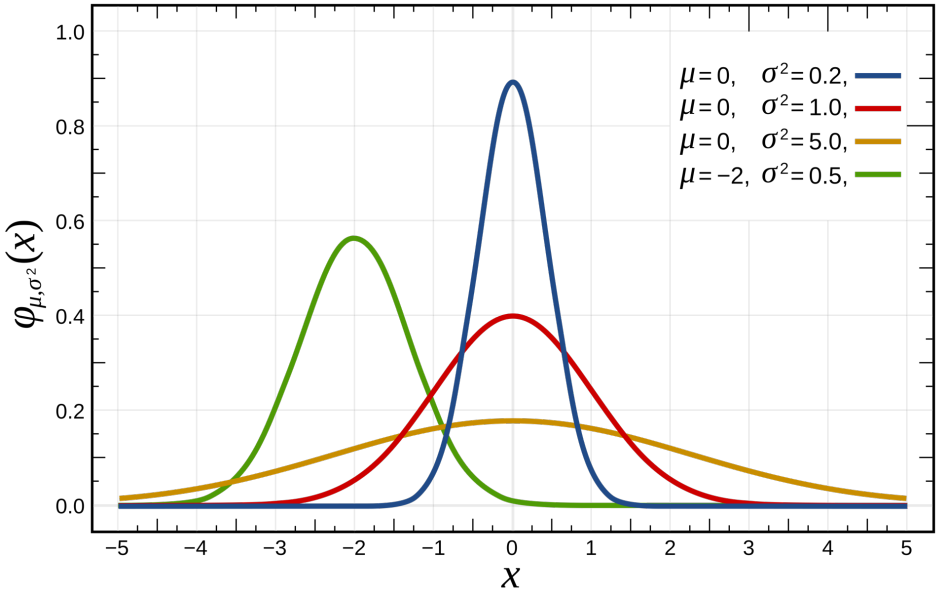


3D Gaussian primitives



由数百万个3D高斯图元构成的最终场景

基础：一维高斯分布



- 由 **均值** （μ）控制：中心在哪里?

由**方差** 控制（$\sigma 2$）：曲线有多宽?

- Formula:

$$g(x) = \frac{2}{\sigma\sqrt{\cdot\,\sigma}} f^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

3D 高斯——几何

G a 3u i3n Distribution The Glipsoid

由 **3D 均值向量** (μ) 控制：位置为 (Y, Z, a)。

由 **协方差矩阵** (ε) 控制：定义 3D 体积、形状与朝向。

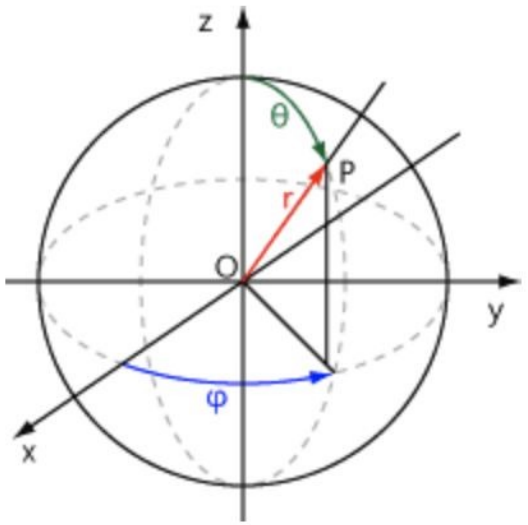
公式：

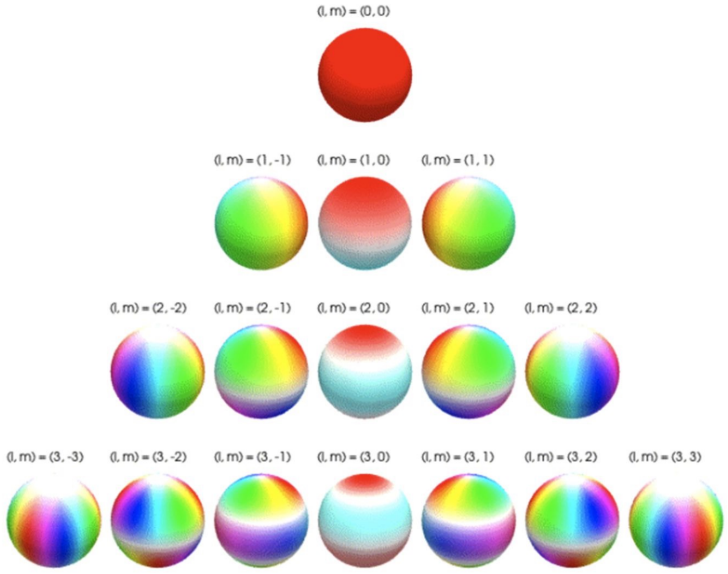
$$G(x) = e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$$

将场景建模为连续的三维密度场。

3G Ga. ssians Wpahi y ani Dolor

- 不透明度 3：透明度级别 3333
- 颜色：球谐函数（SH）系数 球谐光照





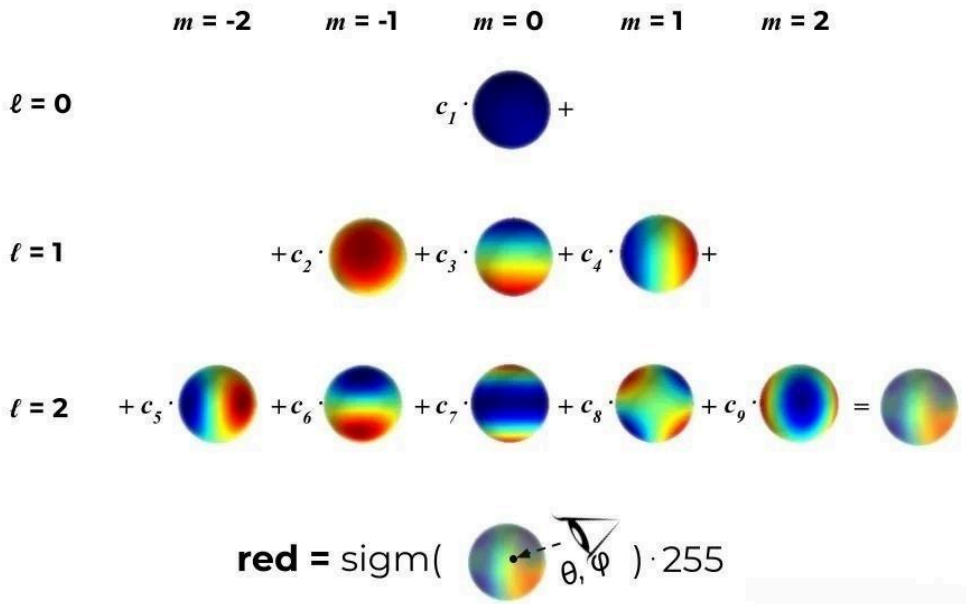
为什么不直接使用简单的 RGB?

- **假设：**如果一个 3D 高斯仅存储一个固定的 (R,G,B) 值，那么它的颜色从任何角度看起来都完全相同。

- **现实：**现实世界中的物体具有高光和反射！特定点的颜色会随你的观察方向而改变。

- **目标：**我们需要一个数学函数，它将相机的观察方向作为输入，并针对该特定角度输出正确的 RGB 颜色。

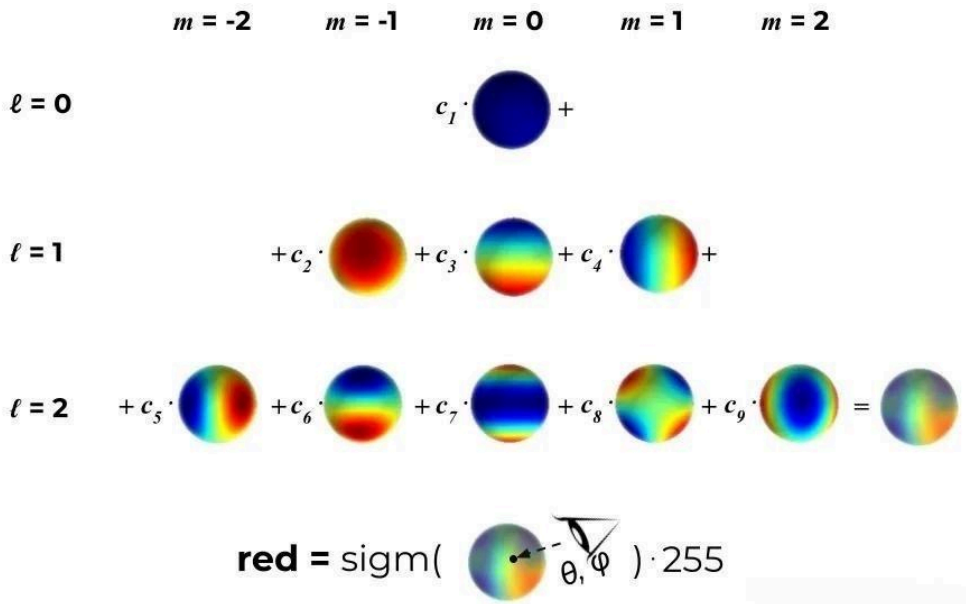
cpoerihal Oart onihs



球谐函数 将一个复杂的三维球面信号（光照）分解为一组基本的三维模式（基函数）。

如何获得颜色：任何复杂的视角相关颜色都可以通过将这些基础模式相加来近似，每个基础模式乘以一个系数。

cpoerihal Oart onihs



我们优化什么：对于每个 3D 高斯，优化器都会学习红、绿、蓝的 SH 系数。

3DGS 通常最多使用 3 阶（每个颜色通道需要 16 个系数 □每个高斯总计 48 个数字）来实现照片级真实的反射效果。

优化：协方差问题

挑战：如何使用梯度下降来优化协方差矩阵（ε）？

数学陷阱：

- 有效的 ε 必须是 **半正定**。
- 并非所有对称矩阵都是有效的协方差矩阵。
- 盲目地应用梯度更新（例如，$\varepsilon_{new} = \varepsilon_{old} - \eta \nabla$ fbtplpi 1tbxf = $i\ tbelfpx$）会迅速生成无效矩阵，导致程序 t o crash

Wp it i□a ion: Toe Do: arianhe aroglet

o□e Sle□3nt nolution□Decomposition

$$\Sigma = RSS^T R^T$$

对于任意有效的缩放向量（X）和旋转（S），该公式在数学上保证得到一个有效的协方差矩阵。

优化：协方差问题

优雅的解决方案：分解

$$\Sigma = RSS^T R^T$$

对于任何有效的缩放向量（X）和旋转（S），该公式在数学上保证得到一个有效的协方差矩阵。

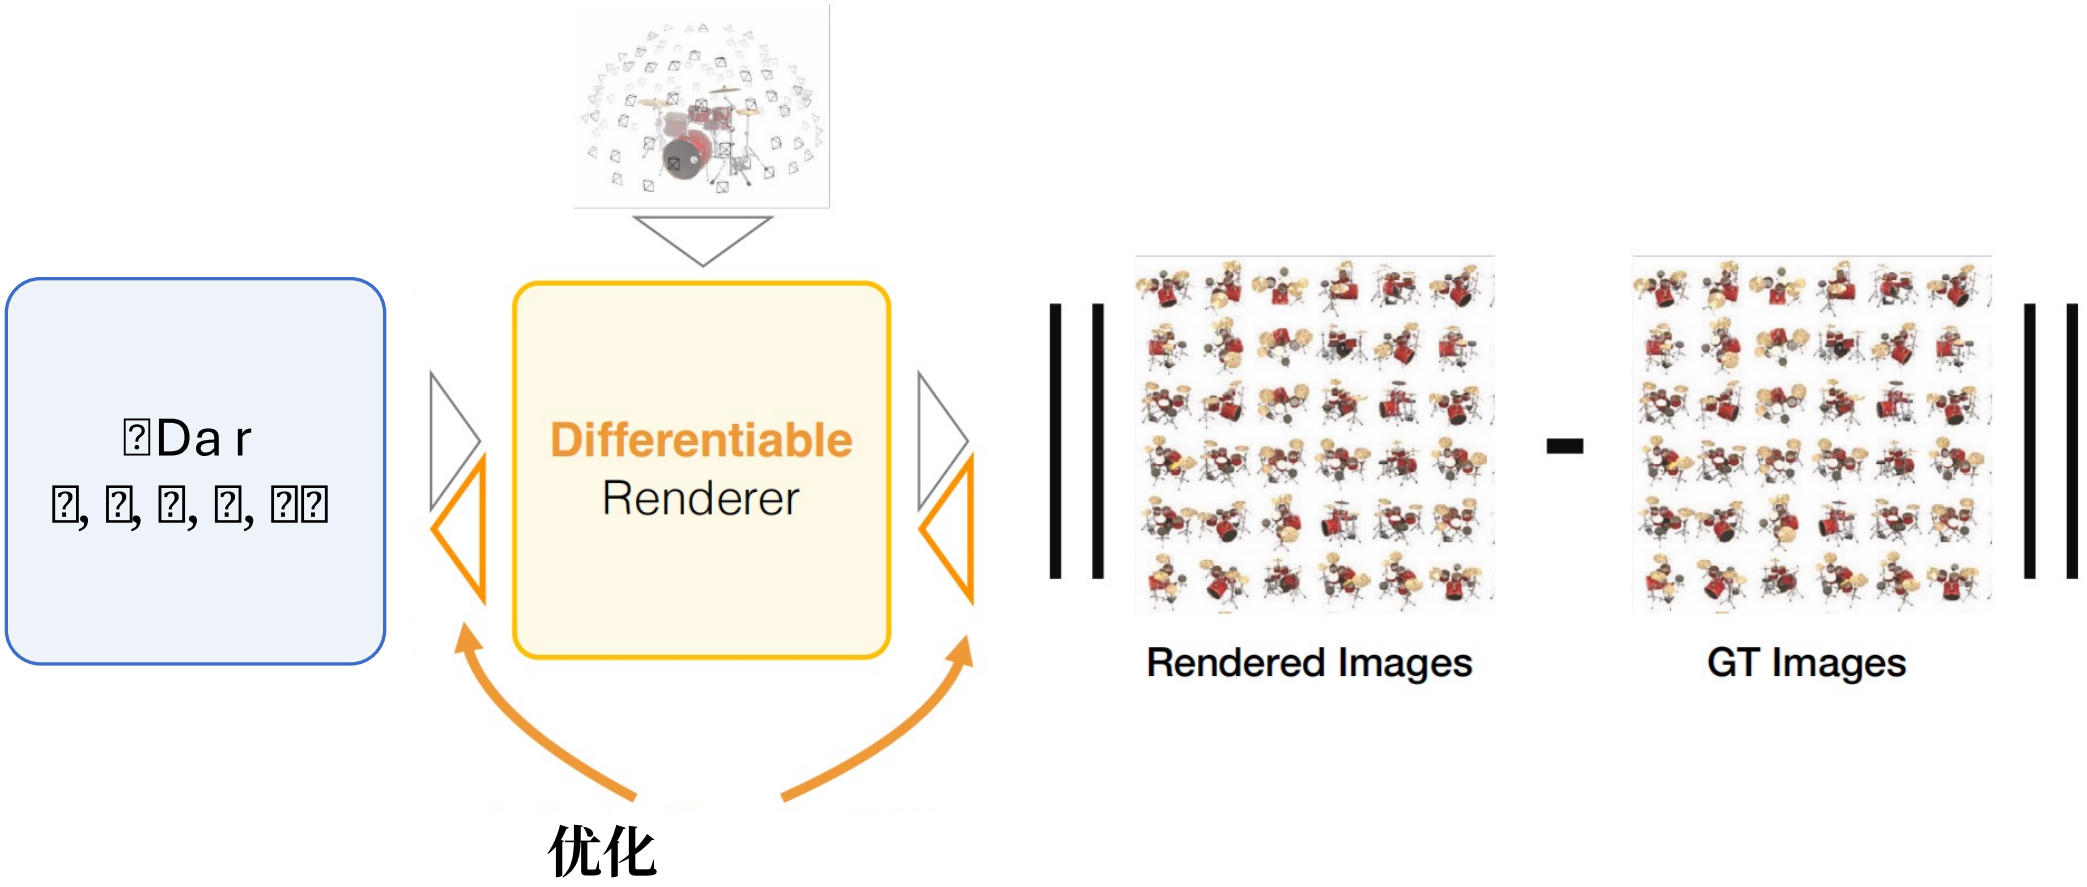
实现细节：旋转矩阵（S）难以直接优化（万向节死锁）。因此，3DGS使用四元数来表示并优化旋转。

3D 高斯优化

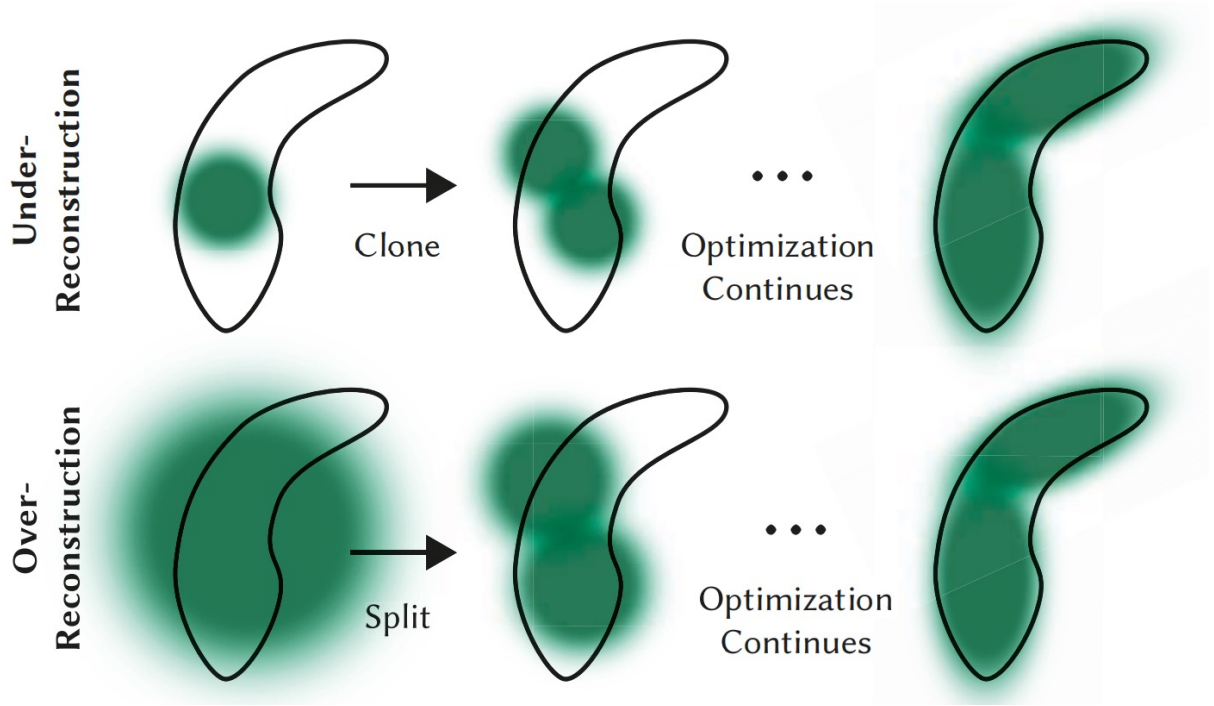
- 位置（均值）：
- 协方差：（由 和 ）
- 不透明度：
- 颜色：球谐函数（SH）系数

梯度下降

3D 高斯优化

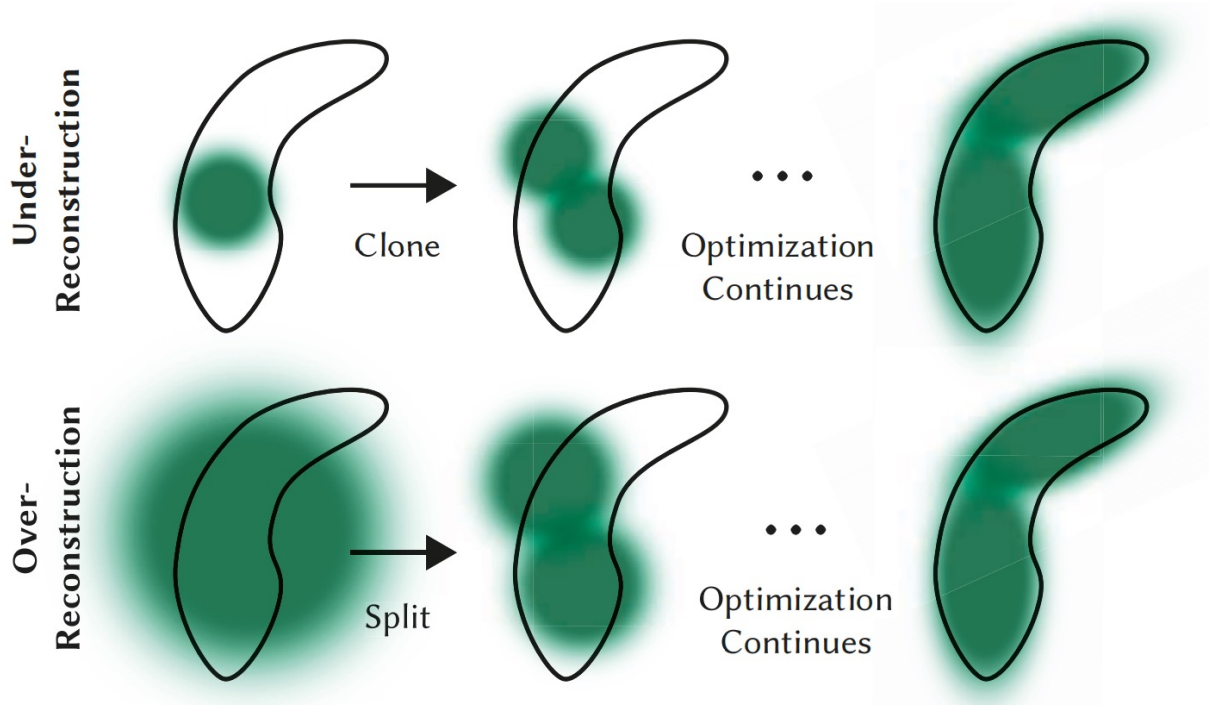


Ai ap i: e Don rol omGa. ssians Gensim ma ion



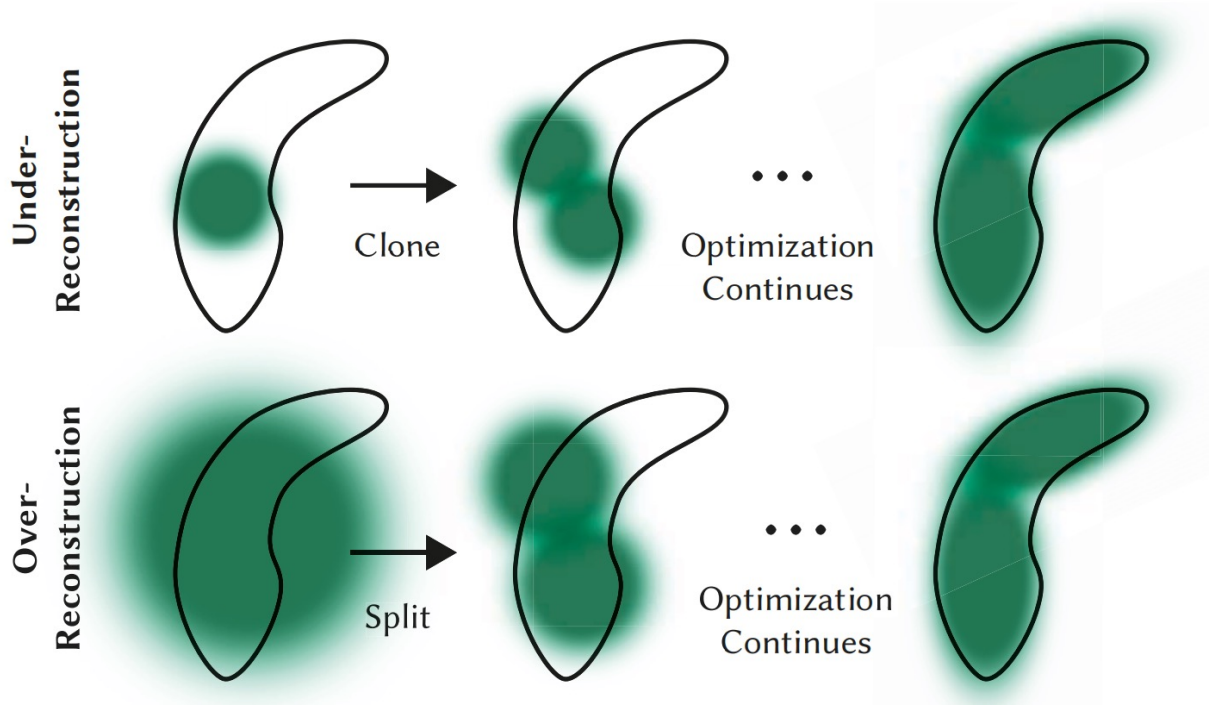
- **目标：**在必要时增加点的数量。

Ai ap i: e Don rol omGa. ssians Gensim ma ion



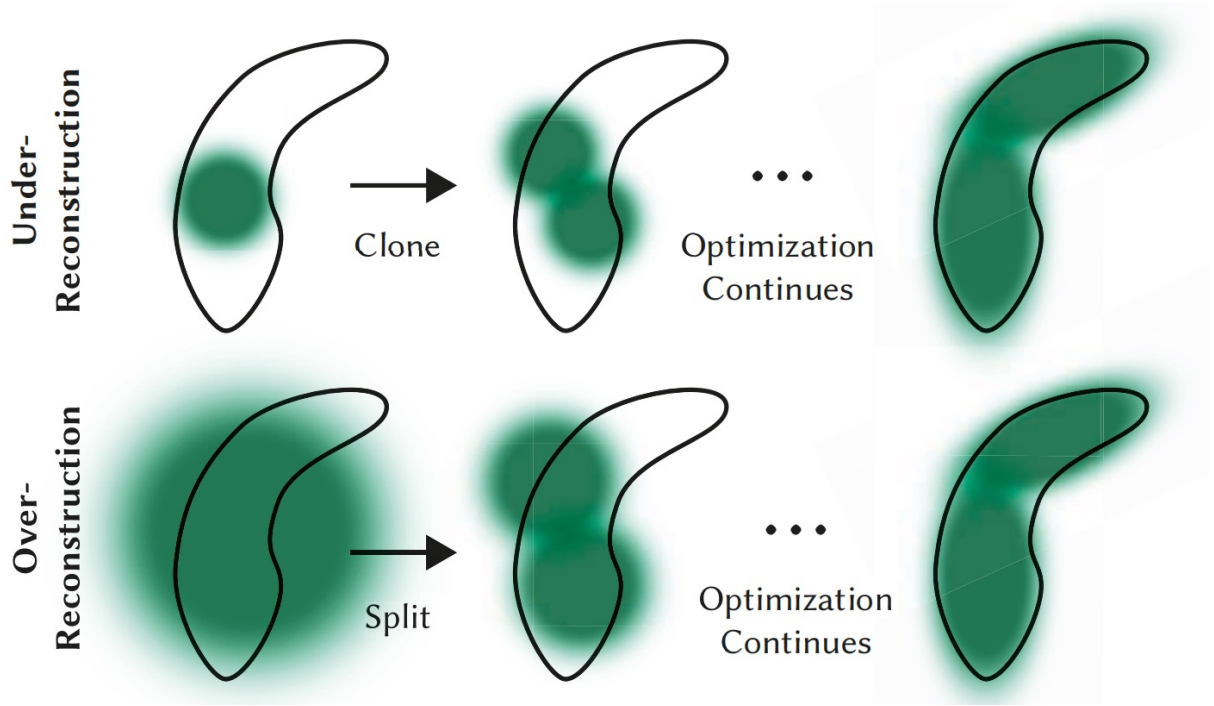
- **目标：** 在必要时增加点的数量。
- **指标：** 具有高位置梯度的点。

高斯的自适应控制——稠密化



- **目标：**在必要时增加点的数量。
- **指标：** 具有高位置梯度的点。
- **含义：**高梯度对应于尚未被很好重建 的区域（优化器难以拟合几何结构）。

高斯的自适应控制——动作



- **克隆** 3D 高斯：欠重建（缺少几何特征）
- **拆分**3D高斯：过度重建（覆盖大面积）
- **移除**3D高斯：不透明度低于阈值

消融实验



无致密化/自适应控制



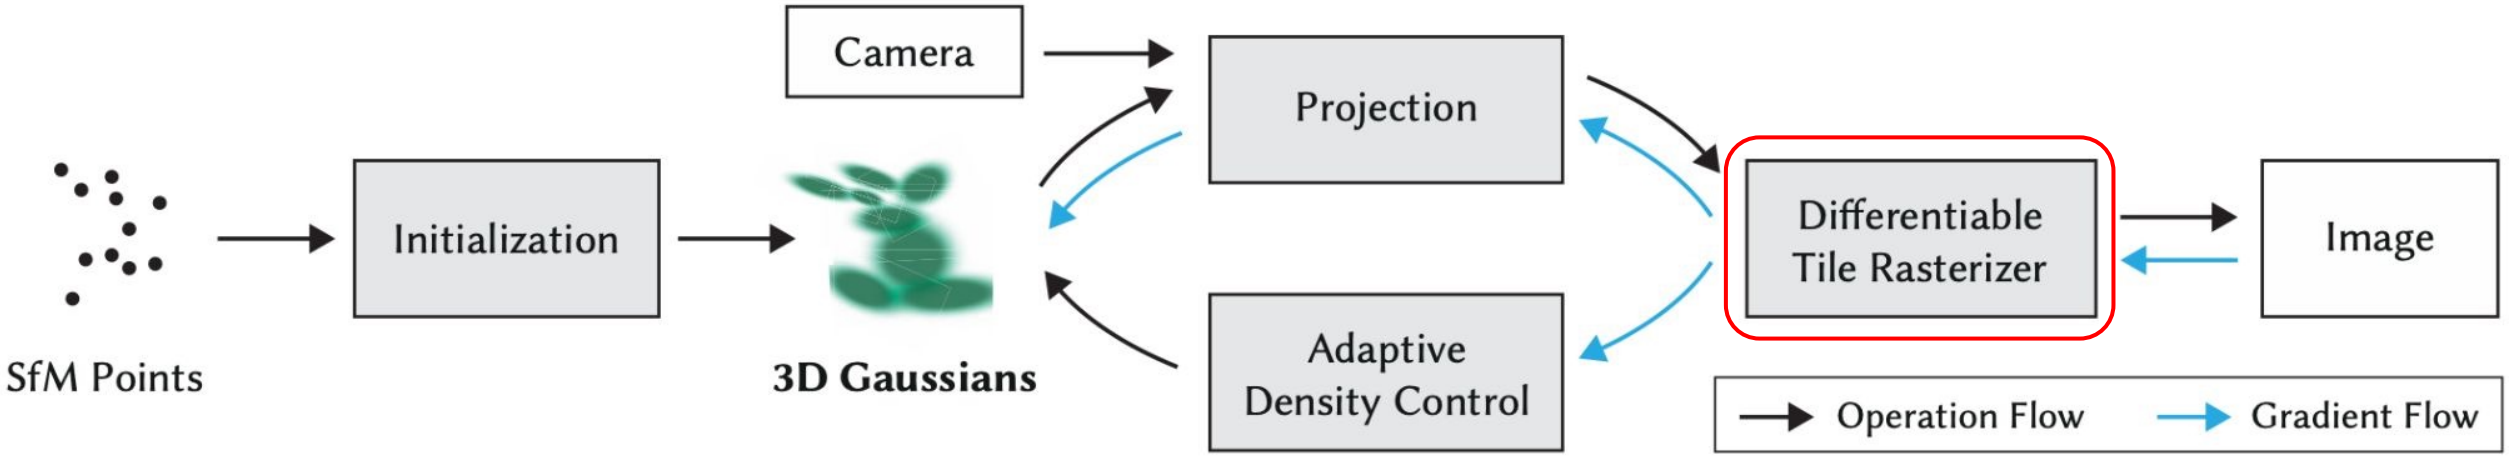
完整运行



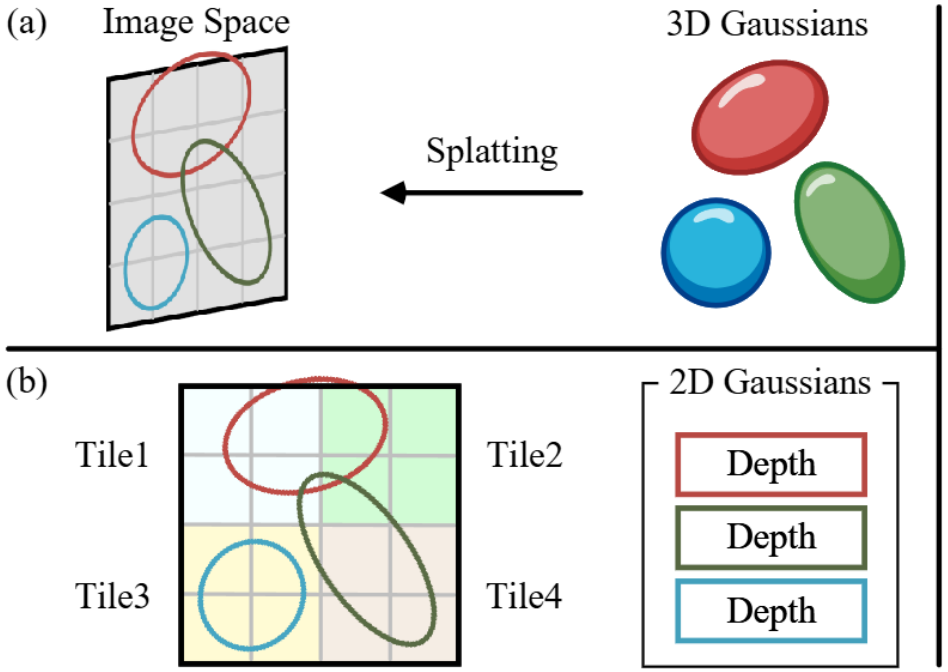


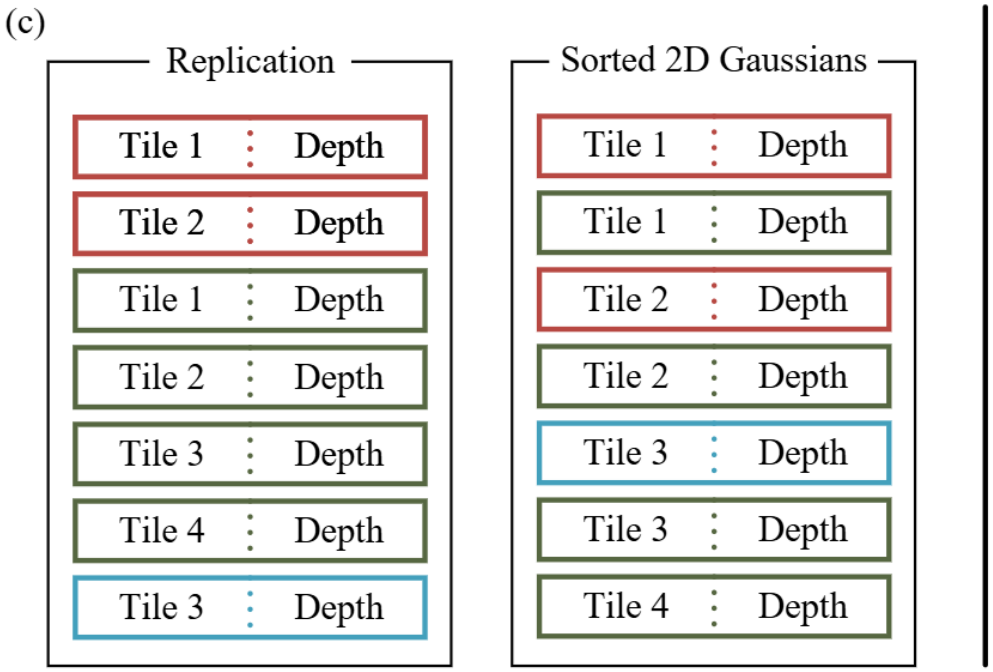
3DGS 管线

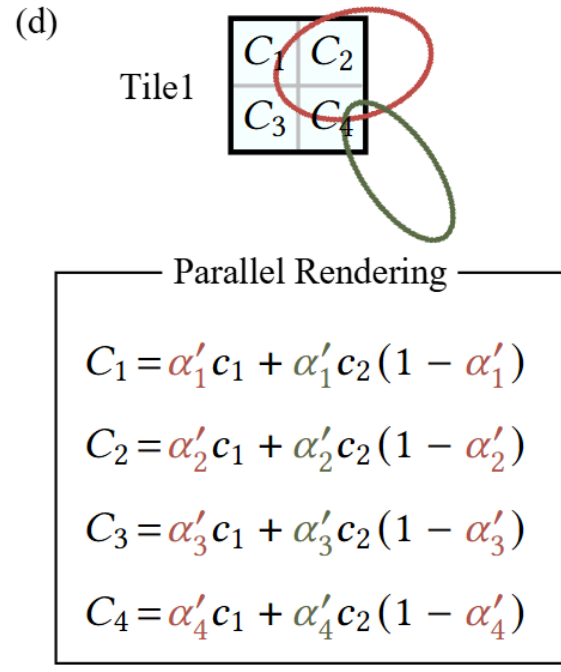
bt ?t?b?r? t r ?n e? er??) ??r ??e-wt ?e ?n t ?ter??t t????



前向渲染过程

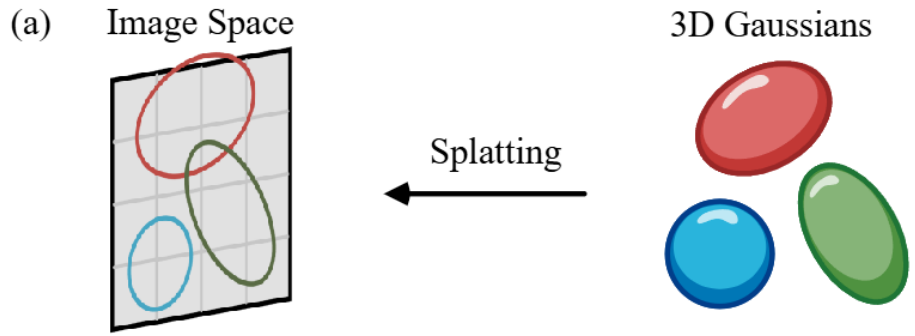


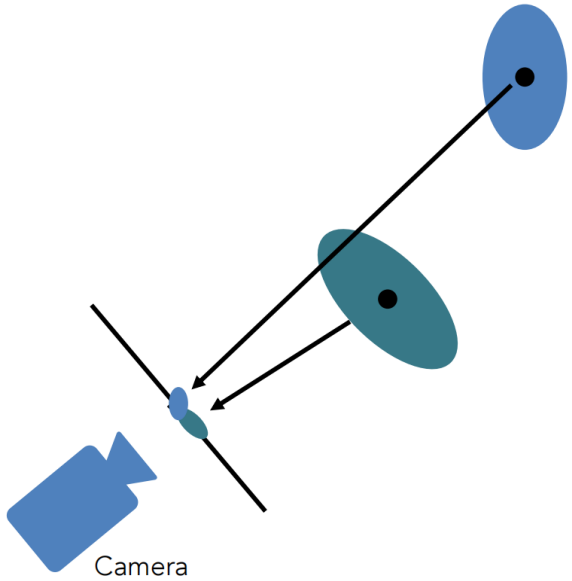




- **(a) 泼溅（3D □□D）：** 将3D高斯投影到2D图像平面。
- **(b) 分块：** 将屏幕划分为互不重叠的图块（例如，16x16像素瓦片）。
- **(c) 复制与排序：** 复制与多个瓦片重叠的高斯，并依据深度从前到后排序。
- **(d) 并行渲染（Alpha 混合）：** 按深度顺序混合颜色。

什么是“Splatting”?

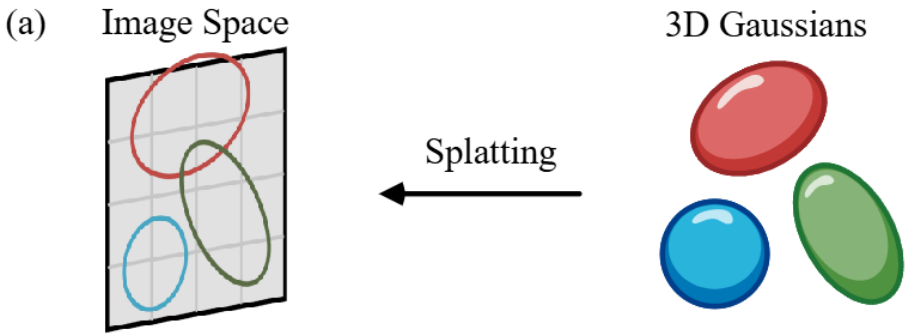


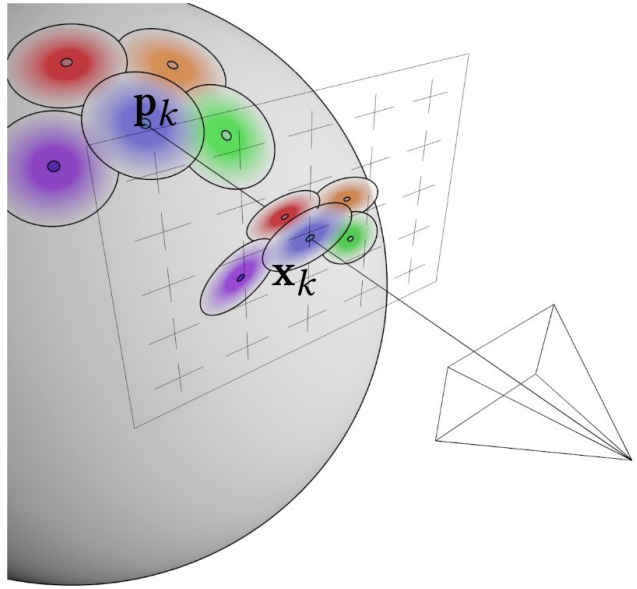


类比（投掷雪球）：

- 将 3D 高斯想象成一个柔软、彩色的雪球。
- 图像平面（屏幕）是一扇玻璃窗。
- “泼溅”（Splatting）是指将那个雪球扔向窗户的过程。

e oa is ?cpla ing??

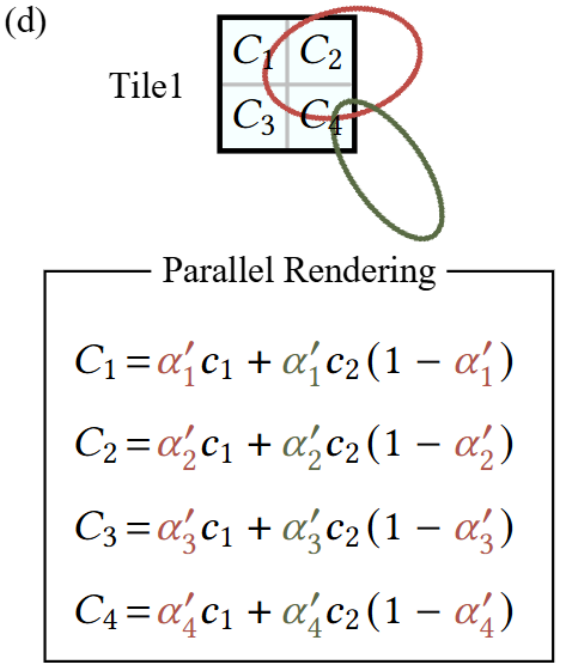


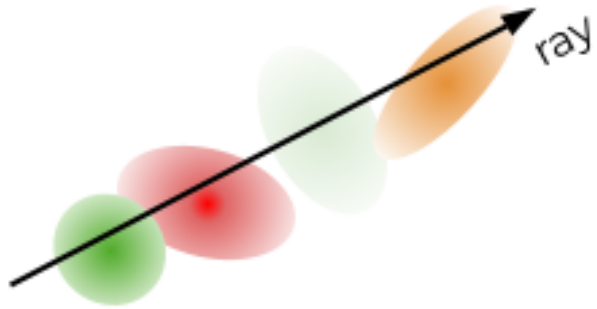


结果： 3D 球体在玻璃上压扁成一个 2D 彩色溅斑（一个椭圆）。

目标： 计算每个3D雪球击中屏幕时的精确2D形状、位置和边界框。

Alpha 混合（颜色累积）





使用排序后的2D高斯逐像素累积颜色：

$$C = \sum_{i \in \mathcal{N}} c_i \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j)$$

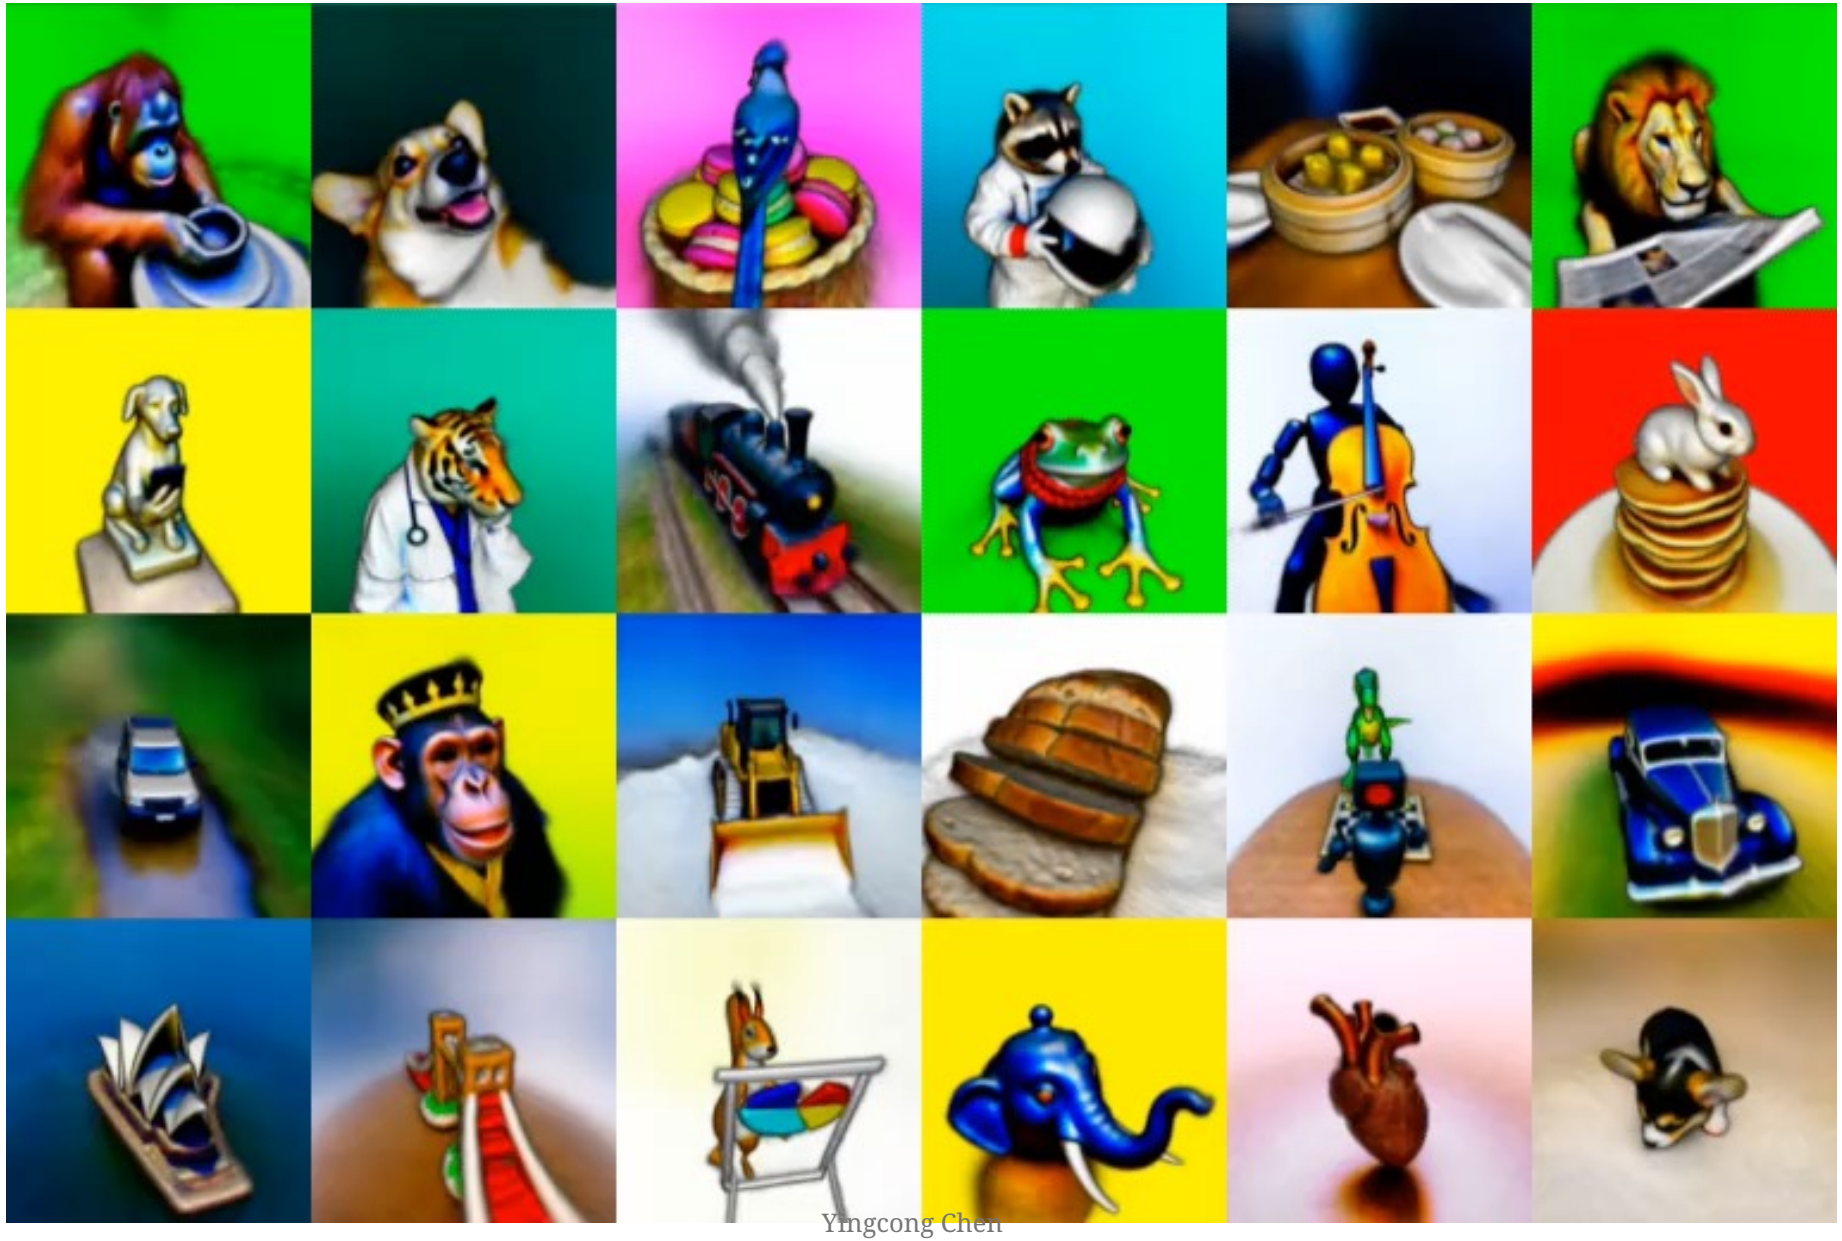
数学翻译：最终颜色 □（当前颜色 □ 不透明度） □（被前方物体遮挡的光）。



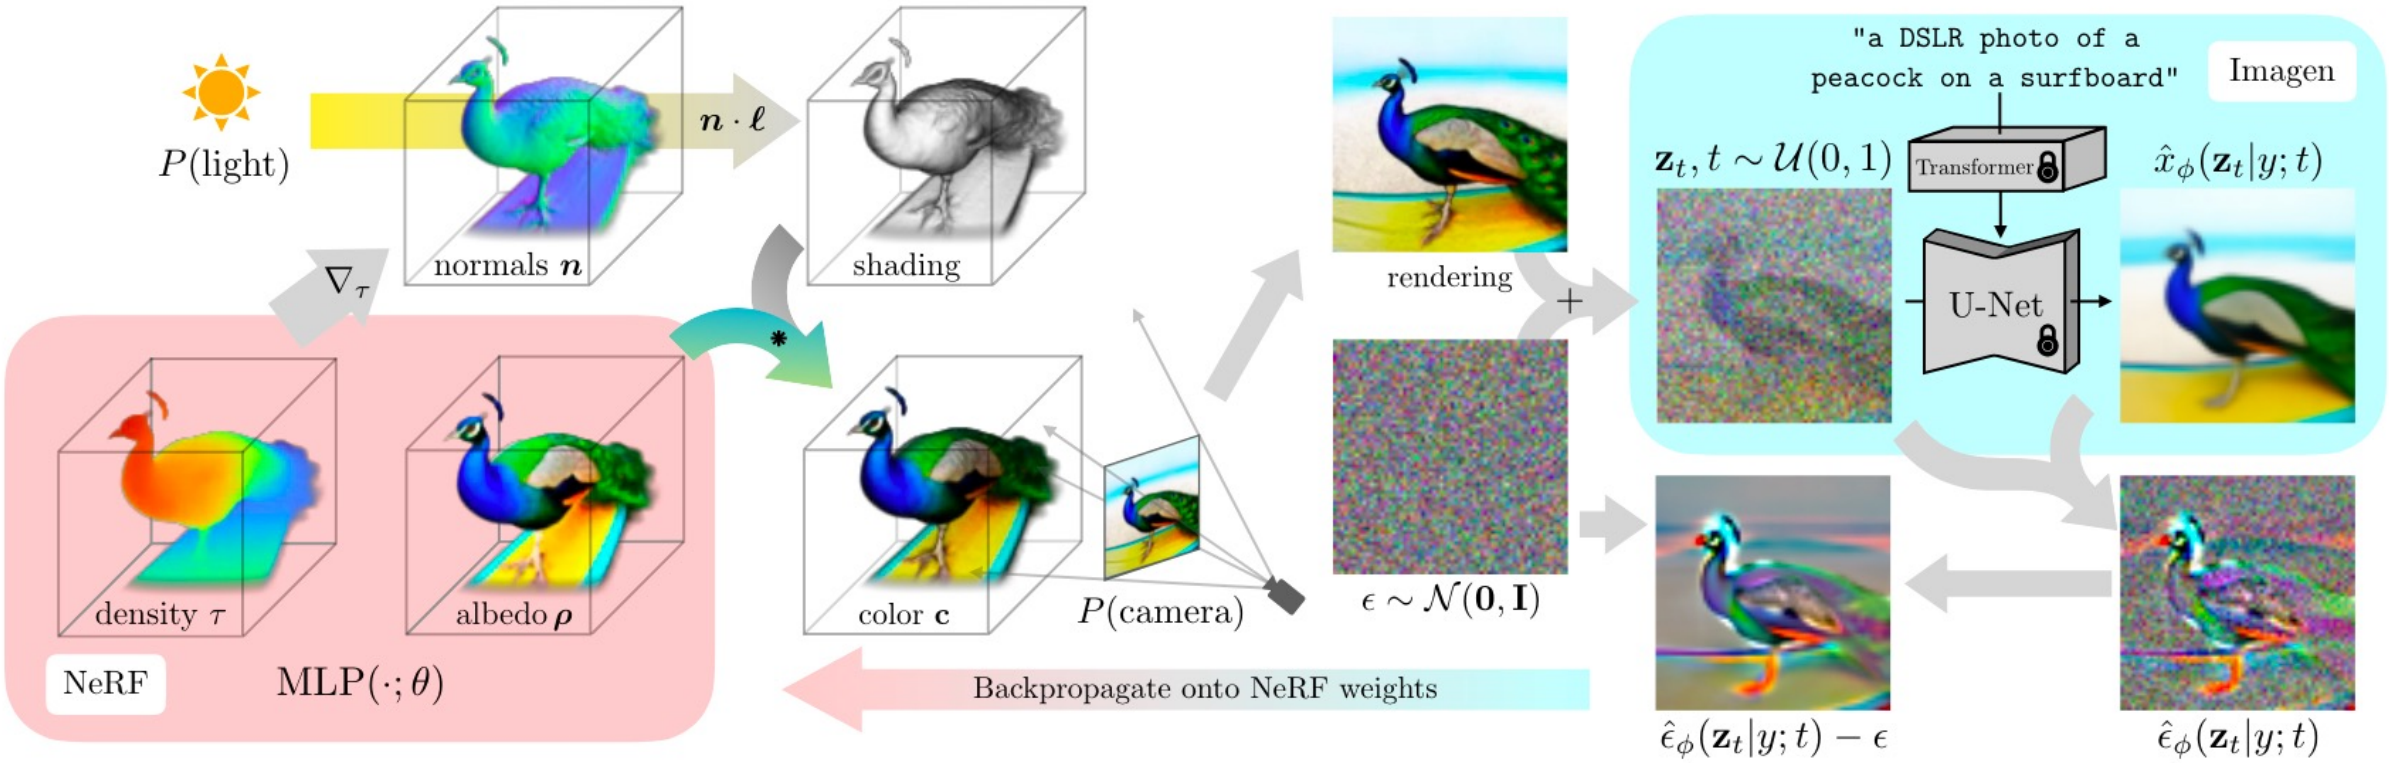
https://antimatter1[illegible].com/splat/

When Generation Meets 3D Reconstruction

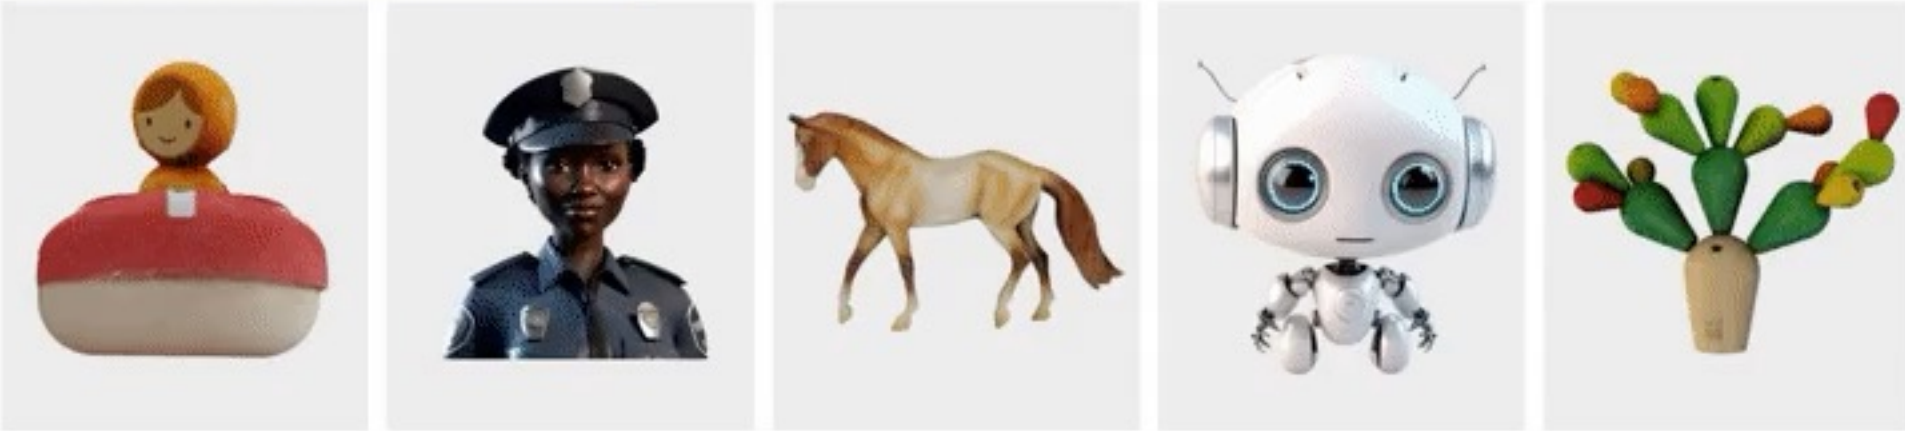
Dreamfusion



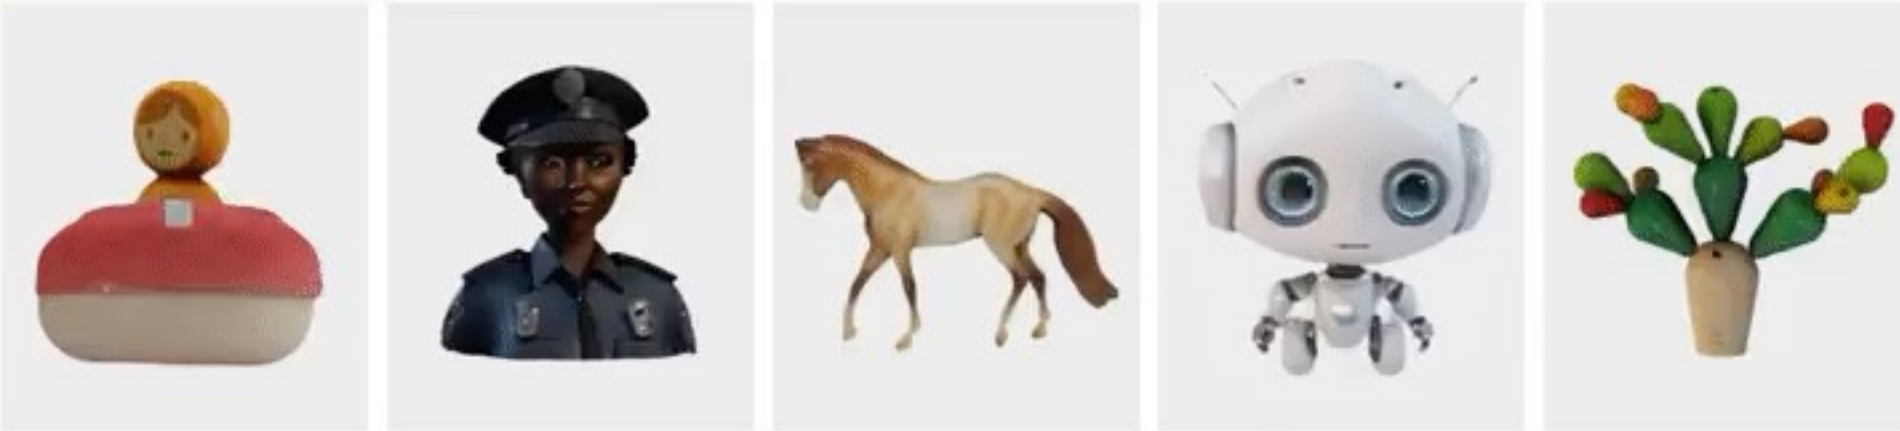
如何训练模型?


P(light)
normals n
n · ℓ
shading
∇τ
density τ
albedo ρ
NeRF
MLP(·; θ)
color c
P(camera)
rendering
ϵ ∼ N(0, I)
Backpropagate onto NeRF weights
"a DSLR photo of a peacock on a surfboard"
Imagen
z_t, t ∼ U(0, 1)
Transformer
U-Net
x̂_φ(z_t|y; t)
ε̂_φ(z_t|y; t) − ϵ
ε̂_φ(z_t|y; t)

Input images



TripoSR outputs



下一步：世界模型

- https://openai.com/index/video-generation-models-as-world-simulators/
- https://gamengen.github.io
- https://research.nvidia.com/labs/dir/cosmos-predict1
- https://dreamzero0.github.io

匿名课堂反馈

Q&A