

图像滤波及其应用

Image Filters and Its Applications · Week 2

王昊 Hao WANG · AI Thrust, Information Hub

香港科技大学 (广州)

今日提纲

上周回顾 (Recap)

随堂测验: Transformer 为何成为现代 AI 的基础模型

图像滤波: 定义、盒式滤波、线性滤波练习

线性滤波器性质; 高斯滤波与可分离性

边界处理与输出尺寸

Sobel 边缘、混合图像 (Hybrid Images)

去噪、中值滤波、双边滤波

模板匹配: 相关、零均值、SSD、归一化互相关

高斯金字塔、由粗到精配准、拉普拉斯金字塔

随堂测验 (Quiz)

为什么 Transformer 被视为现代 AI 的基础模型？下面哪一项最能解释其成功的主要原因？

- A. 它天然支持文本、图像、音频等多模态输入。
- B. 它比以往结构更能建模长程依赖。
- C. 它在数据量、参数量和算力增大时，表现出强且可预测的缩放行为（scaling）。
- D. 其注意力机制与人类认知过程非常相似。

(原课件为选择题，答案请对照课堂讲解。)

什么是图像滤波

图像滤波：在每个位置对局部邻域计算一个函数。

非常重要，可用于：

- 增强图像：去噪、缩放等
- 从图像中提取信息：纹理、边缘、显著点等
- 检测模式：模板匹配 (template matching)

后续内容：卷积神经网络 (CNN) 本质上也是滤波/卷积。

盒式滤波 (Box / Mean Filter)

均值滤波：邻域内每个像素权重相同（例如 3×3 全 1 核，常再归一化）。

输出可写成卷积： $h[m,n] = \sum_{\{k,l\}} g[k,l] \cdot f[m+k, n+l]$

直观效果：用邻域平均替换每个像素 $\rightarrow$ 平滑，削弱尖锐特征。

练习（线性滤波）：

- 核 $[[0,0,0],[0,1,0],[0,0,0]]$ ：原图不变（单位脉冲）
- 核 $[[0,0,0],[1,0,0],[0,0,0]]$ ：图像向左平移 1 个像素
- 原图减去平滑结果（注意核权和为 1）：锐化滤波，放大与局部均值的差异

线性滤波器的关键性质

线性性: $\text{filter}(f_1 + f_2) = \text{filter}(f_1) + \text{filter}(f_2)$

平移不变: $\text{filter}(\text{shift}(f)) = \text{shift}(\text{filter}(f))$

任何线性且平移不变的算子都可表示为卷积。

更多性质:

- 交换律 $a * b = b * a$ (滤波核与图像在概念上对偶)
- 结合律 $a * (b * c) = (a * b) * c \rightarrow$ 连续多个滤波等价于先把核卷在一起再滤一次
- 对加法分配; 标量可提出: $ka * b = k(a * b)$
- 单位元: 单位脉冲 $e = [0, 0, 1, 0, 0]$, $a * e = a$

高斯滤波 (Gaussian)

按距离加权：中心像素权重最大，越远越小（比盒式滤波更自然）。

作用：去掉高频成分（低通），图像更平滑。

- 高斯与自身卷积仍是高斯：连续用宽度 σ 滤两次 $\approx$ 用宽度 $\sigma\sqrt{2}$ 滤一次
- 可分离：2D 高斯 = 两个 1D 高斯的乘积

复杂度：一般 2D 滤波 $O(M \cdot N \cdot m \cdot n)$ ；可分离后 $O(M \cdot N \cdot (m+n))$

核多大？边缘权重应接近 0。经验：半宽 $\geq 3\sigma$ 。

例如 $\sigma=1 \rightarrow$ 半径 3 $\rightarrow$ 核大小 7×7 。

边界与输出尺寸 (实践细节)

窗口伸出图像外时需要外推:

- Clip / fill: 界外当 0 (黑)
- Wrap: 把图像当成环面, 左右/上下相接
- Copy edge: 重复边缘像素
- Reflect / symm: 沿边界镜像

Python (`scipy.signal.convolve2d`) :

- `boundary='fill', fillvalue=0` / `'wrap'` / `'symm'`

输出尺寸 mode:

- `'full'`: 尺寸为 f 与 g 之和
- `'same'`: 与 f 相同
- `'valid'`: 为尺寸之差 (核完全落在图内)

其他滤波：边缘与混合图像

Sobel:

- 垂直边缘核 $\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$ (常取绝对值)
- 水平边缘核 $\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$

混合图像 (Hybrid Images, Oliva et al., SIGGRAPH 2006) :

- 一幅图的低频 (高斯) + 另一幅图的高频 (拉普拉斯 / LoG)
- 近看像高频图, 远看像低频图

参考: https://en.wikipedia.org/wiki/Hybrid_image

滤波的其他应用: 去噪、模板匹配、高斯金字塔、拉普拉斯金字塔。

去噪：高斯 vs 中值 vs 双边

加性高斯噪声：高斯滤波可抑制，但 σ 越大越糊。

椒盐噪声（脉冲噪声）：高斯平滑效果差；中值滤波更好。

中值滤波：窗口内取中值强度。非线性，对离群点更鲁棒。

Python: `scipy.ndimage.median_filter(image, size)`

其他选择：

- 加权中值（离中心越远权重越小）
- 截尾均值（去掉最亮/最暗若干像素再平均）
- 双边滤波：同时按空间距离和灰度差加权，保边去噪
`cv2.bilateralFilter(src, d, sigmaColor, sigmaSpace)`

模板匹配：相关与零均值相关

目标：在图中找到模板（如眼睛）。关键是定义两块的相似度/距离。

方法 0：直接用模板当滤波核做相关

$$h[m,n] = \sum f[k,l] \cdot im[m+k, n+l]$$

问题：亮度偏差——亮区域即使不像眼睛也会得到大响应（大数乘大数）。

方法 1：零均值模板

$$h[m,n] = \sum (f[k,l] - \text{mean}(f)) \cdot im[m+k, n+l]$$

匹配的是明暗相对模式；均匀亮区响应接近 0。阈值后可得到真正检测点。

模板匹配：SSD 与归一化互相关

方法 2：平方差之和 SSD

$$h[m,n] = \sum (f[k,l] - im[m+k,n+l])^2$$

可拆成：常数 + 线性滤波 + 对 im^2 用全 1 核滤波 → 用滤波实现更快。

缺点：对整体亮度平移敏感。

方法 3：归一化互相关 NCC（余弦相似度）

减去各自均值，再除以模板与图块标准差之积。

Python: `cv2.matchTemplate(im, template, cv2.TM_CCORR_NORMED)`

若要找更大/更小的目标？→ 图像金字塔。

高斯金字塔与由粗到精配准

采样回顾：先低通（高斯）再降采样，得到低分辨率图。

为何必须低通？直接降采样会产生混叠（aliasing）。

额外好处：加速。

由粗到精配准：

1. 建高斯金字塔
2. 在最粗层用 SSD 对齐（搜索范围大、图小）
3. 逐层变细，只在粗层结果附近小范围（如 5×5 ）搜索

更快，但不保证与全分辨率穷举相同；模板含大量重要高频时可能失败；有噪声时反而可能更稳。

金字塔在深度学习中的延伸

空间金字塔池化 SPP: He et al., TPAMI 2015, 目标检测。

特征金字塔网络 FPN: Lin et al., CVPR 2017, 目标检测。

金字塔场景解析网络 PSPNet: Zhao et al., CVPR 2017, 图像分割。

拉普拉斯滤波与拉普拉斯金字塔

拉普拉斯 $\approx$ 单位脉冲 - 高斯；高斯拉普拉斯 (LoG) 响应平滑区弱、边缘等尖锐处强。

构建 2 层拉普拉斯金字塔：

- Gaussian_0 = 原图
- Smoothed_0 = 对 Gaussian_0 高斯平滑
- Laplacian_0 = Gaussian_0 - Smoothed_0
- 对平滑图降采样得到 Gauss_1 / Lap_1

重建：Smoothed_0 上采样平滑后 + Laplacian_0 = 原图。

混合图像也可在拉普拉斯金字塔的不同频带上合成（高频 $\rightarrow$ 低频）。

本讲要点 (Take-home)

图像滤波可用于：去噪、图像增强、模板匹配.....

高斯金字塔支持跨分辨率匹配，并提升速度。

稍作修改，高斯金字塔就变成拉普拉斯金字塔，在图像合成中很有用。

欢迎匿名课堂反馈。

说明：原版 PDF 含逐步卷积示意、效果对比图等，请对照
image filters-week2.pdf 一起看。