

AIAA 3111 - 数据挖掘导论

课程信息与 基本介绍_x000B_

Dr. Zhidan LIU



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)



助理教授,
INTR 与 AI 学域
研究员, NTU
博士, 浙江大学

<https://liuzhidan.github.io/>
zhidanliu@hkust-gz.edu.cn

AIoT · 边缘智能 · 智慧出行



刘志丹
新加坡



微信

研究方向

- 人工智能物联网
- 以人为本的感知与计算
- 移动与边缘智能
- 智慧出行与城市智能


学术成果/服务

- 主持三项国家自然科学基金 (含2项面上项目)
- 在 ACM MobiCom、MobiSys、KDD、IEEE ICDE、ICDM 以及 IEEE TKDE、IEEE TMC、IEEE TITS 等顶级期刊与会议上发表论文 60 余篇, 并拥有 14 项领域专利
- IEEE TETCI 副主编
- IEEE/CCF 高级会员

从感知到智能: 构建面向物理世界的智能系统

代表性科研项目

#1 以人为本的感知与智能




(MobiSys'19, KDD'24, TMC'25, TMC'26)

#2 智慧出行与城市智能



- 交通感知 (TMC'24, TITS'26)
- 交通预测 (TITS'25)
- GPS 增强 (TMC'24)
- 共享出行 (ICDE'20, IOTJ'22, TMC'24,)
- 交通调度 (TITS'22, TMC'25)
- 数据合成 (DASFAA'21, TMC'26)
- 出行分析 (TMC'23, TKDE'25, CIKM'25-26)
- 交通信号控制 - Astra (KDD'26)

#3 边缘 AI 与智能系统



- (1) 端侧/边缘部署 → 推理
- (2) 感知 → 学习 → 推理 → 行动


(ACM MobiCom, SenSys, UbiComp, IEEE TMC)

来源: <https://www.instagram.com/p/DXpBrG8IXRO/>


关于 Zhidan LIU 研究组

MobiX Research Group

The **MobiX** (*Mobile Intelligence & eXploration*) research group is dedicated to advancing the vision of smart mobility. We explore and develop innovative systems driven by efficient mobile sensing, ubiquitous computing, and mobility data analytics. Our research spans across urban computing, the Artificial Internet of Things (AIoT), and spatio-temporal data mining. The mission of **MobiX** is to conduct cutting-edge research in these intersecting fields, delivering robust solutions that yield both high academic impact and real-world practical value.



欢迎本科生加入，通过 X-Program、竞赛或其他合作探索新的研究问题。



课程安排

时间：周一 15:00-16:20PM / 周五 10:30-11:50AM

地点：Lecture Hall A, 线下授课

授课教师	邮箱	办公室	答疑时间
Zhidan Liu	zhidanliu@hkustgz.edu.cn	W4-306	周二 15:00-17:00

助教：

姓名	邮箱	学域
WANG, Jiyu	jwang738@connect.hkust-gz.edu.cn	INTR
LI, Cong	cli166@connect.hkust-gz.edu.cn	DSA



预期学习成果 (ILOs)

1. 掌握与数据挖掘相关的文献知识，并全面理解相关科学方法与技术。
2. 具备构建数据挖掘系统的实践技能。
3. 批判性地运用理论、方法与知识，解决数据挖掘中的基本问题。
4. 能够独立开展数据挖掘应用中具有意义的研究或创新。



课程进度



周次	主题
1	绪论
2	数据预处理
3	模式挖掘 I
4	模式挖掘 II
5	分类（基础）
6	分类（进阶）
7	期中考试
8	聚类 I
9	聚类 II
10	异常检测
11	多样化数据上的数据挖掘
12	数据挖掘中的进阶 LLM 与智能体
13	小组海报展示与问答
TBD	期末考试



参考文献

教材:

- [Data Mining: Concepts and Techniques, 4th ed.](#), by Jiawei Han, Jian Pei and Hanghang Tong
- [Introduction to Data Mining \(Second Edition\)](#), by Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar



成绩评定

总评成绩构成如下

- 课程参与：10%
- 书面作业：20%（四次作业）
- 期中考试：25%
- 课程项目：20%
 - 最后一周海报展示
- 期末考试：25%



成绩评定

小组项目与海报

- **组队：**2-4 人，请尽快组队。
- **海报：**海报展示（5 分钟简介与问答），安排在期末考试前一周。
- **项目重点：**将数据挖掘应用于实际问题。
- **项目选题：**
 - 选项 1：自行组队，围绕个人感兴趣的问题头脑风暴；
 - 选项 2：如有需要，我们将提供潜在选题列表以指导探索。
该列表将尽快公布，且不晚于期中考试。
- **评分细则：**小组项目与海报展示的评分细则将在期中考试后公布。



学术诚信守则

- 我们严格执行 HKUST Honor Code

请务必阅读并理解！

The HKUST Academic Honor Code

Honesty and integrity are central to the academic work of HKUST. Students of the University must observe and uphold the highest standards of academic integrity and honesty in all the work they do throughout their program of study.



As members of the University community, students have the responsibility to help maintain the academic reputation of HKUST in its academic endeavors.



Sanctions will be imposed on students, if they are found to have violated the regulations governing academic integrity and honesty.

生成式 AI 正确使用提示


- ChatGPT 及相关 LLM 是革命性工具，鼓励用于学习与研究，如轻度编辑、思路探索
- 禁止直接使用 ChatGPT 及其他 LLM 生成的内容

**学会用工具提升自己
而不是偷懒！**

大规模数据无处不在！

□ 我们生活在一个数据被持续、快速大量生成的世界

- 商店与信用卡交易数据
- 科学测量数据
- 健康记录、脑影像、日常测量
- Google 查询、点击、浏览行为、广告
- 社交网络数据，如 Meta、X、微博
- 移动数据、轨迹
- 手机使用、通话
- 可穿戴设备
- 机器与工作流监控



数据创造价值

LLM (如 ChatGPT、DeepSeek) 依赖海量数据进行训练

DA

I'm looking to write marketing copy to make my email marketing more engaging. The product I'm promoting is an office cleaning service. What subject lines would you suggest for a sequence of 3 emails. I want to send 3 welcome emails for new prospects.



Here are a few suggestions for subject lines for a sequence of 3 welcome emails for a new prospect promoting an office cleaning service:  


1. "Say Goodbye to Messy Offices with Our Top-Notch Cleaning Services"
2. "Improve Your Employee's Wellness and Productivity with Our Cleaning Services"
3. "Upgrade Your Office's Appearance with Our Professional Cleaning Services"

You may also want to consider including a sense of urgency or scarcity in your subject lines to encourage the recipient to open and read the email right away. For example, "Limited Time Offer: Get 15% off Your First Cleaning Service" or "Don't Miss Out on Our Exclusive Cleaning Package Deals."

It's also important to keep in mind that the subject line should be relevant to the content in the email and should accurately reflect what the recipient can expect when they open the email.

Another tip is to use personalization in the subject line by using recipient's name, company name, or location which will increase the open rate as it will look more personalized and less like spam.

数据创造价值



精准/个性化医疗:

利用患者基因型及相关全部数据，为其找到最佳治疗方案

此外：通过海量数据记录理解药物副作用

数据创造价值

The self-driving car's sensors

Just like a person has five senses, Google's self-driving car has a variety of gadgets that detect nearby objects so it can avoid them.

Global Positioning System software
Helps car determine its location.

Position sensor
Located in the wheel hub, this sensor helps determine car's location from wheel rotations.


Radar
Measures speed of cars ahead.

Orientation sensor
Located in car's interior, it acts like the car's inner ear, sensing motion and balance.

Laser
Provides a 360-degree view around the car and helps determine its location.

Microphone
Can detect sirens of approaching emergency vehicles.

Videocameras
With one on each of the car's four corners and another on its roof, they help the car recognize objects around it.



How the car operates

- 1 Any object the vehicle's sensors spot is interpreted by software to determine if it's a pedestrian, cyclist, vehicle or something else.
- 2 Using what it's learned from previous driving, the software makes predictions about what objects will do next.
- 3 The software analyzes the information to decide whether it is safe to accelerate, turn or hit the brakes.

Source: Google
Graphic: Tribune News Service



How the car sees the world

This computerized image is what Google researchers monitoring sensor data see as they ride in the vehicle.

- Other vehicle
- Pedestrian
- Cyclist
- Objects that warrant caution
- A crosswalk, indicating the car needs to stop
- A traffic signal, warning of upcoming railroad tracks
- Path where Google's car intends to go

自动驾驶汽车：


汽车是下一台计算机。未来的智能汽车能够自动驾驶并从数据中学习

此外：智慧城市 – 城市计算

数据创造价值




计算机通过观察数据学会玩游戏



机器人可以从示范中学习

数据创造价值



利用数据开展危机管理


数据复杂且相互关联

- 多种数据类型：表格、文本、时间序列、图像、视频、图等。
 - 时空特性
 - 多模态数据
- 相互关联的不同类型数据：
 - 从手机可采集用户位置、好友信息、场所签到、Twitter 上的观点、微信动态、相机图像、搜索引擎查询




什么是数据挖掘？

- ❑ **数据挖掘是在大规模数据集中发现有趣模式、模型及其他知识的过程**
 - ❑ “数据挖掘”：用词不当？更应是“从数据中挖掘知识”
 - ❑ 其他术语：从数据中挖掘知识、KDD（从数据中发现知识）、模式发现、知识抽取、数据分析、信息收割
- ❑ “数据挖掘研究如何采集、处理、分析数据并从中获得有用洞见”
 - Charu Aggarwal (@IBM)



数据挖掘：知识发现中的关键步骤



□ 知识发现过程

□ 数据准备

□ 数据清洗

□ 数据集成

□ 数据变换

□ 数据选择

□ 数据挖掘

□ 模式/模型评估

□ 知识呈现

数据挖掘的数据类型

□ 结构化 vs. 非结构化数据

- 结构化：形态统一、记录或表状结构，由数据字典定义，属性集合固定，每个属性有固定取值范围与语义
- 例如：存储于关系数据库、数据立方体、数据矩阵及许多数据仓库中的数据

	A	B	C	D	E	F	G
1	Purchase ID ▾	Last name ▾	First name ▾	Birthday ▾	Country ▾	Date of purchase ▾	Amount of purchase ▾
2	1	Davidson	Michael	04/03/1986	United States	10/12/2016	37
3	2	Vito	Jim	09/01/1994	United Kingdom	02/02/2016	85
4	3	Johnson	Tom	23/08/1972	France	02/11/2016	83
5	4	Lewis	Peter	18/10/1979	Germany	22/11/2016	27
6	5	Koenig	Edward	13/05/1983	Argentina	26/03/2015	43
7	6	Preston	Jack	16/06/1991	United States	06/11/2016	77
8	7	Smith	David	11/03/1965	Canada	15/11/2016	23
9	8	Brown	Luis	03/09/1997	Australia	03/07/2015	74
10	9	Miller	Thomas	07/01/1980	Germany	07/11/2016	13
11	10	Williams	Bill	26/07/1960	United States	20/11/2015	80
12	11	Gemini	Alexia	12/09/1995	Canada	11/03/2017	35
13	12	Bond	James	25/02/1975	United Kingdom	12/08/2017	40
14	13	Burgle	Patricia	01/12/1990	United States	18/01/2015	55
15	14	Reding	Michelle	07/04/1985	Canada	23/02/2017	28
16	15	Harvey	Billy	14/07/1971	United Kingdom	12/01/2016	41
17							

结构化数据（表格数据）

数据挖掘的数据类型

□ 结构化 vs. 非结构化数据

- 半结构化: 允许数据对象包含集合值、少量异构类型值或嵌套结构, 或允许对象/子对象结构灵活、动态定义
- 具有一定结构且语义明确的数据, 如事务数据集、序列数据集 (例如时间序列、基因或蛋白质数据、Weblog 数据)

```
{
  "patient_id": "P003",
  "timeline": [
    {"t": "2025-08-30T08:55:00Z", "event": "Arrival-ED"},
    {"t": "2025-08-30T09:02:00Z", "event": "ECG", "result": "ST-elevation?"},
    {"t": "2025-08-30T09:20:00Z", "event": "Lab-Troponin", "value": 0.38}
  ]
}
```

序列数据 (半结构化)


```
{
  "transaction_id": "TX-100231",
  "patient_id": "P001",
  "timestamp": "2025-09-01T12:00:05Z",
  "items": [
    {"drug": "Aspirin", "dose": "100mg", "qty": 30},
    {"drug": "Atorvastatin", "dose": "20mg", "qty": 30}
  ],
  "payment": {"method": "Card", "amount": 28.60}
}
```

事务数据 (半结构化)


数据挖掘的数据类型

□ 结构化 vs. 非结构化数据


- 图或网络数据：更复杂的一类半结构化数据集
- 非结构化数据：文本数据与多媒体（如音频、图像、视频）数据



图或网络



图像（非结构化数据）




文本（非结构化数据）

主诉：胸闷 2 小时。
ECG 显示 V2-V4
ST 段抬高。建议
肌钙蛋白检测并
立即心内科会诊。


数据挖掘的数据类型

□ 结构化 vs. 半结构化 vs. 非结构化数据





现实世界数据往往是异构的

现实世界数据往往由结构化、半结构化和非结构化数据混合组成。



数据挖掘的数据类型

问题：半结构化还是非结构化数据？



仅凭数据类型并不能决定挖掘方法


相同结构，不同语义

- 二者都是序列，但含义不同。
 - DNA 序列：发现基序与突变
 - 购买序列：发现偏好与下一商品行为

相同数据，不同问题

- 出行记录
 - 预测未来需求 → 预测
 - 对相似区域分组 → 聚类
 - 发现异常行程 → 异常检测
 - 发现常见路径 → 模式挖掘

不同语义与分析目标需要不同的挖掘方法。



数据到达方式改变挖掘方式

□ 存储数据 vs. 流数据

- 存储数据：有限，存放于各类大规模数据仓库
- 流数据（如视频监控或遥感）：动态、持续到达、无限、需实时响应——对有效数据挖掘构成挑战

	Batch / Stored Data	Streaming Data
Scope	Finite and stored	Continuous and potentially unbounded
Access	Can be processed repeatedly	Usually processed in one or a few passes
Priority	Accuracy and comprehensive analysis	Low latency and limited memory
Examples	Historical transactions, archived records	Sensor feeds, network traffic, live clickstreams
Typical methods	Offline and batch algorithms	Online and incremental algorithms

对流数据，往往必须在完整数据集尚未齐备时就做出决策。

我们能从数据中发现什么？

□ 数据概要

描述数据集的主要特征

□ 频繁模式与关联挖掘

发现经常共同出现的项或事件

□ 分类与回归

预测类别标签或数值

□ 聚类分析

在无预定义标签的情况下发现自然分组

□ 离群点分析



识别异常或出乎意料的观测

Five Core Questions in Data Mining

Question	Task
What is typical?	Data Summarization
What occurs together?	Pattern Mining
What will happen?	Classification & Regression
What groups naturally exist?	Clustering
What is unusual?	Anomaly Detection

数据概要：什么是典型的？

- ❑ 目标：给出数据集紧凑、可解释的描述
- ❑ 示例：按产品、地区和月份汇总销售
- ❑ 输出：聚合、画像、比较与可视化概要



模式挖掘：什么会一起出现？

- ❑ 输入：一组事务或事件序列
- ❑ 目标：发现频繁共现的项或事件
- ❑ 示例：
 - ❑ {Smartphone} → {Phone Case}
 - ❑ Diaper □ Beer [0.5%, 75%] （支持度、置信度）
- ❑ 关键度量：支持度、置信度与提升度




$$\begin{aligned} \text{Rule } X \Rightarrow Y & \begin{cases} \text{Support} = \frac{\text{Frequency}(X,Y)}{N} \\ \text{Confidence} = \frac{\text{Frequency}(X,Y)}{\text{Frequency}(X)} \\ \text{Lift} = \frac{\text{Support}}{\text{Support}(X) * \text{Support}(Y)} \end{cases} \end{aligned}$$

关联并不必然意味着因果。

预测：将会发生什么？

- 预测：分类或回归
 - 基于若干带标签的训练样本构建模型（函数）
 - 描述并区分类别或概念，用于未来预测



Classification

Predict a categorical label

Spam or not spam?

Fraud or legitimate?

Regression

Predict a numerical value

How long will a trip take?


How much demand will occur?

二者都从带标签样本中学习预测关系。

聚类：自然存在哪些分组？

- 输入：无标签数据（无监督学习）
- 目标：发现相似对象的分组
- 原则：簇内相似度高、簇间相似度低
 - 最大化簇内相似度，最小化簇间相似度。
- 示例：按出行模式对城市区域分组


分类预测已知类别；聚类发现未知分组。



异常检测：什么是异常的？

□ 离群点分析



- 离群点：不符合数据总体行为的数据对象
- 它可能表示误差、稀有事件或新现象
- 某事物是否异常往往取决于其上下文
 - 噪声还是例外？——此人之弃物，或为彼人之珍宝



离群点可能是噪声——也可能是最有价值的观测。

挖掘有序与演化数据

- 序列、时间序列与演化分析
- 挖掘数据流：有序、随时间变化、可能无限的数据流



Data	Question	Example
Sequence	What events frequently follow one another?	Phone → Case → Earbuds
Time series	How does a value change over time?	Traffic demand
Data stream	What is happening right now?	Live sensor readings

顺序与时间序列会引入普通表格可能无法刻画的趋势、依赖与变化。



挖掘图：数据如何关联？

□ 图：节点表示实体；边表示关系

- 例如：社交网络、路网、引文网络与通信网络

□ 图挖掘

- 识别重要节点 → 排序
- 发现紧密连接的群体 → 社区发现
- 预测缺失或未来边 → 链路预测
- 发现重复结构 → 子图挖掘




任务与技术并不相同

Data Mining Tasks—What?	Techniques—How?
Classification	Decision trees
Regression	Statistical models
Clustering	K-means
Pattern mining	Apriori
Anomaly detection	Isolation-based methods
Multiple tasks	Neural networks / Deep learning

深度学习是一类可支撑多种数据挖掘任务的技术，而非独立的挖掘任务。

示例：数据挖掘任务与技术



并非每个发现的模式都有用

- ❑ 数据挖掘算法可能发现数千个候选模式。其中许多是平凡、冗余、不稳定或与用户无关的。

- ❑ 如何识别有趣的模式？

- ❑ 有效性：该模式在新的或未见数据上是否成立？
- ❑ 新颖性：是否揭示了出乎意料或此前未知的内容？
- ❑ 效用：能否支撑有意义的决策或行动？

- ❑ 可解释性：用户能理解并解释该模式？

Objective Measures	Subjective Measures
Accuracy	Novelty
Support / coverage	Usefulness
Statistical significance	Actionability
Robustness on new data	Interpretability

趣味性既取决于统计证据，也取决于用户需求。

并非每个发现的模式都有用

□ 如何识别有趣的模式？

Objective Measures	Subjective Measures
Accuracy	Novelty
Support / coverage	Usefulness
Statistical significance	Actionability
Robustness on new data	Interpretability


□ 示例：“高峰时段交通更拥堵。”

- 有效？新颖？有用？
- 大概是 / 否 / 视情况而定

一个模式可以在统计上有效，但在实践中并无趣味。

为何现实世界的数据挖掘具有挑战?


- ❑ 规模_x000B_数百万乃至数十亿条记录
- ❑ 高维_x000B_数千甚至数百万个特征
- ❑ 数据异构性_x000B_表格、文本、图像、序列、图以及多模态数据
- ❑ 动态环境_x000B_流数据及随时间变化的模式
- ❑ 情境与用户需求_x000B_统计上有效的模式在实践中未必有用



现实世界的数据挖掘需要可扩展算法、可靠系统以及领域理解。

数据挖掘融合多学科

从可靠数据基础到可行动决策的递进路径




AI、机器学习、数据挖掘与数据科学

- 这些领域相互重叠，但关注数据生命周期中不同的问题与阶段。

Field	Central Goal	Typical Focus
Artificial Intelligence	Build systems that exhibit intelligent behavior	Reasoning, planning, perception, learning
Machine Learning	Learn models and representations from data	Prediction and generalization
Data Mining	Discover valid, novel, and useful patterns from data	Patterns, clusters, anomalies and predictive insights
Data Science	Turn data into evidence and decisions	The end-to-end data lifecycle

数据挖掘已嵌入日常系统

- ❑ 数字平台_x000B_搜索排序、内容推荐、垃圾信息检测
- ❑ 商业与金融_x000B_购物篮分析、需求预测、欺诈检测
- ❑ 科学与医疗_x000B_疾病风险分析、生物标志物发现、科学数据分析
- ❑ 城市与物联网_x000B_交通预测、出行分析、传感器异常检测



数据挖掘常在界面背后运作，将行为数据与传感器数据转化为决策。

有用的数据挖掘也必须负责任

- ❑ 隐私与同意_x000B_数据的采集与使用是否恰当？
- ❑ 偏见与公平_x000B_数据与模型是否对特定群体不利？
- ❑ 透明与问责_x000B_决策能否被解释、质疑并纠正？
- ❑ 安全与滥用_x000B_数据或发现的模式是否可能被滥用？

我们能否做？ → 我们应否做？ → 谁可能受影响？

小结

□ 今日五个要点

- 数据具有多种形态与表示
- 不同问题对应不同挖掘任务
- 发现的模式必须加以评估
- 数据挖掘融合算法、系统与领域知识
- 有用的挖掘也必须负责任

