

AIAA 3111 - 数据挖掘导论

数据、度量与数据预处理

Dr. Hao Liu



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)

提纲

- ❑ 数据类型
- ❑ 数据统计
- ❑ 相似度与距离度量
- ❑ 数据质量、数据清洗与数据集成
- ❑ 数据变换
- ❑ 降维
- ❑ 小结

数据集类型：(1) 记录型数据

- 关系记录
 - 关系表，高度结构化
- 数据矩阵，如数值矩阵、交叉表


	China	England	France	Japan	USA	Total
Active Outdoors Crochet Glove		12.00	4.00	1.00	240.00	257.00
Active Outdoors Lycra Glove		10.00	6.00		323.00	339.00
InFlux Crochet Glove	3.00	6.00	8.00		132.00	149.00
InFlux Lycra Glove		2.00			143.00	145.00
Triumph Pro Helmet	3.00	1.00	7.00		333.00	344.00
Triumph Vertigo Helmet		3.00	22.00		474.00	499.00
Xtreme Adult Helmet	8.00	8.00	7.00	2.00	251.00	276.00
Xtreme Youth Helmet		1.00			76.00	77.00
Total	14.00	43.00	54.00	3.00	1,972.00	2,086.00

Person:

Pers_ID	Surname	First_Name	City
0	Miller	Paul	London
1	Ortega	Alvaro	Valencia
2	Huber	Urs	Zurich
3	Blanc	Gaston	Paris
4	Bertolini	Fabrizio	Rom

Car:

Car_ID	Model	Year	Value	Pers_ID
101	Bentley	1973	100000	0
102	Rolls Royce	1965	330000	0
103	Peugeot	1993	500	3
104	Ferrari	2005	150000	4
105	Renault	1998	2000	3
106	Renault	2001	7000	3
107	Smart	1999	2000	2



- 事务数据

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk


	team	coach	pla y	ball	score	game	n wi	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

- 文档数据：文本文档的词频向量（矩阵）

数据集类型：(2) 图与网络



□ 交通网络

□ 万维网



□ 分子结构



□ 社交或信息网络



数据集类型：(3) 有序数据

□ 视频数据：图像序列

□ 时序数据：时间序列



□ 序列数据：事务序列


□ 基因序列数据

Start

Human	GTTTGGAGG -- ATGTTCAACAAATGCTCCTTTTCATTCTCTATTTACAGACCTGCCGCA
Chimpanzee	GTTTGGAGG -- ATGTTCAATAAATGCTGCTTTCACTCCTCTATTTACAGACCTGCCGCA
Macaque	GTTTGGAGG -- ATGCTCAATAAATGCTCCTTTTCATTCTCTATTTACAAACTTGCCGCA
Human	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Chimpanzee	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Macaque	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Human	GATCTGGAGACTAA - CTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Chimpanzee	GATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Macaque	TATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Human	CAGAATACGATTTAGCAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Chimpanzee	CAGAATACGATTTAGCAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Macaque	CAGAATATGATTTAGCAAATTACTTCTTAAGATATTATTTTGCATTTCTATATTCTCCTA
Human	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Chimpanzee	CCCTGAGTTGATGTGTGAGCGTATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Macaque	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTCACAAAGCCAGGTATATATACATTACG
Human	GACAGGTAAGTAAAAACATATTATTATTCTACGTTTTTGCCAAAAATTTTAAATTTTC
Chimpanzee	GACAGGTAAGTAAAAACATATTATTATTCTACGTTTTTGCCAAAAATTTTAAATTTTC
Macaque	GACAGGTAAGTAAAAA - CATATTATTATTCTAGGTTTTTGCCAAAGAGTTTAAATTTTC
Human	AACGTGTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACA
Chimpanzee	AACGTGTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACA
Macaque	AACGTGTGTGCATGTGTTGGTAA --- CGTAAAACAAATTCAGTACG

数据集类型：(4) 空间、图像与多媒体数据

□ 空间数据：地图



□ 图像数据：

□ 视频数据：

结构化数据的重要特征

- 维数
 - 维数灾难
- 稀疏性
 - 仅计存在与否
- 分辨率
 - 模式依赖于尺度
- 分布
 - 中心趋势与离散程度

数据对象

- ❑ 数据集由数据对象组成
- ❑ 数据对象表示一个实体
- ❑ 示例：
 - ❑ 销售数据库： 顾客、商品、销售
 - ❑ 医疗数据库： 患者、治疗
 - ❑ 大学数据库： 学生、教师、课程
- ❑ 也称样本、示例、实例、数据点、对象、元组
- ❑ 数据对象由属性描述
- ❑ 数据库行 → 数据对象； 列 → 属性

属性

- **属性（或维、特征、变量）**

- 数据字段，表示数据对象的某种特征。
- 例如： *customer_ID*、 *name*、 *address*

- **类型：**

- 标称（如 red、blue）
- 二元（如 {true, false}）
- 序数（如 {freshman, sophomore, junior, senior}）
- 数值型：定量
 - 区间标度：100°C 是区间标度
 - 比率标度：100°K 是比率标度，因为它是 50 °K 的两倍
- 离散属性与连续属性

属性类型

□ 标称：类别、状态或“事物的名称”

- *Hair_color* = {auburn, black, blond, brown, grey, red, white}
- 婚姻状况、职业、ID 号码、邮政编码

□ 二元

- 仅有 2 个状态（0 和 1）的标称属性
- 对称二元：两种结果同等重要
 - 例如：gender
- 非对称二元：结果重要性不等。
 - 例如：医学检测（阳性 vs. 阴性）
 - 惯例：将 1 赋给最重要的结果（如 HIV 阳性）

□ 序数

- 取值有有意义的顺序（排序），但相邻取值之间的幅度未知
- *Size* = {small, medium, large}, 成绩、军衔

数值属性类型

- 数量（整数或实值）

- 区间

 - 在等距单位的标度上度量

 - 取值有序

 - 例如：C° 或 F° 温度、日历日期

 - 无真正的零点

- 比率

 - 固有零点

 - 可以说取值比度量单位高出一个数量级（10 K° 是 5 K° 的两倍）。

 - 例如：Kelvin 温度、长度、计数、货币量

离散属性与连续属性

□ 离散属性

- 取值集合有限或可数无限
 - 例如：邮政编码、职业，或文档集合中的词集合
- 有时表示为整型变量
- 注：二元属性是离散属性的特例

□ 连续属性

- 属性取值为实数
 - 例如：温度、身高或体重
- 实践中，实值只能用有限位数字测量和表示
- 连续属性通常表示为浮点变量

数据统计

- 度量中心趋势
- 度量数据的离散程度
- 协方差与相关分析
- 数据基本统计的图形展示

数据的基本统计描述

□ 动机

- 更好地理解数据：中心趋势、变异与散布

□ 数据离散特征

- 中位数、最大值、最小值、分位数、离群点、方差、...

□ 数值维对应已排序区间

- 数据离散：


- 在多种精度粒度上分析

- 对已排序区间做箱线图或分位数分析

□ 对计算得到的度量做离散分析

- 将度量折叠进数值维


- 对变换后的立方体做箱线图或分位数分析




度量中心趋势： (1) 均值

□ 均值（代数度量）（样本 vs. 总体）：

注：n 为样本量，N 为总体规模。


$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


$$\mu = \frac{\sum x}{N}$$

□ 加权算术平均：


$$\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

□ 截尾均值：

□ 去掉极端值（如奥运会体操计分）

度量中心趋势：(2) 中位数

□ 中位数：

□ 取值为奇数时取中间值，否则取中间两个值的平均

□ 用插值估计（分组数据）：

<i>age</i>	<i>frequency</i>
1-5	200
6-15	450
16-20	300
21-50	1500
51-80	700
81-110	44

近似中位数

中位数所在区间之前的累计和

区间宽度 ($L_2 - L_1$)

$$median = L_1 + \left(\frac{n/2 - (\sum freq)_l}{freq_{median}} \right) width$$

区间下限


度量中心趋势：(3) 众数

□ 众数：数据中出现频率最高的值

□ 单峰

□ 经验公式：




$$mean - mode = 3 \times (mean - median)$$



□ 多峰

□ 双峰


□ 三峰




对称与偏斜数据

- 对称、正偏与负偏数据的中位数、均值与众数


对称



正偏




负偏



正态分布曲线的性质

← — — — — — 表示数据离散、散布 — — — — — →



表示中心趋势

相关分析（针对分类数据）

□ X2 (chi-square) 检验:

$$\chi^2 = \sum_i^n \frac{\overset{\text{observed}}{\downarrow} (O_i - E_i)^2}{\underset{\text{expected}}{E_i}}$$

- 原假设：两个分布相互独立
- 对 χ^2 值贡献最大的单元格，是实际计数与期望计数相差很大的那些
 - χ^2 值越大，变量相关的可能性越大
- 注：相关并不意味着因果
 - 一座城市的医院数量与汽车盗窃数量相关
 - 二者都与第三个变量因果相关：population

卡方计算：示例

	下象棋	不下象棋	行合计
喜欢科幻	250 (X1)	200 (X2)	450
不喜欢科幻	50 (X3)	1000 (X4)	1050
列合计	300	1200	1500

□ 原假设：两个分布相互独立

□ 这意味着什么？

□ 喜欢科幻与不喜欢科幻两组中，下棋与不下棋的人数比例相同

□ $X1+X2=450$ $X3+X4=1050$

□ $X1+X3=300$ $X2+X4=1200$

卡方计算：示例

	下象棋	不下象棋	行合计
喜欢科幻	250 (90)	200 (360)	450
不喜欢科幻	50 (210)	1000 (840)	1050
列合计	300	1200	1500

90 如何得出?

$$450/1500 * 300 = 90$$

- χ^2 (chi-square) 计算 (括号中的数字是根据两类数据分布算出的期望计数)

$$\chi^2 = \frac{(250-90)^2}{90} + \frac{(50-210)^2}{210} + \frac{(200-360)^2}{360} + \frac{(1000-840)^2}{840} = 507.93$$

我们可以拒绝
.....的原假设
独立性, 置信水
平为 0.001

- 表明 like_science_fiction 与 play_chess 在该组中相关

卡方计算：示例

	A	B	C	D	行合计
1					200
0					1000
列合计	300	300	300	300	1200

□ 自由度

- $(\text{\#categories_in_variable_A} - 1)(\text{\#categories_in_variable_B} - 1)$
- 可以自由变化的取值个数

卡方计算：示例


	下象棋	不下象棋	行合计
喜欢科幻	250 (90)	200 (360)	450
不喜欢科幻	50 (210)	1000 (840)	1050
列合计	300	1200	1500

$$\chi^2 = \frac{(250-90)^2}{90} + \frac{(50-210)^2}{210} + \frac{(200-360)^2}{360} + \frac{(1000-840)^2}{840} = 507.93$$

□ 自由度 = ?

我们可以拒绝
.....的原假设
独立性，置信水
平为 0.001

Values of the Chi-squared distribution



	P										
DF	0.995	0.975	0.20	0.10	0.05	0.025	0.02	0.01	0.005	0.002	0.001
1	0.0000393	0.000982	1.642	2.706	3.841	5.024	5.412	6.635	7.879	9.550	10.828
2	0.0100	0.0506	3.219	4.605	5.991	7.378	7.824	9.210	10.597	12.429	13.816
3	0.0717	0.216	4.642	6.251	7.815	9.348	9.837	11.345	12.838	14.796	16.266
4	0.207	0.484	5.989	7.779	9.488	11.143	11.668	13.277	14.860	16.924	18.467
5	0.412	0.831	7.289	9.236	11.070	12.833	13.388	15.086	16.750	18.907	20.515
6	0.676	1.237	8.558	10.645	12.592	14.449	15.033	16.812	18.548	20.791	22.458

单变量的方差（数值数据）

- 随机变量 X 的方差度量 X 的取值偏离其均值或期望的程度：

$$\sigma^2 = \text{var}(X) = E[(X - \mu)^2] = \begin{cases} \sum_x (x - \mu)^2 f(x) & \text{if } X \text{ is discrete} \\ \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx & \text{if } X \text{ is continuous} \end{cases}$$

- 其中 σ^2 是 X 的方差， σ 称为标准差

μ 是均值，且 $\mu = E[X]$ 是 X 的期望

- 也即，方差是相对均值平方偏差的期望

- 也可写成：

- 样本方差

$$\sigma^2 = \text{var}(X) = E[(X - \mu)^2] = E[X^2] - \mu^2 = E[X^2] - [E(x)]^2$$

$$s^2 = \frac{1}{n} \sum_i^n (x_i - \hat{\mu})^2$$

$$s^2 = \frac{1}{n - 1} \sum_i^n (x_i - \hat{\mu})^2$$

两个变量的协方差

- Covariance between two variables X_1 and X_2

$$\sigma_{12} = E[(X_1 - \mu_1)(X_2 - \mu_2)] = E[X_1 X_2] - \mu_1 \mu_2 = E[X_1 X_2] - E[X_1]E[X_2]$$

where $\mu_1 = E[X_1]$ is the respective mean or **expected value** of X_1 ; similarly for μ_2

- Sample covariance between X_1 and X_2 : $\hat{\sigma}_{12} = \frac{1}{n} \sum_{i=1}^n (x_{i1} - \widehat{\mu}_1)(x_{i2} - \widehat{\mu}_2)$
- Sample covariance is a generalization of the sample variance:

$$\hat{\sigma}_{11} = \frac{1}{n} \sum_{i=1}^n (x_{i1} - \widehat{\mu}_1)(x_{i1} - \widehat{\mu}_1)$$

- **Positive covariance:** If $\sigma_{12} > 0$
- **Negative covariance:** If $\sigma_{12} < 0$

两个变量的协方差

- **Independence:** If X_1 and X_2 are independent, $\sigma_{12} = 0$ but the reverse is not true
 - Some pairs of random variables may have a covariance 0 but are not independent
 - Only under some additional assumptions (e.g., the data follow multivariate normal distributions) does a covariance of 0 imply independence

□ Example:

X_1	1	-1	
X_2	0	1	-1

$$\sigma_{12} = E[(X_1 - \mu_1)(X_2 - \mu_2)] = E[X_1X_2] - \mu_1\mu_2 = E[X_1X_2] - E[X_1]E[X_2]$$

$$E(X_1)=?$$

$$E(X_2)=?$$

$$E(X_1X_2)=?$$

示例： 协方差计算

- 设两只股票 x_1 与 x_2 在一周内有如下取值：
 - $(2, 5), (3, 8), (5, 10), (4, 11), (6, 14)$
- 问题： 若两只股票受同一行业趋势影响，其价格会一同涨跌吗？
- 协方差公式
- 其计算可简化为：
$$\sigma_{12} = E[(X_1 - \mu_1)(X_2 - \mu_2)] = E[X_1 X_2] - \mu_1 \mu_2 = E[X_1 X_2] - E[X_1]E[X_2]$$
 - $E(X_1) = (2 + 3 + 5 + 4 + 6) / 5 = 20/5 = 4$
 - $E(X_2) = (5 + 8 + 10 + 11 + 14) / 5 = 48/5 = 9.6$
 - $\sigma_{12} = (2 \times 5 + 3 \times 8 + 5 \times 10 + 4 \times 11 + 6 \times 14) / 5 - 4 \times 9.6 = 4$
- 因此，由于 $\sigma_{12} > 0$ ， x_1 与 x_2 同时上升

两个数值变量之间的相关性

- ❑ 变量 x_1 与 x_2 的相关系数是标准化协方差，即用各变量的标准差对协方差进行归一化

$$\rho_{12} = \frac{\sigma_{12}}{\sigma_1 \sigma_2} = \frac{\sigma_{12}}{\sqrt{\sigma_1^2 \sigma_2^2}}$$


- ❑ 属性 x_1 与 x_2 的相关系数：

$$\hat{\rho}_{12} = \frac{\hat{\sigma}_{12}}{\hat{\sigma}_1 \hat{\sigma}_2} = \frac{\sum_{i=1}^n (x_{i1} - \hat{\mu}_1)(x_{i2} - \hat{\mu}_2)}{\sqrt{\sum_{i=1}^n (x_{i1} - \hat{\mu}_1)^2 \sum_{i=1}^n (x_{i2} - \hat{\mu}_2)^2}}$$

其中 n 为元组数， μ_1 和 μ_2 分别为 x_1 和 x_2 的均值， σ_1 和 σ_2 分别为 x_1 和 x_2 的标准差

- ❑ 若 $\rho_{12} > 0$ ：A 与 B 正相关（ x_1 的取值随 x_2 增大而增大）
 - ❑ 值越大，相关性越强
- ❑ 若 $\rho_{12} = 0$ ：相互独立（前提与协方差部分讨论的假设相同）
- ❑ 若 $\rho_{12} < 0$ ：负相关

相关系数变化的可视化



- 相关系数取值范围: $[-1, 1]$
- 一组散点图展示点集及其相关系数从 -1 到 1 的变化

协方差矩阵

- 变量 x_1 与 x_2 的方差与协方差信息可汇总为 2×2 协方差矩阵:

$$\begin{aligned}\Sigma &= E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T] = E\left[\begin{pmatrix} X_1 - \mu_1 \\ X_2 - \mu_2 \end{pmatrix} \begin{pmatrix} X_1 - \mu_1 & X_2 - \mu_2 \end{pmatrix}\right] \\ &= \begin{pmatrix} E[(X_1 - \mu_1)(X_1 - \mu_1)] & E[(X_1 - \mu_1)(X_2 - \mu_2)] \\ E[(X_2 - \mu_2)(X_1 - \mu_1)] & E[(X_2 - \mu_2)(X_2 - \mu_2)] \end{pmatrix}\end{aligned}$$

- 推广到 d 维 $\begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{pmatrix}$ 有


$$D = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{d1} & x_{d2} & \cdots & x_{dd} \end{pmatrix} \quad \Sigma = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T] = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_d^2 \end{pmatrix}$$

基本统计描述的图形展示

- ❑ 箱线图：五数概括的图形展示
- ❑ 直方图：横轴为取值，纵轴表示频数
- ❑ 分位数图：每个取值 x_i 与 f_i 配对，表示约 $100 f_i \%$ 的数据 $\square x_i$
- ❑ 分位数-分位数（q-q）图：将一个单变量分布的分位数对应到另一分布的相应分位数
- ❑ 散点图：每一对取值作为一对坐标，在平面上描点

度量数据离散程度：四分位数与箱线图


- ❑ 四分位数：Q1（第 25 百分位）、Q3（第 75 百分位）
- ❑ 四分位距： $IQR = Q3 - Q1$
- ❑ 五数概括：min、Q1、中位数、Q3、max
- ❑ 箱线图：用箱子表示数据
 - ❑ Q1、Q3、IQR：箱体两端位于第一、第三四分位数，即箱体高度为 IQR
 - ❑ 中位数（Q2）用箱内一条线标出
 - ❑ 须：箱体外延伸至最小值与最大值的两条线
 - ❑ 离群点：超出指定离群阈值的点，单独绘制
 - ❑ 离群点：通常为高于/低于 $1.5 \times IQR$ 的取值




直方图分析

直方图

- 直方图：用柱形展示分组频数的图形
- 直方图与条形图的区别
 - 直方图用于展示变量的分布，条形图用于比较变量
 - 直方图绘制分箱后的定量数据，条形图绘制分类数据
 - 条形图中的条可重排，直方图则不可
 - 与条形图的区别在于：表示数值的是条的面积，而非条形图中的高度；当各类宽度不同时，这一区别至关重要





Olympic Medals of all Times (till 2012 Olympics)



条形图


直方图往往比箱线图提供更多信息



- 左侧两个直方图可能对应相同的箱线图表示
 - min、Q1、中位数、Q3、max 取值相同
- 但数据分布却明显不同



分位数图

- 展示全部数据（便于观察总体形态与异常点）
- 绘制分位数信息
 - 对按递增排序的数据 x_i , f_i 表示约 100 $f_i\%$ 的数据小于或等于 x_i





分位数-分位数 (Q-Q) 图

- 将一个单变量分布的分位数对应到另一分布的相应分位数
- 观察：从一个分布到另一个分布是否存在平移？
- 示例：各分位数上 Branch 1 与 Branch 2 所售商品单价。Branch 1 的单价往往低于 Branch 2






散点图

- 初步观察二维数据中的点簇、离群点等
- 每一对取值作为一对坐标，在平面上描点






正相关与负相关数据



- 左半部分为正相关
- 右半部分为负相关

不相关数据



相似度与距离度量

- ❑ 数据矩阵与相异度矩阵
- ❑ 标称属性的邻近度度量
- ❑ 二元属性的邻近度度量
- ❑ 数值数据的相异度：Minkowski 距离
- ❑ 序数属性的邻近度度量
- ❑ 混合类型属性的相异度
- ❑ 余弦相似度
- ❑ 度量分布相近程度：Kullback-Leibler 散度
- ❑ 在相似度度量中捕捉隐含语义

相似度、相异度与邻近度

□ 相似度度量或相似度函数

- 量化两个对象相似程度的实值函数
- 度量两个数据对象有多相似：取值越大越相似
- 常落在 $[0,1]$ ：0 表示不相似；1 表示完全相似

□ 相异度（或距离）度量


- 度量两个数据对象差异程度的数值
- 某种意义上是相似度的反面：取值越小越相似
- 最小相异度常为 0（即完全相似）
- 取值范围为 $[0, 1]$ 或 $[0, \infty)$ ，取决于定义

□ 邻近度通常指相似度或相异度

数据矩阵与相异度矩阵

□ 数据矩阵

- 含 n 个数据点、 l 维的数据矩阵


$$D = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1l} \\ x_{21} & x_{22} & \dots & x_{2l} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nl} \end{pmatrix}$$


□ 相异度（距离）矩阵

- n 个数据点，仅记录距离 $d(i, j)$ （通常为度量）

- 通常对称，因而为三角矩阵

- 距离函数通常因实数、布尔、分类、序数、比率与向量变量而不同

- 可根据应用与数据语义为不同变量赋权


$$\begin{pmatrix} 0 & & & \\ d(2,1) & 0 & & \\ \vdots & \vdots & \ddots & \\ d(n,1) & d(n,2) & \dots & 0 \end{pmatrix}$$


数值数据的标准化

- Z-score:
$$z = \frac{x - \mu}{\sigma}$$
 - x : 待标准化的原始得分, μ : 总体均值, σ : 标准差
 - 原始得分与总体均值之间、以标准差为单位的距离
 - 原始得分低于均值时为负, 高于均值时为“+”
- 另一种做法: 计算平均绝对偏差

其中
$$s_f = \frac{1}{n} (|x_{1f} - m_f| + |x_{2f} - m_f| + \dots + |x_{nf} - m_f|)$$

- 标准化度量 (z-score):
$$m_f = \frac{1}{n} (x_{1f} + x_{2f} + \dots + x_{nf})$$
- 使用平均绝对偏差比使用标准差更稳健
$$z = \frac{x_{if} - m_f}{s_f}$$

示例：数据矩阵与相异度矩阵



数据矩阵

point	attribute1	attribute2
$x1$	1	2
$x2$	3	5
$x3$	2	0
$x4$	4	5

相异度矩阵 (按 Euclidean 距离)

	$x1$	$x2$	$x3$	$x4$
$x1$	0			
$x2$	3.61	0		
$x3$	2.24	5.1	0	
$x4$	4.24	1	5.39	0

数值数据上的距离：Minkowski 距离

□ Minkowski 距离：常用距离度量

$$d(i, j) = \sqrt[p]{|x_{i1} - x_{j1}|^p + |x_{i2} - x_{j2}|^p + \cdots + |x_{il} - x_{jl}|^p}$$

其中 $i = (x_{i1}, x_{i2}, \dots, x_{il})$ 与 $j = (x_{j1}, x_{j2}, \dots, x_{jl})$ 为两个 l 维数据对象， p 为阶数（如此定义的距离亦称 L - p 范数）

□ 性质

□ 若 $i \neq j$ 则 $d(i, j) > 0$ ，且 $d(i, i) = 0$ （正定性）

□ $d(i, j) = d(j, i)$ （对称性）

□ $d(i, j) \leq d(i, k) + d(k, j)$ （三角不等式）

□ 满足这些性质的距离称为度量

□ 注：也存在非度量相异度，例如集合差

Minkowski 距离的特例

□ $p = 1$: (L1 范数) Manhattan (或街区) 距离

□ 例如 Hamming 距离: 两个二元向量中不同的比特数

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{il} - x_{jl}|$$

□ $p = 2$: (L2 范数) Euclidean 距离


□ $p \geq 1$: (Lmax 范数, L ∞ 范数) “supremum” 距离

□ 向量各分量 (属性) 差的最大值

$$d(i, j) = \lim_{p \rightarrow \infty} \sqrt[p]{|x_{i1} - x_{j1}|^p + |x_{i2} - x_{j2}|^p + \cdots + |x_{il} - x_{jl}|^p} = \max_{f=1}^l |x_{if} - x_{jf}|$$

示例：特例下的 Minkowski 距离

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5



Manhattan (L_1)

L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)

L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum (L_∞)

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0

二元属性的邻近度度量

□ 二元数据的列联表

		对象 j		
		1	0	sum
对象 i	1	q	r	$q + r$
	0	s	t	$s + t$
sum		$q + s$	$r + t$	p

□ 对称二元变量的距离度量:

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

□ 非对称二元变量的距离度量:

$$d(i, j) = \frac{r + s}{q + r + s}$$

□ Jaccard 系数 (非对称二元变量的相似度):

□ 注: Jaccard 系数等同于“coherence”:

$$sim_{Jaccard}(i, j) = \frac{q}{q + r + s}$$

(模式发现中讨论的概念)

$$coherence(i, j) = \frac{sup(i, j)}{sup(i) + sup(j) - sup(i, j)} = \frac{q}{(q + r) + (q + s) - q}$$

示例：非对称二元变量之间的相异度

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

- Gender 为对称属性（不计入）
- 其余属性为非对称二元属性
- 令取值 Y 和 P 为 1，取值 N 为 0
- 距离：
$$d(i, j) = \frac{r + s}{q + r + s}$$

$$d(jack, mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(jack, jim) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(jim, mary) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

		Mary			
			1	0	Σ_{row}
Jack	1	2	0	2	
	0	1	3	4	
	Σ_{col}	3	3	6	

		Jim		
		1	0	Σ_{row}
Jack	1	1	1	2
	0	1	3	4
	Σ_{col}	2	4	6

		Mary		
		1	0	Σ_{row}
Jim	1	1	1	2
	0	2	2	4
	Σ_{col}	3	3	6

分类属性的邻近度度量

- 分类数据，亦称标称属性
 - 示例：Color (red, yellow, blue, green) 、 职业等
- 方法 1：简单匹配
 - m : 匹配数, p : 变量总数

$$d(i, j) = \frac{p - m}{p}$$

- 方法 2：使用大量二元属性
 - 为 M 个标称状态各建一个新的二元属性

序数变量

- 序数变量可以是离散的或连续的
- 次序重要，例如年级 (freshman、sophomore、junior、senior)
- 可按区间标度处理
 - 用秩替换序数变量取值： $r_{if} \in \{1, \dots, M_f\}$
 - 将每个变量的范围映射到 $[0, 1]$ ，用下式替换第 f 个变量上第 i 个对象
$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$
 - 示例：freshman: 0; sophomore: 1/3; junior: 2/3; senior 1
 - 于是距离： $d(\text{freshman}, \text{senior}) = 1$, $d(\text{junior}, \text{senior}) = 1/3$
 - 再用区间标度变量的方法计算相异度

混合类型属性

- 数据集可包含各类属性
 - 标称、对称二元、非对称二元、数值与序数
- 可用加权公式综合其作用：

$$d(i, j) = \frac{\sum_{f=1}^p w_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p w_{ij}^{(f)}}$$

- 若 f 为数值：使用归一化距离
- 若 f 为二元或标称：若 $x_{if} = x_{jf}$ 则 $d_{ij}(f) = 0$ ；否则 $d_{ij}(f) = 1$
- 若 f 为序数

- 计算秩 z_{if} （其中

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

- 将 z_{if} 按区间标度处理

两个向量的余弦相似度

- 文档可用词袋或长向量表示，每个属性记录某一词项（词、关键词或短语）在文档中的频次

Document	team	coach	hockey	baseball	soccer	penalty	score	win	loss	season
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

- 其
- 应用：信息检索、生物分类、基因特征映射等
- 余弦度量：若 d_1 与 d_2 为两个向量（如词频向量），则

$$\cos(d_1, d_2) = \frac{d_1 \bullet d_2}{\|d_1\| \times \|d_2\|}$$


其中 $\bullet$ 表示向量点积， $\|d\|$ 表示向量 d 的长度

示例：计算余弦相似度

- 计算余弦相似度：

$$\cos(d_1, d_2) = \frac{d_1 \bullet d_2}{\|d_1\| \times \|d_2\|}$$

$$\text{sim}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$



其中 $\bullet$ 表示向量点积， $\|d\|$ ：向量 d 的长度

- 例：求文档 1 与文档 2 的相似度。

$$d_1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0) \quad d_2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)$$

- 首先计算向量点积

$$d_1 \bullet d_2 = 5 \times 3 + 0 \times 0 + 3 \times 2 + 0 \times 0 + 2 \times 1 + 0 \times 1 + 0 \times 1 + 2 \times 1 + 0 \times 0 + 0 \times 1 = 25$$

- 再计算 $\|d_1\|$ 和 $\|d_2\|$


$$\|d_1\| = \sqrt{5 \times 5 + 0 \times 0 + 3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0} = 6.481$$

$$\|d_2\| = \sqrt{3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 1 \times 1 + 1 \times 1 + 0 \times 0 + 1 \times 1 + 0 \times 0 + 1 \times 1} = 4.12$$


- 计算余弦相似度： $\cos(d_1, d_2) = 25 / (6.481 \times 4.12) = 0.94$

KL 散度：比较两个概率分布



- *Kullback-Leibler (KL) 散度：度量同一变量 x 上两个概率分布的差异*
 - 来自信息论，与相对熵、信息散度及判别信息密切相关
- *$D_{KL}(p(x) \parallel q(x))$: $q(x)$ 相对 $p(x)$ 的散度，度量用 $q(x)$ 近似 $p(x)$ 时损失的信息*



Original Gaussian PDF's



KL Area to be Integrated



$$D_{KL}(p(x) \parallel q(x)) = \sum_{x \in X} p(x) \ln \frac{p(x)}{q(x)}$$

离散形式

$$D_{KL}(p(x) \parallel q(x)) = \int_{-\infty}^{\infty} p(x) \ln \frac{p(x)}{q(x)} dx$$

致谢：Wikipedia 条目：The Kullback-Leibler (KL) divergence

连续形式

关于 KL 散度的补充

$$D_{KL}(p(x)||q(x)) = \sum_{x \in X} p(x) \ln \frac{p(x)}{q(x)}$$

- KL 散度度量：在基于 $q(x)$ （作为 $p(x)$ 的理论、模型、描述或近似）编码时，对来自 $p(x)$ （“真实”分布）的样本额外所需的期望比特数
- KL 散度不是距离度量，也不是度量：不对称，不满足三角不等式（ $DKL(P||Q)$ 不等于 $DKL(Q||P)$ ）
- 应用中， P 通常表示数据、观测的“真实”分布或精确计算的理论分布，而 Q 通常表示对 P 的理论、模型、描述或近似。
- 从 Q 到 P 的 Kullback–Leibler 散度记为 $DKL(P||Q)$ ，度量信念由先验概率分布 Q 修正为后验概率分布 P 时所获得的信息。换言之，是用 Q 近似 P 时损失的信息量。
- KL 散度有时也称用 P 代替 Q 所获得的 information gain。亦称 P 相对 Q 的 relative entropy。

计算 KL 散度时的细节

- 由公式, $DKL(P, Q) \geq 0$, 且 $DKL(P \parallel Q) = 0$ 当且仅当 $P = Q$
- 当 $p = 0$ 或 $q = 0$ 时如何?
$$D_{KL}(p(x) \parallel q(x)) = \sum_{x \in X} p(x) \ln \frac{p(x)}{q(x)}$$
 - $\lim_{p \rightarrow 0} p \log p = 0$
 - 当 $p \neq 0$ 而 $q = 0$ 时, $DKL(p \parallel q)$ 定义为 ∞ , 即若事件 e 可能 ($p(e) > 0$), 而另一分布断定其绝对不可能 ($q(e) = 0$), 则两分布完全不同
- 但实践中 P 与 Q 来自频数分布, 未计入未见事件的可能性, 因此需要平滑
- 示例: $P : (a : 3/5, b : 1/5, c : 1/5)$. $Q : (a : 5/9, b : 3/9, d : 1/9)$
 - 需引入小常数 ϵ , 例如 $\epsilon = 10^{-3}$
 - P 中观测到的符号集 $SP = \{a, b, c\}$, $SQ = \{a, b, d\}$, $SU = \{a, b, c, d\}$
 - 平滑: 向各分布补入缺失符号, 概率为 ϵ
 - $P' : (a : 3/5 - \epsilon/3, b : 1/5 - \epsilon/3, c : 1/5 - \epsilon/3, d : \epsilon)$
 - $Q' : (a : 5/9 - \epsilon/3, b : 3/9 - \epsilon/3, c : \epsilon, d : 1/9 - \epsilon/3)$
 - 随后即可计算 $DKL(P' \parallel Q')$

在相似度度量中捕捉隐含语义

- 上述相似度度量无法捕捉隐含语义
 - 哪几对更相似：Geometry、algebra、music、politics?
- 相同词袋可能表达截然不同的含义
 - “The cat bites a mouse” vs. “The mouse bites a cat”
 - 这超出了向量空间模型所能处理的范围
- 此外，对象可由更复杂的结构与连接构成（如图与网络）
- 需要能处理复杂语义的新相似度度量
 - 例：分布式表示与表示学习

数据质量、数据清洗与数据集成

- ❑ 数据质量度量
- ❑ 数据清洗
- ❑ 数据集成

_x000B_什么是数据预处理？ —主要任务

□ 数据清洗

- 处理缺失数据、平滑噪声数据、识别或去除离群点，并消除不一致

□ 数据集成

- 集成多个数据库或文件

□ 数据归约

- 维归约
- 数量归约
- 数据压缩

□ 数据变换与数据离散化

- 规范化
- 概念分层生成

为何要预处理数据？——数据质量问题

- 数据质量度量：多维视角
 - 准确性：正确或错误，是否准确
 - 完整性：未记录、不可得，...
 - 一致性：有的已改有的未改、悬空，...
 - 时效性：是否及时更新？
 - 可信度：数据正确性有多可信？
 - 可解释性：数据是否易于理解？

数据清洗

- 现实世界数据是脏的：存在大量可能不正确的数据，例如仪器故障、人为或计算机错误、传输错误
 - 不完整：缺少属性值、缺少感兴趣属性，或仅含汇总数据
 - 例如 Occupation = " " （缺失数据）
 - 含噪：含有噪声、错误或离群点
 - 例如 Salary = "-10" （错误）
 - 不一致：编码或名称存在矛盾，例如
 - Age = "42" , Birthday = "03/07/2010"
 - 原先评级为 "1, 2, 3" , 现为 "A, B, C"
 - 重复记录之间的不一致
 - 有意为之（例如伪装的缺失数据）
 - 人人的生日都是 Jan. 1?

不完整（缺失）数据

- ❑ 数据并非总能获得
 - ❑ 例如，销售数据中许多元组的若干属性（如顾客收入）无记录值
- ❑ 缺失数据可能由于
 - ❑ 设备故障
 - ❑ 与其他已记录数据不一致因而被删除
 - ❑ 因误解而未录入数据
 - ❑ 录入时某些数据被认为不重要
 - ❑ 未登记数据的历史或变更
- ❑ 缺失数据可能需要推断

如何处理缺失数据？


- ❑ 忽略该元组：通常在类标缺失（做分类）时使用——当各属性缺失比例差异很大时效果不佳
- ❑ 手工填补缺失值：繁琐 + 不可行？
- ❑ 自动填补为
 - ❑ 全局常量：例如 “unknown”，一个新类？！
 - ❑ 该属性的均值
 - ❑ 同一类全部样本的属性均值：更聪明
 - ❑ **最可能的值：基于推断，如 Bayesian 公式或决策树**

含噪数据

- ❑ **噪声：测量变量中的随机误差或方差**
- ❑ **属性值不正确可能由于**
 - ❑ 数据采集仪器故障
 - ❑ 数据录入问题
 - ❑ 数据传输问题
 - ❑ 技术限制
 - ❑ 命名约定不一致
- ❑ **其他数据问题**
 - ❑ 重复记录
 - ❑ 不完整数据
 - ❑ 不一致数据

如何处理噪声数据？

- 分箱
 - 首先对数据排序并划分成（等频）箱
 - 然后可用箱均值平滑、箱中位数平滑、箱边界平滑等
- 回归
 - 通过将数据拟合到回归函数进行平滑
- 聚类
 - 检测并去除离群点
- 半监督：计算机与人工联合检查
 - 检测可疑值并由人工核查（例如处理可能的离群点）



作为过程的数据清洗

□ 数据不一致检测

- 使用元数据（如域、值域、依赖、分布）
- 检查字段过载
- 检查唯一性规则、连续性规则和空值规则
- 使用商业工具
 - 数据擦洗：利用简单领域知识（如邮政编码、拼写检查）检测错误并纠正
 - 数据审计：通过分析数据发现规则与关系以检测违规者（如用相关与聚类发现离群点）

□ 数据迁移与集成

- 数据迁移工具：允许指定变换
- ETL（抽取/变换/加载）工具：允许用户通过图形界面指定变换

□ 两个过程的集成

- 迭代且交互（如 Potter' s Wheels）

数据集成

- 数据集成
 - 将来自多个源的数据合并为一致的存储
- 为何需要数据集成？
 - 有助于减少/避免噪声
 - 获得更完整的图景
 - 提高挖掘速度与质量
- **模式集成：**
 - 例如，A.cust-id □ B.cust-#
 - 集成来自不同源的元数据
- **实体识别：**
 - 从多个数据源识别现实世界实体，例如 Bill Clinton = William Clinton

数据集成中的噪声处理

- 检测数据值冲突
 - 对同一现实世界实体，不同源的属性值不同
 - 可能原因：无原因、不同表示、不同度量，例如公制 vs. 英制单位
- 解决冲突信息
 - 取均值/中位数/众数/最大/最小
 - 取最近值
 - 真值发现：考虑数据源质量
- 数据清洗 + 数据集成

数据集成中的冗余处理

- ❑ 集成多个数据库时经常出现冗余数据
 - ❑ *对象识别：同一属性或对象在不同数据库中可能有不同名称*
 - ❑ *可导出数据：某属性可能是另一表中的“派生”属性，例如年收入*
- ❑ 冗余属性可通过相关分析和协方差分析检测

数据变换

- ❑ 规范化
- ❑ 离散化
- ❑ 数据压缩
- ❑ 抽样

数据变换

- ❑ 将给定属性的全部取值映射到一组替换值的函数，使得每个旧值可对应到某一个新值
- ❑ 方法
 - ❑ 平滑：去除数据中的噪声
 - ❑ 属性/特征构造
 - ❑ 由给定属性构造新属性
 - ❑ 聚集：汇总
 - ❑ 规范化：缩放至较小的指定区间
 - ❑ 最小-最大规范化
 - ❑ z-score 规范化
 - ❑ 小数定标规范化
 - ❑ 离散化：概念层次攀升

规范化

□ 最小-最大规范化：映射到 $[new_min_A, new_max_A]$

$$v' = \frac{v - min_A}{max_A - min_A} (new_max_A - new_min_A) + new_min_A$$

□ 例：设收入范围 \$12,000 到 \$98,000，规范化到 $[0.0, 1.0]$

□ 则 \$73,000 映射为

$$\frac{73,600 - 12,000}{98,000 - 12,000} (1.0 - 0) + 0 = 0.716$$

□ Z-score 规范化 (μ : 均值, σ : 标准差) :

$$v' = \frac{v - \mu_A}{\sigma_A}$$

Z-score: 原始分数与总体均值的距离，以标准差为单位

□ 例：设 $\mu = 54,000$, $\sigma = 16,000$ 。则 $\frac{73,600 - 54,000}{16,000} = 1.225$

□ 小数定标规范化

$$v' = \frac{v}{10^j} \quad \text{其中 } j \text{ 是使 } \text{Max}(|v'|) < 1 \text{ 的最小整数}$$

离散化

- 三类属性
 - 标称——来自无序集合的值，例如颜色、职业
 - 序数——来自有序集合的值，例如军衔或学术职级
 - 数值——实数，例如整数或实数
- 离散化：将连续属性的值域划分为区间
 - 然后可用区间标签替换实际数据值
 - 通过离散化减小数据规模
 - 有监督 vs. 无监督
 - 分裂（自顶向下）vs. 合并（自底向上）
 - 可对属性递归执行离散化
 - 为进一步分析做准备，例如分类

数据离散化方法

- 分箱
 - 自顶向下分裂，无监督
- 直方图分析
 - 自顶向下分裂，无监督
- 聚类分析
 - 无监督，自顶向下分裂或自底向上合并
- 决策树分析
 - 有监督，自顶向下分裂
- 相关（例如 χ^2 ）分析
 - 无监督，自底向上合并
- 注：所有方法均可递归应用

简单离散化：分箱

□ 等宽（距离）划分

- 将值域划分为 N 个等宽区间：均匀网格
- 若 A 和 B 分别为属性的最低与最高值，则区间宽度为： $W = (B - A)/N$ 。
- 最直接，但离群点可能主导展示效果
- 偏斜数据处理不佳

□ 等深（频率）划分

- 将值域划分为 N 个区间，每个区间含大约相同数量的样本
- 数据缩放效果好
- 处理分类属性可能较棘手

示例：用于数据平滑的分箱方法

□ 已排序的价格数据（美元）：4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34

* 划分为等频（等深）箱：

- Bin 1: 4, 8, 9, 15
- Bin 2: 21, 21, 24, 25
- Bin 3: 26, 28, 29, 34


* 按箱均值平滑：

- Bin 1: 9, 9, 9, 9
- Bin 2: 23, 23, 23, 23
- Bin 3: 29, 29, 29, 29


* 按箱边界平滑：

- Bin 1: 4, 4, 4, 15
- Bin 2: 21, 21, 25, 25
- Bin 3: 26, 26, 26, 34


无监督离散化：分箱 vs. 聚类




数据



等宽 (距离) 分箱



等深 (频率) (分箱)



K-means 聚类效果更好

基于分类与相关分析的离散化

- 分类（例如决策树分析）
 - 有监督：给定类标，例如恶性 vs. 良性
 - 用熵确定分裂点（离散化点）
 - 自顶向下，递归分裂
 - 细节将在“分类”一章讲解
- 相关分析（例如 Chi-merge：基于 χ^2 的离散化）
 - 有监督：使用类信息
 - 自底向上合并：找出最佳相邻区间（类分布相似，即 χ^2 值低的区间）进行合并
 - 递归合并，直至满足预定义停止条件

概念层次生成

- ❑ **概念层次将概念（即属性值）按层次组织，通常与数据仓库中的每个维相关联**
- ❑ 概念层次形成：递归归约数据，用高层概念（如青年、成年或老年）收集并替换低层概念（如年龄的数值）
- ❑ 概念层次可由领域专家和/或应用设计者显式指定
- ❑ 数值与标称数据均可自动形成概念层次——对数值数据使用所示离散化方法

标称数据的概念层次生成



- 由用户或专家在模式层显式指定属性的偏序/全序
 - *street < city < state < country*
- 通过对一组值显式分组来指定层次
 - {Urbana, Champaign, Chicago} < Illinois
- 仅指定部分属性
 - 例如, 仅 *street < city*, 其余不指定
- 通过分析不同取值个数自动生成层次 (或属性层级)
 - 例如, 对属性集合: {street, city, state, country}

数据归约


- **数据归约：**
 - 获得数据集的归约表示
 - 体积小得多，但分析结果几乎相同
- 为何数据归约？——数据库/数据仓库可能存储 TB 级数据
 - 在完整数据集上运行复杂分析可能耗时很长
- **数据归约方法（也称数据规模归约或数量归约）**
 - 回归与对数线性模型
 - 直方图、聚类、抽样
 - 数据压缩

数据归约：参数方法 vs. 非参数方法

- 通过选择更小的替代数据表示来减小数据量
- **参数方法（例如回归）**
 - 假定数据拟合某模型，估计模型参数，只存储参数并丢弃数据（可能的离群点除外）
 - 例：对数线性模型—— m -D 空间中一点的取值表示为适当边际子空间上的乘积
- **非参数方法**
 - 不假定模型
 - 主要类别：直方图、聚类、抽样、...



直方图




对原始数据
聚类

分层抽样

参数数据归约：回归分析

- 回归分析：对由因变量（也称响应变量或测量）取值以及一个或多个自变量（也称解释变量或预测变量）组成的数值数据进行建模与分析的一类技术的统称
- 估计参数以使数据达到“最佳拟合”
- 最常用最小二乘法评价最佳拟合，也使用过其他准则




- 用于预测（包括时间序列数据的预报）、推断、假设检验以及因果关系建模

线性回归与多元回归


□ 线性回归: $Y = w X + b$

- 将数据建模为拟合直线
- 常用最小二乘法拟合直线
- 两个回归系数 w 和 b 确定直线，需用手头数据估计
- 将最小二乘准则用于已知值 $Y_1, Y_2, \dots, X_1, X_2, \dots$




□ 非线性回归:

- 用模型参数的非线性组合且依赖于一个或多个自变量的函数对数据建模
- 用逐次逼近法拟合数据




多元回归与对数线性模型

- 多元回归: $Y = b_0 + b_1 X_1 + b_2 X_2$
 - 允许将响应变量 Y 建模为多维特征向量的线性函数
 - 许多非线性函数可变换为上述形式
- 对数线性模型:
 - 一种数学模型，其函数的对数是模型参数的线性组合，从而可应用（可能是多元）线性回归
 - 基于较小的维组合子集，估计多维空间中每个点（元组）在一组已离散化属性上的概率
 - 有助于降维与数据平滑




直方图分析

- 将数据划分为桶，并存储每桶的平均值（和）
- 划分规则：
 - 等宽：桶区间相等
 - 等频（或等深）



聚类

- 按相似性将数据集划分为簇，仅存储簇表示（如质心和直径）
- 若数据成簇则很有效，若数据“涂抹”则不然
- 可有层次聚类，并存储于多维索引树结构
- 聚类定义与聚类算法有多种选择
- 聚类分析将在第 10 章深入学习



抽样

- 抽样：获得小样本 s 以代表整个数据集 N
- 使挖掘算法的复杂度相对数据规模可能亚线性 -> 例如成对相关
- 关键原则：选择数据的代表性子集
 - 存在偏斜时，简单随机抽样性能可能很差
 - 发展自适应抽样方法，例如分层抽样：

抽样类型

- 简单随机抽样：每个对象被选中的概率相等

- 无放回抽样



 - 对象一旦被选中，即从总体中移除

- 有放回抽样

 - 被选中的对象不从总体中移除


- 分层抽样

 - 划分（或聚类）数据集，并从每个划分中抽取样本（按比例，即大约相同的数据百分比）



数据压缩

- ❑ 字符串压缩
 - ❑ 有丰富理论与经过充分调优的算法
 - ❑ 通常无损，但未经展开时只能做有限操作
- ❑ 音频/视频压缩
 - ❑ 通常有损压缩，可逐步求精
 - ❑ 有时可不重构整体而重构信号的小片段
- ❑ 时间序列不是音频
 - ❑ 通常较短且随时间缓慢变化
- ❑ 降维也可视为数据压缩的形式



有损 vs. 无损压缩




降维

- 什么是降维?
- 降维方法
 - 主成分分析
 - 属性子集选择
 - 非线性降维方法

什么是降维?

□ 维数灾难

- 维数增加时，数据变得越来越稀疏
- 对聚类、离群点分析至关重要的点密度与距离变得不那么有意义
- 子空间的可能组合将指数增长



什么是降维？

□ 维归约

- 通过得到一组主变量，减少所考虑的随机变量个数

□ 降维的优点

- 避免维数灾难
- 有助于消除无关特征并减少噪声
- 减少数据挖掘所需的时间与空间
- 便于可视化

降维方法

- 降维方法体系

- **特征选择：找出原始变量（或特征、属性）的一个子集**

- **特征提取：将高维空间中的数据变换到更低维空间**

- 一些典型的降维方法


- 主成分分析

- 属性子集选择

- 非线性降维

主成分分析 (PCA)


- ❑ PCA：一种统计过程，用正交变换将可能相关变量的一组观测转换为称为主成分的线性不相关变量取值
- ❑ 将原始数据投影到小得多的空间，从而实现降维
- ❑ 方法：求协方差矩阵的特征向量，这些特征向量定义新空间



球沿直线运动。三台摄像机的数据含大量冗余

主成分分析（方法）


- 给定 n 维空间中的 N 个数据向量，求 $k \leq n$ 个正交向量（主成分）以最好地表示数据
 - 规范化输入数据：使各属性落入同一取值范围
 - 计算 k 个标准正交（单位）向量，即主成分
 - 每个输入数据（向量）均为这 k 个主成分向量的线性组合
 - 主成分按“重要性”或强度递减排序
 - 因主成分已排序，可通过剔除弱成分（即低方差成分）压缩数据（即用最强主成分重构对原始数据的良好近似）
- 仅适用于数值型数据



主成分分析

属性子集选择

- 降低数据维度的另一种方法
- 冗余属性
 - 重复了一个或多个其他属性中的大部分或全部信息
 - 例如，商品售价与已付销售税额
- 无关属性
 - 不含对当前数据挖掘任务有用的信息
 - 例：学生学号通常与预测其 GPA 无关



属性选择中的启发式搜索


- d 个属性共有 2^d 种可能的属性组合
- 典型的启发式属性选择方法：
 - 属性独立假设下的最佳单属性：由显著性检验选取
 - 最佳逐步特征选择：
 - 先选取最佳单属性
 - 再在给定第一属性条件下选取次优属性，.....
 - 逐步属性剔除：
 - 反复剔除最差属性
 - 选择与剔除相结合的最佳方案
 - 最优分支限界：
 - 使用属性剔除与回溯

属性创建（特征生成）

- 创建比原始属性更能有效刻画数据集重要信息的新属性（特征）
- 三类一般方法
 - 属性提取
 - 领域相关
 - 将数据映射到新空间（见数据归约）
 - 例如，傅里叶变换、小波变换、流形方法（本课不讲）
 - 属性构造
 - 组合特征（见“高级分类”一章中的判别频繁模式）
 - 数据离散化

非线性降维方法

- PCA 是线性降维方法
 - 每个主成分都是原始输入属性的线性组合
 - 当输入数据近似服从高斯分布或形成少数线性可分簇时效果较好
- 当输入数据线性不可分时，需构造邻近矩阵 (P)，并学习保持邻近关系、含 k 个特征 ($k \ll d$) 的新矩阵



非线性降维：SNE

□ SNE (随机邻域嵌入)

□ 用下式构造邻近矩阵 P :

$$P(i, j) = \frac{e^{-d_{ij}^2}}{\sum_{l=1, l \neq i}^n e^{-d_{il}^2}} \text{ where } d_{ij}^2 = \frac{\|x_i - x_j\|^2}{2\sigma^2}$$

□ 表示 x_j 是 x_i 邻居的概率

□ 假设已学得低维表示 $\hat{x}_i$, 可用类似方式计算另一估计邻近矩阵: $\hat{P}(i, j)$

□ 希望估计邻近矩阵 $\hat{P}$ 尽可能接近 P

□ 即最小化总体 K-L 散度, 亦即

$$\hat{x}_i = \arg \min_{\hat{x}_i, (i=1, \dots, n)} \sum_{i=1}^n D_{KL}(P_i || \hat{P}_i)$$

Step 1: Proximity Construction

Step 2: Preserving Proximity


SNE

$$P(i, j) = \frac{e^{-d_{ij}^2}}{\sum_{l=1, l \neq i}^n e^{-d_{il}^2}}$$

$$\min \sum_{i=1}^n \text{KL}(P_i || \hat{P}_i)$$


示例：非线性数据点上的比较：线性与非线性降维方法

- 可视化：线性与非线性降维方法示例
 - 给定二维空间中的一组输入数据（图(a)）：红、蓝数据点线性不可分
 - PCA 变换无法使其线性可分
 - t-SNE（t 分布 NSE）可使其线性可分




(a) Input data

(b) PCA



(d) t-SNE

邻近矩阵热图: 线性与非线性降维方法



PCA 与 t-SNE 中邻近矩阵的热图

- ❑ 两个对角块分别表示两个簇内部的邻近度
- ❑ 两个非对角块表示来自两个簇的数据之间的邻近度
- ❑ 采用非线性方法 (t-SNE) 时, 同一簇内数据元组的邻近度远高于不同簇之间的邻近度

小结

- ❑ 数据类型与属性类型
 - ❑ 标称、二元、序数、数值，离散与连续属性
- ❑ 数据统计
 - ❑ 中心趋势、离散程度、协方差与相关
- ❑ 度量数据相似性与相关性
 - ❑ 标称、二元、数值、序数及混合类型的邻近度量
 - ❑ 余弦相似度、KL 散度
- ❑ 数据质量度量、数据清洗与数据集成
- ❑ 数据变换：规范化、离散化、数据压缩与抽样
- ❑ 降维方法体系
 - ❑ 主成分分析（PCA）、属性子集选择与非线性降维

Q & A



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)