

AIAA 3111 - 数据挖掘导论

模式挖掘：基本概念与方法

Dr. Hao Liu



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)

模式挖掘：基本概念与方法

□ 基本概念



□ 频繁项集挖掘方法


□ 哪些模式有趣？——模式评估方法

□ 小结


什么是模式？

□ 什么是模式？


- 模式：在数据集中**频繁共同出现**（或强相关）的**项、子序列或子结构的集合**
- 模式表示数据集内在且重要的性质



频繁项集




频繁序列



频繁结构

什么是模式发现？

- ❑ 模式发现：从海量数据集中揭示模式
- ❑ 可回答如下问题：
 - ❑ 哪些商品经常被一起购买？
 - ❑ 购买 iPad 之后常见的后续购买是什么？



模式发现：为何重要？

□ 许多核心数据挖掘任务的基础

- 关联、相关与因果分析
- 挖掘序列、结构（如子图）模式
- 分类：基于判别模式的分析
- 聚类分析：基于模式的子空间聚类

□ 广泛应用

- 购物篮分析、交叉营销、目录设计、促销活动分析、Web 日志分析、生物序列分析
- 多种数据类型：时空、多媒体、时间序列与流数据

基本概念：事务数据库

□ 事务数据库 (TDB)

- 每条事务对应一个标识符，称为 TID。
- 每种售出项也可带有计数

Tid	购买的项
1	Beer, Nuts, Diaper
2	Beer, Coffee, Diaper
3	Beer, Diaper, Eggs
4	Nuts, Eggs, Milk
5	Nuts, Coffee, Diaper, Eggs, Milk

基本概念：k-项集及其支持度

- 项集：一个或多个项组成的集合

$$I = \{I_1, I_2, \dots, I_m\}$$

- k-项集：含 k 个项的项集：

$$X = \{x_1, \dots, x_k\}$$

- 例：{Beer, Nuts, Diaper} 是 3-项集

- 绝对支持度（计数）

- $\text{sup}\{X\}$ = 项集 X 的出现次数

- 例： $\text{sup}\{\text{Beer}\} = 3$
- 例： $\text{sup}\{\text{Diaper}\} = 4$
- 例： $\text{sup}\{\text{Beer}, \text{Diaper}\} = 3$
- 例： $\text{sup}\{\text{Beer}, \text{Eggs}\} = 1$

Tid	购买的项
1	Beer, Nuts, Diaper
2	Beer, Coffee, Diaper
3	Beer, Diaper, Eggs
4	Nuts, Eggs, Milk
5	Nuts, Coffee, Diaper, Eggs, Milk

- 相对支持度

- $s\{X\}$ = 包含 X 的事务比例（即事务包含 X 的概率）
- 例： $s\{\text{Beer}\} = 3/5 = 60\%$
- 例： $s\{\text{Diaper}\} = 4/5 = 80\%$
- 例： $s\{\text{Beer}, \text{Eggs}\} = 1/5 = 20\%$

基本概念：频繁项集（模式）

□ 若项集（或模式） x 的支持度不低于 minsup 阈值 σ ，则 x 是频繁的

□ 设 $\sigma = 50\%$ （ σ ：minsup 阈值）
对于给定的 5 条事务数据集

□ 全部频繁 1-项集：

□ Beer: 3/5 (60%); Nuts: 3/5 (60%);
Diaper: 4/5 (80%); Eggs: 3/5 (60%)

□ 全部频繁 2-项集：

□ {Beer, Diaper}: 3/5 (60%)

□ 全部频繁 3-项集？

□ 无

Tid	购买的项
1	Beer, Nuts, Diaper
2	Beer, Coffee, Diaper
3	Beer, Diaper, Eggs
4	Nuts, Eggs, Milk
5	Nuts, Coffee, Diaper, Eggs, Milk

□ 为何左侧这些项集构成任意 k 的频繁 k -项集（模式）的完全集？

□ 观察：可能需要高效方法来挖掘频繁模式的完全集




从频繁项集到关联规则

□ 与项集相比，关联规则往往更有说明力

□ 例：Diaper $\Rightarrow$ Beer

□ 购买尿布很可能伴随购买啤酒



注：X $\cup$ Y：两个项集的并

■ 该集合同时包含 X 与 Y

关联规则

- ❑ 如何计算 关联规则 $X \rightarrow Y$ 的强度 (X 与 Y 都是 项集) ?→
- ❑ 先计算以下两个度量: s 与 c .
 - ❑ 支持度 $X \cup Y$ 的
 - ❑ 例: $s\{\text{Diaper}, \text{Beer}\} = 3/5 = 0.6$ (即 60%)
 - ❑ 置信度 $X \rightarrow Y$
 - ❑ 包含 X 的事务 也包含 Y 的条件概率:
$$c = \text{sup}(X, Y) / \text{sup}(X)$$
 - ❑ 例: $c = \text{sup}\{\text{Diaper}, \text{Beer}\} / \text{sup}\{\text{Diaper}\} = 3/4 = 0.75$
- ❑ 模式分析中, 我们常关注那些主导 数据库 的规则, 这两个度量保证 X 与 Y 的流行度与 相关性。

Tid	购买的项
1	Beer, Nuts, Diaper
2	Beer, Coffee, Diaper
3	Beer, Diaper, Eggs
4	Nuts, Eggs, Milk
5	Nuts, Coffee, Diaper, Eggs, Milk

挖掘频繁项集与关联规则

关联规则挖掘

- 给定两个阈值：minsup, minconf
- 找出全部规则 $X \Rightarrow Y$ (s, c) 使得 $s \geq \text{minsup}$ 且 $c \geq \text{minconf}$

设 minsup = 50%

- 频繁 1-项集：Beer: 3, Nuts: 3, Diaper: 4, Eggs: 3
- 频繁 2-项集：{Beer, Diaper}: 3

设 minconf = 50%

- $\text{Beer} \Rightarrow \text{Diaper}$ (60%, 100%)
- $\text{Diaper} \Rightarrow \text{Beer}$ (60%, 75%)

(问：满足这两个条件的规则是否都在这里?)

Tid	购买的项
1	Beer, Nuts, Diaper
2	Beer, Coffee, Diaper
3	Beer, Diaper, Eggs
4	Nuts, Eggs, Milk
5	Nuts, Coffee, Diaper, Eggs, Milk

观察：

- 挖掘关联规则与挖掘频繁模式是非常接近的问题
- 大规模数据集的挖掘需要可伸缩方法



挑战：频繁模式太多！

- 长模式包含组合爆炸数量的子模式
- 下列 TDB1 含有多少频繁项集 ($\text{minsup} = 1$) ?

□ TDB₁: $T_1: \{a_1, \dots, a_{50}\}; T_2: \{a_1, \dots, a_{100}\}$

□ 试一试

1-项集 : $\{a_1\}: 2, \{a_2\}: 2, \dots, \{a_{50}\}: 2, \{a_{51}\}: 1, \dots, \{a_{100}\}: 1,$

2-项集 : $\{a_1, a_2\}: 2, \dots, \{a_1, a_{50}\}: 2, \{a_1, a_{51}\}: 1 \dots, \dots, \{a_{99}, a_{100}\}: 1,$

$\dots, \dots, \dots, \dots$

99-项集 : $\{a_1, a_2, \dots, a_{99}\}: 1, \dots, \{a_2, a_3, \dots, a_{100}\}: 1$

100-项集 : $\{a_1, a_2, \dots, a_{100}\}: 1$

- 频繁项集总数 :

$$\binom{100}{1} + \binom{100}{2} + \binom{100}{3} + \dots + \binom{100}{100} = 2^{100} - 1$$

对任何人都过大、难以
计算或存储！



以压缩形式表示模式：闭模式

- 如何应对这一挑战？
- 方案 1：闭模式：模式（项集） X 是闭的，若 X 频繁，且不存在超模式 $Y \supset X$ 与 X 具有相同支持度
 - 设事务库 TDB1: T1: {a1, ..., a50}; T2: {a1, ..., a100}
 - 设 $\text{minsup} = 1$ 。TDB1 含有多少闭模式？
 - 两个： P1: “{a1, ..., a50}: 2”； P2: “{a1, ..., a100}: 1”
- 闭模式是频繁模式的无损压缩
 - 减少模式数量，但不丢失支持度信息！
 - 仍可得出：“{a2, ..., a40}: 2”，“{a5, a51}: 1”

以压缩形式表示模式：极大模式

- ❑ 方案 2：极大模式：模式 X 是极大模式，若 X 频繁且不存在频繁超模式 $Y \supset X$
- ❑ 与闭模式的差别？
 - ❑ 不关心极大模式之子模式的真实支持度
 - ❑ 设事务库 TDB1: T1: {a1, ..., a50}; T2: {a1, ..., a100}
 - ❑ 设 $\text{minsup} = 1$ 。TDB1 含有多少极大模式？
 - ❑ 一个：P: "{a1, ..., a100}: 1"
- ❑ 极大模式是有损压缩！
 - ❑ 只知道 {a1, ..., a40} 是频繁的
 - ❑ 但不再知道 {a1, ..., a40} 等的真实支持度！
- ❑ 因此许多应用中，挖掘闭模式比挖掘极大模式更可取

模式挖掘：基本概念与方法

- 基本概念

- 频繁项集挖掘方法



- 哪些模式有趣？——模式评估方法

- 小结

高效模式挖掘方法

- 频繁模式的向下封闭性
 - Apriori 算法
 - Apriori 的扩展或改进
- 利用垂直数据格式挖掘频繁模式
- FPGrowth：频繁模式增长方法
- 挖掘闭模式

频繁模式的向下封闭性

- 观察：由 TDB1: T1: {a1, ..., a50}; T2: {a1, ..., a100}
 - 得到**频繁项集**：{a1, ..., a50}
 - 并且其所有子集都**频繁**：{a1}, {a2}, ..., {a50}, {a1, a2}, ..., {a1, ..., a49}, ...
 - 频繁模式之间存在**隐含关系**！
- 频繁模式的向下封闭性（也称“Apriori”性质）
 - 若 {beer, diaper, nuts} **频繁**，则 {beer, diaper} 也**频繁**
 - 每条包含 {beer, diaper, nuts} 的**事务**也包含 {beer, diaper}
 - Apriori：频繁项集的任一子集必频繁
- 高效挖掘方法论
 - 若**项集 S** 的任一子集不**频繁**，则 S 不可能**频繁**——何？

Apriori 剪枝与可伸缩挖掘方法

- Apriori 剪枝原理：若某项集不频繁，则不应再生成其超集！
(Agrawal & Srikant @VLDB'94, Mannila, et al. @ KDD' 94)
- 可伸缩挖掘方法： 三大途径
 - 逐层、基于连接： Apriori (Agrawal & Srikant@VLDB'94)
 - 垂直数据格式：Eclat (Zaki, Parthasarathy, Ogiwara, Li @KDD'97)
 - 频繁模式投影与增长：FPgrowth (Han, Pei, Yin @SIGMOD'00)

Apriori：候选生成与测试方法

- Apriori 概要（逐层、候选生成与测试）
 - 扫描一次 DB，得到频繁 1-项集
 - 重复
 - 由长度为 k 的频繁项集生成长度为 $(k+1)$ 的候选项集
 - 对照 DB 测试候选，得到频繁 $(k+1)$ -项集
 - Set $k := k + 1$
 - 直到无法再生成频繁集或候选集
 - 返回所得到的全部频繁项集

Apriori 算法（伪代码）

C_k : 大小为 k 的候选项集

F_k : 大小为 k 的频繁项集

$K := 1$;

$F_k := \{frequent\ items\}$; // 频繁 1-项集

While ($F_k \neq \emptyset$) **do** { // 当 F_k 非空

$C_{k+1} :=$ candidates generated from F_k ; // 候选生成

 Derive F_{k+1} by counting candidates in C_{k+1} with respect to TDB at minsup;

$k := k + 1$

}

return $\bigcup_{k=1}^K F_k$ // 返回每一层生成的 F_k

Apriori 算法——示例

数据库 TDB

Tid	Items
10	A, C, D
20	B, C, E
30	A, B, C, E
40	B, E

minsup = 2

第 1 次扫描

C_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

F_1

Itemset	sup
{A}	2
{B}	3
{C}	3
{E}	3

C_2

Itemset	sup
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

第 2 次扫描

C_2

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

F_2

Itemset	sup
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

C_3

Itemset
{B, C, E}

第 3 次扫描

F_3

Itemset	sup
{B, C, E}	2

Apriori：实现技巧

□ 如何生成候选？

□ 步骤 1：自连接 F_k

□ 步骤 2：剪枝

□ 候选生成示例

□ $F_3 = \{abc, abd, acd, ace, bcd\}$

□ 自连接： $F_3 * F_3$


□ 由 abc 与 abd 得到 $abcd$

□ 由 acd 与 ace 得到 $acde$

□ 剪枝：

□ $acde$ 被删除，因为 ade 不在 F_3 中

□ $C_4 = \{abcd\}$



候选生成（伪代码）

□ 假设 F_{k-1} 中的项按某顺序排列

□ // 步骤 1：连接

for each p in F_{k-1}

for each q in F_{k-1}

if $p.item_1 = q.item_1, \dots, p.item_{k-2} = q.item_{k-2}, p.item_{k-1} < q.item_{k-1}$ {

$c = \text{join}(p, q)$


□ // 步骤 2：剪枝

if $\text{has_infrequent_subset}(c, F_{k-1})$

continue // 剪枝

else add c to C_k

}



Apriori：改进与替代方法

- ❑ 减少事务数据库扫描遍数

后续幻灯片讨论



- ❑ 划分（如 Savasere, et al., 1995）

- ❑ 动态项集计数（Brin, et al., 1997）

- ❑ 缩小候选数量

后续幻灯片讨论



- ❑ 散列（如 DHP: Park, et al., 1995）

- ❑ 用支持度下界剪枝（如 Bayardo 1998）

- ❑ 抽样（如 Toivonen, 1996）

- ❑ 利用特殊数据结构

- ❑ 树投影（Agarwal, et al., 2001）

- ❑ H-miner (Pei, et al., 2001)

- ❑ 超立方体分解（如 LCM: Uno, et al., 2004）

划分法：数据库只扫描两遍

- 定理：任何在 TDB 中潜在**频繁**的项集，必在 TDB 的至少一个划分中**频繁**



- 方法：扫描 DB 两遍（A. Savasere, E. Omiecinski and S. Navathe, VLDB'95）
 - 扫描 1：划分数据库，使每个划分能装入主存（为什么？）
 - 在该划分中挖掘局部**频繁**模式
 - 扫描 2：汇总全局**频繁**模式
 - 找出全局**频繁**项集候选（至少在一个划分中**频繁**者）
 - 再扫描一遍 TDB_i，得到这些候选的**真实**频次

直接散列与剪枝 (DHP)

- 散列： $v = \text{hash}(\text{itemset})$
- 第 1 次扫描：计数 1-项集时，对 2-项集散列以计算桶计数
- 例：TDB 第 1 次扫描时，计数 1-项集，并将事务中的 2-项集散列到对应桶

- ☐ {ab, ad, ce}
- ☐ {bd, be, de}
- ☐ ...

第一次扫描结束时，

- 若 $\text{minsup} = 80$ ，删除 ab, ad, ce ，因为 $\text{count}\{ab, ad, ce\} < 80$

不同项集的 V 可能相同

项集	计数
{ab, ad, ce}	35
{bd, be, de}	298
.....	...
{yz, qs, wt}	58

散列表



检查 minsup

关键观察：若 k-项集对应哈希桶计数低于 minsup 阈值，则该 k-项集不可能频繁

DHP (直接哈希与剪枝) : (J. Park, M. Chen, and P. Yu, SIGMOD'95)

探索垂直数据格式：ECLAT

- ❑ ECLAT（等价类变换）：基于集合交运算的深度优先搜索算法 [Zaki et al. @KDD'97]

- ❑ 垂直格式

- ❑ Tid-Lists 的性质

- ❑ $t(X) = t(Y)$: X 与 Y 总是同时出现（例如 $t(ac) = t(d)$ ）
- ❑ $t(X) \supseteq t(Y)$: 含 X 的事务一定含 Y （例如 $t(ac) \supseteq t(ce)$ ）

- ❑ 频繁模式：垂直交集

- ❑ 用 diffset 加速挖掘

- ❑ 只跟踪 tid 的差集

- ❑ $t(e) = \{T_{10}, T_{20}, T_{30}\}, t(ce) = \{T_{10}, T_{30}\} \rightarrow \text{Diffset}(ce, e) = \{T_{20}\}$

水平数据格式的事务数据库

Tid	Itemset
10	a, c, d, e
20	a, b, e
30	b, c, e

垂直数据格式的事务数据库

$t(e) = \{T_{10}, T_{20}, T_{30}\};$
 $t(a) = \{T_{10}, T_{20}\};$
 $t(ae) = \{T_{10}, T_{20}\}$

项	TidList
a	10, 20
b	20, 30
c	10, 30
d	10
e	10, 20, 30

为何用模式增长挖掘频繁模式？

- Apriori：广度优先搜索挖掘算法
 - 先找出全部频繁 k -项集
 - 再导出频繁 $(k+1)$ -项集候选
 - 再次扫描数据库，找出真正的频繁 $(k+1)$ -项集
- 探索不同挖掘方法的动机
 - 能否设计深度优先搜索挖掘算法？
 - 对频繁项集 ρ ，后续搜索能否仅限于包含 ρ 的事务？
- 由此引出频繁模式增长方法：FPGrowth

FPGrowth (J. Han, J. Pei, Y. Yin, “Mining Frequent Patterns without Candidate Generation,” SIGMOD 2000)

示例：从事务数据库到有序频繁项表

示例：事务数据库样例

TID	事务中的项
100	$\{f, a, c, d, g, i, m, p\}$
200	$\{a, b, c, f, l, m, o\}$
300	$\{b, f, h, j, o, w\}$
400	$\{b, c, k, s, p\}$
500	$\{a, f, c, e, l, p, m, n\}$

设 $\text{min_support} = 3$

❑ 扫描数据库一次，找出单项频繁模式：

$f:4, a:3, c:4, b:3, m:3, p:3$

❑ 按频次降序排列频繁项，得到 f-list

F-list = f-c-a-b-m-p

❑ 再次扫描数据库，用各事务的有序频繁项表构造 FP-tree

TID	事务中的项	有序频繁项表
100	$\{f, a, c, d, g, i, m, p\}$	f, c, a, m, p
200	$\{a, b, c, f, l, m, o\}$	f, c, a, b, m
300	$\{b, f, h, j, o, w\}$	f, b
400	$\{b, c, k, s, p\}$	c, b, p
500	$\{a, f, c, e, l, p, m, n\}$	f, c, a, m, p

示例：由事务数据库构造 FP-tree

TID	有序频繁项表
100	<i>f, c, a, m, p</i>
200	<i>f, c, a, b, m</i>
300	<i>f, b</i>
400	<i>c, b, p</i>
500	<i>f, c, a, m, p</i>

FP-Tree 构造：
对每条事务，将有序频繁项表插入 FP-tree，合并共享分支并累加计数

插入第 1 个频繁项表后：
“f, c, a, m, p”

项	Frqncy	hdr
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	

头表

插入第 2 个频繁项表后
“f, c, a, b, m”

itm	hdr
f	
c	
a	
b	
m	
p	

插入全部频繁项表后

itm	hdr
f	
c	
a	
b	
m	
p	

行分治

□ 模式挖掘可按当前模式划分

□ 含 p 的模式： p 的条件数据库： $fcam:2, cb:1$

□ p 的条件数据库（即在 p 出现条件下的数据库）：


□ 项 p 的变换前缀路径

□ 含 m 但不含 p 的模式： m 的条件数据库： $fca:2, fcab:1$

□

min_support = 3

项	频数	表头
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	



各模式的条件数据库

项	条件数据库
c	$f:3$
a	$fc:3$
b	$fca:1, f:1, c:1$
m	$fca:2, fcab:1$
p	$fcam:2, cb:1$

递归挖掘各条件数据库

min_support = 3

条件数据库

项	条件数据库
c	f:3
a	fc:3
b	fca:1, f:1, c:1
m	fca:2, fcab:1
p	fcam:2, cb:1

□ 对每个条件数据库


□ 挖掘单项模式

□ 构造其 FP-tree 并挖掘

p 的条件数据库: $fcam:2, cb:1 \rightarrow c:3$

m 的条件数据库: $fca:2, fcab:1 \rightarrow$

b 的条件数据库: $fca:1, f:1, c:1 \rightarrow \phi$



接着挖掘 m 的 FP-tree:

fca:3

实际上, 对单分支 FP-tree, 全部频繁模式可一次生成

$m:3$


$fm:3, cm:3, am:3$

$fcm:3, fam:3, cam:3$

$fcam:3$

特例：FP-tree 中的单一前缀路径

- 设（条件）FP-tree T 有一条共享的单一前缀路径 P
- 挖掘可分解为两部分





FPGrowth：用模式增长挖掘频繁模式

- 频繁模式增长（FPGrowth）方法的要点
 - 找出频繁单项，并按各单项模式划分数据库
 - 对每个划分后的数据库（亦称该模式的条件数据库）递归执行上述过程以增长频繁模式
 - 为高效处理，可构造高效数据结构 FP-tree
- 挖掘变为
 - 递归构造并挖掘（条件）FP-tree
 - 直到所得 FP-tree 为空，或只含一条路径——单路径将生成其所有子路径组合，每一组合都是频繁模式

用基于项的数据投影扩展 FP-growth

- 若 FP-tree 无法放入内存？——不构造 FP-tree
 - 按频繁单项“投影”数据库
 - 为每个投影数据库构造并挖掘 FP-tree
- 并行投影 vs. 划分投影
 - 并行投影：按每个频繁项投影数据库
 - 空间开销大，各划分可并行处理
 - 划分投影：按序划分数据库
 - 将未处理部分交给后续划分



模式挖掘：基本概念与方法

- 基本概念
- 频繁项集挖掘方法
- 哪些模式有趣？——模式评估方法
- 小结



如何判断规则/模式是否有趣？

- 模式挖掘会生成大量模式/规则
 - 并非所有生成的模式/规则都有趣
- 趣味性度量：客观 vs. 主观
 - 客观趣味性度量
 - 支持度、置信度、相关性， ...
 - 主观趣味性度量：
 - 不同用户对趣味性的判断可能不同
 - 由用户指定
 - 基于查询：与用户特定请求相关
 - 对照其知识库判断
 - 意外性、新颖性、时效性

支持度-置信度框架的局限

- 关联规则 “A $\Rightarrow$ B” [s, c] 中的 s 与 c 是否有趣？

注意！

- 示例：某学校关于打篮球和/或吃麦片的学生人数统计如下：

	play-basketball	不打篮球	行合计
eat-cereal	400	350	750
不吃麦片	200	50	250
列合计	600	400	1000

二维列联表

- 关联规则挖掘可能得到：

- $play\text{-}basketball \Rightarrow eat\text{-}cereal$ [40%, 66.7%] (更高的 s 与 c)

- 但该强关联规则有误导：吃麦片学生总体比例为 75% > 66.7%，更有说明力的规则是：

- $\neg play\text{-}basketball \Rightarrow eat\text{-}cereal$ [35%, 87.5%] (高 s 与 c)

趣味性度量：Lift

- 度量事件依赖/相关：lift

$$lift(B, C) = \frac{c(B \rightarrow C)}{s(C)} = \frac{s(B \cup C)}{s(B) \times s(C)}$$

- Lift(B, C) 可表明 B 与 C 的相关程度

- Lift(B, C) = 1: B 与 C 独立
- > 1: 正相关
- < 1: 负相关

- 对本例,

$$lift(B, C) = \frac{400/1000}{600/1000 \times 750/1000} = 0.89$$

$$lift(B, \neg C) = \frac{200/1000}{600/1000 \times 250/1000} = 1.33$$

- 因此 B 与 C 负相关, 因为 $lift(B, C) < 1$;

- B 与 $\neg C$ 正相关, 因为 $lift(B, \neg C) > 1$

Lift 比 s 与 c 更有说明力

	B	$\neg B$	Σ_{row}
C	400	350	750
$\neg C$	200	50	250
$\Sigma_{\text{col.}}$	600	400	1000

趣味性度量： χ^2

- 检验相关事件的另一度量： χ^2

$$\chi^2 = \sum \frac{(Observed - Expected)^2}{Expected}$$

- 对右侧表格，

$$\chi^2 = \frac{(400 - 450)^2}{450} + \frac{(350 - 300)^2}{300} + \frac{(200 - 150)^2}{150} + \frac{(50 - 100)^2}{100} = 55.56$$

- 查 χ^2 分布表 $\rightarrow$ B、C 相关
- χ^2 检验表明 B 与 C 负相关：期望值为 450，观测值仅为 400
- 因此 χ^2 也比支持度-置信度框架更有说明力

	B	$\neg B$	Σ_{row}
C	400 (450)	350 (300)	750
$\neg C$	200 (150)	50 (100)	250
Σ_{col}	600	400	1000

期望值

观测值

Lift 与 χ^2 : 它们总是好的度量吗 ?

- 空事务：既不含 B 也不含 C 的事务
- 考察新数据集 D
 - BC (100) 远少于 B $\neg$ C (1000) 与 $\neg$ BC (1000), 但 $\neg$ B $\neg$ C (100000) 很多
 - B 与 C 不太可能同时出现!
- 但 $\text{Lift}(B, C) = 8.44 \gg 1$ (Lift 显示 B 与 C 强正相关!)
- $\chi^2 = 670$: $\text{Observed}(BC) \gg \text{期望值}(11.85)$
- 空事务过多可能“搅浑一锅汤” !

	B	$\neg B$	Σ_{row}
C	100	1000	1100
$\neg C$	1000	100000	101000
$\Sigma_{\text{col.}}$	1100	101000	102100

空事务

附期望值的列联表

	B	$\neg B$	Σ_{row}
C	100 (11.85)	1000	1100
$\neg C$	1000 (988.15)	100000	101000
$\Sigma_{\text{col.}}$	1100	101000	102100

趣味性度量与空不变性

- 空不变性指：空事务数量不影响度量值。
- 若干趣味性度量：有些具有空不变性

Measure	Definition
$\chi^2(A, B)$	$\sum_{i,j} \frac{(e(a_i, b_j) - o(a_i, b_j))^2}{e(a_i, b_j)}$
$Lift(A, B)$	$\frac{s(A \cup B)}{s(A) \times s(B)}$
$Allconf(A, B)$	$\frac{s(A \cup B)}{\max\{s(A), s(B)\}}$
$RuleConf(A, B)$	$\frac{s(A \cap B)}{s(A \cup B)}$

Let

$$p = \frac{s(A \cup B)}{s(A)} = P(B|A)$$

$$q = \frac{s(A \cup B)}{s(B)} = P(A|B)$$

p, q are null invariant

Essentially min, max,
mean variants of p, q

空不变性：一项重要性质

□ 为何空不变性对海量事务数据分析至关重要？

□ 许多事务可能既不含牛奶也不含咖啡！

牛奶 vs. 咖啡列联表

	<i>milk</i>	$\neg milk$	Σ_{row}
<i>coffee</i>	<i>mc</i>	$\neg mc$	<i>c</i>
$\neg coffee$	<i>m</i> $\neg c$	$\neg m$ $\neg c$	$\neg c$
Σ_{col}	<i>m</i>	$\neg m$	Σ

□ Lift 与 χ^2 不具空不变性：不宜评估空事务过多或过少的数据！

□ 许多度量不具空不变性！

空事务
相对 *m* 与 *c*

Data set	<i>mc</i>	$\neg mc$	<i>m</i> $\neg c$	$\neg m$ $\neg c$	χ^2	<i>Lift</i>
<i>D</i> ₁	10,000	1,000	1,000	100,000	90557	9.26
<i>D</i> ₂	10,000	1,000	1,000	100	0	1
<i>D</i> ₃	100	1,000	1,000	100,000	670	8.44
<i>D</i> ₄	1,000	1,000	1,000	100,000	24740	25.75
<i>D</i> ₅	1,000	100	10,000	100,000	8173	9.18
<i>D</i> ₆	1,000	10	100,000	100,000	965	1.97

空不变度量的比较

- 并非所有空不变度量都同等有效
- 哪一个更好？
 - D4—D6 可区分各空不变度量
 - Kulc (Kulczynski 1927) 表现稳健，并对双向蕴涵保持平衡

双变量列联表

	<i>milk</i>	$\neg milk$	Σ_{row}
<i>coffee</i>	<i>mc</i>	$\neg mc$	<i>c</i>
$\neg coffee$	$m\neg c$	$\neg m\neg c$	$\neg c$
Σ_{col}	<i>m</i>	$\neg m$	Σ

5 个度量都具空不变性

Data set	<i>mc</i>	$\neg mc$	$m\neg c$	$\neg m\neg c$	<i>AllConf</i>	Jaccard	<i>Cosine</i>	<i>Kulc</i>	<i>MaxConf</i>
<i>D</i> ₁	10,000	1,000	1,000	100,000	0.91	0.83	0.91	0.91	0.91
<i>D</i> ₂	10,000	1,000	1,000	100	0.91	0.83	0.91	0.91	0.91
<i>D</i> ₃	100	1,000	1,000	100,000	0.09	0.05	0.09	0.09	0.09
<i>D</i> ₄	1,000	1,000	1,000	100,000	0.5	0.33	0.5	0.5	0.5
<i>D</i> ₅	1,000	100	10,000	100,000	0.09	0.09	0.29	0.5	0.91
<i>D</i> ₆	1,000	10	100,000	100,000	0.01	0.01	0.10	0.5	0.99

细微之处：在这些情形上它们不一致

Kulczynski 度量与不平衡比

- IR (不平衡比) : 度量规则蕴涵中项集 A 与 B 的不平衡 :

$$IR(A, B) = \frac{|s(A) - s(B)|}{s(A) + s(B) - s(A \cup B)}$$

- Kulczynski 与不平衡比 (IR) 应用, 可清晰刻画 D4 至 D6 三个数据集
 - D4 中性且平衡 ; D5 中性但不平衡
 - D6 中性但极不平衡

Data set	mc	$\neg mc$	$m\neg c$	$\neg m\neg c$	Jaccard	Cosine	Kulc	IR
D_1	10,000	1,000	1,000	100,000	0.83	0.91	0.91	0
D_2	10,000	1,000	1,000	100	0.83	0.91	0.91	0
D_3	100	1,000	1,000	100,000	0.05	0.09	0.09	0
D_4	1,000	1,000	1,000	100,000	0.33	0.5	0.5	0
D_5	1,000	100	10,000	100,000	0.09	0.29	0.5	0.89
D_6	1,000	10	100,000	100,000	0.01	0.10	0.5	0.99

示例：分析 DBLP 合作者关系

- DBLP：计算机科学研究文献书目数据库

- > 3.8 million 条关于作者、论文、venue、年份等信息

ID	Author A	Author B	$s(A \cup B)$	$s(A)$	$s(B)$	Jaccard	Cosine	Kulc
1	Hans-Peter Kriegel	Martin Ester	28	146	54	0.163 (2)	0.315 (7)	0.355 (9)
2	Michael Carey	Miron Livny	26	104	58	0.191 (1)	0.335 (4)	0.349 (10)
3	Hans-Peter Kriegel	Joerg Sander	24	146	36	0.152 (3)	0.331 (5)	0.416 (8)
4	Christos Faloutsos	Spiros Papadimitriou	20	162	26	0.119 (7)	0.308 (10)	0.446 (7)
5	Hans-Peter Kriegel	Martin Pfeifle	18	146	18	0.123 (6)	0.351 (2)	0.562 (2)
6	Hector Garcia-Molina	Wilburt Labio	16	144	18	0.110 (9)	0.314 (8)	0.500 (4)
7	Divyakant Agrawal	Wang Hsiung	16	120	16	0.133 (5)	0.365 (1)	0.567 (1)
8	Elke Rundensteiner	Murali Mani	16	104	20	0.148 (4)	0.351 (3)	0.477 (6)
9	Divyakant Agrawal	Oliver Po	12	120	12	0.100 (10)	0.316 (6)	0.550 (3)
10	Gerhard Weikum	Martin Theobald	12	106	14	0.111 (8)	0.312 (9)	0.485 (5)

导师-学生关系：Kulc 高, Jaccard 低, cosine 中等

- 哪些作者对关系强？A 是导师还是学生？

- 用 Kulc 发现导师-学生及密切合作者

有效模式估用哪些度量？

- 许多大规模数据集中空值情形占主导
 - 多数购物篮既无牛奶也无咖啡；多数论文作者既非 Mike 也非 Jim；.....
- 空不变性是一项重要性质
- 若空事务不占主导，Lift、 χ^2 与 cosine 是好度量
 - 否则应用 Kulczynski + Imbalance Ratio 来判断模式趣味性
- 练习：从研究文献数据中挖掘科研合作
 - 从研究文献数据（如 DBLP）中找出一组频繁合作者
 - 能否找出可能的导师-学生关系及其发生年份？
 - 文献：C. Wang, J. Han, Y. Jia, J. Tang, D. Zhang, Y. Yu, and J. Guo, "Mining Advisor-Advisee Relationships from Research Publication Networks", KDD'10

模式挖掘：基本概念与方法

- 基本概念
- 频繁项集挖掘方法
- 哪些模式有趣？——模式评估方法
- 小结



小结

- 基本概念
 - 什么是模式发现？为何重要？
 - 基本概念：频繁模式与关联规则
 - 压缩表示：闭模式与极大模式
- 高效模式挖掘方法
 - 频繁模式的向下封闭性
 - Apriori 算法
 - Apriori 的扩展或改进
 - 利用垂直数据格式挖掘频繁模式
 - FPGrowth：频繁模式增长方法
 - 挖掘闭模式
- 模式评估
 - 模式挖掘中的趣味性度量
 - 趣味性度量：Lift 与 χ^2
 - 空不变度量
 - 趣味性度量比较

推荐阅读（基本概念）

- ❑ R. Agrawal, T. Imielinski, and A. Swami, “Mining association rules between sets of items in large databases”, 刊于 SIGMOD'93
- ❑ R. J. Bayardo, “Efficiently mining long patterns from databases”, 刊于 SIGMOD'98
- ❑ N. Pasquier, Y. Bastide, R. Taouil, and L. Lakhal, “Discovering frequent closed itemsets for association rules”, 刊于 ICDT'99
- ❑ J. Han, H. Cheng, D. Xin, and X. Yan, “Frequent Pattern Mining: Current Status and Future Directions”, Data Mining and Knowledge Discovery, 15(1): 55-86, 2007

推荐阅读（高效模式挖掘方法）

- ❑ R. Agrawal and R. Srikant, “Fast algorithms for mining association rules”, VLDB'94
- ❑ A. Savasere, E. Omiecinski, and S. Navathe, “An efficient algorithm for mining association rules in large databases”, VLDB'95
- ❑ J. S. Park, M. S. Chen, and P. S. Yu, “An effective hash-based algorithm for mining association rules”, SIGMOD'95
- ❑ S. Sarawagi, S. Thomas, and R. Agrawal, “Integrating association rule mining with relational database systems: Alternatives and implications”, SIGMOD'98
- ❑ M. J. Zaki, S. Parthasarathy, M. Ogihara, and W. Li, “Parallel algorithm for discovery of association rules”, Data Mining and Knowledge Discovery, 1997
- ❑ J. Han, J. Pei, and Y. Yin, “Mining frequent patterns without candidate generation”, SIGMOD'00
- ❑ M. J. Zaki and Hsiao, “CHARM: An Efficient Algorithm for Closed Itemset Mining”, SDM'02
- ❑ J. Wang, J. Han, and J. Pei, “CLOSET+: Searching for the Best Strategies for Mining Frequent Closed Itemsets”, KDD'03
- ❑ C. C. Aggarwal, M.A., Bhuiyan, M. A. Hasan, “Frequent Pattern Mining Algorithms: A Survey”, in Aggarwal and Han (eds.): Frequent Pattern Mining, Springer, 2014

推荐阅读（模式评估）

- ❑ C. C. Aggarwal and P. S. Yu. A New Framework for Itemset Generation. PODS'98
- ❑ S. Brin, R. Motwani, and C. Silverstein. Beyond market basket: Generalizing association rules to correlations. SIGMOD'97
- ❑ M. Klemettinen, H. Mannila, P. Ronkainen, H. Toivonen, and A. I. Verkamo. Finding interesting rules from large sets of discovered association rules. CIKM'94
- ❑ E. Omiecinski. Alternative Interest Measures for Mining Associations. TKDE'03
- ❑ P.-N. Tan, V. Kumar, and J. Srivastava. Selecting the Right Interestingness Measure for Association Patterns. KDD'02
- ❑ T. Wu, Y. Chen and J. Han, Re-Examination of Interestingness Measures in Pattern Mining: A Unified Framework, Data Mining and Knowledge Discovery, 21(3):371-397, 2010

Q & A



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)