



AIAA 3111 - 数据挖掘导论

第4讲：模式挖掘：高级方法

Dr. Zhidan Liu



香港科技大学(广州)
THE HONG KONG
UNIVERSITY OF SCIENCE AND
TECHNOLOGY (GUANGZHOU)

第3讲回顾：我们挖掘什么

概念	所回答的问题	关键条件
频繁项集	哪些项会同时出现？	支持度 $\geq \text{minsup}$
关联规则	给定 x , y 有多常随之出现？	置信度与提升度
闭模式	扩展后支持度能否保持？	无等支持度超集
最大模式	模式扩展后能否仍频繁？	无频繁超集

支持度衡量普遍程度；置信度是条件性的；提升度将规则与独立性比较。

模式挖掘：高级方法

- 挖掘多层与多维模式
- 基于约束的模式挖掘
- 挖掘序列模式
- 挖掘子图模式
- 小结

第4讲路线图

第1部分：更广泛的模式与约束

- 多层与多维关联
- 稀有模式与负相关模式
- 约束性质与剪枝策略

第2部分：有序模式与结构化模式

- 序列模式与 GSP
- 基于投影数据库的模式增长
- 频繁子图与闭子图挖掘

第3讲聚焦频繁项集；
第4讲扩展模式语言与搜索空间。

为什么需要高级模式挖掘？

基本购物篮假设

- 单一扁平的项空间
- 单一支持度阈值
- 无序事务
- 挖掘全部合格模式

真实数据

- 项属于层次与维度
- 稀有事件可能价值很高
- 顺序与图结构可能重要
- 用户常常指定约束

高级方法改变模式表示、兴趣度度量或搜索策略。

挖掘多层频繁模式

□ 项常常形成层次

- 牛奶: Dairyland 2% 牛奶
- 面包: Wonder 小麦面包

统一支持度

第1层
min_sup = 5%

第2层
min_sup = 5%

牛奶
[支持度 = 10%]

2% 牛奶
[支持度 = 6%]

脱脂牛奶
[支持度 = 2%]

递减支持度

第1层
min_sup = 5%

第2层
min_sup = 1%

□ 遵循概念层次的项的最小支持度阈值

□ 多层统一最小支持度

□ 层次递减最小支持度: 较低层的项预期支持度更低

□ 高效挖掘: 共享多层挖掘

□ 用最低最小支持度向下传递候选集

挖掘多层关联时的冗余过滤

□ 冗余过滤：因“祖先”关系而冗余

- 规则 (1): 牛奶 $\Rightarrow$ 小麦面包 [支持度 = 8%, 置信度 = 70%]

- 规则 (2): 2% 牛奶 $\Rightarrow$ 小麦面包 [支持度 = 2%, 置信度 = 72%]

- 设售出的 2% 牛奶约占按加仑计牛奶销量的 $\frac{1}{4}$

- 规则 (2) 很大程度上可由规则 (1) 及 2% 牛奶的普遍程度解释。

- 一般而言：若某规则的支持度接近按其“祖先”规则得到的“期望”值，且置信度与其“祖先”相近，则该规则冗余

问：若规则 (1) 是规则 (2) 的祖先，应剪掉哪一条？

概念层次间的冗余

祖先信息为更具体的规则提供基线。

1. 祖先规则牛奶 $\Rightarrow$ 小麦面包的支持度为 8%，置信度为 70%。
2. 设 2% 牛奶占全部牛奶销量的四分之一。
3. 2% 牛奶 $\Rightarrow$ 小麦面包的期望支持度约为 $8\% \times 1/4 = 2\%$ 。
4. 观测支持度 2% 与置信度 72% 相对祖先规则几乎不增加信息。

当后裔规则明显偏离从祖先继承的期望时，它才有趣。

为不同种类的项定制最小支持度

- 在每次关联挖掘中，我们对所有待挖掘的项或项集使用同一最小支持度阈值
- 现实中，有些项（如钻石、手表等）价值高但出现较少
- 因此需要为不同种类的项设置定制的最小支持度
- 一种方法：使用基于分组的“个性化”最小支持度
 - 例如，{钻石, 手表}：0.05%；{面包, 牛奶}：5%； ...
 - 如何高效挖掘这类规则？
 - 现有可扩展挖掘算法可以很容易扩展以覆盖这类情形

挖掘多维关联

❑ 单维规则（例如，项都在“商品”维）

❑ $\text{buys}(X, \text{"milk"}) \Rightarrow \text{buys}(X, \text{"bread"})$

❑ 多维规则（即项位于 ≥ 2 个维或谓词中）

❑ 维间关联规则（谓词不重复）

❑ $\text{age}(X, \text{"18-25"}) \wedge \text{occupation}(X, \text{"student"}) \Rightarrow \text{buys}(X, \text{"coke"})$

❑ 混合维关联规则（谓词可重复）

❑ $\text{age}(X, \text{"18-25"}) \wedge \text{buys}(X, \text{"popcorn"}) \Rightarrow \text{buys}(X, \text{"coke"})$

❑ 属性可为类别型或数值型

❑ 类别属性（如职业、商品：取值之间无序）：用数据立方体做维间关联

❑ 数值属性：数值型，取值间有隐式顺序——离散化、聚类与梯度方法

关联规则的三种形式

规则类型	谓词	示例
单维	一个重复的维	$\text{buys}(\text{milk}) \Rightarrow \text{buys}(\text{bread})$
维间	无重复谓词	$\text{age}(18-25) \wedge \text{student} \Rightarrow \text{buys}(\text{coke})$
混合维	至少一个重复谓词	$\text{age}(18-25) \wedge \text{buys}(\text{popcorn}) \Rightarrow \text{buys}(\text{coke})$

- 维间规则：每个谓词至多出现一次
- 混合维规则：至少一个谓词出现多于一次

稀有模式与负模式

❑ 稀有模式

- ❑ 支持度极低但有趣（例如购买劳力士手表）
- ❑ 如何挖掘？为不同组项设置个性化、基于分组的最小支持度阈值

❑ 负模式

- ❑ 负相关：不太可能同时发生
- ❑ 例：同一顾客不太可能既买 Ford Expedition（一款 SUV）又买 Ford Fusion（一款混合动力车），因此购买二者很可能是负相关模式
- ❑ 如何定义负模式？

定义负相关模式

□ 基于支持度的定义

□ 若项集 A 与 B 都频繁，但很少同时出现，即

□ $\text{sup}(A \cup B) \ll \text{sup}(A) \times \text{sup}(B)$

□ 则 A 与 B 负相关

这是否让你想起提升度的定义？

□ 这对大型事务数据集是好定义吗？

□ 例：设商店两种针线包 A 与 B 各售出 100 次，但只有一笔事务同时包含 A 与 B

□ 当事务总数为 200 时，有

□ $s(A \cup B) = 0.005, s(A) \times s(B) = 0.25, s(A \cup B) \ll s(A) \times s(B)$

□ 加入 19,800 笔零事务后 ($N = 20,000$)：

□ $s(A \cup B) = 0.00005, s(A) \times s(B) = 0.000025$ ，于是结论反转

□ 这里的问题是什么？

零事务会改变结果：该定义不是零事务不变的

定义负相关：定义中需要零事务不变性

- 有用的负相关度量应当是零事务不变的
 - 直觉：两个项集 A 与 B 是否负相关，不应受零事务数量的影响
- 基于 Kulczynski 度量的定义
 - 若项集 A 与 B 频繁，但 $(s(A \cup B)/s(A) + s(A \cup B)/s(B))/2 < \epsilon$ ，
则 A 与 B 负相关
- 对同一针线包问题：
 - 该值在 $N = 200$ 与 $N = 20,000$ 时不变
 - 若 $\epsilon = 0.02$ ，则有
$$\text{Kulc}(A,B) = (0.01 + 0.01)/2 = 0.01 < \epsilon$$



ϵ 是负
模式阈值

快速检查：哪种度量是零事务不变的？

问题：加入 10,000 笔既不含 A 也不含 B 的事务。哪种度量保持不变？

A. 相对支持度(A)	B. 提升度(A,B)
C. Kulc(A,B)	D. 相对支持度(AUB)

答案：C. Kulc(A,B)

为何进行基于约束的挖掘？

- 实践中的模式挖掘：常常是用户引导的交互过程
 - 用户用数据挖掘查询语言（或图形界面）指定挖掘内容，并给出各类约束
- 基于约束的挖掘：连同用户给出的约束一起挖掘
- 为何要基于约束挖掘？
 - 用户灵活性：用户对挖掘内容给出约束
 - 优化：系统利用这些约束提高挖掘效率
 - 例如，将约束深入推进到挖掘过程中

基于约束的挖掘流程

同一约束既可以指导结果，也可以指导搜索。

1. 用户指定目标数据、模式形式和兴趣度条件。
2. 系统将查询转换为对模式和数据的约束。
3. 挖掘算法把可安全使用的约束推进到候选生成或投影中。
4. 系统检验剩余候选，只返回合格模式。

只有系统能在最终输出之前实施约束，该约束才能提高效率。

模式挖掘中的用户约束

约束类型	示例	控制
数据	今年的纽约门店	哪些记录进入挖掘
维 / 层	品牌与顾客类别	哪些属性出现
兴趣度	支持度 ≥ 0.02	哪些模式合格
模式形式	包含牛奶; 长度 ≤ 4	模式必须呈现的形式

本讲聚焦模式约束，因为其数学性质可用于剪枝。

用模式反单调性剪枝模式空间

TID	事务
10	a, b, c, d, f, h
20	b, c, d, f, g, h
30	b, c, d, f, g
40	a, c, e, f, g

min_sup = 2

项	价格	利润
a	100	40
b	40	0
c	150	-20
d	35	-15
e	55	-30
f	45	-10
g	80	20
h	10	5

- 约束 c 是反单调的

- 若项集 S 违反约束 c , 则其任意超集也违反
- 因此, 对项集 S 的挖掘可以终止

- 例 1: $c1: \text{sum}(S.\text{price}) \leq v$ 是反单调的

- 例 2: $c2: \text{range}(S.\text{profit}) \leq 15$ 是反单调的

- 项集 ab 违反 $c2$ ($\text{range}(ab) = 40$)

- ab 的每个超集也都违反

$$\text{range}(S.\text{profit}) = \max(S.\text{profit}) - \min(S.\text{profit})$$

- 例 3. $c3: \text{sum}(S.\text{Price}) \geq v$ 不是反单调的

- 例 4. $c4: \text{support}(S) \geq \sigma$ 是反单调的吗?

- 是! Apriori 剪枝本质上就是用反单调约束进行剪枝!

注: $\text{item.price} > 0$
利润可以为负

面向模式反单调约束的 Apriori

项	价格
1	1
2	2
3	3
4	4
5	5

Min_sup=2

约束:

$\text{Sum}\{S.\text{price}\} < 5$

数据库 D

TID	Items
10	1 3 4
20	2 3 5
30	1 2 3 5
40	2 5

扫描 D

C1

itemset	sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

F1

itemset	sup.
{1}	2
{2}	3
{3}	3
{5}	3

可提前剪枝

C2

itemset	sup
{1 2}	1
{1 3}	2
{1 5}	1
{2 3}	2
{2 5}	3
{3 5}	2

扫描 D

C2

itemset
{1 2}
{1 3}
{1 5}
{2 3}
{2 5}
{3 5}

F2

itemset	sup
{1 3}	2
{2 3}	2
{2 5}	3
{3 5}	2



C3

itemset
{2 3 5}

扫描 D

F3

itemset	sup
{2 3 5}	2

快速检查：是否反单调？

问题：假设所有价格为正。哪个约束是反单调的？

A. $\text{sum}(\text{price}) \geq 100$	B. $\text{average}(\text{profit}) \geq 20$
C. $\text{sum}(\text{price}) \leq 100$	D. $\text{length} \geq 3$

答案：C. $\text{sum}(\text{price}) \leq 100$

模式单调性及其作用

TID	事务
10	a, b, c, d, f, h
20	b, c, d, f, g, h
30	b, c, d, f, g
40	a, c, e, f, g

min_sup = 2

项	价格	利润
a	100	40
b	40	0
c	150	-20
d	35	-15
e	55	-30
f	45	-10
g	80	20
h	10	5

- 约束 c 为单调：若项集 S 满足约束 c ，则其任一超集也满足
 - 即后续挖掘中无需再检查 c
 - 收益不如反单调
- 例 1: $c1: \text{sum}(S.\text{Price}) \geq v$ 为单调
- 例 2: $c2: \text{min}(S.\text{Price}) \leq v$ 为单调
- 例 3: $c3: \text{range}(S.\text{profit}) \geq 15$ 为单调
 - 项集 ab 满足 $c3$
 - ab 的每个超集也满足

单调约束与反单调约束

性质	反单调	单调
继承	不满足传递给超集	满足传递给超集
搜索用途	失败后剪枝	满足后停止复查
价格为正	$\text{sum}(\text{price}) \leq v$	$\text{sum}(\text{price}) \geq v$
支持度	$\text{support} \geq \sigma$	$\text{support} \leq \sigma$

反单调约束通常在前缀增长搜索中提供更强早期剪枝。

可转换约束:对事务中的数据排序

TID	事务
10	a, b, c, d, f, h
20	a, b, c, d, f, g, h
30	b, c, d, f, g
40	a, c, e, f, g

min_sup = 2

项	价格	利润
a	100	40
b	40	0
c	150	-20
d	35	-15
e	55	-30
f	45	-5
g	80	30
h	10	5

- 通过对事务中的项适当排序, 将困难约束转换为(反)单调
- 考察 $c1: \text{avg}(S.\text{profit}) > 20$
 - 按 (profit) 值降序排列各项
 - $\langle a, g, h, b, f, d, c, e \rangle$
 - 项集 ab 违反 $c1$ ($\text{avg}(ab) = 20$)
 - ab^* (即 ab 投影数据库) 同样违反
 - 因此 $c1$ 并非全局反单调, 但在利润降序下为可转换反单调。

可转换约束依赖于增长顺序

- 平均利润在任意集合扩展下既非单调也非反单调
- 按利润降序排列各项，且只增长遵守顺序的前缀
- 当前缀平均值低于阈值后，后续更低利润的项无法将其恢复
- 此剪枝对前缀增长有效，但对任意 Apriori 子集生成无效

排序规则是证明的一部分。没有它，剪枝判定就不安全。

项重排序对 Apriori 有效吗?

TID	事务
10	a, b, c, d, f, h
20	a, b, c, d, f, g, h
30	b, c, d, f, g
40	a, c, e, f, g

Min_sup=2; 约束: $\text{avg}(\text{S.profit}) > 20$

扫描 D

F1

itemset	sup.
{a}	3
{f}	4
{g}	3
{d}	3
...	...

F2

itemset	sup.
{af}	3
{fg}	3
{ag}	2
{ad}	2
...	...

利润降序:
<a, g, h, b, f, d, c, e>

剪枝过早

项	价格	利润
a	100	40
b	40	0
c	150	-20
d	35	-15
e	55	-30
f	45	-5
g	80	30
h	10	5

- $\text{avg}(gf) = 12.5 < 20$, $\text{avg}(af) = 17.5 < 20$, $\text{avg}(ag) = 35 > 20$
- 但 $\text{avg}(agf) = 21.7 > 20$
- Apriori 不会将 "agf" 生成为候选

重排序使前缀剪枝安全, 但不能使 Apriori 的全子集剪枝安全。

基于数据反单调性的数据空间剪枝

TID	事务
10	a, b, c, d, f, h
20	b, c, d, f, g, h
30	b, c, d, f, g
40	a, c, e, f, g

min_sup = 2

项	价格	利润
a	100	40
b	40	0
c	150	-20
d	35	-15
e	55	-30
f	45	-10
g	80	20
h	10	5

- 约束 c 为数据反单调：在挖掘过程中，若数据条目 t 在 c 下不能满足模式 p ，则 t 也不能满足 p 的超集
 - 数据空间剪枝：可剪去数据条目 t
- 例 1： $c1: \text{sum}(S.\text{Profit}) \geq v$ 为数据反单调
 - 设约束 $c1$ 为： $\text{sum}(S.\text{Profit}) \geq 25$
 - T30: {b, c, d, f, g} 可删除，因其任意组合都无法构成利润之和 ≥ 25 的 S
- 例 2： $c2: \text{min}(S.\text{Price}) \leq v$ 为数据反单调
 - 考虑 $v = 5$ ，但某事务（如 T50）中每一项的价格都高于 10
- 例 3： $c3: \text{range}(S.\text{Profit}) > 25$ 为数据反单调

数据空间剪枝应递归探索

TID	事务	项	利润
10	a, b, c, d, f, h	a	40
20	b, c, d, f, g, h	b	0
30	b, c, d, f, g	c	-20
40	a, c, e, f, g	d	-15
min_sup = 2		e	-30
		f	-10
		g	20
		h	5

- 例. $c3: \text{range}(S.\text{Profit}) > 25$
 - 检查 b 的投影数据库
 - 但项 "a" 不频繁 ($\text{sup} = 1$)

- 从 T10 中去掉 "a (40)" 之后
 - T10 不再能满足 c3
 - 因为 "b (0)" 以及 "c (-20), d (-15), f (-10), h (5)"
 - 去掉 T10 后, 也可剪去 T20 中的 "h"

b 的投影数据库



TID	事务
10	a, c, d, f, h
20	c, d, f, g, h
30	c, d, f, g

b 的投影数据库

TID	事务
10	a, c, d, f, h
20	c, d, f, g, h
30	c, d, f, g

递归探索数据空间剪枝（续）

约束：
 $\text{range}\{S.\text{profit}\} > 25$

b 的投影数据库

事务	
10	a , c, d, f, h
20	c, d, f, g, h
30	c, d, f, g

递归
数据
剪枝

b 的 FP-tree

单分支: cdfg: 2

b 的投影数据库中只需挖掘单分支 "cdfg: 2"

- 注：仅当在 b 的投影数据库中按 min-sup 剪去 "a" 后，c3 才能有效剪去 T10

模式空间与数据空间剪枝

问题	模式空间剪枝	数据空间剪枝
去掉什么?	候选模式或分支	事务或投影记录
典型原因	任何扩展都无法满足 c	该记录无法支持满足约束的扩展
示例	支持度低于 minsup	可达最大利润低于 v
收益	候选更少	支持度计数代价更低

强挖掘策略通常同时缩小两个空间，但每一步剪枝都需要各自的安全性论证。

简洁性：同时剪枝数据空间与模式空间

- **简洁性：若约束 c 可通过直接操作数据来强制执行**
- 例 1：寻找包含项 i 的模式
 - 只挖掘 i 投影数据库（数据空间剪枝）
- 例 2：寻找不含项 i 的模式
 - 从数据库中删除 i 后再挖掘（模式空间剪枝）
- 例 3： $c3: \min(S.Price) \leq v$ 是简洁的
 - 从合格的低价项出发，挖掘其投影数据库；高价项仍可加入
- 例 4： $c4: \sum(S.Price) \geq v$ 不是简洁的
 - 无法事先确定，因为项集 S 的价格之和持续增大

简洁约束

可在挖掘前强制执行

- 包含项 i
- 排除项 i
- $\min(\text{price}) \leq v$, 使用合格锚点与投影数据

无法事先判定

- $\text{sum}(\text{price}) \geq v$
- 无有效排序时 $\text{average}(\text{profit}) \geq v$
- 计数出现次数之前 $\text{support} \geq \sigma$

简洁性问的是：直接操作数据能否精确强制该约束。

带约束的 FP-Growth: 将简洁约束深入下推

项	价格
1	1
2	2
3	3
4	4
5	5

TID	Items
10	1 3 4
20	2 3 5
30	1 2 3 5
40	2 5

删除
不频繁
长度 1

TID	Items
10	1 3
20	2 3 5
30	1 2 3 5
40	2 5

Min_sup=2

约束: $\min\{S.price\} \leq 2$

无需对 3 或 5 投影

1-投影数据库

TID	Items
10	3
30	2 3 5

2-投影数据库

TID	项
20	3 5
30	1 3 5
40	5

不同种类的约束对应不同的剪枝策略

- 总之, 约束可分为模式空间剪枝约束与数据空间剪枝约束

模式空间剪枝约束	数据空间剪枝约束
■ 反单调: 若违反约束 c, 可终止其后续挖掘 ■ 单调: 若已满足 c, 无需再次检查 c ■ 可转换: 若处理中能对项适当排序, 则 c 可转换为单调或反单调 ■ 简洁: 若约束 c 可通过直接操作数据来强制执行	■ 数据简洁: 可在模式挖掘初始阶段剪枝数据空间 ■ 数据反单调: 若事务 t 不满足 c, 则可剪去 t 以减少数据处理开销

如何处理多个约束？

- 在模式挖掘中使用多个约束是有益的
- 但不同约束可能要求相互冲突的项排序
 - 若 c_1 与 c_2 的排序存在冲突
 - 尝试先排序数据并强制执行其中一个约束(选哪一个?)
 - 再在挖掘投影数据库时强制执行另一约束
- 例: $c_1: \text{avg}(S.\text{profit}) > 20$, 以及 $c_2: \text{avg}(S.\text{price}) < 50$
 - 假设 c_1 的剪枝能力更强
 - 按利润降序排序并先使用 c_1
 - 对每个投影数据库, 按价格升序排列各项, 并在挖掘中强制执行 c_2

处理多个约束

- 估计哪个约束能去除搜索空间的最大部分
- 尽早应用简洁或强反单调约束
- 保持可转换约束所要求的项排序
- 仅当后续剪枝证明仍然成立时，才在投影数据库内重排
- 输出前验证全部约束，即使其中一些已用于早期剪枝

最佳实施顺序取决于剪枝能力、计算代价与排序兼容性。

第1部分综合： 我们可以剪枝什么？

情形	安全操作	原因
模式不满足反单调 c	停止扩展该分支	所有超集均不满足
模式满足单调 c	停止在超集上检查 c	所有超集均满足
约束是简洁的	先过滤或投影数据	直接实施是精确的
记录无法满足任何扩展	删除该记录	数据反单调性

第2部分将模式表示从无序集合改为序列和图。

附录

第1部分备用幻灯片

第3讲回顾：Apriori

阶段	操作	原因
1. 连接	由 F_{k-1} 中的相容对生成 C_k	只有频繁 $(k-1)$ -项集才能参与
2. 剪枝	若任一 $(k-1)$ -子集不在 F_{k-1} 中，则删除该候选	不频繁子集使每个超集都不频繁
3. 计数	扫描事务数据库，为幸存候选计数	支持度必须在数据上度量
4. 选择	当 $\text{support}(X) \geq \text{minsup}$ 时保留 X ，以形成 F_k	重复直到 F_k 为空

Apriori 交替进行候选生成与数据库扫描；向下闭包提供剪枝保证。

第3讲回顾：Apriori 的优化与替代方法

方法	变化之处	效率思路
DHP	Apriori 候选过滤	对 k-项集哈希并剪掉低计数桶；缩减事务
Partition	Apriori 数据库访问	挖掘局部频繁集，再在第二次扫描中验证其并集
ECLAT	垂直 TID 列表表示	在深度优先搜索中对 TID 集合求交
FP-growth	压缩前缀树表示	挖掘条件模式基，无需显式候选

DHP 与 Partition 优化 Apriori；ECLAT 与 FP-growth 重组数据与搜索。

第1部分学习目标

更广的模式空间需要对所挖掘内容有更强控制。

- 为层次化与异质项选择支持度阈值
- 区分稀有模式与负相关模式
- 将约束分为反单调、单调、可转换或简洁
- 判断约束能剪枝模式、数据，还是两者

统一支持度与逐层降低支持度

策略	示例	优点	风险
统一 minsup	每层均为 5%	简单且可比	漏掉具体的低层项
逐层降低的 minsup	乳制品 5%; 牛奶种类 1%	发现更细的模式	产生更多候选

低层项分摊父项支持度，因此往往需要更低的阈值。

稀有模式与负模式

性质	稀有模式	负模式
主要问题	该模式是否很少出现？	A 与 B 的共现是否少于预期？
所需边际	非核心	A 与 B 各自都应出现得足够频繁
典型度量	带自定义阈值的支持度	一种零事务不变的相关度量
示例	Rolex 购买	两种替代商品

仅凭较低的联合支持度，无法区分稀有与负关联。

数据挖掘中各类用户指定约束

- 知识类型约束 — 指定要挖掘的知识类型
 - 例如：分类、关联、聚类、离群点发现.....
- 数据约束 — 使用类 SQL 查询
 - 例如：找出今年纽约商店中一起售出的商品
- 维度/层次约束 — 类似于关系数据库中的投影
 - 例如：与地区、价格、品牌、顾客类别相关
- 兴趣度约束 — 各类阈值
 - 例如：强规则： $\text{min_sup} \geq 0.02$, $\text{min_conf} \geq 0.6$, $\text{min_correlation} \geq 0.7$
- 规则（或模式）约束  本研究的重点
 - 例如：小额销售 ($\text{price} < \$10$) 引发大额销售 ($\text{sum} > \200)

Kulczynski 度量是零事务不变的

Kulc 对两个条件共现概率取平均。

1. 使用 $\text{count}(A)=100$ 、 $\text{count}(B)=100$ 与 $\text{count}(A \cup B)=1$ 。
2. $P(B|A)=1/100=0.01$ ，且 $P(A|B)=1/100=0.01$ 。
3. $\text{Kulc}(A,B)=[P(B|A)+P(A|B)]/2=(0.01+0.01)/2=0.01$ 。
4. 加入零事务会改变 N ，但不改变这些条件概率。

当负相关阈值 $\varepsilon = 0.02$ 时， $\text{Kulc} = 0.01$ 表示负关联。

约束性质及其用途

性质	安全推断	主要用途
反单调	失败在扩展下持续	剪枝模式分支
单调	满足在扩展下持续	停止重复检查
可转换	排序产生上述性质之一	实现前缀剪枝
简洁	直接选择即可实施该约束	缩小初始搜索空间
数据反单调	记录无法支持后续扩展	剪枝投影数据

一个约束可能具有不止一种有用性质。

三个约束的实例策略

约束顺序是算法设计决策，而不仅是查询语言细节。

1. 要求：支持度 ≥ 2 。全程保持 Apriori 或 FP-growth 的支持度剪枝。
2. 要求： $\min(\text{price}) \leq 50$ 。从符合条件的低价锚点与投影数据库出发。
3. 要求： $\text{average}(\text{profit}) > 20$ 。在可行时采用经验证的利润降序增长顺序。
4. 输出前对幸存模式计数，并对照全部三个约束加以验证。

先实施低代价、安全且剪枝力强的约束；推迟无法安全剪枝的高代价检查。

第1部分检查

问题：某模式违反反单调约束。挖掘算法可以安全地做什么？

A. 保留所有超集	B. 剪枝每个超集
C. 声明其为最大模式	D. 降低 minsup

答案：B. 剪枝每个超集

第2部分：序列模式与图模式

先顺序，后结构

模式挖掘：高级方法

- 挖掘多层与多维模式
- 基于约束的模式挖掘
- 挖掘序列模式
- 挖掘子图模式
- 小结

序列模式挖掘

- 什么样的模式是序列的？
- 序列：顺序真正重要
 - 不能交换序列中的两项却仍得到同一序列
- 例：英语是序列的：主语 → 动词 → 宾语

- 其他要点：
 - 序列模式使用事件顺序；精确时间戳与时间间隔是可选约束
 - 时间序列分析对按时间索引的测量建模，并常使用实际间隔

项集与序列问的问题不同

表示	等价?	示例问题
项集 {A,B}	$\{A,B\} = \{B,A\}$	哪些项一起出现?
序列 $\langle A,B \rangle$	$\langle A,B \rangle \neq \langle B,A \rangle$	哪个事件倾向于先发生?
事件集 $\langle\langle A\ B \rangle\rangle$	A 与 B 同属一个事件	哪些项出现在同一步?

序列模式挖掘保留事件之间的顺序，但不保留单个事件集内部的顺序。

序列模式示例

□ 序列模式挖掘的应用

- 顾客购物：先买笔记本电脑，再买数码相机，然后买智能手机
- 医疗过程：看医生、取药、医生监测进展、医生据此应对 → 加药/减药
- 自然灾害：灾前、灾中、灾后
- 科学实验：步骤 1、步骤 2、步骤 3
- 市场事件：上涨、回调与复苏可能形成反复出现的有序模式
- 生物序列：改变核苷酸或氨基酸顺序会改变所得序列及其功能

阅读序列记号


括号将同一事件中观察到的项归为一组。

1. 从左到右将 $\langle a \ (bc) \ d \rangle$ 读作三个有序元素。
2. 第一个元素包含项 a 。
3. 第二个元素同时包含 b 和 c ；其内部顺序无关。
4. 第三个元素包含 d 。

序列长度通常计项数，序列大小计元素数；应说明算法采用哪种约定。

序列模式与序列模式挖掘

- 序列模式挖掘：给定一组序列，找出全部频繁子序列（即满足 min_sup 阈值）



- 一个元素可以包含一组项（也称为事件）
* 元素内的项无序，并按字母顺序列出

一个序列数据库

SID	序列
10	<a(abc)(ac)d(cf)>
20	<(ad)c(bc)(ae)>
30	<(ef)(ab)(df)cb>
40	<eg(af)cbc>

子序列如何匹配


匹配使用有序包含，而不是字符串相等。

1. 目标模式： $\langle a (bc) d c \rangle$ 。
2. 数据库序列： $\langle a (abc) (ac) d (cf) \rangle$ 。
3. 将 a 匹配到第一个元素，将 (bc) 匹配到第二个元素，因为 $\{b,c\} \subseteq \{a,b,c\}$ 。
4. 将 d 匹配到第四个元素，将 c 匹配到第五个元素；未使用的元素可以跳过。

子序列保持顺序，但不要求元素相邻，也不要求元素完全相等。

序列模式与序列模式挖掘

- 序列模式挖掘：给定一组序列，找出全部频繁子序列（即满足 min_sup 阈值）

 **<a(bc)dc> 是 <a(abc)(ac)d(cf)> 的子序列**

- 给定支持度阈值 min_sup = 2,
 <(ab)c> 是序列模式

一个序列数据库

SID	序列
10	<a(abc)(ac)d(cf)>
20	<(ad)c(bc)(ae)>
30	<(ef)(ab)(df)cb>
40	<eg(af)cbc>

序列模式的支持度

- 当 s 是某序列的子序列时，该序列支持模式 s
- 每个序列 ID 至多计入一次支持计数，即使 s 出现多次
- $\text{支持计数}(s) = \text{包含 } s \text{ 的序列 ID 数}$
- $\text{相对支持度}(s) = \text{支持计数}(s) / \text{序列数}$

频数统计的是支持该模式的序列数，而不是序列内部的嵌入次数。

序列模式挖掘算法

- ❑ 算法要求：高效、可扩展、找出完整集合、纳入各类用户特定约束
- ❑ Apriori 性质仍然成立：若子序列 s_1 不频繁，则 s_1 的任何超序列都不可能频繁
- ❑ 代表性算法
 - ❑ GSP (Generalized Sequential Patterns): Srikant & Agrawal, EDBT '96

GSP: 逐层序列挖掘

Apriori 性质对子序列同样成立。

1. 找出频繁的长度 1 序列。
2. 连接相容的频繁长度 k 序列，生成长度 $(k+1)$ 候选。
3. 剪掉其必要子序列不频繁的候选。
4. 扫描序列数据库，统计支持度并保留频繁候选。
5. 重复，直到没有候选为止。

GSP 把 Apriori 剪枝从项集推广到有序子序列，但仍需反复生成候选并扫描。

GSP: 基于 Apriori 的序列模式挖掘

- 初始候选：全部 8 个单元元素序列
 - $\langle a \rangle, \langle b \rangle, \langle c \rangle, \langle d \rangle, \langle e \rangle, \langle f \rangle, \langle g \rangle, \langle h \rangle$
- 扫描数据库一次，统计每个候选的支持度

SID	序列
10	$\langle (bd)cb(ac) \rangle$
20	$\langle (bf)(ce)b(fg) \rangle$
30	$\langle (ah)(bf)abf \rangle$
40	$\langle (be)(ce)d \rangle$
50	$\langle a(bd)bcb(ade) \rangle$

$min_sup = 2$

候选	支持度
$\langle a \rangle$	3
$\langle b \rangle$	5
$\langle c \rangle$	4
$\langle d \rangle$	3
$\langle e \rangle$	3
$\langle f \rangle$	2
$\langle g \rangle$	1
$\langle h \rangle$	1



GSP (Generalized Sequential Patterns): Srikant & Agrawal @ EDBT'96)

三类长度 2 候选

候选形式	含义	m 个频繁项时的数量
$\langle a\ b \rangle$	a 出现在 b 之前	m^2 , 包括重复项
$\langle b\ a \rangle$	b 出现在 a 之前	已包含在 m^2 中
$\langle (a\ b) \rangle$	a 与 b 同时出现	$m(m-1)/2$

当 $m=6$ 时, GSP 生成 $6^2 + 6 \times 5 / 2 = 51$ 个长度 2 候选。

GSP: 基于 Apriori 的序列模式挖掘

□ 示例：生成长度 2 候选序列

单项 × 单项 – 合计: $(6 * 6)$

	<a>		<c>	<d>	<e>	<f>
<a>	<aa>	<ab>	<ac>	<ad>	<ae>	<af>
	<ba>	<bb>	<bc>	<bd>	<be>	<bf>
<c>	<ca>	<cb>	<cc>	<cd>	<ce>	<cf>
<d>	<da>	<db>	<dc>	<dd>	<de>	<df>
<e>	<ea>	<eb>	<ec>	<ed>	<ee>	<ef>
<f>	<fa>	<fb>	<fc>	<fd>	<fe>	<ff>

$min_sup = 2$

候选	支持度
<a>	3
	5
<c>	4
<d>	3
<e>	3
<f>	2
<g>	1
<h>	1



集合 (无序) – 合计: $(6 * 5) / 2$

	<a>		<c>	<d>	<e>	<f>
<a>		<(ab)>	<(ac)>	<(ad)>	<(ae)>	<(af)>
			<(bc)>	<(bd)>	<(be)>	<(bf)>
<c>				<(cd)>	<(ce)>	<(cf)>
<d>					<(de)>	<(df)>
<e>						<(ef)>
<f>						

Apriori 剪枝

□ 无剪枝 (含 g 和 h)

$$8 * 8 + 8 * 7 / 2 = 92$$

长度为 2 的候选

□ 有剪枝:

$$6 * 6 + 6 * 5 / 2 = 51$$

长度为 2 的候选

GSP 挖掘与剪枝

5扫: 1候选, 1个长5模式

4扫: 8候选, 7个长4模式

3扫: 46候选, 20个长3, 20不在库

2扫: 51候选, 19个长2, 10不在库

1扫: 8候选, 6个长1模式

<(bd)cba>

<abba> <(bd)bc> ...

<abb> <aab> <aba> <baa> <bab> ...

<aa> <ab> ... <af> <ba> <bb> ... <ff> <(ab)> ... <(ef)>

<a> <c> <d> <e> <f> <g> <h>

去掉不在库或支持度 < min_sup 的候选

长度

5

4

3

2

1

$6 * 6 + 6 * 5 / 2 = 51$

GSP 算法

从 k = 1 开始重复, 直到 k <= length

扫描数据库, 找出“长度为 k”的频繁序列

用 Apriori 从“长度为 k”的频繁序列生成“长度为 (k+1)”的候选序列

令 k = k+1

直到找不到频繁序列或候选

min_sup = 2

SID	序列
10	<(bd)cb(ac)>
20	<(bf)(ce)b(fg)>
30	<(ah)(bf)abf>
40	<(be)(ce)d>
50	<a(bd)bcb(ade)>

GSP 为何代价变高

计算

- 每个序列长度扫描一次数据库
- 早期层次候选集很大
- 计数时子序列匹配代价高

搜索浪费

- 许多候选在数据库中从未出现
- 长模式产生大量重叠候选
- 稀疏序列几乎无法复用候选

模式增长方法在投影数据库内工作，从而避免生成全局候选。

PrefixSpan: 按前缀增长模式

- 选择一个频繁前缀，例如 ⟨a⟩
- 构建前缀投影数据库，只保留该前缀出现之后的后缀
- 在该较小数据库中统计局部频繁的扩展项
- 扩展该前缀并递归，而不生成全局候选集

投影把一个大搜索问题转化为若干更小的条件问题。

一个简单的前缀投影数据库

SID	原始序列	前缀 $\langle a \rangle$ 之后的后缀
S1	$\langle a \ b \ c \rangle$	$\langle b \ c \rangle$
S2	$\langle a \ c \ b \rangle$	$\langle c \ b \rangle$
S3	$\langle b \ a \ c \rangle$	$\langle c \rangle$

在 $\langle a \rangle$ 投影数据库中， b 出现在两个后缀中， c 出现在三个后缀中。

PrefixSpan 中的前缀增长

每次递归调用只挖掘与其前缀相容的序列。

1. 从前缀 $\langle a \rangle$ 及其投影数据库开始。
2. 若 minsup 计数为 2，则 b 和 c 均可作为扩展。
3. 生成 $\langle a b \rangle$ 与 $\langle a c \rangle$ ，并为每个前缀构建新的投影数据库。
4. 继续，直到不再有局部频繁扩展。

PrefixSpan 仍依赖支持度的反单调性；它改变的是搜索空间的表示与探索方式。

GSP 与 PrefixSpan

方面	GSP	PrefixSpan
搜索	广度优先	深度优先模式增长
候选	显式全局候选	前缀扩展
数据库访问	反复全库扫描	递归投影数据库
主要代价	候选生成与匹配	投影规模与递归

两种方法并非在每个数据集上都占优；序列密度与模式长度决定这一权衡。

模式挖掘：高级方法





- 挖掘多层与多维模式
- 基于约束的模式挖掘
- 挖掘序列模式
- 挖掘子图模式
- 小结



什么是图模式挖掘?



□ 化学信息学:

▣ 挖掘频繁化合物结构



□ 社交网络、网络社区、推文.....

▣ 寻找频繁的科研合作子图



带标号图模式

术语	含义	示例
顶点标号	实体类型	碳原子；用户角色
边标号	关系类型	化学键；关注
子图	选定顶点与边，并保持标号	官能团
嵌入	模式到图的一次映射	一次出现位置

图模式挖掘必须同时处理组合增长与图同构。

频繁 (子) 图模式

□ 给定带标号图数据集 $D = \{G_1, G_2, \dots, G_n\}$, 子图 g 的支持图集为 $D_g = \{G_i \mid g \subseteq G_i, G_i \in D\}$


□ $\text{support}(g) = |D_g| / |D|$

□ 若 $\text{support}(g) \geq \text{min_sup}$, 则 (子) 图 g 频繁

□ 例: 化学结构


□ 另一种做法:

□ 从单个大图或网络中挖掘
频繁子图模式



$\text{min_sup} = 2$

频繁图模式



支持度按图计数

不要把嵌入次数与图级支持度混淆。

1. 设 D 含三个带标号图 $G1$ 、 $G2$ 和 $G3$ 。
2. 模式 g 在 $G1$ 中出现两次，在 $G2$ 中出现一次，在 $G3$ 中不出现。
3. 支持图集为 $D_g = \{G1, G2\}$ 。
4. $\text{support count}(g) = 2$ ，相对 $\text{support}(g) = 2/3$ 。

在图事务数据库中，同一图内的多次嵌入仍只计为一个支持图。

图的支持度计数为何困难

对项集

- 包含判定只是简单的子集检验
- 项的规范次序立即可得
- 支持度计数可用哈希或集合交

对图

- 包含判定需要保标号的节点映射
- 同一图有许多等价画法与遍历
- 子图同构主导计数代价

图挖掘既需要剪枝，也需要规范表示。

快速检查：图支持度

一个子图在 G1 中出现五次，在 G2 中出现一次，在 G3 中出现零次。它的支持度计数是多少？

A. 1	B. 2
C. 5	D. 6


答案：B. 2 个支持图

图模式挖掘的应用

- ❑ 生物信息学
 - ❑ 基因网络、蛋白质相互作用、代谢通路
- ❑ 化学信息学：挖掘化合物结构
- ❑ 社交网络、网络社区、推文.....
- ❑ 手机网络、计算机网络.....
- ❑ Web 图、XML 结构、语义网、信息网络
- ❑ 软件工程：程序执行流分析
- ❑ 图分类、聚类、压缩、比较与相关分析的基本构件
- ❑ 图索引与图相似性搜索

基于 Apriori 的方法

- Apriori 性质：若大小为 k 的子图频繁，则其每个子图都频繁；一个不频繁子图即可剪枝该候选
- 连接相容的频繁 k -子图，生成大小为 $(k+1)$ 的候选
- 迭代挖掘过程：
 - 候选生成 → 候选剪枝 → 支持度计数 → 候选消除



Apriori 式图挖掘


图的连接比项集连接更复杂，因为共享子图可以有多种映射。

1. 连接相容的频繁 k -子图，生成大小为 $(k+1)$ 的候选。
2. 对候选做规范化并去除重复。
3. 若任一必需的 k -子图不频繁，则剪枝该候选。
4. 检验哪些数据库图包含该候选，以计数支持度。

频繁蕴含每个子图都频繁；反之不成立。

候选生成：顶点增长与边增长

- 方法：对大小为 k 的图做广度优先搜索与 Apriori 式连接
 - 生成大小为 $(k+1)$ 的候选图时存在多种可能



- 每次增加一个顶点来生成新图
 - AGM (Inokuchi, Washio, & Motoda, PKDD'00)
- 每次增加一条边来生成新图
 - FSG (Kuramochi & Karypis, ICDM'01)
- 边增长通常比顶点增长更能减少候选重复

重复候选问题

- 同一无标号结构可用不同顶点编号画出
- 不同增长历史可产生同构候选
- 朴素去重需要反复做图同构检验
- 规范编码为每个图同构类指定一个代表

gSpan 只增长规范 DFS 编码，从而避免大多数重复。

模式增长方法

□ 子图从 k -边经深度优先增长到 $(k+1)$ -边, 再到 $(k+2)$ -边子图

□ 主要挑战


□ 生成大量重复子图

□ 解决问题的主要思想

□ 定义子图的生成顺序

□ DFS 生成树: 用深度优先搜索把图展平为序列

□ gSpan (Yan & Han, ICDM'02)



gSpan 中的规范 DFS 编码


该编码表示结构、标号与遍历顺序。

1. 运行深度优先搜索，记录每条遍历边的端点下标与标号。
2. 一幅图可有许多合法 DFS 编码，因为遍历起点与分支可以不同。
3. 按字典序比较这些编码，保留最小 DFS 编码。
4. 挖掘过程中只有最小编码代表该图。

规范编码把图等价检验转化为增长过程中一致的序比较。

gSpan: 按序增长图模式

- **子图模式增长中的最右路径扩展**
 - 最右路径: DFS 树中从根到最近发现顶点的路径
 - 减少重复子图的生成
- **完备性: 用最右路径扩展枚举图是完备的**
- DFS 编码: 用深度优先搜索把图展平为序列



最右路径扩展

前向扩展

- 从当前最右路径上的一个顶点出发
- 增加一个新顶点与一条新边
- 新顶点成为最新的 DFS 顶点


后向扩展

- 从当前最右顶点出发
- 连接到最右路径上的一个祖先
- 不增加顶点而闭合一个环

将扩展限制在最右路径上，可在控制重复的同时保持完备性。

挖掘闭图模式

- 最多 2^n 个边子集 $\rightarrow$ 闭频繁子图
- 频繁图 G 是闭的，若不存在与 G 支持度相同的超图



闭意味着不存在支持图集合相同的真频繁超图

- 无损压缩：不包含非闭图，但仍保留所有频繁子图
- 算法 CloseGraph：直接挖掘闭图模式

闭频繁图


定义与闭项集同一思想，只是用图包含代替集合包含。

1. 图 G 频繁，并由 $\{G_1, G_2, G_3\}$ 支持。
2. 真超图 H 同样由 $\{G_1, G_2, G_3\}$ 支持。
3. 因此 G 与 H 的支持度相等。
4. G 不是闭的，因为 H 增加了结构且未失去任何支持图。

闭图模式去除支持度等价的冗余，同时保留精确的支持度信息。

CloseGraph: 直接挖掘闭图模式

- CloseGraph: 通过扩展 gSpan 挖掘闭图模式 (Yan & Han, KDD'03)



CloseGraph 提前终止

- 设 G 的每次出现都能扩展到更大的图 H
- 则 G 与 H 共享同一支持图集合
- G 不可能是闭的，因为 H 是支持度相等的真超图
- 从更大的代表继续增长，并在闭包条件安全时剪掉 G 的冗余后代

剪枝判断取决于出现级等价，而不只是数值支持度相等。


频繁图挖掘算法

方法	搜索	重复控制	输出
AGM / FSG	广度优先候选	连接后规范化	全部频繁图
gSpan	深度优先模式增长	最小 DFS 编码	全部频繁图
CloseGraph	基于 gSpan 的闭增长	基于闭包的剪枝	闭频繁图


这些方法的主要差别在于枚举顺序、重复处理与输出压缩。

实验与性能比较


- 来自 NCI/NIH 的 AIDS 抗病毒筛选化合物数据集
- 该数据集包含 43,905 个化合物
- 发现的模式：最小支持度越小，发现的子图模式越大、越有意义



模式数：频繁与闭



运行时间：频繁与闭





应用：支持子结构相似性搜索


- 在图数据库中查找包含与给定查询图相似子结构的图

- 例. 数据：化合物数据库


- 查询图 q:



(a)



(b)



(c)

- 如何高效做相似性搜索?

- 顺序扫描 + 计算子图相似度——代价过高!

- 建立图索引以支持近似搜索?

- 需要爆炸式数量的子图才能覆盖所有相似子图!

- 一个精巧的方案 (Yan, Yu, & Han, SIGMOD'05):

- 保留图索引结构, 但在查询空间中选择特征

第 4 讲综合

数据与模式	主要挑战	代表性思想
层次 / 多维项	阈值与冗余	层次感知的支持度与祖先过滤
基于约束的项集	大量无关搜索空间	把安全约束推进挖掘
序列	顺序与大量候选	GSP 或前缀投影增长
图	同构与重复	规范 DFS 增长与闭模式

在全部四种设定中，表示方式与反单调性决定哪些可以安全剪枝。

最终快速检查

哪一项陈述正确？

A. 顺序在序列中从不重要	B. 含不频繁子图的候选可以被剪枝
C. 每个闭图都是极大的	D. Lift 是零不变的

答案：B